



T.C.
EGE ÜNİVERSİTESİ
Sağlık Bilimleri Enstitüsü



MEME KANSERİNDE PET/BT SONUCU ÜZERİNDE MAKİNE ÖĞRENMESİ YÖNTEMİ İLE KEMOTERAPİ YANITININ ÖNGÖRÜLMESİ

Doktora Tezi

Yusuf Kağan DAĞDEVİREN

Sağlık Biyoinformatiği Anabilim Dalı

İzmir
2026

T.C.
EGE ÜNİVERSİTESİ
Sağlık Bilimleri Enstitüsü

**MEME KANSERİNDE PET/BT SONUCU ÜZERİNDE
MAKİNE ÖĞRENMESİ YÖNTEMİ İLE
KEMOTERAPİ YANITININ ÖNGÖRÜLMESİ**

Yusuf Kağan DAĞDEVİREN

Danışman
Prof. Dr. Petek BALLAR KIRMIZIBAYRAK

Sağlık Biyoinformatiği Anabilim Dalı
Yüksek Lisans Derecesi ile Doktora Programı

İzmir
2026

Tez Deęerlendirme Kurulu Üyeleri

(Adı Soyadı)

(İmza)

Başkan : Prof. Dr. Petek BALLAR KIRMIZIBAYRAK

(Danışman)

Üye : Prof. Dr. Yasemin ERAÇ

Üye : Prof. Dr. Yasemin BAŞBINAR

Üye : Prof. Dr. Burak ORDİN

Üye : Doç.Dr. Özgür GÜMÜŞ

Üye : Dr. Öğr. Üyesi. Alper KÖSE

Doktora Tezinin kabul edildięi tarih:

Önsöz

Bu tez, bir akademik çalışmanın ötesinde, çok katmanlı bir keşif yolculuğunun ürünüdür. Eczacılık, nükleer tıp, onkoloji, bilgisayar programcılığı, işletme ve biyoinformatik alanlarında edindiğim eğitim ve deneyimler; bu uzun yolculukta yanıma aldığım farklı pusulalar ve stratejik haritalar gibiydi.

Yolculuğumun çıkış noktasını, meme kanseri hastalarında neoadjuvan kemoterapi sonrası tedavi yanıtının tahmin edilmesi sorunsalı oluşturdu. Bu kritik soruyu yanıtlamak için tek bir disiplinin sınırları içinde kalmanın, yolu yarıda bırakmak anlamına geleceğini fark ettim. Her eğitim deneyimimden süzülen farklı perspektifler; ilaçların moleküler dansı, görüntülemenin sessiz dili, tedavi protokollerinin stratejik haritası, algoritmaların sarsılmaz mantığı ve sistem düşüncesinin bütünsel bakışı, beni daha meşakkatli ancak çok daha zengin bir rotaya yönlendirdi.

Yolculuğun ilk duraklarında, binlerce hasta kaydını büyük bir titizlikle tarayarak işe başladım. PET/BT görüntülerini yeniden yorumlarken, patoloji raporlarının satır aralarını okurken ve karmaşık laboratuvar sonuçlarını değerlendirirken klinik birikimim en güvenilir rehberim oldu. İstatistiksel analizlerin zorlu geçitlerinde ise analitik düşünme pratiğim yolumu aydınlattı.

Bu süreçteki en büyük keşfim, farklı disiplinlerin bir araya geldiğinde yarattığı o eşsiz sinerjiydi. Biyoinformatik; tıpkı bir şefin mutfağındaki farklı malzemeleri ustalıklı harmanlaması gibi, her disiplinin kendine özgü karakterini koruyarak yeni ve güçlü bir bütün yaratma sanatıydı. Bu sentezi her aşamada bizzat hissettim ve özümledim. Eksik verilerle veya teknik engellerle karşılaştığımda hem istatistiksel yöntemlerin matematiksel gücünü hem de klinik deneyimin sezgisel bilgeliğini birleştirerek ilerledim.

Yolculuk boyunca en zorlu anlar, aynı zamanda en çok geliştiğim anlardı. Model performansını optimize etmek için geçen uykusuz kodlama maratonları, kullanıcı dostu arayüzler için çizilen yüzlerce taslak ve veri dengesizliği sorunlarıyla boğuşmak... Her bir zorluk, farklı disiplinlerden getirdiğim bilgileri test etme ve onları tek bir potada eritme fırsatı sundu. Doktora eğitimimi biyoinformatik alanında

sürdürme kararımın ne kadar isabetli olduğunu, bu alanın farklı bakış açılarını kaybetmeden bir araya getirme sanatındaki ustalığını gördükçe bir kez daha anladım.

Yolculuğun sonunda ulaştığım nokta, sadece bir doktora tezi değil, farklı dünyaların buluştuğu özgün bir sentezdir. Bu çalışmanın meme kanseri hastalarının tedavi süreçlerine somut bir katkı sağlaması ve klinisyenlerin karar verme süreçlerinde bir fener görevi görmesi, başlangıçtaki hedeflerimin çok ötesinde bir anlam taşımaktadır. Her yolculuğun bir sonu vardır; ancak burada öğrenilen dersler ve keşfedilen yeni patikalar, bilimsel serüvenimin bir sonraki evresi için yeni ufuklar açmaktadır.

Hayat, bir yolculuğun bitip yenisinin başladığı akışkan bir süreçten ibarettir. Bugüne kadarki tüm yolculuklarımda beni destekleyen, ancak bu seferki yolculuğumda kaybettiğim Annem ve Babama derin saygı ve minnettarlıkla yoluma devam ediyorum. Onların inancı ve sabrı, bu bilimsel yolculukta beni hiçbir zaman yalnız bırakmadı. Bugüne kadar çıktığım tüm yollarda beni hep destekleyen, yoldaşım, ışığım ve idolüm olan iki özel insan; bu hayatta imza attığım her başarı, aslında sizin bana bıraktığınız o asil mirasın bir yansımasıdır. Gittiğiniz yere de, bu dünyada bıraktığınız gibi güzellikler ve zarafet kattığınızdan hiç şüphem yok.

İzmir, 25.06.2026

Kağan DAĞDEVİREN

Özet

Meme Kanseri PET/BT Sonucu Üzerinde Makine Öğrenmesi Yöntemi İle Kemoterapi Yanıtının Öngörülmesi

Meme kanseri, heterojen yapısı nedeniyle tedaviye verilen yanıtın bireyler arasında önemli farklılıklar gösterdiği bir hastalıktır. Neoadjuvan kemoterapi (NAK), tedaviye yanıtın erken dönemde değerlendirilmesine olanak sağlamakta olup, patolojik tam yanıt (pCR) ve rezidüel kanser yükü (Residual Cancer Burden, RCB) gibi göstergeler klinik karar süreçlerinde kritik rol oynamaktadır. Ancak, tedavi öncesinde bu yanıtın güvenilir şekilde öngörülebilmesi halen önemli bir klinik gereksinimdir. Bu doktora tezinde, meme kanserinde neoadjuvan kemoterapi (NAK) yanıtının öngörülmesi amacıyla PET/BT (Pozitron Emisyon Tomografisi/Bilgisayarlı Tomografi) verileri ile çok boyutlu klinik ve patolojik değişkenlerin bütünleşik olarak değerlendirilmesi hedeflenmiştir. Retrospektif kohortta yer alan 328 hastada tedavi yanıtı Rezidüel Kanser Yükü (RCB) sınıfları ile değerlendirilmiş; dağılım RCB-0 (pCR) %27,4 (n=90), RCB-I %10,4 (n=34), RCB-II %43,6 (n=143) ve RCB-III %18,6 (n=61) olarak belirlenmiştir. RCB ile ilişkili değişkenler çoklu analizlerle incelenmiş ve pCR öngörüsü için değişken önemine dayalı modelleme yaklaşımı geliştirilmiştir. Bu kapsamda en iyi performans gösteren model olarak L2 (Ridge) lojistik regresyon modeli seçilmiş; test setinde AUC=0,803 ve çapraz doğrulamada AUC=0,826 elde edilmiştir. Belirlenen optimal eşik değerinde model, %69,7 doğruluk, %72,2 duyarlılık ve %68,8 özgüllük ile dengeli bir performans göstermiştir. RCB'nin çok sınıflı öngörüsünde ise en iyi sonuç, tüm değişkenleri içeren modelde LightGBM algoritması kullanılarak elde edilmiştir (test AUC=0,838; doğruluk=0,636; F1=0,602). Bulgular, multimodal veri entegrasyonunun tedavi yanıtının öngörülmesinde anlamlı katkı sağlayabileceğini göstermektedir. Geliştirilen modellerin klinik uygulamaya aktarılabilirliğini değerlendirmek amacıyla çok platformlu bir karar destek sistemi tasarlanmış ve farklı hesaplama ortamları arasında yüksek düzeyde sayısal tutarlılık sağlandığı doğrulanmıştır. Ayrıca gerçekleştirilen sağlık ekonomisi analizinde, model temelli yaklaşımın belirli senaryolarda maliyet-etkin olabileceğine işaret edilmiştir.

Sonu olarak, bu tez alıřması, meme kanserinde NAK yanıtının ngrlmesine ynelik btnleřik bir modelleme yaklařımının uygulanabilirlięini ortaya koymakta ve klinik karar srelerine destek saęlayabilecek bir ereve sunmaktadır.

Anahtar Kelimeler; Meme Neoplazileri; Neoadjuvan Tedavi; Patolojik Tam Yanıt; Radyomik; Makine ęrenmesi; Maliyet-Etkinlik Analizi.

Abstract

Prediction of Chemotherapy Response in Breast Cancer Using Machine Learning Methods Based on PET/CT Results

Breast cancer is a disease in which treatment response varies substantially among individuals due to its heterogeneous nature. Neoadjuvant chemotherapy (NAC) enables early evaluation of treatment response, and indicators such as pathological complete response (pCR) and Residual Cancer Burden (RCB) play a critical role in clinical decision-making. However, the reliable prediction of treatment response prior to therapy remains an important unmet clinical need. In this doctoral thesis, it was aimed to predict NAC response in breast cancer through the integrated evaluation of PET/CT (Positron Emission Tomography/Computed Tomography) data together with multidimensional clinical and pathological variables. In a retrospective cohort of 328 patients, treatment response was assessed using RCB classes, with the following distribution: RCB-0 (pCR) 27.4% (n=90), RCB-I 10.4% (n=34), RCB-II 43.6% (n=143), and RCB-III 18.6% (n=61). Variables associated with RCB were analyzed using multivariate methods, and a variable-importance-based modeling approach was developed for pCR prediction. Within this framework, the best-performing model was identified as L2 (Ridge) logistic regression, achieving an AUC of 0.803 on the test set and an AUC of 0.826 in cross-validation. At the optimal threshold, the model demonstrated balanced performance with 69.7% accuracy, 72.2% sensitivity, and 68.8% specificity. For multiclass prediction of RCB, the best results were obtained using the LightGBM algorithm with a model incorporating all variables (test AUC=0.838; accuracy=0.636; F1-score=0.602). These findings indicate that multimodal data integration can make a meaningful contribution to predicting treatment response. To evaluate the clinical translatability of the developed models, a multi-platform clinical decision support system was designed, and a high level of numerical consistency across different computational environments was confirmed. In addition, health economic analysis suggested that a model-based approach may be cost-effective under certain scenarios. In conclusion, this thesis demonstrates the feasibility of an integrated modeling approach for predicting NAC response in breast cancer and provides a framework that may support clinical decision-making processes.

Keywords; Breast Neoplasms; Neoadjuvant Therapy; Pathologic Complete Response; Radiomics; Machine Learning; Cost-Effectiveness Analysis.

İçindekiler

Önsöz	II
Özet.....	IV
Abstract	VI
İçindekiler	VIII
Tablolar Dizini.....	XIV
Şekiller Dizini.....	XVIII
Grafikler Dizini	XXII
Kısaltma Listesi	XXIII
Giriş	1
1.1. Araştırmanın Problemi.....	1
1.2. Araştırmanın Sorusu.....	2
1.3. Araştırmanın Hipotezleri	2
1.4. Araştırmanın Varsayımları.....	3
1.5. Araştırmanın Sınırlılıkları	4
1.6. Araştırmanın Amacı	5
Genel Bilgiler	6
2.1. Kanser Biyolojisi ve Meme Kanserinde Neoadjuvan Tedaviye Genel Bakış	6
2.1.1. Meme Kanseri: Epidemiyoloji, Patogenez ve Risk Faktörleri	7
2.1.2. Meme Kanseri Alt Türleri ve Çeşitlilik.....	9
2.1.3. Meme Kanseri ve Laboratuvar Patolojisi	11
2.1.4. Klinik ve Moleküler Patoloji Arasındaki İlişki	13
2.2. Kemoterapi	14
2.2.1. Hedefe Yönelik Tedavi ve Kemoterapinin Birlikte Kullanımı.....	16
2.3. Neoadjuvan Kemoterapi ve Tedavi Yanıtının Değerlendirilmesi.....	16
2.3.1. Patolojik Tam Yanıt (pCR) ve Sınırlılıkları	17
2.3.2. Neoadjuvan Yanıtın Görüntüleme ile İzlenmesi	17
2.4. Rezidüel Kanser Yüğü (RCB).....	18
2.5. RCB ve Tedavi Yanıtını Belirleyen Klinikopatolojik Faktörler	20
2.6. Onkolojide Veri Tabanlı Yaklaşımların Teorik Temelleri	23
2.6.1. Hassas Tıp ve Hesaplamalı Tahmin Modelleri.....	25
2.6.2. Açıklanabilir Yapay Zeka (XAI) ve Klinik Karar Destek Sistemleri	25

2.7. Onkolojik Tahmin Modellemelerinde Temel Referans: Lojistik Regresyon	26
2.7.1. İkili (Binary) ve Çoklu (Multiple) Lojistik Regresyon ve Klinik Karar Süreci.....	26
2.7.2. Model Performansının Değerlendirilmesi	27
2.7.3. Değişken Seçimi ve Aşırı Uyum (Overfitting) Riski.....	28
2.7.4. Yöntemin Sınırları ve Makine Öğrenmesi ile İlişkisi.....	28
2.8. Büyük Veri ve Klinik Veri Yönetimi.....	28
2.9. Makine Öğrenmesi ve Onkolojide Çok Değişkenli Veriden Anlam Çıkarma	30
2.9.1. Denetimli Öğrenme ve Klinik Sınıflandırma Problemleri	31
2.9.2. Tablo Verilerinde Yaygın Yaklaşımlar: Ağaç Tabanlı Modeller	31
2.9.3. Sınıf Dengesizliği ve Klinik Önemi	33
2.9.4. Model Değerlendirmesi: Güvenilir ve Genellenebilir Modeller	34
2.9.5. Açıklanabilir Yapay Zekâ ve Klinik Güven	37
2.10. Klinik Veri Kaynağı ve Uygulama	37
2.10.1. PET/BT'nin Meme Kanserindeki Klinik Rolü.....	38
2.10.2. Kantitatif Metabolik Parametreler: SUV, MTV ve TLG.....	39
2.10.3. Radyomik Analiz ve LIFEx Yazılımı	40
2.10.4. Klinik Karar Destek Sistemleri	42
2.10.4.1. Klinik Karar Destek Sistemlerinde Veri Entegrasyonu, Güvenlik ve Etik Standartlar.....	44
2.10.4.2. Çok Platformlu Entegrasyon ve Veri Standartları.....	44
2.10.4.3. Çok Katmanlı Güvenlik Mimarisi.....	44
2.10.4.4. Yasal ve Etik Çerçeve: KVKK ve GDPR Uyumlu	45
2.11. Klinik Yorum ve Ekonomik Değerlendirme	45
2.11.1. pCR ve RCB'nin Klinik Kararlara Etkisi	46
2.11.2. Yüksek Rezidüel Hastalık Yükü (RCB-III): Prognostik Ağırlık ve Tedavi Yoğunlaştırma İhtiyacı.....	47
2.11.2.1. NAK Sonrası Yanıt Değerlendirmesinde Görüntüleme: Sınırlılıklar ve Tamamlayıcı Yaklaşımlar	47

2.11.2.2. Sınıf Dengesizliği ve Klinik Ağırlığı Yüksek Nadir Sınıflarda (Örn. RCB-III) Modelleme Güçlükleri.....	48
2.11.3. Sağlık Ekonomisi Perspektifi: Maliyet-Etkinlik ve Uygulanabilirlik.....	48
3. Gereç ve Yöntem	50
3.1. Çalışma Tasarımı, Ortam ve Veri Kaynakları.....	50
3.2. Etik Onay ve Veri Gizliliği	51
3.3. Popülasyon: Dahil Etme ve Dışlama Ölçütleri	51
3.3.1. Dahil Etme Kriterleri.....	51
3.3.2. Dışlama Ölçütleri: Klinik Kohort (Aşama 1)	51
3.3.3. Dışlama Ölçütleri: PET/BT Radyomik Alt Grup (Aşama 2)	52
3.4. Sonlanımlar ve Bağımsız Değişkenler	52
3.4.1. Bağımlı Değişkenler	52
3.4.2. Bağımsız Değişkenler ve Tematik Yapı.....	52
3.4.3. Veri Kodlama ve Standardizasyon	53
3.5. Eksik Veri, İmputasyon ve Ölçekleme	53
3.5.1. Eksik Veri İncelemesi, Varsayımlar ve Genel Çerçeve	53
3.5.2. Hibrit Sıralı Zincirleme KNN İmputasyonu.....	54
3.5.3. Ölçekleme ve Dönüşümler	55
3.6. İstatistiksel Analiz (Klinik ve Klinikopatolojik İlişkiler)	55
3.6.1. Tanımlayıcı ve Karşılaştırmalı Analizler	55
3.6.2. Güç, Sağkalım ve Duyarlılık Analizleri.....	55
3.7. pCR Tahmini İçin Lojistik Regresyon Modellemesi.....	56
3.7.1. Değişken Seçimi ve Model Kurulumu	56
3.7.2. Model Değerlendirme	56
3.7.3. Değişken Önem Skorlaması ve Önceliklendirme Çerçevesi.....	57
3.8. RCB Kategorisi İçin Makine Öğrenmesi Modellemesi.....	58
3.8.1. Veri Bölme ve Ön işleme.....	58
3.8.2. Algoritmalar ve Model Geliştirme	58
3.8.3. Performans ve Güvenilirlik Analizi.....	59
3.8.4. Model Yorumlanılabilirliği.....	60
3.9. PET/BT Radyomik İş Akışı (Alt Kohort)	60
3.9.1. Görüntüleme ve Segmentasyon.....	60

3.9.2. Özellik Çıkarımı ve Ön İşleme.....	61
3.9.3. Radyomik Modelleme	61
3.10. Yazılım Ortamı, Paketler ve Tekrarlanabilirlik	61
3.11. Klinik Karar Destek Sistemine Entegrasyon (Translasyonel Yöntem)	62
3.12. Sağlık Ekonomisi ve Maliyet-Etkinlik Analizi	63
Bulgular.....	67
4.1. Rezidüel Kanser Yüğü (RCB) Skorunun Klinikopatolojik Özelliklerle İlişkisi	67
4.1.1. Hasta Popülasyonu ve RCB Dağılım Özellikleri.....	67
4.1.2. RCB Skoru ile Klinik ve Patolojik Faktörler Arasındaki İlişkiler.....	69
4.1.3. Tüm Değişkenlerde Grup Karşılaştırmaları ve Çoklu Test Analizi	73
4.1.4. RCB Kategorik Sınıflaması ve Klinik Profil	77
4.1.5. Veri Kalitesi, Eksik Veri ve İmputasyon Analizi	86
4.1.6. Değişkenler Arası Korelasyon Yapısı.....	90
4.1.7. RCB ve Sağkalım Sonuçları	101
4.2. Neoadjuvan Yanıtın Klinikopatolojik Belirteçlerle Öngörülmesi: İkili ve Çoklu Lojistik Regresyon Yaklaşımı.....	103
4.2.1. Değişkenlerin Önem Skorlarına Göre Kategorize Edilmiş Özeti.....	103
4.2.1.1. Çok Güçlü Öngörücüler (9 puan).....	103
4.2.1.2. Güçlü Öngörücüler (7-8 puan).....	109
4.2.2. Çoklu Lojistik Regresyon Analizi Bulguları.....	132
4.2.2.1. Veri Setinin Yapılandırılması ve Değişken Seçimi.....	132
4.2.2.2. Çoklu Bağlantı (Multicollinearity) Analizi ve Dummy Değişken Kodlama	133
4.2.2.3. Regülerizasyon Tekniklerinin Karşılaştırılması	135
4.2.2.4. Eşik Değeri (Threshold) Optimizasyonu.....	137
4.2.2.5. Çapraz Doğrulama Sonuçları ve Genellenebilirlik.....	138
4.2.2.6. Aşırı Uyum (Overfitting) Analizi.....	138
4.2.3. Final Model Seçimi: Model 1 (L2 – Ridge)	140
4.2.4. Final Model Katsayıları ve Değişkenlerin Etki Düzeyleri.....	142
4.3. Makine Öğrenmesi Kapsamında Modüler ve Kademeli Modelleme Yaklaşımı	145

4.3.1. Kademeli Özellik Entegrasyonu ve Model Performansı	145
4.3.2. Tekil Modellerin Sınıf Bazlı Örüntüsü.....	151
4.3.3. Kombine Modellerin Sınıf Bazlı Örüntüsü	153
4.3.4. Nihai Modelin Seçimi	155
4.3.4.1. Özellik Kategorilerinin Katkı Analizi	157
4.3.4.2. SMOTE'un Genel Etkisi.....	157
4.3.4.3. Algoritma Karşılaştırmaları.....	158
4.3.5. Sınıf Bazlı Performans, Ayırıştırma ve Güvenilirlik Analizleri.....	158
4.3.6. Model Doğrulama ve Güvenilirlik Analizleri	165
4.3.7. Karşılaştırmalı Sentez: Model Sinerjisi, Klinik Hata Desenleri ve SMOTE Etkisi.....	181
4.3.7.1. Model Sinerjisi ve Özellik Etkileşimi	181
4.3.7.2. Klinik Açından Ağırlıklandırılmış Hata Desenleri	182
4.4.PET-BT Verilerinin RCB Öngörüsüne Katkısı.....	186
4.4.1. PET-BT Alt Örnekleminde Model Performansı	186
4.4.2. PET-BT Değişkenlerinin Ek Katkısı ve SMOTE Etkisi	190
4.4.3. Nested Cross-Validation ve Bootstrap Analizleri.....	193
4.4.4. Sınıf Bazlı Performans ve ROC Analizi	197
4.4.5. Özellik Önem Analizi ve Yorumlanabilirlik.....	202
4.4.6. Kalibrasyon, Öğrenme Eğrileri ve CV-Test Uyumu.....	206
4.4.7. Seçici PET Değişkeni Senaryoları.....	209
4.5. Makine Öğrenmesi Modellerinin Klinik Karar Destek Sistemine Entegrasyonu ve Çevirimsel Tıp Uygulamaları	215
4.5.1. pCR Klinik Karar Destek Aracı	216
4.5.2. BCRIS Web Uygulaması	218
4.5.3. BCRIS Masaüstü Uygulaması.....	228
4.5.4. HİP Mobil Uygulaması	229
4.5.5. Platformlar Arası Entegrasyon.....	234
4.6. Sağlık Ekonomisi ve Maliyet-Etkinlik Analizi Perspektifi.....	236
4.6.1. Model Performansının Sağlık Ekonomisi Açısından Karşılaştırılması ..	236
4.6.2. 100 Hastalık Hipotetik Kohortta Maliyet-Etkinlik Simülasyonu	236
4.6.3. ICER ve Artımlı Analiz	239

4.6.4. Hibrit Basamaklı Strateji	240
4.6.5. Duyarlılık Analizi.....	242
4.6.6. Ulusal Perspektiften Bütçe Etkisi	243
4.5.6. Bulguların Bütüncül Yapısı.....	247
Tartışma	248
5.1. Rezidüel Kanser Yüğü (RCB) Skorunun Klinikopatolojik Özelliklerle İlişkisi	248
5.2. Neoadjuvan Yanıtın Klinikopatolojik Belirteçlerle Öngörölmesi: İkili ve Çoklu Lojistik Regresyon Yaklaşımı.....	253
5.3. Makine Öğrenmesi Kapsamında Modüler ve Kademeli Modelleme Yaklaşımı	257
5.4. PET-BT Verilerinin RCB Öngörüsüne Katkısı	265
5.5. Makine Öğrenmesi Modellerinin Klinik Karar Destek Sistemine Entegrasyonu ve Çevirimsel Tıp Uygulamaları	272
5.6. Sağlık Ekonomisi ve Maliyet-Etkinlik Analizi Perspektifi.....	285
Sonuç ve Öneriler.....	289
6.1. Klinik Pratiğe Yönelik Öneriler	290
6.2. Araştırma ve Geliştirmeye Yönelik Öneriler	290
6.3. Metodolojik Öneriler	291
Kaynaklar	292
Teşekkür	335

Tablolar Dizini

Tablo 1 RCB Skor Tanımlayıcı İstatistikleri.....	67
Tablo 2 RCB Skoru ile RCB Bileşenleri Arasındaki Spearman Korelasyon Analizi Sonuçları.....	69
Tablo 3 Levene Testi Sonuçları (En İyi Heterojen ve En Beklenmedik Homojen Varyanslar).....	73
Tablo 4 Grup Testi Sonuçları (En İyi ve En Beklenmedik Sonuçlar).....	74
Tablo 5 Chi-kare/Fisher's Exact Testi Sonuçları (RCB Kategorize, En İyi ve En Beklenmedik Sonuçlar).....	74
Tablo 6 Bonferroni/FDR Düzeltilmiş Sonuçlar	76
Tablo 7 RCB Sınıf Dağılımı.....	78
Tablo 8 Orijinal Sütunlarda Eksik Veri Oranları	86
Tablo 9 Özelliklerin Doğruluk Oranları ve Standart Sapmaları	88
Tablo 10 %5 Maskeleye Doğruluk Testi Sonuçları	89
Tablo 11 RCB Skoru ile Klinik ve Patolojik Değişkenler Arasındaki En Yüksek Korelasyon Katsayıları.....	90
Tablo 12 En Yüksek 20 Cramer's V Korelasyon Çifti (Bonferroni anlamlı)	92
Tablo 13 En Düşük 20 Cramer's V Korelasyon Çifti (Bonferroni anlamlı).....	93
Tablo 14 Çok Değişkenli Cox Regresyon Analizi Sonuçları (OS).....	102
Tablo 15 Çok Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328).....	107
Tablo 16 Çok Güçlü Düzeyde Öngörücü Değişkenlerin Önem Skoru Değerlendirmesi	109
Tablo 17 Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328).....	116
Tablo 18 Güçlü düzeyde öngörücü Değişkenlerin Önem Skoru Değerlendirmesi (7-8 Puan).....	121
Tablo 19 Orta Düzey Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328).....	124
Tablo 20 Orta Düzeyde Öngörücü Değişkenlerin Önem Skoru Değerlendirmesi (5-6 Puan).....	126

Tablo 21 Bağımsız Değişkenlerin Önem Skorlarına Göre Toplu Sıralaması (Değişken Havuzu).....	128
Tablo 22 Univariate İkili Lojistik Regresyon Analizine Göre pCR Öngörücü Değişkenlerin Önem Sınıflarına Göre Özeti (Skor ≥ 5).....	130
Tablo 23 Veri Seti Özellikleri ve Eğitim-Test Ayırımı	133
Tablo 24 Çoklu Doğrusal Bağlantı Kontrolü Sonuçları	134
Tablo 25 Multicollinearity Nedeniyle Modelden Çıkarılan Değişkenler	134
Tablo 26 Modellerin Performans Karşılaştırması (Optimal Eşik Değerleri ile).....	135
Tablo 27 Eşik Optimizasyonu ve Performansa Etkisi.....	137
Tablo 28 Çapraz Doğrulama Sonuçları.....	138
Tablo 29 Aşırı Uyum Analizi (Eğitim vs. Test AUC)	138
Tablo 30 Final Model Performans Özeti (Model 1 L2-Ridge)	141
Tablo 31 Final Modelde En Yüksek Etkiye Sahip İlk 15 Değişken (Mutlak Beta Katsayısına Göre).....	143
Tablo 32 Kademeli RCB Modellerinde Algoritma $\times$ SMOTE'ye Göre Test AUC, F1 ve CV–Test Gap Özeti.	148
Tablo 33 (Devamı)	149
Tablo 34 (Devamı)	150
Tablo 35 Tekil Modellerin RCB Sınıflarına Göre Precision, Recall, F1-score, AUC ve Specificity Performansları.....	152
Tablo 36 Birleşik Modellerin RCB Sınıflarına Göre Precision, Recall, F1-score, AUC ve Specificity Performansları	154
Tablo 37 Model ALL - Sınıf Bazında Detaylı Metrikler (LightGBM SMOTE YOK)	159
Tablo 38 Nested CV Sonuçları – Sınıf Bazlı Özet İstatistikler (Model ALL, LightGBM, SMOTE yok).....	166
Tablo 39 Nested CV Sonuçları – Global Özet (Model ALL, LightGBM; SMOTE yok vs SMOTE var)	167
Tablo 40 Nested CV Sonuçları – Outer Fold Bazlı Detay (Model ALL, LightGBM; SMOTE yok).....	167

Tablo 41 Sınıf Bazlı Bootstrap %95 Güven Aralıkları – Precision, Recall ve F1-Score	170
Tablo 42 Sınıf Bazlı Bootstrap %95 Güven Aralıkları – AUC ve Specificity	171
Tablo 43 Kombine Modellerde Sinerjik Kazanç/Kayıp Analizi	181
Tablo 44 Klinik Açısından Ağırlıklandırılmış Hata Türlerinin Model Bazında Dağılımı	182
Tablo 45 Kritik, Önemli Ve Kabul Edilebilir Hata Kategorilerine Göre Karşılaştırmalı Özet	184
Tablo 46 Tüm Modellerde SMOTE Etkisi Özeti	185
Tablo 47 PET/BT Analizi Model Performans Karşılaştırması - Tüm Algoritmalar ve SMOTE Koşulları	188
Tablo 48 SMOTE Etkisi Karşılaştırması - En İyi Algoritmalar İçin	191
Tablo 49 PET Verilerinin Katkısı - Model ALL vs Model ALL+PET Karşılaştırması (SMOTE'lu).....	193
Tablo 50 Nested Cross-Validation Performans Metrikleri	194
Tablo 51 PET-BT Katkısının İstatistiksel Anlamlılık Testleri.....	195
Tablo 52 Test Seti Performansı ve Bootstrap Güven Aralıkları	196
Tablo 53 Sınıf Bazında AUC Değerleri	197
Tablo 54 Sınıf Bazında Test Seti Performans Metrikleri	200
Tablo 55 PET/BT Özelliklerinin Feature Importance Değerleri.....	203
Tablo 56 PET/BT Özelliklerinin Permutation Importance Değerleri	205
Tablo 57 PET/BT Özelliklerinin Katkı Özeti	205
Tablo 58 Learning Curve Final Değerleri	208
Tablo 59 CV-Test Gap ve Bootstrap CI Analizi	209
Tablo 60 Model Performanslarının Kapsamlı Karşılaştırması.....	210
Tablo 61 Özellik Seçimi Senaryoları ve Performans Karşılaştırması.....	212
Tablo 62 Senaryolarda Çıkarılan ve Kalan PET Özellikleri	213
Tablo 63 Geliştirilen Sistemlerin Karşılaştırmalı Özellikleri	215

Tablo 64 pCR Klinik Karar Destek Aracı – Kullanıcı Arayüzü	218
Tablo 65 pCR Model Parametreleri	218
Tablo 66 BCRIS Web Uygulaması Kullanıcı Kullanım İstatistikleri ve Memnuniyet Düzeyi	220
Tablo 67 PDF İndirme Özelliği Özellikleri	222
Tablo 68 Sistem Altyapısı ve DNS Konfigürasyonu	224
Tablo 69 SSL/TLS Sertifika Özellikleri	224
Tablo 70 SSL Labs Güvenlik Skoru	225
Tablo 71 Güvenlik Açıkları Tarama Sonuçları	225
Tablo 72 HTTP Güvenlik Başlıkları Değerlendirmesi	226
Tablo 73 Django Güvenlik Önlemleri ve Uygulama Durumu	226
Tablo 74 İstemci Uyumluluğu Test Sonuçları (Seçilmiş Örnekler)	227
Tablo 75 Tespit Edilen Güvenlik Açıkları ve Risk Değerlendirmesi	227
Tablo 76 BCRIS Masaüstü Uygulaması Teknik Özellikleri	228
Tablo 77 BCRIS Masaüstü Uygulaması Performans Metrikleri	229
Tablo 78 Benzersiz Kod Sistemi Özellikleri	233
Tablo 79 Excel Dosyası Oluşturma Özellikleri	233
Tablo 80 Hekim Doğrulama Süreci Metrikleri	233
Tablo 81 HİP Uygulaması Güvenlik Önlemleri	233
Tablo 82 Model R ve Model ALL Senaryolarının Karşılaştırmalı Sonuçları (100 Hasta Kohortu Simülasyonu)	237
Tablo 83 Türkiye Sağlık Sistemi Perspektifinden Yıllık Perspektifte Bütçe Etkisi ve QALY Analizi (uptake %30; n=1.500)	244

Şekiller Dizini

Şekil 1. Random Forest Karar Süreci Klinik Örnek Diyagramı	32
Şekil 2. Boosting Algoritmalarının İşleyişi.....	33
Şekil 3. Makine Öğrenmesi Performans Ölçütleri ve Model Değerlendirme Yöntemleri Sınıflandırması	34
Şekil 4. K-Katlı ve Katmanlı Çapraz Doğrulama Karşılaştırması	35
Şekil 5. Model Tabanlı RCB Tahmininin Klinik Karar Akış Şeması ve Maliyet Etkisi Bulunan Karar Noktaları	63
Şekil 6. Hibrit Yaklaşım - Risk-Tabanlı Basamaklı Tanı Algoritması ve Operasyonel Yük Analizi	65
Şekil 7. Tezin Metodolojik Akış Diyagram	66
Şekil 8. RCB Skor – Violin Plot İlişkisi.....	69
Şekil 9. RCB Skorunun Seçili Klinikopatolojik Değişkenlere Göre Boxplot Dağılımları	72
Şekil 10. Seçili Değişkenler İçin T-Testi ve Ki-Kare Testine Dayalı Güç Eğrileri ...	77
Şekil 11. Eksik Veri Isı	87
Şekil 12. RCB Skoru ile Klinik, Histopatolojik ve Radyolojik Parametreler Arasındaki Korelasyon Isı Haritası.....	91
Şekil 13. Isı Haritası (Kategorik değişkenler arası Cramér's V Korelasyonlarının Dağılımı)	94
Şekil 14. Ağ Grafiği (Cramér's V > 0.4).....	95
Şekil 15. Kategorik Risk Haritası - 1	96
Şekil 16. Kategorik Risk Haritası - 2	97
Şekil 17. Kategorik Risk Haritası - 3	98
Şekil 18. Kategorik Risk Haritası - 4	99
Şekil 19. Kategorik Risk Haritası - 5	100
Şekil 20. Regularization Etkisi Karşılaştırması.....	136
Şekil 21. ROC Eğrileri Karşılaştırması (Tüm Modeller)	136
Şekil 22. Optimal Eşik Karşılaştırması (Default vs Optimal).....	137

Şekil 23. Overfitting Analizi (Train vs Test AUC).....	139
Şekil 24. Model Performans Karşılaştırması (Optimal Eşik ile).....	139
Şekil 25. Test Veri Seti Üzerinde Model 1 L2 (Ridge) için Optimal Eşik Değeri (0,277) Kullanılarak Elde Edilen Karışıklık Matrisi.)	142
Şekil 26. Değişkenlerin Etki Düzeyleri (Beta Katsayıları)	144
Şekil 27. Kademeli özellik kümelerine göre test AUC, test macro-F1 ve CV ortalama±Std değişimi	147
Şekil 28. Model R ve Model ALL İçin Test Metrikleri İle Çapraz Doğrulama Ortalama±Standart Sapma Değerlerinin Karşılaştırılması.....	156
Şekil 29. Model ALL RCB Sınıfları için Karışıklık Matrisi.....	159
Şekil 30. Model ALL RCB Sınıfları İçin ROC Eğrileri	160
Şekil 31. Model ALL Kesinlik Duyarlılık Eğrisi.....	161
Şekil 32. Model ALL RCB Sınıfları Kalibrasyon Eğrisi	162
Şekil 33. RCB Sınıfları Kümülatif Kazanç Analizi: Model ALL	163
Şekil 34. Model ALL RCB Sınıflarının Lift Analizi	164
Şekil 35. Nested CV Gap Analizi (Global AUC; 5 Outer Fold; SMOTE yok vs SMOTE var)	168
Şekil 36. Model ALL için Sınıf Bazlı Karar Eğrisi Analizi.....	173
Şekil 37. Model ALL İçin Kalibrasyon Eğrileri (Ham Model, Platt Scaling, Isotonic Regression).....	174
Şekil 38. Model ALL İçin Global SHAP Özellik Önem Özeti.....	176
Şekil 39. RCB-0 Sınıfı İçin SHAP Özellik Önem Analizi.....	177
Şekil 40. RCB-I Sınıfı İçin SHAP Özellik Önem Analizi	178
Şekil 41. RCB-II Sınıfı İçin SHAP Özellik Önem Analizi.....	179
Şekil 42. RCB-III Sınıfı İçin SHAP Özellik Önem Analizi	180
Şekil 43. Nested Cross-Validation Sonuçlarının Boxplot Karşılaştırması	194
Şekil 44. Nested CV AUC Karşılaştırması	195
Şekil 45. Bootstrap Güven Aralıkları Görselleştirmesi.....	196

Şekil 46. Sınıf Bazında ROC Eğrileri Karşılaştırması	198
Şekil 47. ROC Eğrileri - En İyi Algoritmalar İçin Her Model.....	199
Şekil 48. Sınıf Bazında Performans Metrikleri Karşılaştırması	200
Şekil 49. Confusion Matrix Karşılaştırması	202
Şekil 50. Feature Importance Analizi.....	204
Şekil 51. Permutation Importance Analizi	206
Şekil 52. Kalibrasyon Eğrileri	207
Şekil 53. Learning Curve Analizi.....	208
Şekil 54. CV-Test Gap ve Bootstrap CI Görselleştirmesi.....	209
Şekil 55. pCR Klinik Karar Destek Aracı – Kullanıcı Arayüzü	217
Şekil 56. BCRIS Web Uygulaması Ana Sayfa Ekran Görüntüsü	219
Şekil 57. BCRIS Web Uygulaması - Sekme Yapısı ve Veri Girişi Arayüzü.....	220
Şekil 58. BCRIS Web Uygulaması - Excel Dosyası Yükleme Arayüzü	222
Şekil 59. BCRIS Web Uygulaması - RCB Tahmin Sonuçları Görselleştirmesi.....	222
Şekil 60. BCRIS Web Uygulaması - pCR Tahmin Sonuçları Görselleştirmesi.....	223
Şekil 61. BCRIS Web Uygulaması - Dil Seçimi Arayüzü	223
Şekil 62. Benzersiz ID (Kimlik) Atama (Deneme Hastası na atanan ID ve ID Paylaşım Seçenekleri).....	229
Şekil 63. HİP Ana Giriş Ekranı	230
Şekil 64. Yeni Hasta Kaydı Oluşturma Ekranı	230
Şekil 65. HİP Mobil Uygulaması - Hasta Oluşturma ve Kod Üretme Arayüzü	230
Şekil 66. Veri Toplama Ana Ekranı ve Veri Girişi Arayüzü	231
Şekil 67. HİP Veri Birleştirme ve Durum Takibi Arayüzü.....	231
Şekil 68. HİP Mobil Uygulaması – Hekim Kayıt Arayüzü.....	232
Şekil 69. HİP Android Uygulaması - Google Play Store Ekran Görüntüsü	232
Şekil 70 Sistem Entegrasyonu ve Veri Akışı Diyagramı	235

Şekil 71. 100 Hastalık Kohortta Model R ve Model ALL'ın RCB-0 Tespitindeki Hasta Sayısı Karşılaştırması.....	236
Şekil 72. Model R ve Model ALL'ın RCB-0 ve RCB-III Tespit Karşılaştırması....	238
Şekil 73. 100 Hastalık Kohortta TP ve FN Projeksiyonu	238
Şekil 74. Maliyet Bileşenlerinin Karşılaştırılması - Model R vs Model ALL	239
Şekil 75. Model R ve Model ALL İçin Gereksiz Adjuvan Kemoterapi Nedeniyle QALY Kaybı ve Hasta Sayısı Karşılaştırması	240
Şekil 76. Model ALL'ın Model R'ye göre artımlı maliyet-etkinlik düzlemi (ICER analizi).....	240
Şekil 77. Hibrit Yaklaşım - Risk-Tabanlı Basamaklı Tanı Algoritması Ve Maliyet Analizi	241
Şekil 78. Model R, Hibrit Yaklaşım ve Model ALL İçin Gereksiz Adjuvan Kemoterapi Nedeniyle QALY Kaybı ve Hasta Sayısı Karşılaştırması.....	241
Şekil 79. Model R, Hibrit Yaklaşım ve Model ALL için Incremental Maliyet-Etkinlik Analizi	242
Şekil 80. Duyarlılık Analizi - pCR Prevalansına Göre Model ALL ve Hibrit Yaklaşımın ICER Değerleri ve WHO Maliyet-Etkinlik Eşikleri ile Karşılaştırması	243
Şekil 81. Model Sonuçları Üzerindeki Belirsizliklerin Değerlendirilmesi: Tornado Diyagramı.....	243
Şekil 82. Türkiye ulusal perspektifinde yıllık bütçe etkisi karşılaştırması - Model R, Hibrit ve Model ALL	245
Şekil 83. Türkiye sağlık sistemi perspektifinde 5 yıllık projeksiyonda Model R'ye göre ek bütçe etkisi ve QALY kazancı (5.000 hasta/yıl)	245
Şekil 84. Türkiye sağlık sistemi perspektifinde 5 yıllık kümülatif bütçe etkisi ve QALY kazancı projeksiyonu.....	246

Grafikler Dizini

Grafik 1. Öğrenme ve Validasyon Eğrileri	36
Grafik 2. Overfitting ve Underfitting Değerlendirmesi	36
Grafik 3. RCB Skorunun Frekans, Yoğunluk ve Modal Dağılımı.....	68
Grafik 4. RCB Sınıf Dağılımı	78
Grafik 5. Model P Grubundaki Değişkenlerin Sunbrust Grafiği	80
Grafik 6. Model O Grubundaki Değişkenlerin Sunbrust Grafiği.....	81
Grafik 7. Model D Grubundaki Değişkenlerin Sunbrust Grafiği.....	82
Grafik 8. Model C Grubundaki Değişkenlerin Sunbrust Grafiği	83
Grafik 9. Model B Grubundaki Değişkenlerin Sunbrust Grafiği	84
Grafik 10. Model R Grubundaki Değişkenlerin Sunbrust Grafiği	85
Grafik 11. RCB-0 (pCR) vs RCB I/II/III OS Kaplan-Meier Eğrileri.....	101
Grafik 12. RCB Kategorilerine Göre OS Kaplan-Meier Eğrileri.....	102
Grafik 13. Model ALL Değişkenlerin Önem Düzeyleri	165
Grafik 14. Model ALL İçin Bootstrap AUC Dağılımının SMOTE Uygulanma Durumuna Göre Karşılaştırılması (B=500, stratified resampling).....	169
Grafik 15. Sınıf Bazlı Bootstrap Güven Aralıkları – Precision, Recall ve F1-Score.....	172
Grafik 16. SMOTE’lu Koşulda Algoritma Karşılaştırması (Test AUC, Accuracy, F1-Macro)	189
Grafik 17. SMOTE Etkisi Performansı Karşılaştırması.....	192
Grafik 18. Bootstrap AUC Dağılımları ve Karşılaştırması	195

Kısaltma Listesi

18F-FDG	: 18F-Florodeoksiglikoz
ABO	: ABO kan grubu sistemi
AC-T	: Doksorubisin (Adriamisin) + Siklofosfamid ardından taksan rejimi (AC→T)
ACRIN	: American College of Radiology Imaging Network
AES-256	: 256-bit Advanced Encryption Standard
AES-GCM	: AES – Galois/Counter Mode
AJCC	: American Joint Committee on Cancer
ALP	: Alkalen Fosfataz
ALT	: Alanin Aminotransferaz
ANOVA	: Analysis of Variance (Varyans Analizi)
API	: Application Programming Interface
APK	: Android Package Kit
ARIA	: Accessible Rich Internet Applications
AST	: Aspartat Aminotransferaz
AUC	: Area Under the Curve (eğri altında kalan alan)
BCRIS	: Breast Cancer Response Intelligence System
BI-RADS	: Breast Imaging Reporting and Data System
BUN	: Kan Üre Nitrojen
CA15-3	: Kanser Antijeni 15-3
CAA	: Certification Authority Authorization (DNS kaydı)
CAP/ASCO	: CAP American Society of Clinical Oncology
CDSS	: Clinical Decision Support System

CE	: Conformité Européenne
CEA	: Carcinoembryonic Antigen
CI	: Confidence Interval (Güven Aralığı)
CIS	: Carcinoma in situ
CPU	: Central Processing Unit
CRISP-DM	: Cross-Industry Standard Process for Data Mining
CRP	: C-Reaktif Protein
CSP	: Content Security Policy
CSRF	: Cross-Site Request Forgery
CSS	: Cascading Style Sheets
CSS3	: Cascading Style Sheets Level 3
CSV	: Comma-Separated Values
CV	: Cross-Validation (Çapraz Doğrulama)
DCIS	: Ductal Carcinoma In Situ (Duktal Karsinoma in situ)
DFS	: Hastalıksız Sağkalım
DICOM	: Digital Imaging and Communications in Medicine
DM	: Diabetes Mellitus (Diyabet)
DNS	: Domain Name System
DVC	: Data Version Control
EBCTCG	: Early Breast Cancer Trialists' Collaborative Group
ECDH	: Elliptic Curve Diffie–Hellman
EFS	: Event-Free Survival
EHR	: Elektronik Sağlık Kayıtları
EKG	: Elektrokardiyografi
ER	: Estrojen Reseptörü (Estrogen Receptor)

ESMO	: European Society for Medical Oncology
F1-Score	: F1 skoru
FDA	: Amerika Birleşik Devletleri Gıda ve İlaç Dairesi
FDR	: False Discovery Rate
FISH	: Fluorescence In Situ Hybridization
FN	: False Negative (Yanlış Negatif)
FP	: False Positive (Yanlış Pozitif)
GA	: Güven Aralığı
GDPR	: General Data Protection Regulation
GGT	: Gama Glutamil Transferaz
GLCM	: Gray-Level Co-occurrence Matrix
GLRLM	: Gray-Level Run Length Matrix
GLSZM	: Gray-Level Size Zone Matrix
GLUT	: Glucose Transporter (Glikoz taşıyıcısı)
GSYH	: Gayrisafi Yurt İçi Hasıla
GUI	: Graphical User Interface (Grafik Arayüz)
Hb	: Hemoglobin
HbA1c	: Hemoglobin A1c (Glikozile Hemoglobin)
HBYS	: Hastane Bilgi Yönetim Sistemi
HER2	: Human Epidermal Growth Factor Receptor 2
HIPAA	: Health Insurance Portability and Accountability Act
HRT	: Hormon Replasman Tedavisi
HSTS	: HTTP Strict Transport Security
HTML	: HyperText Markup Language
HTTP	: Hypertext Transfer Protocol

HTTPS	: Hypertext Transfer Protocol Secure
IBSI	: Image Biomarker Standardization Initiative
ICC	: Intraclass Correlation Coefficient
ICER	: Artımlı Maliyet-Etkinlik Oranı
ID	: Identifier (kimlik)
IE	: Internet Explorer
ILR	: İkili Lojistik Regresyon
IP	: Internet Protocol
IQR	: Interquartile Range (Çeyrekler Arası Aralık)
JS	: JavaScript
JSON	: JavaScript Object Notation
KNN	: k-En Yakın Komşu
KOAH	: Kronik Obstrüktif Akciğer Hastalığı
KVKK	: Kişisel Verilerin Korunması Kanunu
L1	: L1 düzenleme (Lasso)
L2	: L2 düzenleme (Ridge)
LASSO	: Least Absolute Shrinkage and Selection Operator
LDH	: Laktat Dehidrogenaz
LGBM	: Light Gradient Boosting Machine (LightGBM)
LIFEx	: Local Image Features Extraction
LLR	: Likelihood Ratio
MAE	: Mean Absolute Error (Mutlak Hata)
MAR	: Missing At Random (Rastgele Eksik)
ML	: Machine Learning (Makine Öğrenmesi)
MODEL ALL	: PET/BT Hariç Tüm Değişkenlerin Dahil Edildiği

	: Model
MODEL PET	: Sadece PET/BT Değişkenlerinin Dahil Edildiği
	: Model
MODEL ALL+PET	: Tüm Değişkenlerin Dahil Edildiği Model
MR	: Manyetik Rezonans
MTV	: Metabolic Tumor Volume (Metabolik Tümör Hacmi)
MVT	: Model–View–Template (Django mimarisi)
NAK	: Neoadjuvan Kemoterapi
NCCN	: National Comprehensive Cancer Network
NGTDM	: Neighborhood Gray-Tone Difference Matrix
NPV	: Negatif Öngörü DeğeriOdds Ratio (Olasılık Oranı)
OS	: Overall Survival (Genel Sağkalım)
PACS	: Picture Archiving and Communication System
PARP	: Poly(ADP-ribose) polymerase
PET/BT	: Pozitron Emisyon Tomografisi/Bilgisayarlı Tomografi
PPV	: Positive Predictive Value
PR	: Progesteron Reseptörü; ayrıca Precision–Recall
QALY	: Quality-Adjusted Life Year
R2	: R^2 / Pseudo R^2 bağlamında açıklayıcılık ölçütü
RCB	Rezidüel Kanser Yüğü (Residual Cancer Burden)
RCB-0	: RCB sınıfı 0 (pCR)
RCB-I	: RCB sınıfı 1 (Minimal Rezidü Hastalık)
RCB-II	: RCB sınıfı 2 (Orta Rezidü Hastalık)
RCB-III	: RCB sınıfı 3 (Yaygın Rezidü Hastalık)
RF	: Random Forest

RF/GBM	: Random Forest / Gradient Boosting Machine
ROBOT	: Return Of Bleichenbacher's Oracle Threat
ROC	: Receiver Operating Characteristic
ROI	: Region of Interest
RSA	: Rivest–Shamir–Adleman
SECTRA	: Sectra (PACS/DICOM Arşiv Sistemi Platform Adı)
SGK	: Sosyal Güvenlik Kurumu
SHA256	: Secure Hash Algorithm 256-bit (Sertifika Parmak İzi
SHAP	: SHapley Additive exPlanations
SMOTE	: Synthetic Minority Over-sampling Technique
SMS	: Short Message Service
SQL	: Structured Query Language
SS	: Standart Sapma
SSD	: Solid State Drive
SSL	: Secure Sockets Layer
SSL/TLS	: Secure Sockets Layer / Transport Layer Security
SUV	: Standardized Uptake Value
SUVmax	: Maksimum Standardized Uptake Value
SUVmean	: Ortalama Standardized Uptake Value
SUVpeak	: Tepe Standardized Uptake Value
T0	: TNM T evresi 0
T1	: TNM T evresi 1
T2	: TNM T evresi 2
T3	: TNM T evresi 3
T4	: TNM T evresi 4

TIL	: Tümör İnfiltrasyon Lenfositleri
TL	: Türk Lirası
TLG	: Total Lesion Glycolysis (Toplam Lezyon Glikolizi)
TLS	: Transport Layer Security
TNM	: Tümör–Nod–Metastas (Kanser Evrelemesi)
TNBC	: Triple Negatif Memem Kanseri
TP	: True Positive (Doğru Pozitif)
TPR	: True Positive Rate (Doğru Pozitif Oranı)
TSH	: Tiroid Stimüle Edici Hormon
URL	: Uniform Resource Locator
UTC	: Coordinated Universal Time
VIF	: Variance Inflation Factor (Varyans Şişirme Faktörü)
VKİ	: Vücut Kitle İndeksi
VOI	: Volume of Interest
WCAG	: Web Content Accessibility Guidelines
WHO	: World Health Organization (Dünya Sağlık Örgütü)
XGB	: eXtreme Gradient Boosting (XGBoost)
XML	: eXtensible Markup Language
XSS	: Cross-Site Scripting
e-GFR	: estimated Glomerular Filtration Rate
pCR	Patolojik Tam Yanıt
ypN0	Neoadjuvan Sonrası Patolojik Nod Negatifliği (ypN0)
Tis	Tumor in situ (in situ tümör evresi)

Giriş

Meme kanseri, dünya genelinde kadınlarda en sık görülen malignite olup, hastalığın heterojen biyolojik yapısı tedaviye verilen yanıtın bireyler arasında değişkenlik göstermesine neden olmaktadır. Neoadjuvan kemoterapi (NAK), tümör boyutunun küçültülmesi ve tedavi yanıtının erken dönemde değerlendirilmesi açısından önemli bir tedavi yaklaşımıdır. Bu süreçte patolojik tam yanıt (pCR) ve rezidüel kanser yükü (Residual Cancer Burden, RCB), prognozun belirlenmesinde ve tedavi stratejisinin yönlendirilmesinde kritik rol oynamaktadır.

Bununla birlikte, NAK yanıtının tedavi öncesinde güvenilir şekilde öngörülebilmesi halen önemli bir klinik gereksinimdir. Mevcut yaklaşımlar klinik, patolojik ve görüntüleme temelli parametrelere dayanmakla birlikte, bu değişkenlerin tekil veya sınırlı kombinasyonlarla değerlendirilmesi, hastalığın çok boyutlu doğasını yeterince yansıtmakta yetersiz kalabilmektedir.

Makine öğrenmesi yöntemleri, farklı veri tiplerinin birlikte analiz edilmesine olanak sağlayarak bu sınırlılıkların aşılmasında potansiyel bir çözüm sunmaktadır. Özellikle PET/BT verilerinin klinik ve patolojik değişkenlerle birlikte değerlendirilmesi, tedavi yanıtının daha doğru ve bireyselleştirilmiş şekilde öngörülmesine katkı sağlayabilir. Ancak mevcut çalışmalar genellikle sınırlı veri entegrasyonu ve klinik uygulamaya aktarım açısından kısıtlıdır.

Bu tez çalışmasında, meme kanserinde neoadjuvan kemoterapi yanıtının öngörülmesi amacıyla klinik, patolojik ve PET/BT verilerinin bütünleşik olarak kullanıldığı makine öğrenmesi temelli modeller geliştirilmiş; hem pCR hem de RCB sonuçlarının öngörülmesi hedeflenmiştir. Ayrıca geliştirilen yaklaşımın klinik karar süreçlerine entegrasyon potansiyeli değerlendirilmiştir.

1.1. Araştırmanın Problemi

Neoadjuvan kemoterapi (NAK) öncesinde, hastaların tedaviye yanıt verip vermeyeceğinin güvenilir şekilde öngörülememesi, klinik karar süreçlerinde önemli bir belirsizlik oluşturmaktadır. Bu belirsizliğin temel nedeni, mevcut klinik yaklaşımların yalnızca sınırlı sayıda patolojik biyobelirteç (ER, PR, HER2, Ki-67) ile sınırlı kalması ve meme kanserinin çok faktörlü biyolojik yapısını yeterince yansıtamamasıdır.

Klinik, demografik, biyokimyasal ve görüntüleme verilerinin sistematik entegrasyonunun yetersiz olması, öngörü modellerinin eksik kalmasına ve klinik uygulanabilirliğinin sınırlandırılmasına neden olmaktadır. Özellikle 18F-FDG PET/BT'nin prognostik değeri kanıtlanmış olmasına rağmen, bu verilerin klinikopatolojik parametrelerle bütünleşik kullanımı ve RCB öngörüsüne katkısı sınırlı düzeyde araştırılmıştır.

Ayrıca, mevcut modellerin önemli bir bölümü klinik pratiğe aktarılabilir araçlara dönüştürülememiştir. Bu translasyonel boşluk, araştırma çıktılarının hasta bakımına entegrasyonunu kısıtlamaktadır.

1.2. Araştırmanın Sorusu

Bu araştırma, PICO (Population, Intervention, Comparison, Outcome) çerçevesinde yapılandırılmıştır. Araştırmanın temel sorusu, neoadjuvan kemoterapi uygulanan meme kanseri hastalarında klinik, patolojik ve görüntüleme verilerinin makine öğrenmesi yöntemleri ile bütünleşik analizinin, geleneksel istatistiksel yaklaşımlara kıyasla rezidüel kanser yükünü (RCB) daha doğru öngörüp öngöremeyeceğini ve bu modellerin klinik karar destek sistemlerine entegre edilebilirliğini değerlendirmektir. Bu kapsamda çalışma; klinikopatolojik değişkenlerin RCB ile ilişkisini, pCR öngörüsünde lojistik regresyon modellerinin performansını, makine öğrenmesi algoritmalarının katkısını, PET/BT verilerinin ek değerini ve geliştirilen modellerin klinik uygulamaya aktarılabilirliğini çok boyutlu olarak incelemektedir.

1.3. Araştırmanın Hipotezleri

Bu araştırmanın ana hipotezi, multimodal veri entegrasyonu temelinde geliştirilen makine öğrenmesi modellerinin, neoadjuvan kemoterapi (NAK) yanıtının öngörülmesinde geleneksel istatistiksel yaklaşımlara kıyasla daha yüksek performans sağlayabileceği varsayımına dayanmaktadır. Başka bir ifadeyle, klinik, patolojik ve görüntüleme verilerinin bütünleşik analizi ile oluşturulan modelleme yaklaşımının pCR ve rezidüel kanser yükü (RCB) öngörüsünde daha güçlü bir ayırt edicilik sunması beklenmektedir.

Bu ana çerçeveyi sınamak üzere aşağıdaki alt hipotezler tanımlanmıştır:

1. Makine öğrenmesi algoritmaları, doğrusal modellere kıyasla daha yüksek öngörü gücü sağlayabilir.

2. PET/BT verilerinin modele eklenmesi, belirli hasta alt gruplarında prediktif performansı artırabilir.
3. Uygun özellik seçimi yöntemleri, model stabilitesini ve genellenebilirliğini iyileştirebilir.
4. Geliştirilen modeller, klinik karar destek sistemlerine entegre edilebilir niteliktedir.
5. Model temelli yaklaşım, belirli koşullar altında maliyet-etkin olabilir.

Bu hipotez seti, çalışmanın yöntemsel doğruluk, klinik uygulanabilirlik, translasyonel değer ve sağlık ekonomisi boyutlarını birlikte değerlendirmeyi amaçlayan bütüncül araştırma yaklaşımını yansıtmaktadır.

1.4. Araştırmanın Varsayımları

Bu araştırma, retrospektif olarak elde edilen klinik verilerin gerçek hasta popülasyonunu ve klinik uygulama örüntülerini yeterli düzeyde temsil ettiği varsayımına dayanmaktadır. Çalışma kapsamında derlenen değişkenlerin, hasta kayıtlarından standardize bir yaklaşımla elde edildiği ve veri kalitesinin analiz sonuçlarını destekleyecek düzeyde olduğu kabul edilmiştir.

Bağımlı değişken olarak kullanılan rezidüel kanser yükü (RCB) skorlamasının, uluslararası kabul gören standart protokollere uygun biçimde gerçekleştirildiği; patolojik değerlendirmelerde gözlemciler arası uyumun kabul edilebilir sınırlar içinde olduğu varsayılmıştır. Bu kabul, RCB temelli sınıflandırmanın yöntemsel tutarlılığı açısından çalışmanın temel dayanaklarından birini oluşturmaktadır.

Veri setindeki eksik gözlemlerin rastgele dağıldığı (MAR yaklaşımıyla uyumlu) ve analiz çıktılarında sistematik bir yanlılık üretmediği varsayılmıştır. Ayrıca, çalışmaya dahil edilen hasta grubunun demografik, klinik ve patolojik özellikler bakımından hedef popülasyonu makul düzeyde temsil ettiği; bu nedenle bulguların benzer hasta gruplarına temkinli biçimde genellenebilir nitelik taşıdığı öngörülmektedir.

Yöntemsel açıdan, kullanılan makine öğrenmesi yöntemlerinin uygun hiperparametre optimizasyonu ve çapraz doğrulama stratejileriyle geliştirildiği; model performansının ayırım gücü, kalibrasyon ve kararlılık boyutlarında güvenilir biçimde değerlendirildiği kabul edilmiştir. Bu doğrultuda, elde edilen bulguların yalnızca istatistiksel düzeyde değil, metodolojik sağlamlık ve klinik karar süreçlerine katkı açısından da anlamlı çıkarımlar sağlayabileceği varsayılmaktadır.

Son olarak, geliştirilen modelleme yaklaşımının karar destek sistemlerine aktarımı sırasında kullanılan teknik altyapının, araştırma kapsamındaki kullanım amacı için yeterli düzeyde doğruluk ve bütünlük sağladığı varsayılmıştır. Bu çerçevede çalışmanın bulgularının, metodolojik geçerlilik ile klinik uygulanabilirlik arasında dengeli bir değerlendirme zemini sunduğu kabul edilmektedir.

1.5. Araştırmanın Sınırlılıkları

Bu çalışmanın bulguları, metodolojik tasarım ve veri yapısından kaynaklanan belirli sınırlılıklar çerçevesinde yorumlanmalıdır. Bu sınırlılıklar, hem iç geçerliliği etkileyen etmenleri hem de sonuçların genellenebilirliğini sınırlandıran unsurları içermektedir. Çalışmanın temel sınırlılığı, retrospektif tasarımından kaynaklanmaktadır. Bu durum, hasta uyumu, tedaviye bağlı yan etkiler ve yaşam kalitesi gibi bazı klinik değişkenlerin standart biçimde izlenmesini kısıtlamaktadır. Ayrıca, verilerin tek bir tersiyer merkezden elde edilmiş olması bulguların farklı popülasyonlara genellenebilirliğini sınırlamaktadır.

Zamansal açıdan, rezidüel kanser yükü (RCB) değerlendirmesinin neoadjuvan kemoterapi sonrası tek bir zaman noktasında yapılmış olması ve uzun dönem sağkalım verilerinin çalışmaya dahil edilmemesi önemli bir sınırlılık oluşturmaktadır. Bu durum, RCB kategorilerinin prognostik değerinin uzun dönem klinik sonuçlarla ilişkilendirilmesini kısıtlamaktadır.

Veri setine ilişkin bir diğer önemli sınırlılık, RCB kategorileri arasındaki sınıf dengesizliğidir. Özellikle bazı alt grupların düşük temsil edilmesi, makine öğrenmesi modellerinin bu sınıfları ayırt etme performansını olumsuz etkileyebilmektedir. Veri dengeleme yöntemleri uygulanmış olsa da, bu durum model çıktıları üzerinde potansiyel bir yanlılık oluşturabilir.

Biyolojik açıdan, genomik ve moleküler veri setlerinin (gen ekspresyonu, mutasyon profilleri, mikroRNA ve proteomik veriler) çalışmaya dahil edilmemesi, tümör biyolojisinin çok boyutlu yapısının tam olarak yansıtılamamasına neden olmaktadır.

Görüntüleme analizlerinde kullanılan yöntemler de belirli sınırlılıklar içermektedir. PET/BT verilerinde ROI (Region of Interest) tanımlamasının manuel olarak yapılması, gözlemciye bağlı değişkenlik riskini artırabilmektedir. Ayrıca, kullanılan yazılım ve analiz süreçleri operatör deneyimine bağlı olarak farklılık gösterebilmektedir.

Geliştirilen model ve yazılım sistemleri henüz gerçek klinik ortamda prospektif olarak doğrulanmamış olup, bu durum klinik uygulamaya doğrudan aktarım açısından bir sınırlılık oluşturmaktadır.

Son olarak, çalışmada gerçekleştirilen maliyet analizleri belirli dönem verilerine dayanmaktadır. Ekonomik parametrelerdeki değişkenlikler (enflasyon, kur dalgalanmaları vb.) uzun dönem maliyet projeksiyonlarının doğruluğunu etkileyebilir.

1.6. Araştırmanın Amacı

Bu araştırmanın temel amacı, neoadjuvan kemoterapi uygulanan meme kanseri olgularında rezidüel kanser yükü (RCB) kategorisinin tedavi öncesi öngörüsüne yönelik olarak klinik, patolojik ve 18F-FDG PET/BT verilerini entegre eden çok modlu (multimodal) tahmin modelleri geliştirmek ve söz konusu modellerin klinik karar verme süreçlerine sağlayabileceği katkıyı ortaya koymaktır.

Bu ana amaç kapsamında çalışma;

- RCB ile ilişkili belirleyicilerin sistematik biçimde tanımlanmasını,
- İstatistiksel yöntemler ile makine öğrenmesi tabanlı modelleme yaklaşımlarının karşılaştırmalı olarak değerlendirilmesini,
- PET/BT değişkenlerinin öngörü performansına kattığı marjinal değerlerin incelenmesini,
- Geliştirilen modellerin yorumlanabilirlik ve genellenebilirlik düzeyinde analiz edilmesini,
- Model sonuçlarının klinik kullanıma uygun karar destek araçlarına dönüştürülebilirliğinin değerlendirilmesini amaçlamaktadır.

Bu doğrultuda araştırma, yalnızca model performansını artırmayı hedefleyen bir yöntem çalışması olmanın ötesinde, elde edilen bulguların klinik pratiğe aktarılabilirliğini sorgulayan translasyonel bir çerçeve sunmaktadır. Nihai hedef, NAK öncesi RCB öngörü doğruluğunu yükselterek tedavi kararlarının daha zamanında, daha isabetli ve hasta-özel biçimde planlanmasına katkı sağlamaktır.

Genel Bilgiler

2.1. Kanseri Biyolojisi ve Meme Kanseri Neoadjuvan Tedaviye Genel Bakış

Kanser, hücrelerin büyüme, çoğalma ve ölüm süreçlerini düzenleyen moleküler kontrol mekanizmalarının bozulması sonucu ortaya çıkan, çok basamaklı ve heterojen bir hastalık grubudur. Bu süreç genellikle hücre DNA'sında meydana gelen mutasyonlarla başlamakta; bu mutasyonlar hücre döngüsü denetimini bozarak kontrolsüz proliferasyona yol açmaktadır. Normal hücrelerde büyüme ve programlı hücre ölümü (apoptoz) dengeli biçimde sürdürülürken, kanser hücrelerinde bu denge proliferasyon lehine kayar ve hücreler dokularda birikerek tümör oluşumuna neden olmaktadır (Hanahan ve Weinberg, 2011; Hanahan, 2022).

Her tümör kanser niteliği taşımamaktadır. İyi huylu tümörler sınırlı büyüme gösterirken, kötü huylu tümörler çevre dokulara invazyon ve metastaz potansiyeline sahiptir (National Cancer Institute, 2024). Kanser hücreleri, büyüme baskılayıcı sinyallere karşı direnç geliştirmekte ve programlı hücre ölümünden kaçarak bağımsız çoğalma yeteneği kazanmaktadır. Bununla birlikte tümör gelişimi yalnızca genetik değişikliklerle sınırlı olmayıp tümör mikroçevresi, immün yanıt ve epigenetik düzenlemeler gibi çok sayıda faktörün etkileşimiyle şekillenmektedir (Hanahan ve Weinberg, 2011; Hanahan, 2022). Bu çok katmanlı yapı, kanserin tek bir parametre ile açıklanamayacağını ve çok boyutlu değerlendirme gerektirdiğini göstermektedir.

Kanserin tanı ve tedavi yaklaşımı, hücre davranışına, kanser tipine ve evresine göre değişiklik göstermektedir. Farklı kanser türleri hücre yapısı, gelişim şekli ve tedavi yanıtları bakımından belirgin farklılıklar gösterdiği için doğru sınıflama uygun tedavi seçiminde kritik rol oynamaktadır. Bu sınıflamada genetik mutasyonlar, tümör çeşitleri ve hastalık evresi gibi unsurlar dikkate alınmaktadır (Siegel ve ark., 2024).

Kanserler, köken aldıkları hücre ve dokulara göre farklı türlere ayrılmaktadır. Klinik sınıflandırmada temel olarak katı (solid) tümörler ve hematolojik kanserler ayrıtılmaktadır. Katı tümörler belirli organ veya dokularda lokalize hücre birikimiyle ortaya çıkmakta ve zamanla çevre dokuları invaze edebilir ve metastaz geliştirebilmektedir. Buna karşın, hematolojik kanserler kan, kemik iliği ve lenf sistemi gibi sıvı dokuları etkileyerek sistemik bir hastalık profili göstermektedir. (Armitage ve ark., 2017). Anemi, enfeksiyonlara yatkınlık ve kanama eğilimi sık görülen klinik bulgulardır (Siegel ve ark., 2024). Bu iki ana grup arasındaki biyolojik

ve klinik farklılıklar, tanı ve tedavi yaklaşımlarının da temelden farklılaşmasına neden olmaktadır. Hematolojik kanserlerde, tedavi çoğunlukla sistemik yaklaşımlar gerektirmekte; kemoterapi temel tedavi yöntemi olmakla birlikte, immünoterapi, hedefe yönelik ajanlar ve kemik iliği nakli belirli hasta gruplarında kullanılmaktadır (Armitage ve ark., 2017; Kantarjian ve ark., 2023; Tang ve ark., 2023). Katı tümörlerde ise tanı ve tedavi yaklaşımları tümörün tipi, boyutu, evresi ve biyolojik özelliklerine göre değişmekte; bu nedenle doğru sınıflandırma uygun tedavi seçiminde (cerrahi, kemoterapi, radyoterapi, hedefe yönelik tedaviler ve immünoterapiler) kritik rol oynamaktadır (Siegel ve ark., 2024; DeVita ve ark., 2019; Gradishar ve ark., 2023). Kanser biyolojik ve klinik heterojenitesi, tanı ve tedavi süreçlerinin bireyselleştirilmesini zorunlu kılmaktadır. Genetik yatkınlık, çevresel faktörler (tütün kullanımı, alkol, radyasyon, kimyasal maruziyetler) ve enfeksiyöz ajanlar hastalığın gelişiminde rol oynamakta; bu faktörlerin etkisi bireyler arasında değişkenlik göstermektedir (WHO (Dünya Sağlık Örgütü), 2024; Siegel ve ark., 2024). Bu durum, aynı kanser türü içinde bile farklı klinik seyir ve tedavi yanıtları ile sonuçlanmaktadır. Dolayısıyla kanserin değerlendirilmesinde tek bir parametreye dayalı yaklaşımlar yetersiz kalmakta ve çok parametrelili, entegre analiz yaklaşımlarına ihtiyaç duyulmaktadır.

Bu bağlamda, özellikle meme kanseri gibi belirgin heterojenite gösteren tümörlerde, tedavi yanıtının öngörülmesi klinik karar süreçlerinin en kritik ve en zorlayıcı bileşenlerinden biri olarak öne çıkmaktadır. Bu zorluk, yalnızca klasik klinik ve patolojik parametrelerle değil; aynı zamanda radyolojik ve metabolik verilerin de entegre edildiği çok boyutlu yaklaşımların geliştirilmesini gerekli kılmaktadır.

2.1.1. Meme Kanseri: Epidemiyoloji, Patogenez ve Risk Faktörleri

Meme kanseri, kadınlarda görülen en yaygın malignite türlerinden biri olup dünya genelinde önemli bir morbidite ve mortalite nedenidir. Uluslararası Kanser Araştırma Ajansı'nın 2022 yılı verilerine göre, küresel ölçekte yaklaşık 2.3 milyon yeni meme kanseri vakası bildirilmiş ve bu hastalığa bağlı olarak 670.000'den fazla ölüm gerçekleşmiştir. Bu istatistikler, özellikle erken tanı imkanlarının sınırlı olduğu bölgelerde daha belirgin hale gelmektedir (International Agency for Research on Cancer, 2022). Hastalığın özellikle erken evrelerde asemptomatik seyredebilmesi,

tarama ve erken tanı yaklaşımlarını prognoz açısından belirgin hale getirmektedir (Siegel ve ark., 2024).

Meme kanserinin patogenezi, hücrelerde biriken genetik değişikliklerin, hormonal düzenleyicilerin ve çevresel maruziyetlerin etkileşimi ile şekillenen çok faktörlü bir süreçtir. Bu çerçevede risk faktörleri genel olarak genetik/ailevi, hormonal ve çevresel/yaşam tarzı bileşenleri şeklinde sınıflandırılabilir. Bu sınıflama, bireysel risk profillerinin oluşturulmasına ve önleme stratejilerinin geliştirilmesine temel oluşturmaktadır (Colditz ve Bohlke, 2014). Bu çok katmanlı yapı, yalnızca hastalık gelişimini değil, aynı zamanda tedaviye verilen yanıtın bireyler arasında farklılık göstermesini de açıklayan temel unsurlardan biridir.

Genetik ve ailevi faktörler, özellikle DNA onarım yollarında rol alan germline mutasyonlar aracılığıyla meme kanseri riskini artırmakta; BRCA1/2 gibi genlerdeki bozukluklar genomik kararsızlık üzerinden tümörleşmeyi kolaylaştırmakta ve bazı olgularda daha erken yaşta ve daha agresif klinik seyirle ilişkilendirilmektedir (Antoniou ve ark., 2003; Ford ve ark., 1998). Aile öyküsü, genetik riskin klinik göstergelerinden biri olup birinci derece akrabalarda meme kanseri varlığı riski anlamlı düzeyde artırmaktadır. Güncel kılavuzlar doğrultusunda genetik testler (BRCA ve TP53 gibi mutasyonlar için çoklu gen panel sekanslama) ve risk temelli tarama yaklaşımları (MR/mamografi gibi) yüksek riskli grupların yönetiminde kullanılmaktadır (National Comprehensive Cancer Network [NCCN], 2024). Bununla birlikte genetik etkenler tüm olguların sınırlı bir kısmını açıklamakta; birçok vakada somatik mutasyonlar ve epigenetik değişiklikler öne çıkmaktadır.

Hormonal faktörler, meme epiteli üzerinde proliferatif baskıyı artırarak ve DNA hasarı birikimini kolaylaştırarak meme kanseri riskini etkileyebilmektedir. Meme epitelinde hücre döngüsünü ve doku yenilenmesini düzenleyen temel hormonlar olan östrojen ve progesteron hormonlarına uzun süreli maruziyet (ör. erken menarş, geç menopoz, nulliparite veya ilk doğum yaşının ileri olması gibi) yaşam boyu mitotik döngü sayısını artırarak mitotik hata ve mutasyon birikimi riskini yükseltebilmektedir. Bu doğrultuda menopoz sonrası hormon replasman tedavisi (HRT) özellikle kombine östrojen–progesteron kullanımında, meme kanseri insidansında artışla ilişkilendirilmiş; risk artışının tedavi süresi ve doz ile belirginleştiği bildirilmiştir (Micha ve ark., 2022; Colditz ve Bohlke, 2014).

Çevresel ve yaşam tarzı faktörleri de meme kanseri riskinde önemli rol oynamaktadır. İyonize radyasyon, DNA çift zincir kırıkları oluşturması nedeniyle özellikle duyarlı dönemlerde (adolesan ve genç erişkinlik) uygulandığında riski belirgin biçimde artırabilmektedir (Boice ve ark., 2002). Alkol tüketimi, östrojen metabolizmasını ve serum östrojen düzeylerini etkileyerek riski artışına katkıda bulunurken; obezite özellikle menopoz sonrası dönemde yağ dokusunda artan aromataz aktivitesiyle periferik östrojen üretimini yükseltip inflamatuvar mikroçevreyi güçlendirebilmektedir. Fiziksel inaktivite ise hem kilo artışı hem de insülin direnci/inflamasyon üzerinden dolaylı risk artışı ile ilişkilidir. Buna karşın emzirme ve düzenli fiziksel aktivite gibi koruyucu faktörlerin, hormonal maruziyet paternini değiştirme ve metabolik–inflamatuvar yükü azaltma yoluyla risk azalımıyla ilişkili olabileceği bildirilmiştir (Collaborative Group on Hormonal Factors in Breast Cancer, 2002).

Bu faktörlerin bütüncül değerlendirilmesi, bireysel risk profillerinin belirlenmesine katkı sağlamakta; ancak meme kanserinin klinik davranışı yalnızca risk faktörleri ile açıklanamamaktadır. Aynı risk profiline sahip hastalar arasında dahi tümör biyolojisi ve tedavi yanıtı açısından belirgin farklılıklar gözlenebilmektedir. Bu durum, meme kanserinde heterojenitenin yalnızca hastalık gelişimi ile sınırlı olmadığını, aynı zamanda tedavi yanıtını da doğrudan etkilediğini göstermektedir.

2.1.2. Meme Kanseri Alt Türleri ve Çeşitlilik

Meme kanseri, biyolojik ve klinik heterojenitesi nedeniyle moleküler alt tiplere ayrılarak değerlendirilmekte ve bu sınıflandırma klinik pratikte tedavi seçiminde önemli bir rol oynamaktadır. Klinik uygulamada alt tipler çoğunlukla immünohistokimyasal surrogate belirteçler üzerinden; östrojen reseptörü (ER), progesteron reseptörü (PR), HER2 ekspresyonu ve Ki-67 proliferasyon indeksi kullanılarak tanımlanmaktadır (Burstin ve ark., 2019). Bu sınıflandırma, tümörün biyolojik davranışı ve tedaviye yanıt potansiyeli hakkında yol gösterici bilgiler sunmaktadır.

Hormon reseptör pozitif (ER/PR+) meme kanserleri, tüm vakaların yaklaşık %70-80'ini oluşturmakta olup genellikle daha düşük proliferasyon hızı ve daha geç metastaz eğilimi ve görece olarak daha iyi prognoz ile ilişkilidir (Early Breast Cancer Trialists' Collaborative Group – EBCTCG, 2015). Bununla birlikte bu grubun biyolojik

davranışları heterojen olup; proliferasyon indeksleri ve ek moleküler özellikler, aynı alt tip içinde bile belirgin biyolojik ve klinik farklılıklar ortaya koyabilmektedir. Bu durum, hormon reseptör pozitif meme kanserlerinin tek bir homojen grup olarak değerlendirilmemesi gerektiğini ortaya koymaktadır (EBCTCG, 2015).

HER2 pozitif meme kanserleri, tümör hücrelerinde HER2 gen amplifikasyonu veya protein aşırı ekspresyonu ile karakterize olup tüm vakaların yaklaşık %15–20'sini oluşturmaktadır. Bu alt tip, genellikle yüksek proliferasyon hızı, erken nüks eğilimi ve agresif klinik seyir ile ilişkilidir. HER2 sinyal yolları, hücre proliferasyonu ve hayatta kalma yollarının aktivasyonunda merkezi rol oynamaktadır. Bu nedenle HER2 durumu, yalnızca alt tip tanımlamasında değil, aynı zamanda tedaviye yanıtın öngörülmesinde de kritik bir belirteçtir. Klinik olarak HER2 pozitif tümörler, özellikle neoadjuvan tedaviye (NAK) yüksek yanıt potansiyeli gösteren alt tipler arasında yer almaktadır (Gianni ve ark., 2010).

Triple negatif meme kanseri (TNBC), ER, PR ve HER2 ekspresyonunun olmaması ile tanımlanır ve olguların yaklaşık %10–15'ini oluşturmaktadır. Bu alt tip, genellikle genç yaşta ortaya çıkmakta, yüksek proliferasyon hızı ve erken metastaz eğilimi göstermektedir. Klinik seyir sıklıkla agresif olup, diğer alt tiplere kıyasla daha sınırlı tedavi seçenekleri ve daha düşük sağkalım oranları ile ilişkilidir (Dent ve ark., 2007). TNBC, biyolojik açıdan oldukça heterojen bir gruptur ve DNA hasar onarım mekanizmalarındaki bozukluklar, özellikle BRCA1 ilişkili tümörlerde belirgin rol oynayabilmektedir. Bu biyolojik özellikler, TNBC'nin kemoterapiye duyarlılığını ve patolojik yanıt paternlerini etkileyebilmektedir (Tutt ve ark., 2010, Mateo ve ark., 2021).

Neoadjuvan tedavi bağlamında moleküler alt tipler, patolojik tam yanıt (pCR) oranları ve uzun dönem klinik sonuçlarla yakından ilişkilidir. Özellikle HER2 pozitif ve TNBC alt tiplerinde pCR elde edilmesi, prognoz açısından güçlü bir belirteç olarak kabul edilmektedir (Cortazar ve ark., 2014). Ancak, aynı moleküler alt tipe sahip hastalarda dahi tedavi yanıtı ve rezidüel hastalık düzeyi arasında belirgin farklılıklar gözlenebilmektedir. Bu durum, moleküler alt tip sınıflandırmasının tek başına yeterli olmadığını ve tedavi yanıtının öngörülmesinde ek parametrelere ihtiyaç duyulduğunu göstermektedir.

Bu noktada, neoadjuvan tedavi sonrası tümör yükünün kantitatif olarak değerlendirilmesini sağlayan Rezidüel Kanser Yüğü (Residual Cancer Burden, RCB) kavramı ön plana çıkmaktadır. RCB, yalnızca yanıtın varlığını değil, yanıtın derecesini de objektif olarak ölçebilmesi nedeniyle klinik karar süreçlerinde önemli bir araçtır. Bununla birlikte, RCB kategorilerinin tedavi öncesinde öngörülebilmesi halen önemli bir klinik ihtiyaç olarak devam etmektedir.

Sonuç olarak, moleküler alt tipler meme kanserinin biyolojik davranışı ve tedaviye yanıtının anlaşılmasında önemli bir çerçeve sunsa da, hastalığın klinik seyrini ve neoadjuvan tedavi sonrası yanıtı tüm yönleriyle açıklamakta sınırlı kalabilmektedir. Bu sınırlılık, tedavi sonrası rezidüel hastalığın nicel olarak değerlendirilmesini sağlayan ek ölçütlerin ve çok parametrelili yaklaşımların gerekliliğini ortaya koymaktadır.

2.1.3. Meme Kanseri ve Laboratuvar Patolojisi

Meme kanseri, belirgin moleküler ve morfolojik heterojenitesi nedeniyle patolojik değerlendirmelerin kritik olduğu bir hastalıktır. Tanıdan tedavi planlamasına ve prognostik risk sınıflamasına kadar tüm süreç, laboratuvar patolojisinden elde edilen bilgiler üzerine inşa edilmektedir. Hücresel morfoloji, immünohistokimyasal belirteçler ve seçilmiş moleküler analizler; tümörün alt tipinin, agresiflik düzeyinin ve tedaviye hedef olabilecek biyobelirteçlerin tanımlanmasını sağlamaktadır (Hammond ve ark., 2010).

Bu çalışma bağlamında patoloji, yalnızca “tanı koyan” bir disiplin değil; aynı zamanda RCB hesabında kullanılan parametreleri (tümör boyutu, hücresellik, nodal tutulum) ve NAK yanıtını etkileyen biyolojik belirteçleri (ER, PR, HER2, Ki-67 gibi) sağlayan merkezi veri kaynağıdır. Dolayısıyla bu çalışmada kullanılan birçok bağımsız değişken doğrudan patoloji raporlarından elde edilmekte; böylece patolojik veriler, hem RCB ölçümünün doğrudan girdisini hem de NAK yanıt modellerinde yer alan temel öngörücüleri oluşturmaktadır.

Patolojik inceleme, tümörün histolojik tipini, invazyon derecesini ve grade’ini belirleyerek biyolojik davranış hakkında temel bilgi sunmaktadır. Hematoksilen-eozin (HveE) boyalı kesitlerin mikroskopik değerlendirilmesiyle tümörün histolojik tipi (örneğin invaziv duktal, lobüler), grade’i (nottingham sistemi), lenfovasküler invazyon durumu, duktal carcinoma in situ (DCIS) bileşeni ve cerrahi sınır (marj) durumu gibi

parametreleri raporlanmaktadır. Bu deęişkenler, yalnızca prognostik açıdan deęil, aynı zamanda tedavi yanıtının dolaylı belirteçleri olarak da önem taşımaktadır.

İmmünohistokimyasal (İHK) analizler, meme kanserinde hormon reseptörleri (ER, PR) ve HER2 durumunun deęerlendirilmesinde standart yöntemdir. ER/PR durumu, adjuvan hormonal tedavi endikasyonunu; HER2 durumu ise HER2-hedefli ajanların uygulanabilirliğini belirler. HER2'nin sınırda veya belirsiz olduęu durumlarda, gen amplifikasyonunu ortaya koymak için Fluorescence In Situ Hybridization (FISH) gibi ek testler kullanılmakta ve böylece tedavi hedefi netleştirilmektedir (Hammond ve ark., 2010; Wolff ve ark., 2018).

Metastatik lenf nodlarının patolojik incelemesi (örneğin sentinel lenf nodu biyopsisi) hastalığın evrelemesinde ve tedavi planlamasında kritik bir bileşendir. Sentinel lenf nodu biyopsisi ve aksiller diseksiyon örnekleri üzerinden yapılan patolojik incelemeler, nodal tutulumun varlığını ve yaygınlığını ortaya koymakta; bu bilgiler RCB skorunun nodal bileşenini oluşturmaktadır. Bu nedenle lenf nodu verileri, yalnızca evreleme parametresi deęil, aynı zamanda modelleme açısından önemli bir öngörücü deęişken nitelięi taşımaktadır.

Moleküler patoloji, tümörün genetik ve transkripsiyonel özelliklerini inceleyerek klasik histopatolojik deęerlendirmeyi tamamlamaktadır. Genomik testler (örneğin çok genli panel analizleri) ve seçilmiş mutasyon deęerlendirmeleri, özellikle ER pozitif hastalarda ESR1 mutasyonlarının endokrin tedavi direncini öngörmesi, HER2-düşük veya sınırda olgularda yeni nesil HER2-hedefli ilaçlara aday hastaların belirlenmesi, triple negatif meme kanserinde BRCA1/2 mutasyonlarının PARP (Poly(ADP-ribose) polymerase) inhibitörleri için, PD-L1 (Programmed Death-Ligand 1) ekspresyonunun immünoterapi için hasta seçiminde kullanılması gibi örneklerle tedavi karar süreçlerine doğrudan yansımaktadır (Modi ve ark., 2022; Tutt ve ark., 2021). Buna ek olarak, dolaşımdaki tümör DNA'sını (ctDNA) analiz eden "liquid biyopsi" yöntemleri, minimal rezidüel hastalığın non-invaziv takibini mümkün kılmakta ve erken nüksün öngörülmesinde umut verici araçlar olarak deęerlendirilmektedir. Bu yaklaşım, patolojik yanıt ve RCB gibi cerrahi sonrası parametrelerle birlikte dinamik bir risk izlemi sağlamaktadır.

Bu çalışmada genomik veri doğrudan kullanılmamış olmakla birlikte, moleküler patoloji kavramı; klinik ve patolojik verilerin gelecekte genomik katmanlarla entegre

edilebileceği genişletilebilir bir çerçeve sunmaktadır. Bu durum, geliştirilen modeller, ileride gen ekspresyon profilleri ve mutasyon verileri ile zenginleştirilerek daha rafine biyoinformatik platformlara dönüştürülebilecektir.

Sonuç olarak, patolojik veriler yalnızca tanı ve sınıflama amacıyla değil; aynı zamanda neoadjuvan tedavi yanıtının nicel değerlendirilmesi ve öngörülmesi açısından merkezi bir rol oynamaktadır. Bu nedenle, patoloji verilerinin klinik ve radyolojik parametrelerle birlikte ele alınması, meme kanserinde daha doğru ve bireyselleştirilmiş tahmin modellerinin geliştirilmesi için temel bir gereklilik oluşturmaktadır.

2.1.4. Klinik ve Moleküler Patoloji Arasındaki İlişki

Klinik ve moleküler patoloji, meme kanseri yönetiminde birbirini tamamlayan ve birlikte değerlendirildiğinde anlam kazanan iki temel bileşendir. Klinik patoloji; tümör boyutu, multifokalite, lenf nodu durumu, cerrahi sınır ve görüntüleme bulguları gibi makroskopik ve mikroskopik verileri sağlamaktadır. Moleküler patoloji ise tümörün genomik ve immünolojik özelliklerini ekleyerek bu tabloyu derinleştirmektedir. Bu iki katmanın entegrasyonu, hasta bazında daha doğru risk sınıflaması ve daha uygun tedavi stratejisinin belirlenmesine imkân tanımaktadır (Hammond ve ark., 2010).

Uluslararası kılavuzlar, Amerikan Patologlar Koleji (CAP - College of American Pathologists) ve Amerikan Klinik Onkoloji Derneği (ASCO - American Society of Clinical Oncology) gibi kurumların önerileri, biyobelirteçlerin (ER, PR, HER2, Ki-67 vb.) değerlendirilmesinde standardizasyon büyük önem taşımaktadır. Bu standartlar, farklı merkezler arasında sonuçların karşılaştırılabilirliğini ve tedavi kararlarının tutarlılığını artırmaktadır. Aynı şekilde, mamografi ve manyetik rezonans (MR) gibi görüntüleme yöntemlerinden elde edilen BI-RADS (Breast Imaging Reporting and Data System) kategorileri ile patolojik ve moleküler bulguların uyumlu yorumlanması; hem aşırı tedaviyi (overtreatment) hem de yetersiz tedaviyi (undertreatment) önlemeye yardımcı olmaktadır.

Bununla birlikte, klinik ve moleküler verilerin tek başına değerlendirilmesi çoğu zaman hastalığın biyolojik davranışını ve tedavi yanıtını tam olarak açıklamakta yetersiz kalmaktadır. Aynı klinik ve moleküler özelliklere sahip hastalarda dahi belirgin farklı tedavi yanıtları gözlenebilmesi, bu veri katmanlarının tekil kullanımının sınırlılıklarını ortaya koymaktadır. Bu durum, meme kanserinde heterojenitenin

yalnızca tanımlanması değil, aynı zamanda bu heterojenitenin çok boyutlu olarak modellenmesi gerektiğini göstermektedir.

Son yıllarda dijital patoloji ve yapay zekâ temelli yaklaşımlar, histopatolojik kesitlerin otomatik analizi, TIL skorlama ve biyobelirteç değerlendirmesinde gözlemciye bağlı değişkenliğin azaltılması gibi alanlarda önemli ilerlemeler sağlamıştır. Bu tür araçlar, klinik ve moleküler verilerle birleştirildiğinde, daha nesnel ve yeniden üretilebilir (reprodüksiyon yüksek) risk sınıflama modelleri geliştirilmesine olanak vermektedir (Hammond ve ark., 2010; Topol, 2019). Ancak bu verilerin klinik karar süreçlerine etkin biçimde entegre edilebilmesi için farklı veri türlerinin birlikte değerlendirilmesini sağlayan yöntemlere ihtiyaç duyulmaktadır.

Bu çalışma, klinik ve patolojik verileri; radyolojik ve metabolik (PET/BT) parametrelerle birlikte entegre eden bir yaklaşım benimseyerek, klinik–moleküler–görüntüleme verilerinin RCB üzerindeki ortak etkisini nicel modellerle ortaya koymayı amaçlamaktadır. Böylece, patoloji raporları yalnızca tanı ve sınıflama aracı olmaktan çıkarak, makine öğrenmesi tabanlı klinik karar destek sistemlerinin ana veri kaynağı haline gelmektedir.

2.2. Kemoterapi

Kemoterapi, sitotoksik ilaçlarla hızla bölünen hücrelerin hedeflenmesine dayalı sistemik bir tedavi yaklaşımıdır. Meme kanserinde hem adjuvan hem de neoadjuvan dönemde uygulanarak, uygun hastalarda uzun dönem sağkalımı anlamlı ölçüde artırdığı gösterilmiştir (EBCTCG, 2018; Burstein ve ark., 2023). Tedavi şemaları tümörün evresine, moleküler alt tipine ve hastanın genel durumuna göre bireyselleştirilmekte; bu durum tedavi yanıtında gözlenen heterojenitenin önemli nedenlerinden birini oluşturmaktadır.

Meme kanserinde antrasiklin ve taksan içeren kombinasyon rejimleri (örneğin AC-T: doksorubisin, siklofosamid, paklitaksel) standart tedavi yaklaşımları arasında yer almaktadır (Denduluri ve ark., 2021).

Kemoterapötik ajanlar, temel olarak hızlı proliferasyon gösteren hücreleri hedef alarak antitümör etki oluşturur. Bu etki, hücre döngüsünün farklı fazlarında DNA hasarı oluşturulması, mitotik iğ oluşumunun engellenmesi ve apoptozun indüklenmesi gibi mekanizmalar üzerinden gerçekleşmektedir.

Meme kanserinde yaygın kullanılan başlıca ilaç grupları arasında antrasiklinler (ör. doksorubisin), taksanlar (ör. paklitaksel, dosetaksel), antimetabolitler (ör. 5-fluorourasil) ve platin bileşikleri (ör. karboplatin) yer almaktadır. Antrasiklinler topoizomeraaz II inhibisyonu ve serbest radikal oluşumu yoluyla DNA hasarı oluştururken, taksanlar mikrotübül dinamiğini bozarak mitozu durdurmaktadır. Antimetabolitler nükleotid sentezini baskılayarak DNA replikasyonunu engellerken, platin bileşikleri DNA zincirleri arasında çapraz bağlar oluşturarak hücresel çoğalmayı baskılamaktadır (DeVita ve ark., 2022). Antimetabolitler meme kanseri tedavisinde yer almakla birlikte, bu çalışmadaki hasta kohortunda bu ilaç grubunu kullanan örneklere rastlanmamıştır.

Bu ajanların ardışık veya kombine kullanımı, farklı hücre döngüsü basamaklarını hedefleyerek sinerjik bir antitümör etki yaratmaktadır. Antrasiklin-taksan temelli rejimler ve uygun hastalarda platin eklenmesi, özellikle triple negatif ve HER2 pozitif alt tiplerde neoadjuvan kemoterapi sonrası patolojik tam yanıt (pCR) oranlarını belirgin olarak artırmaktadır (Cortazar ve ark., 2014; EBCTCG, 2018; Gennari ve ark., 2021).

Bununla birlikte, tümör hücrelerinin genetik ve moleküler özelliklerine bağlı olarak bu ajanlara verilen yanıt değişkenlik göstermektedir. DNA tamir kapasitesi, proliferasyon hızı, apoptotik yolların durumu ve tümör mikroçevresi gibi faktörler kemoterapiye duyarlılığı belirleyen temel unsurlar arasında yer almaktadır. Bu biyolojik heterojenite, neoadjuvan kemoterapi sonrası gözlenen rezidüel hastalık düzeyinin farklılaşmasına ve dolayısıyla RCB skorundaki değişkenliğe katkı sağlamaktadır.

Kemoterapinin etkinliği yalnızca tümör biyolojisi ile sınırlı olmayıp, tedavi sürecine ilişkin klinik faktörlerden de etkilenmektedir. Tedaviye bağlı yan etkiler, doz azaltımı, kür gecikmesi veya tedavi kesintisi gibi durumlara yol açarak relatif doz yoğunluğunu düşürebilir. Bu durum, tümör üzerindeki terapötik baskının azalmasına ve tedavi yanıtının dolaylı olarak değişmesine neden olabilir. Bu nedenle tedavi toleransı, neoadjuvan kemoterapiye verilen yanıtın değerlendirilmesinde göz önünde bulundurulması gereken önemli bir klinik belirleyici olarak değerlendirilmektedir.

Bu çalışma kapsamında kemoterapinin moleküler etki mekanizmaları ayrıntılı olarak incelenmekten ziyade, tümör yanıtını belirleyen biyolojik bir temel olarak ele alınmış ve bu mekanizmaların klinik çıktılara yansımaları üzerinden değerlendirme yapılmıştır.

2.2.1. Hedefe Yönelik Tedavi ve Kemoterapinin Birlikte Kullanımı

Meme kanseri tedavisinde hedefe yönelik yaklaşımlar, tümör hücrelerinin spesifik moleküler özelliklerini hedef alarak tedavi etkinliğini artırmayı amaçlamaktadır. Bu tedaviler (trastuzumab, pertuzumab, trastuzumab emtansin, PARP inhibitörleri vb.), özellikle HER2 pozitif ve hormon reseptör pozitif alt tiplerde kemoterapi ile birlikte veya ardışık olarak uygulanmakta ve tedavi yanıtını belirgin şekilde iyileştirmektedir. HER2 pozitif hastalarda, HER2-hedefli tedavilerin kemoterapiye eklenmesi neoadjuvan dönemde pCR oranlarını %40–60 düzeyine yükseltmiştir (Slamon ve ark., 2011; Gennari ve ark., 2021; von Minckwitz ve ark., 2012). Benzer şekilde; BRCA mutasyonu taşıyan TNBC hastalarında, platin temelli kemoterapi ile PARP inhibitörlerinin ardışık veya kombine kullanımı nüks riskini azaltmakta ve sağkalımı iyileştirmektedir (Sun ve ark., 2023).

Bu çalışmada, hedefe yönelik tedavi alıp almama bilgisi; tedavi rejimiyle birlikte NAK yanıtı ve RCB üzerinde potansiyel etkisi olabilecek bir klinik değişken olarak değerlendirilmiştir.

2.3. Neoadjuvan Kemoterapi ve Tedavi Yanıtının Değerlendirilmesi

Neoadjuvan kemoterapi, başlangıçta yalnızca inoperabl ya da lokal ileri olgularda tümör yükünü azaltmaya yönelik bir yaklaşım olarak konumlandırılmışken, güncel onkoloji pratiğinde biyolojik alt tipe dayalı tedavi planlamasının ve yanıt-temelli prognostik değerlendirmenin merkezi bir bileşeni haline gelmiştir. Bu dönüşüm, NAK'ın sadece cerrahi hazırlık sağlayan bir küçültme stratejisi değil, aynı zamanda tedavi duyarlılığını in vivo olarak test eden ve adjuvan tedavi kararlarını yönlendiren dinamik bir klinik platform olarak ele alınmasını gerektirmektedir.

NAK, primer tümörü küçültmek, aksiller lenf nodu tutulumunu azaltmak, meme koruyucu cerrahi olanağını artırmak ve tedaviye in vivo yanıtı değerlendirmek amacıyla cerrahi öncesi uygulanan sistemik tedavi yaklaşımıdır. Özellikle büyük tümör çapı, klinik pozitif nodal hastalık, TNBC ve HER2 pozitif alt tipler gibi yüksek riskli hasta gruplarında, güncel kılavuzlarda standart yaklaşım haline gelmiştir (Cortazar ve ark., 2014; Gennari ve ark., 2021; NCCN, 2024).

NAK'ın en önemli klinik avantajlarından biri, tedavi etkinliğinin erken dönemde gözlemlenebilmesidir. Tedavi sonrası elde edilen pCR, özellikle TNBC ve HER2 pozitif alt tiplerde uzun dönem sağkalım için güçlü bir prognostik belirteç olarak kabul

edilmektedir (Cortazar ve ark., 2014; Spring ve ark., 2020). Buna karşın pCR, iki kategorili (var/yok) bir sonlanım ölçütü olması, pCR elde edilemeyen hastalarda rezidüel tümör yükünün derecesini yeterince yansıtamaması açısından önemli bir sınırlılık oluşturmaktadır.

Aynı non-pCR grubunda, minimal rezidüel hastalığı olan hastalar ile belirgin rezidüel taşıyan hastaların birlikte yer alması, klinik karar verme açısından önemli bir heterojeniteye neden olmaktadır. Bu sınırlılık, neoadjuvan tedavi sonrası rezidüel kanser yükünü (RCB) nicel ve daha ayrıntılı şekilde tanımlayan skor sistemlerine olan gereksinimi doğurmuştur.

Bu tez kapsamında, NAK öncesi elde edilen çok boyutlu klinik ve görüntüleme verileri kullanılarak RCB skor ve kategorilerinin öngörülmesi amaçlanmakta; böylece tedavi yanıtının yalnızca postoperatif değerlendirme ile değil, tedavi öncesinde tahmin edilebilir hale getirilmesi hedeflenmektedir.

2.3.1. Patolojik Tam Yanıt (pCR) ve Sınırlılıkları

pCR, genel olarak, neoadjuvan tedavi sonrasında memede invaziv tümör dokusunun ve aksiller lenf nodlarında makrometastatik tutulumun saptanmaması (ypT0/Tis (Patolojik Tam Yanıt/Tümör İn-Sitü), ypN0) şeklinde tanımlanmaktadır (Cortazar ve ark., 2014). pCR elde edilen hastalar; özellikle TNBC ve HER2 pozitif alt tiplerde, pCR elde etmeyenlere kıyasla hem hastalıksız sağkalım hem de genel sağkalım açısından anlamlı avantaj taşımaktadır (Cortazar ve ark., 2014; Spring ve ark., 2020). Bununla birlikte, pCR'nin ikili bir sonlanım ölçütü olması, rezidüel hastalık yükünün derecesine ilişkin ayrıntılı bilgi sunamaması nedeniyle klinik karar verme süreçlerinde sınırlılıklar oluşturmaktadır. Minimal rezidüel hastalığı olan bir hasta ile yaygın rezidüel tümör yükü bulunan bir hastanın aynı non-pCR kategorisinde yer alması, klinik karar verme açısından önemli bir belirsizlik oluşturmaktadır. Bu nedenle, pCR dışı hastalarda rezidüel hastalık miktarını kademe kademe değerlendiren RCB gibi sistemler geliştirilmiştir (Symmans ve ark., 2007; Yau ve ark., 2022).

2.3.2. Neoadjuvan Yanıtın Görüntüleme ile İzlenmesi

NAK sırasında ve sonrasında tümör yanıtının değerlendirilmesinde klinik muayenenin yanı sıra çeşitli görüntüleme yöntemleri kullanılmaktadır. Mamografi ve ultrasonografi, tümör boyutu ve morfolojik değişiklikleri ortaya koyarken, dinamik kontrastlı meme MR'ı, volumetrik değişiklikleri ve rezidüel

hastalık miktarını daha ayrıntılı ve duyarlı biçimde değerlendirebilmektedir.18F-FDG PET/BT, tümörün glukoz metabolizmasına dayalı aktivitesini yansıtarak özellikle erken dönemde biyolojik yanıt hakkında bilgi sağlayabilmektedir (Groheux ve ark., 2012; Janssen ve ark., 2022).

Bu parametreler, tedavi öncesi tümör yükünü ve tedavi sonrası metabolik yanıtı nicel olarak yansıtmaktadır. Bunun yanı sıra, PET/BT görüntülerinden türetilen tekstür (doku) özellikleri, tümör metabolik heterojenliğini ortaya koyarak biyolojik agresiflik hakkında ek bilgi sağlayabilmektedir Moscoso ve ark., 2018).

Bu çalışmada PET/BT'den elde edilen metabolik parametreler; klinik, patolojik, biyokimyasal ve radyolojik değişkenlerle birlikte RCB tahmin modellerine entegre edilmiştir. Böylece NAK alnızca tümör boyutundaki değişim üzerinden değil, metabolik ve yapısal özelliklerin birlikte değerlendirilmesiyle çok boyutlu olarak ele alınmakta, PET/BT temelli parametrelerin RCB öngörüsüne katkısı sistematik biçimde incelenmektedir. Bu yaklaşım, fonksiyonel görüntüleme verilerinin istatistiksel ve makine öğrenmesi tabanlı modellerle birleştirildiği, klinik biyoinformatik odaklı bir çerçeve sunmakta ve gelecekteki klinik karar destek sistemlerine entegrasyon için metodolojik zemin oluşturmaktadır.

2.4. Rezidüel Kanser Yüğü (RCB)

Rezidüel Kanser Yüğü, neoadjuvan sistemik tedavi sonrasında memede ve aksillada kalan tümör yükünü kantitatif olarak tanımlayan, patolojik yanıtı yalnızca 'tam yanıt/yanıtsızlık' ikiliğine indirgmeden süreklilik içinde değerlendirmeyi sağlayan bütünleşik bir sınıflama sistemidir. RCB yaklaşımı, primer tümör yatağındaki invaziv hastalık miktarı ile nodal rezidüel hastalık boyutunu aynı çerçevede birleştirerek prognostik ayırım gücünü artırmakta; böylece adjuvan tedavi yoğunluğunun belirlenmesi, nüks riskinin katmanlanması ve hasta bazlı klinik karar süreçlerinin standardizasyonu açısından güçlü bir referans oluşturmaktadır.

RCB, MD Anderson Kanseri Merkezi tarafından geliştirilen ve NAK sonrası memede ve aksiller lenf nodlarında kalan invaziv hastalık miktarını kantitatif olarak değerlendiren bir skorlama sistemidir (Symmans ve ark., 2007). Bu sistem, pCR dışındaki olgularda rezidual hastalık miktarını sürekli bir skor ve buna karşılık gelen dört kategorik sınıflar şeklinde ifade etmektedir.

Hesaplamada primer tümör boyutları (TB), canlı invaziv tümör hücreliliği (%CA), in situ komponent oranı (%CIS), pozitif lenf nodu sayısı (N) ve en büyük nodal metastatik odağın çapı (M) olmak üzere beş temel parametre kullanılmaktadır. Bu değişkenler primer tümör ve nodal bileşenleri içeren standart bir formülle birleştirilerek toplam RCB skoru elde edilmekte, ardından skor belirli eşiklere göre kategorilere dönüştürülmektedir (Symmans ve ark., 2007; Yau ve ark., 2022). Böylece RCB, NAK sonrası kalan hastalık miktarını hem sayısal hem de kategorik olarak tanımlar.

RCB sistemi hastaları dört prognostik gruba ayırmaktadır: RCB-0 (pCR), RCB-I (minimal rezidüel hastalık), RCB-II (orta düzey rezidüel hastalık) ve RCB-III (yaygın rezidüel hastalık). Çok sayıda çalışmada, RCB skorunun ve kategorilerinin hastalıksız sağkalım (DFS, Disease-Free Survival) ve Genel Sağkalım (OS, Overall Survival) ile güçlü biçimde ilişkili olduğu gösterilmiştir (Symmans ve ark., 2007; Cortazar ve ark., 2014; Yau ve ark., 2022). Genel olarak RCB-0 ve RCB-I hastaları genellikle yüksek DFS ve OS oranlarına sahipken, RCB-III hastalarında nüks ve metastaz riski belirgin olarak artmaktadır.

RCB, pCR'ye göre daha ayrıntılı bir risk sertifikasyonu sunduğu için, özellikle non-pCR hastalarda adjuvan tedavi stratejilerinin belirlenmesinde önemli bir rehber olarak kabul edilmektedir. Uluslararası çok merkezli çalışmalarda neoadjuvan tedavi yanıtını değerlendirmede standart bir araç olarak benimsenmiş ve farklı popülasyonlarda benzer prognostik güç sergilemiştir (Cortazar ve ark., 2014; Yau ve ark., 2022).

RCB hesaplaması için geliştirilen çevrimiçi hesaplayıcılar ve ayrıntılı patoloji kılavuzları, ölçümlerin merkezler arasında standardize edilmesine katkı sağlamıştır. Patolojik inceleme sürecinde yalnızca canlı invaziv kanser hücreleri ve aksiller makrometastazlar dikkate alınmakta; mikrometastazlar ve izole tümör hücreleri sınırlı prognostik etkileri nedeniyle hesaplama dahil edilmemektedir (Symmans ve ark., 2007). Bu standardizasyon, RCB skorlarının merkezler arası karşılaştırılabilirliğini artırmakta ve RCB'yi klinik araştırmalarda güvenilir bir sonlanım ölçütü haline getirmektedir.

Bu tez kapsamında, RCB sürekli skoru ve buna karşılık gelen kategorik sınıflandırma, geliştirilen öngörü modellerinin temel bağımlı değişkenini oluşturmaktadır.

2.5. RCB ve Tedavi Yanıtını Belirleyen Klinikopatolojik Faktörler

NAK sonrası ortaya çıkan patolojik yanıt derinliği ve nihai RCB düzeyi, tek bir biyolojik mekanizma ile açıklanamayacak kadar kompleks ve çok boyutlu bir fenomendir. Tedaviye yanıt veya direnç gelişimi; yalnızca tümör hücrelerinin intrinsik moleküler karakteristiklerine bağlı olmayıp, konakçı immünolojik kapasitesi, metabolik rezervi, anatomik tümör yayılım paterni, komorbidite profili ve demografik özelliklerin oluşturduğu dinamik bir etkileşim ağı içinde şekillenmektedir (Symmans ve ark., 2007; Spring ve ark., 2024). Bu nedenle, NAK sonrası yanıt değerlendirmesi, izole biyobelirteç analizinden öte, karşılıklı etkileşim içindeki çok parametreliliği parametreliliği ve bütüncül bir klinik yaklaşım gerektirmektedir.

Güncel prognostik modelleme literatürü ve geniş kohort temelli meta-analitik çalışmalar, NAK yanıtını ve RCB düzeyini belirleyen bağımsız değişkenlerin altı ana tematik kategoride kümelendiğini ortaya koymaktadır: (1) patolojik ve moleküler biyoloji parametreleri, (2) onkolojik evreleme ve uygulanan tedavi protokolü özellikleri, (3) demografik ve antropometrik hasta karakteristikleri, (4) sistemik komorbidite yükü ve eşlik eden klinik durumlar, (5) biyokimyasal ve metabolik laboratuvar profili, (6) radyolojik ve görüntüleme fenotipi (Cortazar ve ark., 2014; Yau ve ark., 2022). Bu sınıflandırma, geleneksel tümör-merkezli (tumor-centric) yaklaşımdan, hasta-merkezli (patient-centric) bütüncül bir karar destek mimarisine geçişi desteklemektedir.

Bu tez çalışmasında kullanılan 64 bağımsız değişken, söz konusu altı tematik grup altında sistematik olarak yapılandırılmıştır. Her bir değişken için literatürdeki kanıt düzeyi, altta yatan biyolojik mekanizma, etki büyüklüğü (effect size), çok değişkenli modellere katkısı ve klinik karar süreçlerine yansımaları kapsamlı biçimde değerlendirilmiştir. Bu değerlendirme temelinde, değişken seçimi, modelleme ağırlıklandırılması ve sonuçların klinik yorumlanması için referans çerçeve oluşturacak üç basamaklı bir Klinik Önem Hiyerarşisi geliştirilmiştir.

Klinik Önem Hiyerarşisinin birinci düzeyinde (**Kategori I – Yüksek Klinik Önem Taşıyan Çekirdek Belirteçler**, Ağırlık Puanı: 2) uluslararası konsensus kılavuzlarında (NCCN (National Comprehensive Cancer Network), ESMO (European

Society for Medical Oncology), St. Gallen) rutin olarak değerlendirilmesi gerekten, tedavi kararlarını doğrudan etkileyen ve pCR/RCB ile güçlü ilişki sergileyen temel prognostik ve prediktif faktörler yer almaktadır. Bu gruptaki değişkenler için bildirilen Odds Ratio (OR) değerleri tipik olarak yüksek etki aralığında bulunmaktadır (sıklıkla OR >3,0). HER2 statüsü, ER ve PR ekspresyonu, moleküler alt tip sınıflandırması (luminal A/B, HER2-pozitif, triple-negatif), Ki-67 proliferasyon indeksi ve histolojik grade bu kategorinin önde gelen örnekleridir (Burstein ve ark., 2021; Gradishar ve ark., 2023).

Klinik Önem Hiyerarşisinin ikinci düzeyinde (**Kategori II – Destekleyici ve Modülatör Belirteçler**, Ağırlık Puanı: 1) NAK yanıtı ve RCB düzeyi ile istatistiksel olarak anlamlı ilişki göstermekle birlikte, tek başına sınırlı belirleyiciliğe sahip olan, ancak çok değişkenli modellerde öngörü gücünü artıran destekleyici faktörler bulunmaktadır. Klinik tümör evresi (cT), klinik nodal durum (cN), histolojik tip, TIL yoğunluğu, lenfatik ve vasküler invazyon varlığı, bazı radyolojik özellikler (tümör boyutu, multifokalite, meme içi yayılım paterni) bu grupta değerlendirilmektedir (Salgado ve ark., 2015; International Immuno-Oncology Biomarker Working Group (2021).

Klinik Önem Hiyerarşisinin üçüncü düzeyinde ise (**Kategori III – Bağlamsal ve Yardımcı Değişkenle**, Ağırlık Puanı: 0) doğrudan prognostik sinyal gücü düşük veya literatürde tutarsız sonuçlar bildirilmiş olmakla birlikte hasta heterojenitesini yansıtan ve model kalibrasyonuna katkı sağlayan bağlamsal değişkenler yer almaktadır. Demografik özellikler (yaş, etnik köken, sosyoekonomik durum), antropometrik ölçümler (vücut kitle indeksi, vücut yüzey alanı), komorbiditelerin önemli bir kısmı (diabetes mellitus, hipertansiyon, tiroid hastalıkları), rutin laboratuvar parametreleri (hemoglobin, lökosit sayısı, trombosit sayısı, karaciğer ve böbrek fonksiyon testleri) ve bazı görüntüleme detayları bu grupta değerlendirilmiştir (NCCN (Al-Hakim, 2021) ; ESMO (Curigliano, 2023)).

Tez kapsamında kullanılan değişkenler ayrıca modelleme açısından izlenebilir ve klinik olarak anlamlı bir yapı oluşturmak amacıyla altı tematik model altında organize edilmiştir. Bu ontolojik yaklaşım, değişkenlerin yalnızca veri sütunu olarak değil, biyolojik-kimyasal-radyolojik anlam taşıyan çok katmanlı bir klinik ekosistemin

bileşenleri olarak ele alınmasına olanak vermektedir. Her grup, farklı bir klinik bilgi katmanını temsil etmekte; gruplar arası etkileşimler ise NAK yanıtı ve RCB dağılımının çok faktörlü doğasını açıklamaktadır:

Model P (Patolojik ve Moleküler Biyoloji), tümörün içsel biyolojisini en doğrudan yansıtan ER, PR, HER2, Ki-67, moleküler alt tip, histolojik grade, histolojik tip ve TIL gibi değişkenleri kapsamaktadır. Bu grup hem pCR olasılığının öngörülmesinde hem de biyolojik tedavi duyarlılığının yorumlanmasında temel öneme sahiptir.

Model O (Onkolojik Evreleme ve Tedavi Protokolü), hastalığın başlangıç yayılım düzeyi ile uygulanan tedavinin yapısal bileşenlerini bir araya getirmektedir. Klinik evre unsurları, tedavi rejim tipi, anti-HER2 kullanımı, kür sayısı, tedavi süresi ve doz modifikasyonu gibi değişkenler bu grupta yer alır almaktadır. Bu değişkenler, modelin terapötik bağlamı doğru biçimde kurabilmesi açısından önem taşımaktadır.

Model D (Demografik ve Antropometrik Özellikler), yaş, menopoz durumu, vücut kitle indeksi, vücut yüzey alanı ve aile öyküsü gibi hasta özelliklerini içermektedir. Bu parametreler doğrudan tümör biyolojisini belirlemekten çok tedavi toleransı, farmakokinetik farklılıklar ve risk katmanlaması üzerinde dolaylı etkiler oluşturmaktadır.

Model K (Sistemik Komorbidite Profili), hastanın eşlik eden hastalık yükünü kodlayan klinik değişkenleri içerir. Diyabet, hipertansiyon, kardiyovasküler hastalıklar, tiroid bozuklukları ve kronik organ hastalıkları gibi komorbiditeler, tedavi planının uygulanabilirliği ve toksisite riski açısından anlamlı bir arka plan sağlar. Bu grup, özellikle karar destek süreçlerinde tedavi yanıtı kadar tedavi güvenliğinin de dikkate alınması gereken durumlarda tamamlayıcı bir katman işlevi görür.

Model B (Biyokimyasal ve Metabolik Laboratuvar Profili), hastanın organ rezervi, inflamatuvar durumu ve metabolik dengesini yansıtan laboratuvar parametrelerinden oluşur. Laktat dehidrogenaz (LDH), alkalen fosfataz (ALP), alanin aminotransferaz (ALT), aspartat aminotransferaz (AST), kreatinin, glukoz ve C-reaktif protein (CRP) gibi göstergeler; sistemik fizyolojik durumu sayısal olarak modellemeye taşır. Bu değişkenler çoğu zaman tek başına güçlü ayrıştırıcı olmayabilse de, modelin klinik bağlamını güçlendiren ve risk değerlendirmesini destekleyen tamamlayıcı bilgi sağlar.

Model R (Radyolojik ve Görüntüleme Fenotipi), tümörün anatomik ve morfolojik görünümünü tanımlayan görüntüleme temelli değişkenleri içerir. Tümör boyutu,

multifokalite, multisentriklik, meme yoğunluğu (BI-RADS), yayılım paterni, vaskülarite, difüzyon kısıtlaması ve kontrastlanma özellikleri bu gruba örnektir. Radyolojik fenotip, tümör davranışının makroskopik yansımalarını sunduğu için, özellikle çok sınıflı RCB ayırımında modelin ayırt ediciliğine önemli katkı vermektedir.

Tezde kullanılan bu 64 bağımsız değişkenin tamamı, bu altı tematik grup altında ayrıntılı biçimde sınıflandırılmış; her değişken için tanım, ölçüm biçimi, veri tipi, klinik/radyolojik karşılığı, NAK ve RCB ile olası ilişkisi, literatür dayanağı ve atanan klinik önem kategorisi sistematik olarak açıklanmıştır. Ayrıntılı değişken listesi ve sınıflandırma yapısı; literatür örnekleriyle beraber **Ek Bölüm 1’de** sunulmuştur.

Sonuç olarak, bu tez kapsamında tanımlanan klinik önem hiyerarşisi ve tematik değişken sınıflandırması, geliştirilen öngörü modelleri için hem kavramsal hem de analitik bir çerçeve sunmaktadır. Değişkenlerin bu hiyerarşik düzen içinde ele alınması, modelleme sürecinin şeffaflığını artırmakta ve elde edilen sonuçların klinik olarak yorumlanabilirliğini güçlendirmektedir. Bu yaklaşım, NAK yanıtının daha doğru öngörülmesine katkı sağlarken, hasta bazlı kişiselleştirilmiş tedavi stratejilerinin geliştirilmesine de zemin hazırlamaktadır.

2.6. Onkolojide Veri Tabanlı Yaklaşımların Teorik Temelleri

Onkolojide veri tabanlı yaklaşımlar, klinik, patolojik, görüntüleme ve moleküler düzeyde üretilen çok boyutlu gözlemlerin birlikte değerlendirilmesiyle hastalık davranışı, prognoz ve tedavi yanıtı gibi sonuçların istatistiksel öğrenme çerçevesinde modellenmesine dayanmaktadır. Bu çerçevede temel soru, gözlemlenen değişkenlerden hedeflenen klinik sonuçlara ilişkin güvenilir ve genellenebilir eşleştirmeler kurarken aşırı uyum (overfitting), seçim yanlılığı ve dış geçerlilik risklerinin kontrol edilmesidir (Hastie ve ark., 2009). Böyle bir modelleme mantığı, meme kanseri dahil birçok tümör türünde risk sınıflaması, yanıt öngörüsü ve kişiselleştirilmiş tedavi stratejilerinin desteklenmesi amacıyla giderek yaygınlaşmıştır (Kourou ve ark., 2015). Ayrıca klinik karar süreçlerinde yapay zekâ ve makine öğrenmesi yöntemlerinin entegrasyonu, yüksek performanslı tıp vizyonu içinde veri odaklı çıkarımların güvenli ve etik biçimde kullanımını da gündeme getirmektedir (Topol, 2019).

Geleneksel olarak biyoinformatik kavramı, genomik ve moleküler verilerin analizi ile ilişkilendirilmiş olsa da günümüzde kapsamı önemli ölçüde genişlemiştir. Modern onkolojide biyoinformatik; sadece DNA dizilemeyi değil, klinik verilerin, patolojik bulguların ve tıbbi görüntülerin bütünleşik olarak işlenmesini kapsayan “Translasyonel Biyoinformatik” (TBI) disiplinine evrilmiştir (Tenenbaum ve ark., 2014). Bu çalışmanın metodolojik çerçevesini oluşturan bu yaklaşım, veriyi sadece depolayan değil, onu “yatak başı” (bedside) klinik kararları destekleyen bir öngörü aracına dönüştüren disiplinler arası bir köprü işlevi görmektedir.

Klinik pratikte tek bir hastaya ait veri seti; komorbiditelerden tümör belirteçlerine, hormon reseptör statüsünden metabolik görüntüleme parametrelerine kadar uzanan çok katmanlı bir yapı sergilemektedir. Farklı disiplinlerden (Patoloji, Tıbbi Onkoloji, Nükleer Tıp) gelen bu heterojen verilerin entegrasyonu, değişken sayısının yüksekliği ve değişkenler arasındaki karmaşık etkileşimler nedeniyle klasik istatistiksel yöntemlerin sınırlarını zorlamaktadır (Hastie ve ark., 2009; Huang ve ark., 2020). Translasyonel biyoinformatik, birbirinden kopuk veri setleri hâlinde duran bu parametreleri ortak bir matriste birleştirerek, klinik, patolojik, radyolojik ve metabolik bilgilerin birlikte analiz edilmesine olanak tanımaktadır. Bu entegrasyon, NAK yanıtı gibi çok faktörlü süreçlerin modellenmesinde, gürültülü verilerin temizlenmesi ve en değerli özniteliklerin (feature selection) seçilmesi süreçlerinin temelini oluşturmaktadır.

Tıbbi görüntüleme verilerinin sayısallaştırılması da modern onkolojik modellemenin önemli bileşenlerinden biridir. Özellikle Görüntüleme Biyoinformatiği (Imaging Informatics) ve Radyomik (Radiomics), uygulamaları, tıbbi görüntülemenin yalnızca görsel bir tanı aracı olmaktan çıkıp sayısal veri kaynağına dönüşmesini sağlamıştır (Jha ve ark., 2023). Bu doğrultuda 18F-FDG PET/BT verileri, sadece anatomik haritalar değil, tümör heterojenitesini yansıtan sayısal matrisler olarak kabul edilmektedir. SUVmax (Maksimum Standardized Uptake Value) gibi standart ölçümlerin ötesinde, MTV (Metabolik Tümör Hacmi) ve TLG (Toplam Lezyon Glikolizi) gibi volümetrik parametrelerin çıkarımı ve bunların klinik verilerle füzyonu, Görüntüleme Biyoinformatiğinin (Imaging Informatics) temel uygulama alanıdır (Gillies ve ark., 2016). Bu yaklaşım, tümörün biyolojik davranışını cerrahi müdahale olmadan (non-invaziv) öngörmeye olanak tanımaktadır.

2.6.1. Hassas Tıp ve Hesaplamalı Tahmin Modelleri

Hassas tıp (Precision Medicine), tedavi kararlarının “ortalama hasta” yerine “bireysel hasta” özelliklerine göre optimize edilmesini hedeflemektedir. Özellikle NAK sonrası RCB gibi karmaşık sonlanım noktalarının tahmini, doğrusal olmayan (non-linear) veri ilişkilerinin çözümlenmesini gerektirmektedir (Topol, 2019). Bu amaçla kullanılan Random Forest (RF), XGBoost (eXtreme Gradient Boosting) ve LightGBM (Light Gradient Boosting Machine) gibi topluluk (ensemble) öğrenme algoritmaları, değişkenler arasındaki gizli örüntüleri öğrenerek kişiye özgü risk skorları üretebilmektedir.

Bunun yanında klinik veri setlerinde sıkça görülen sınıf dengesizliği (imbalanced data) sorununa karşı, SMOTE (Synthetic Minority Over-sampling Technique) gibi sentetik veri üretim teknikleri kullanılarak nadir görülen ancak klinik önemi yüksek hasta gruplarının (örn. tedaviye yanıtız grup) model tarafından öğrenilmesi sağlayarak performansın dengelenmesine katkı sunmaktadır.

2.6.2. Açıklanabilir Yapay Zeka (XAI) ve Klinik Karar Destek Sistemleri

Yüksek performanslı modellerin klinik uygulamaya aktarılabilmesi yalnızca doğruluk ölçütleri ile sınırlı değildir. Model çıktılarının hekim tarafından anlaşılabilir, sorgulanabilir ve güvenilebilir olması gerekmektedir. Bu nedenle açıklanabilir yapay zekâ (Explainable Artificial Intelligence, XAI) yaklaşımları son yıllarda büyük önem kazanmıştır.

SHAP (SHapley Additive exPlanations) gibi yöntemler, oyun teorisine dayalı matematiksel yapısıyla her bir değişkenin (örneğin Ki-67 veya PET/BT parametreleri) model tahminine ölçüde ve hangi yönde katkı sağladığını göstererek karar sürecinin şeffaflaştırılması, yapay zeka çıktılarının hekim tarafından doğrulanmasına ve güven duyulmasına olanak tanımaktadır (Lundberg ve Lee, 2017). Böylece model yalnızca sonuç üreten bir “kara kutu” olmaktan çıkmakta; klinik akıl yürütmeyi destekleyen, biyolojik açıdan yorumlanabilir bir araç haline gelmektedir.

Biyoinformatik analizlerin nihai hedefi, akademik bir model üretmekten öte, bu modelleri doğrudan klinik karar süreçlerine entegre etmektir. Araştırma bulguları ile günlük klinik uygulama arasındaki translasyonel kopukluk, ancak teorik modellerin güvenilir ve kullanılabilir karar destek yazılımlarına dönüştürülmesiyle giderilebilmektedir (Obermeyer ve Emanuel, 2016) Geliştirilen algoritmaların web

tabanlı arayüzlere, masaüstü yazılımlara veya mobil uygulamalara entegre edilerek Klinik Karar Destek Sistemleri (KDSS) formatına dönüştürülmesi, Biyoinformatiğin, sadece sayısal analiz düzeyinde kalmayıp doğrudan hasta başı karar süreçlerine taşınmasını sağlayan en kritik adım, bu entegrasyondur. Bu sayede, karmaşık istatistiksel ve hesaplamalı analizler klinisyenin karar verme sürecinin ayrılmaz bir parçası hâline gelerek, gerçek zamanlı ve kanıta dayalı karar almayı somut olarak desteklemektedir.

2.7. Onkolojik Tahmin Modellemelerinde Temel Referans: Lojistik Regresyon

Lojistik regresyon, ikili veya kategorik klinik sonuçların olasılığını modellemek amacıyla kullanılan, tıbbi araştırmalarda en yaygın ve en yerleşik istatistiksel yöntemlerden biridir. Doğrusal regresyondan farklı olarak bağımlı değişkenin sürekli değil kategorik olduğu durumlar için geliştirilmiştir. Bu nedenle “var/yok”, “hasta/sağlıklı” veya “yanıtlı/yanıtsız” gibi klinik sonuçların analizinde geniş kullanım alanına sahiptir.. Özellikle onkolojide, hastalık tanısı koyma, tedavi yanıtı öngörme ve risk faktörlerini belirlemede yıllardır “altın standart” olarak kabul edilmektedir (Steyerberg, 2019).

2.7.1. İkili (Binary) ve Çoklu (Multiple) Lojistik Regresyon ve Klinik Karar Süreci

İkili Lojistik Regresyon (İLR), bağımlı değişkenin sadece iki kategoriden (0/1) oluştuğu durumlar için geliştirilmiştir. Bu tez çalışmasının önemli sonlanım noktalarından biri olan patolojik tam yanıt (pCR), doğası gereği ikili bir sonuçtur (pCR var / pCR yok). Bu nedenle pCR öngörüsünde ikili lojistik regresyon uygun ve sık kullanılan bir yöntemdir.

İLR’nin klinisyenler tarafından en çok tercih edilen model olmasının temel nedeni, model katsayılarının Odds Oranı (OR) olarak yorumlanabilmesidir. Odds oranı, belirli bir değişkenin varlığında ilgili klinik sonucun gerçekleşme olasılığının ne ölçüde arttığını veya azaldığını göstermektedir. Örneğin, bir modelde Ki-67 yüksekliği için $OR=2.3$ bulunması, bu faktörün varlığında pCR elde etme şansının 2.3 kat arttığını ifade etmektedir. Eğer %95 güven aralığı 1’in üzerindeyse (örn. 1.4–3.8), bu etki istatistiksel olarak anlamlı ve güçlü kabul edilmektedir (Harrell, 2015). Bu şeffaflık, hekimlerin tedavi kararını verirken sayısal verilere dayanmasını kolaylaştırmaktadır.

Meme kanseri prognozu ve tedavi yanıtı tek bir faktörle açıklanamayacak kadar çok boyutludur. Bu nedenle çok değişkenli lojistik regresyon modelleri, birden fazla bağımsız değişkenin eş zamanlı etkisini değerlendirmek amacıyla kullanılmaktadır. Yaş, tümör boyutu, histolojik grade, hormon reseptör durumu, HER2 ekspresyonu, Ki-67 indeksi ve görüntüleme parametreleri gibi çok sayıda değişken aynı model içerisinde analiz edilebilmektedir.

ÇLR'nin en kritik özelliği, her bir değişkenin etkisini diğer tüm değişkenler sabit tutulduğunda (adjusted effect) göstermesidir. Örneğin; tümör boyutunun etkisi, hastanın yaşı ve moleküler alt tipi kontrol edildiğinde de devam ediyor mu? Bu sorunun yanıtı, gerçek yaşamdaki karmaşık biyolojik ilişkileri modellemek için ÇLR'yi vazgeçilmez kılmaktadır (Hosmer ve ark., 2013).

2.7.2. Model Performansının Değerlendirilmesi

Bir lojistik regresyon modelinin klinik kullanıma uygunluğunu değerlendirmek için yalnızca katsayıların anlamlılığı yeterli değildir. Modelin ayırt edicilik, kalibrasyon ve genel uyum düzeyinin birlikte incelenmesi gerekmektedir. Bu tezde geliştirilen modellerin başarısı, literatürde kabul gören şu kriterlere göre değerlendirilmiştir:

- **Model Anlamlılığı (Likelihood Ratio Test):** Modelin, hiç değişken içermeyen (sadece sabit terim) boş modele göre anlamlı bir katkı sağlayıp sağlamadığını test etmektedir ($p < 0.05$ anlamlıdır).
- **Açıklayıcılık Katsayıları (Pseudo R^2):** Doğrusal regresyondaki R^2 gibi kesin bir “açıklanan varyans” vermese de modelin gücü hakkında fikir vermektedir. Nagelkerke R^2 , 0-1 aralığında normalize edilmiş bir değer sunar; klinik çalışmalarda 0.20-0.40 arası değerler genellikle “kabul edilebilir” düzey olarak görülmektedir (Hosmer ve ark., 2013).
- **Uyum İyiliği (Hosmer-Lemeshow Testi):** Modelin tahmin ettiği olasılıklarla gerçek gözlenen sonuçlar arasındaki uyumu denetlemektedir. Bu testte $p > 0.05$ olması (farkın anlamsız olması), modelin veriye iyi uyum sağladığını (good calibration) göstermektedir.
- **Ayırt Edicilik (AUC- Area Under the Curve):** Günümüzde en yaygın kullanılan performans ölçütüdür. Modelin hasta olanla olmayanı ne kadar iyi ayırabildiğini göstermektedir. Literatürde 0.7-0.8 arası “iyi”, 0.8 üzeri ise “çok iyi” performans olarak sınıflandırılır (Steyerberg, 2019).

2.7.3. Değişken Seçimi ve Aşırı Uyum (Overfitting) Riski

Çoklu lojistik regresyonda, potansiyel tüm modele aynı anda dahil edilmesi, özellikle sınırlı örneklem büyüklüğüne sahip veri setlerinde aşırı uyum (overfitting) riskini artırmaktadır. Aşırı uyum durumunda model eğitim verisinde yüksek performans gösterirken yeni veya dış veri setlerinde başarısız olabilmektedir.

Bu riski yönetmek için literatürde Geriye Doğru Eleme (Backward Elimination), İleriye Doğru Seçim (Forward Selection) ve LASSO (Least Absolute Shrinkage and Selection Operator) gibi cezalandırılmış regresyon yöntemleri kullanılmaktadır. Bu yöntemler, istatistiksel katkısı düşük olan değişkenleri modelden çıkararak daha sade (parsimonious) ve güçlü modeller elde edilmesini sağlamaktadır (Harrell, 2015).

Bu tez kapsamında da değişken seçimi yalnızca algoritmik yöntemlerle değil, klinik önem hiyerarşisi ve literatür temelli değerlendirmeler ile birlikte ele alınmıştır.

2.7.4. Yöntemin Sınırları ve Makine Öğrenmesi ile İlişkisi

Lojistik regresyon güçlü ve yorumlanabilir bir olmakla birlikte bazı sınırlılıklara sahiptir. Temel varsayımı, değişkenler ile sonuç arasında doğrusal (linear) veya log-doğrusal bir ilişki bulunmasıdır. Ancak kanser biyolojisi, genetik faktörler, tümör mikroçevresi ve metabolik parametrelerin (PET/BT) iç içe geçtiği karmaşık ve doğrusal olmayan (non-linear) etkileşimler içerir (Takefuji, 2025). Bu nedenle güncel literatürde lojistik regresyon, genellikle yeni geliştirilen yapay zekâ ve makine öğrenmesi modellerinin performansının kıyaslandığı bir “Temel Referans” (Baseline Model) olarak konumlandırılmaktadır (Christodoulou ve ark., 2019). İdeal bir prognostik modelleme süreci; lojistik regresyonun sağladığı istatistiksel açıklanabilirlik ile makine öğrenmesi algoritmalarının (Random Forest, XGBoost vb.) sağladığı yüksek tahmin gücünün birbirini tamamlayacak şekilde kullanılması önerilmektedir (Steyerberg, 2019).

2.8. Büyük Veri ve Klinik Veri Yönetimi

Geleneksel veri işleme yöntemlerinin kapasitesini aşan, hacim, hız ve çeşitlilik açısından devasa boyutlara ulaşan veri setleri “Büyük Veri” olarak tanımlanır (Chen ve ark., 2014). Sağlık hizmetlerinde dijital kayıt altyapılarının yaygınlaşmasıyla birlikte, klinik verinin hacmi, erişilebilirliği belirgin biçimde artmıştır. Elektronik sağlık kayıtları, laboratuvar bilgi sistemleri, patoloji raporları ve tıbbi görüntüleme

arşivleri gibi çok sayıda kaynaktan elde edilen veriler, çağdaş klinik araştırmaların temel bileşenleri haline gelmiştir. Bu dönüşüm, yalnızca veri miktarındaki artışı değil, aynı zamanda klinik karar destek sistemleri ve öngörü modelleri açısından yeni analiz olanaklarını da beraberinde getirmiştir (Raghupathi W., 2014)

Karar alma süreçlerini kökten dönüştüren stratejik bir kaynak olarak kabul edilen büyük veri (Manyika ve ark., 2011), modern onkoloji araştırmalarında klinik, patolojik ve radyomik parametrelerin bütünleşik yönetimini zorunlu kılan temel paradigmayı oluşturmaktadır.

Sağlık verilerinin çok boyutlu yapısı literatürde sıklıkla “5V modeli” ile açıklanmaktadır. Bu model; veri hacmi (volume), üretim hızı (velocity), çeşitliliği (variety), doğruluğu (veracity) ve klinik değeri (value) boyutlarını tanımlamaktadır. Özellikle onkoloji alanında çok kaynaklı veri yapılarının yönetiminde, hacimden çok çeşitlilik, doğruluk ve klinik değer boyutları öne çıkmaktadır.

Büyük verinin etkin yönetimi, geleneksel ilişkisel veritabanlarının ötesinde, Apache Hadoop ve Spark gibi dağıtık mimarileri gerektirmektedir (White, 2012). Özellikle NoSQL veritabanları (MongoDB, Cassandra), heterojen klinik verilerin esnek ve ölçeklenebilir bir şekilde depolanmasında önemli avantajlar sunmaktadır (Cattell, 2011). Sağlık alanında bu teknolojilerin entegrasyonu, hastalıkların erken teşhisi, tedavi süreçlerinin kişiselleştirilmesi ve sağlık kaynaklarının optimizasyonunda devrim niteliğinde gelişmeler sağlamaktadır (Wang ve ark., 2019). Özellikle radyomik analizlerde görüntü verilerinin sayısal matrislere dönüştürülmesi ve klinik verilerle füzyonu, hassas tıp (precision medicine) uygulamalarının ve prognostik modellemenin teknolojik altyapısını oluşturmaktadır (Litjens ve ark., 2017).

Veri madenciliği, büyük veri kümelerinden önceden bilinmeyen, geçerli ve potansiyel olarak yararlı bilgilerin otomatik olarak çıkarılmasını sağlayan disiplinler arası bir süreçtir (Mishra & Kumar, 2022; Kotsiantos, 2025). Bu süreç, endüstri standardı olan CRISP-DM (Cross-Industry Standard Process for Data Mining) modeli çerçevesinde yürütülmektedir. Altı temel aşamadan (iş anlayışı, veri anlama, veri hazırlama, modelleme, değerlendirme ve dağıtım) oluşan CRISP-DM, bu çalışmadaki klinik problemin tanımlanmasından modelin dağıtımına kadar olan akışı sistematize etmektedir (Shearer, 2000).

Temel Veri Madenciliği Teknikleri

- **Sınıflandırma (Classification):** Verilerin önceden tanımlanmış kategorilere (örn. pCR Var/Yok) atanması işlemidir (Witten ve ark., 2011).
- **Kümeleme (Clustering):** Benzer özelliklere sahip hasta gruplarının keşfedilmesidir (Jain, 2010).
- **Birliktelik Kuralları (Association Rules):** Veri setindeki öğeler arasındaki gizli ilişkilerin (örn. ilaç-yan etki) ortaya çıkarılmasıdır (Teng ve ark., 2020).
- **Aykırı Değer Tespiti (Outlier Detection):** Veri kalitesini bozan anormal değerlerin belirlenmesi, özellikle tıbbi veri setlerinde güvenilirlik açısından kritiktir (Jyothi ve ark., 2020).

2.9. Makine Öğrenmesi ve Onkolojide Çok Değişkenli Veriden Anlam Çıkarma

Meme kanseri gibi biyolojik ve klinik açıdan heterojen hastalıkların seyrini ve tedaviye yanıtını öngörmek, tekil biyobelirteçlerin veya klinik parametrelerin ötesinde, çok sayıda faktörün karmaşık ilişkilerin birlikte değerlendirilmesini gerektirmektedir. Hastanın demografik özelliklerinden tümörün moleküler alt tipine, histopatolojik bulgularından PET/BT ile ölçülen metabolik aktivitesine kadar uzanan bu çok katmanlı veri yapısı, klasik istatistiksel yaklaşımların doğrusal varsayımlarını ve değişken sayısı limitlerini zorlayabilmektedir. Makine öğrenmesi (ML), bu noktada, yüksek boyutlu ve heterojen veri setlerindeki doğrusal olmayan (non-linear) örüntüleri ve gizli ilişkileri veriden öğrenerek, tahmine dayalı modeller inşa etmeyi amaçlayan bir hesaplamalı bilimler disiplini olarak öne çıkmaktadır (Bishop, 2006; Hastie ve ark., 2009).

Klinik araştırmalarda makine öğrenmesi, özellikle tablo formatındaki yapılandırılmış verilerin işlenmesinde ve karmaşık biyolojik süreçlerin modellenmesinde merkezi bir rol üstlenmektedir. Model güvenilirliğinin değerlendirilmesi ve algoritmik kararların şeffaflığı (yorumlanabilirlik), bu teknolojilerin klinik pratiğe entegrasyonunda belirleyici faktörlerdir. Bu çerçevede, NAK sonrası gelişen yanıtın ve RCB'nin hassas bir şekilde tahmin edilmesi gibi çok boyutlu ve doğrusal olmayan problemlerde, makine öğrenmesi yöntemleri geleneksel istatistiksel yaklaşımları tamamlayan güçlü bir teorik zemin ve yüksek öngörü potansiyeli sunmaktadır.

2.9.1. Denetimli Öğrenme ve Klinik Sınıflandırma Problemleri

Klinik tahmin modellemesi çalışmalarının büyük çoğunluğu, denetimli öğrenme (supervised learning) paradigması çerçevesinde yürütülmektedir. Bu yaklaşımda, algoritmaların eğitim süreci, sonucu önceden bilinen “etiketli” veriler (ground truth) üzerinden gerçekleşmektedir. Onkolojik araştırmalarda bu etiketler, genellikle pCR durumu veya RCB sınıfları (0, I, II, III) gibi kategorik risk düzeylerini temsil etmektedir. Temel amaç, girdi değişkenleri (klinik, patolojik veya radyomik özellikler) ile bu sonuç etiketleri arasındaki matematiksel ilişkiyi modelleyerek, sonucu bilinmeyen yeni hastalar için yüksek doğruluklu tahminler üretebilmektir (James ve ark., 2013).


Hedef değişkenin kategorik olduğu bu süreç literatürde “sınıflandırma” (classification) problemi olarak tanımlanmaktadır. Klinik veri setleri ise genellikle sürekli, kategorik ve ordinal değişkenlerin birlikte bulunduğu karmaşık yapılardır. Örneğin Ki-67 gibi sürekli değişkenler, moleküler alt tip gibi kategorik değişkenler ve RCB sınıfları gibi sıralı klinik sonuçlar aynı veri seti içinde birlikte yer alabilmektedir. Ayrıca eksik veri, ölçüm gürültüsü ve değişkenler arası karmaşık etkileşimler de sık karşılaşılan durumlardır. Klinik pratikte kayıt eksiklikleri, ölçüm hataları veya farklı merkezlerden kaynaklanan değişkenlikler görülebilmekte; bir değişkenin prognostik etkisi başka bir değişkenin düzeyine göre değişebilmektedir. Örneğin TILs düzeyinin klinik etkisi moleküler alt tipe bağlı olarak farklılaşabilmektedir.

Bu nedenlerle, model seçimi, veri ön işleme ve performans değerlendirme stratejilerinin, problemin klinik bağlamına uygun şekilde dikkatle tasarlanması gerekmektedir (Hastie ve ark., 2009; Steyerberg, 2019).

2.9.2. Tablo Verilerinde Yaygın Yaklaşımlar: Ağaç Tabanlı Modeller

Yapılandırılmış klinik veri setlerinde en sık tercih edilen yöntemler arasında ağaç tabanlı topluluk (ensemble) modelleri yer almaktadır. Karar ağaçları, veriyi en bilgilendirici değişkenlere göre ardışık olarak dallara ayırarak hiyerarşik bir karar yapısı oluşturmaktadır. Bu “eğer-o zaman” (if-then) kural tabanlı yapıları, klinisyenler için sezgisel olarak anlaşılır olabilmektedir. Ancak, tek bir karar ağacı veri setindeki küçük değişimlere karşı hassas olabildiği ve aşırı uyum riski taşıdığı için, pratikte genellikle çok sayıda ağacı birleştiren topluluk (ensemble) yöntemleri kullanılmaktadır (Hastie ve ark., 2009).

Random Forest, orijinal veri setinden rastgele örneklemeler (bootstrap) oluşturarak her bir örneklem üzerinde bağımsız bir karar ağacı eğitmektedir. Nihai tahmin, bu ağaçların tahminlerinin ortalaması (regresyon) veya sınıflandırma ile belirlenmektedir. Bu yaklaşım, tek bir ağacın varyansını düşürerek daha kararlı ve genellenebilir bir model oluşturabilmektedir (Şekil 1). Rastgele Orman (Random Forest), bagging yöntemini her bir düğümde en iyi dallanmayı ararken değişkenlerin rastgele bir alt kümesini kullanarak daha da ileri taşımaktadır. Bu ek rastgelelik, ağaçlar arasındaki korelasyonu azaltır ve modelin genelleme performansını genellikle daha da artırmaktadır (Breiman, 2001).



Şekil 1. Random Forest Karar Süreci Klinik Örnek Diyagramı

Boosting yöntemleri ise ağaçları bağımsız olarak değil, ardışık bir şekilde inşa etmektedir. Her yeni ağaç, bir önceki ağacın hatalı sınıflandırdığı gözlemlere odaklanarak, modelin zayıf yönlerini düzeltmeyi hedeflemektedir (Şekil 2). Bu sayede, giderek daha güçlü bir topluluk modeli oluşturulmaktadır. XGBoost ve LightGBM gibi modern gradyan artırma algoritmaları, bu yaklaşımın yüksek hesaplama verimliliği ve düzenleştirme (regularization) teknikleri ile optimize edilmiş uygulamalarıdır (Chen ve Guestrin, 2016). Boosting algoritmaları, genellikle tablo verilerinde en yüksek tahmin gücünü sunmakla birlikte, model karmaşıklığı arttıkça aşırı uyum (overfitting) riski de artmaktadır. Bu nedenle, model

performansının titiz değerlendirme yöntemleriyle doğrulanması kritik önem taşımaktadır.




Şekil 2. Boosting Algoritmalarının İşleyişi

2.9.3. Sınıf Dengesizliği ve Klinik Önemi

Tıbbi veri setlerinde, sonuç kategorileri çoğu zaman dengeli dağılmamaktadır. Örneğin pCR elde eden hasta sayısı, pCR elde edemeyen gruba göre daha az olabilir; benzer şekilde RCB-III gibi yüksek riskli gruplar veri setinde sınırlı sayıda temsil edilebilir. Bu durum sınıf dengesizliği (class imbalance) olarak adlandırılır ve standart makine öğrenmesi algoritmalarının, çoğunluk sınıfını doğru tahmin etmeye odaklanarak azınlık sınıfını göz ardı etmesine yol açabilmektedir (He ve Garcia, 2009). Standart algoritmalar çoğunluk sınıfını doğru tahmin etmeye odaklanarak azınlık sınıfında yetersiz performans gösterebilir. Klinik açıdan bu durum önemlidir; çünkü nadir görülen gruplar çoğu zaman en kritik klinik kararları gerektiren hasta alt kümelerini temsil etmektedir. Örneğin pCR elde eden hasta grubunun sınırlı sayıda olduğu veya yüksek riskli RCB kategorilerinin daha az temsil edildiği veri setlerinde, model çoğunluk grubuna yönelerek klinik açıdan değerli ayrımları kaçırabilmektedir. Bu sorunun yönetilmesinde çeşitli stratejiler kullanılmaktadır. Örnekleme yöntemleri arasında, azınlık sınıfını sentetik örneklerle çoğaltan SMOTE (Synthetic Minority Over-sampling Technique) gibi yaklaşımlar veya çoğunluk sınıfındaki örnek sayısını azaltan yeniden örnekleme teknikleri yer almaktadır (Chawla ve ark., 2002). Bir diğer yaklaşım maliyet duyarlı öğrenmedir; bu yöntemde azınlık sınıfını yanlış sınıflandırmanın maliyeti daha yüksek tanımlanarak algoritmanın bu sınıfa daha fazla odaklanması sağlanmaktadır. Performans değerlendirme aşamasında da sadece genel doğruluğa (accuracy) bakmak yerine, her sınıfın performansını ayrı ayrı gösteren metrikleri (örn. duyarlılık, kesinlik, F1-skoru) kullanması önerilmektedir.

2.9.4. Model Değerlendirmesi: Güvenilir ve Genellenebilir Modeller


Bir makine öğrenmesi modelinin klinik değere sahip olabilmesi için, sadece eğitim gördüğü veride değil, daha önce görmediği yeni hasta verilerinde de başarılı bir şekilde çalışması, yani genelleme (generalization) yeteneğinin yüksek olması gerekmektedir. Model değerlendirme yöntemleri Şekil 3’te şematize edilmiştir.



Şekil 3. Makine Öğrenmesi Performans Ölçütleri ve Model Değerlendirme Yöntemleri Sınıflandırması

Klinik uygulamada kullanılabilecek modellerin temel özelliği, geliştirildikleri veri setine özgü kalmaksızın farklı hasta gruplarında da güvenilir sonuçlar üretebilmeleridir. Bu nedenle model değerlendirme süreci, bu genelleme performansını objektif olarak ölçmeyi, aşırı uyum gibi riskleri tespit etmeyi ve farklı modelleri adil bir şekilde karşılaştırmayı amaçlamaktadır (Steyerberg, 2019).

Çapraz doğrulama, modelin genelleme performansını tahmin etmek için kullanılan standart bir yöntemdir. Veri setini tek bir eğitim ve test kümesine ayırmak yerine, veriyi birden çok alt kümeye (katman veya “fold”) bölerek modeli tekrar tekrar eğitmekte ve test etmektedir (Şekil 4). Bu durum, model performansının şans eseri seçilen tek bir test setine bağlı kalmasını önlemekte ve daha kararlı bir performans tahmini sunmaktadır (Bradshaw ve ark., 2023).




Şekil 4. K-Katlı ve Katmanlı Çapraz Doğrulama Karşılaştırması

K-katlı çapraz doğrulamada (k-fold cross-validation), veri seti k adet eşit büyüklükte katmana ayrılmaktadır. Her iterasyonda, katmanlardan biri test seti olarak kullanılırken, geri kalan k-1 katman eğitim için kullanılmaktadır. Bu süreç k kez tekrarlanmakta ve her katmanın test seti olarak kullanılması sağlanmaktadır. Sonunda elde edilen k adet performans skorunun ortalaması, modelin nihai performans ölçütü olarak raporlanmaktadır.


Sınıf dengesizliğinin bulunduğu klinik veri setlerinde, K. atmanlı Çapraz Doğrulama (Stratified Cross-Validation) özellikle önem taşımaktadır. Bu yöntemde her bir katmanın orijinal veri setindeki sınıf oranlarını koruması kritik öneme sahiptir. Katmanlı çapraz doğrulama, her katmanı oluştururken sınıf dağılımını gözetmektedir. Bu sayede, azınlık sınıflarının bazı katmanlarda hiç yer almaması gibi riskler ortadan kalkmakta ve modelin her sınıftaki performansı daha güvenilir bir şekilde değerlendirilmektedir (Seabold ve Perktold, 2010). Şekil 4, bu iki yaklaşım arasındaki

temel farkı, yani katmanlı yöntemin her bir alt kümede sınıf dengesini nasıl koruduğunu kavramsal olarak göstermektedir.

Modelin davranışını anlamak için nihai performans skorlarının ötesine geçmek gerekmektedir. Bu sürecin izlenmesinde öğrenme eğrileri (learning curves) ve doğrulama eğrileri (validation curves) yararlı araçlardır. Öğrenme eğrileri, eğitim veri miktarı arttıkça model performansının nasıl değiştiğini göstererek ek veri toplamanın potansiyel katkısını değerlendirmeye yardımcı olmaktadır. Doğrulama eğrileri ise model karmaşıklığı veya hiperparametre değiştikçe performansın nasıl etkilendiğini ortaya koymaktadır. Böylece optimum model karmaşıklığının seçilmesi mümkün olmaktadır (Bradshaw ve ark., 2023). Bu eğriler, “daha fazla veri toplamak modelin performansını artırır mı?” gibi soruları yanıtlamaya yardımcı olabilmektedir.



Grafik 1. Öğrenme ve Validasyon Eğrileri



Grafik 2. Overfitting ve Underfitting Değerlendirmesi

Model geliştirme sürecinde dikkat edilmesi gereken temel sorunlardan biri aşırı uyumdur (overfitting). Aşırı uyum durumunda model, eğitim verisindeki gerçek örüntülerin yanı sıra rastlantısal gürültüyü de öğrenmekte; bu nedenle eğitim verisinde çok yüksek performans gösterirken yeni verilerde başarısı düşmektedir. Bunun karşıt durumu eksik uyumdur (underfitting); bu durumda model, veri setindeki temel ilişkileri dahi öğrenemeyecek kadar basit kalmaktadır. Klinik tahmin modellemesinde amaç, bu iki uç durumdan kaçınarak eğitim ve doğrulama performansı arasında dengeli, genellenebilir modeller geliştirmektir.

Grafik 1 ve Grafik 2, bu kavramları görselleştirerek, model geliştirme sürecinin amacının sadece skoru maksimize etmek değil, eğitim ve doğrulama performansı arasında ideal bir denge kuran “optimal bölgeyi” bulmak olduğunu vurgulamaktadır.

2.9.5. Açıklanabilir Yapay Zekâ ve Klinik Güven

Özellikle sağlık gibi yüksek riskli alanlarda, bir modelin sadece doğru tahmin yapması yeterli değildir; neden o tahmini yaptığı da anlaşılmalıdır. Yüksek performanslı birçok modern makine öğrenmesi modeli (örn. XGBoost), içsel olarak karmaşık oldukları için “kara kutu” (black-box) olarak nitelendirilmektedir. Yorumlanabilirlik (interpretability) yöntemleri, bu kara kutuyu aralayarak modelin karar verme mantığını şeffaflaştırmayı amaçlamaktadır (Steyerberg, 2019).

SHAP (SHapley Additive exPlanations) gibi modern yaklaşımlar, oyun teorisinden esinlenerek her bir girdi değişkeninin, tek bir hastanın tahminine ne yönde ve ne büyüklükte katkı yaptığını hesaplamaktadır (Lundberg ve Lee, 2017). Böylece örneğin bir hastada yüksek RCB riski tahmini; yüksek Ki-67 değeri, geniş metabolik tümör hacmi veya negatif hormon reseptör durumu gibi klinik olarak anlamlı değişkenlerle ilişkilendirilebilmektedir. Bu şeffaflık, model çıktılarının klinisyen tarafından değerlendirilmesini ve güvenle kullanılmasını kolaylaştırmaktadır.

2.10. Klinik Veri Kaynağı ve Uygulama

Onkolojide veriye dayalı çıkarımların güvenilirliği, kullanılan algoritmalara değil, aynı zamanda modele aktarılan klinik verinin niteliğine ve biyolojik anlamlılığına da bağlıdır (Bradshaw, 2023). Meme kanserinde neoadjuvan kemoterapi yanıtının öngörülmesi gibi kompleks klinik problemlerde; demografik veriler, histopatolojik bulgular, laboratuvar sonuçları ve görüntüleme kaynaklı parametrelerin birlikte

değerlendirilmesi gerekmektedir. (Rajkomar et al., 2019). Bununla birlikte bu tür klinik veri kaynaklarından türetilen öngörülerin yalnızca analitik modelin girdi-çıkıti düzeyinde sunulması yeterli sayılmamakta; klinik karar destek süreçlerine aktarılabilirliği için veri kalitesi ve standardizasyon, model doğrulanması ile klinik iş akışına uyum gibi uygulama gereksinimlerinin bütüncül biçimde ele alınması gerekir (Rajkomar et al., 2019).

Pozitron Emisyon Tomografisi/Bilgisayarlı Tomografi (PET/BT), özellikle 18F-FDG kullanımı ile tümör glukoz metabolizmasını nicel olarak değerlendirebilmekte ve tedavi yanıtına ilişkin erken biyolojik değişimleri gösterebilmektedir. Bu nedenle PET/BT'den elde edilen metabolik ve hacimsel parametreler, meme kanserinde tedavi yanıtı öngörüsü, prognoz değerlendirmesi ve rezidüel hastalık riskinin belirlenmesinde giderek artan biçimde kullanılmaktadır (Araz ve ark., 2022). Ayrıca görüntülerden türetilen radyomik özellikler, tümör heterojenitesine ilişkin ek nicel bilgi sağlayarak veri tabanlı klinik modellerin geliştirilmesine katkı sunmaktadır.

2.10.1. PET/BT'nin Meme Kanserindeki Klinik Rolü

Meme kanseri yönetiminde mamografi, ultrasonografi ve manyetik rezonans görüntüleme gibi anatomik yöntemler tümörün lokalizasyonu ve morfolojik özellikleri hakkında bilgi sağlamaktadır. Buna karşın fonksiyonel görüntüleme yöntemleri, tümörün biyolojik aktivitesi ve metabolik davranışı hakkında ek bilgi sunmaktadır. Bu alandaki en yaygın ve klinik olarak yerleşik yöntemlerden biri olan 18F-Florodeoksiglukoz Pozitron Emisyon Tomografisi/Bilgisayarlı Tomografi (18F-FDG PET/BT), tümör dokusundaki glukoz metabolizmasını görüntüleyerek hastalığın yaygınlığı ve biyolojik agresifliği hakkında önemli veriler sağlamaktadır (Groheux ve ark., 2011).

Nükleer tıp, radyoaktif izotoplarla işaretlenmiş moleküllerin (radyofarmasötikler) belirli fizyolojik süreçlere katılması ve bu süreçlerin dışarıdan dedektörlerle tespit edilmesi prensibine dayanmaktadır (Saha, 2010). PET görüntülemenin temel biyolojik dayanağı, birçok malign hücrede gözlenen artmış glukoz tüketimidir. Warburg etkisi olarak tanımlanan bu metabolik yeniden programlanma sonucunda tümör hücreleri, oksijen varlığında dahi glikolize yönelim gösterebilmektedir. Glukoz analogu olan 18F-FDG, artmış glukoz taşıyıcıları aracılığıyla hücre içine alınmakta ve fosforilendikten sonra metabolik olarak tutulmaktadır. Bu birikim PET dedektörleri

tarafından saptanarak metabolik aktivitenin görüntülenmesine olanak sağlamaktadır (Gambhir, 2002).

Neoadjuvan kemoterapi sürecinde PET/BT'nin önemi daha da artmaktadır. Anatomi küçülme çoğu zaman tedavinin ilerleyen dönemlerinde belirginleşirken, metabolik yanıt daha erken dönemde ortaya çıkabilmektedir. Bu nedenle PET/BT ile izlenen metabolik değişimler, tedavi etkinliğinin erken biyobelirteci olarak değerlendirilmektedir. Tedavi sırasında FDG tutulumu belirgin azalan hastalarda daha iyi patolojik yanıt oranları bildirilmiş; persistan yüksek metabolik aktivitenin ise rezidüel hastalık ve tedavi direnci ile ilişkili olabileceği gösterilmiştir.

PET/BT'nin önemli avantajlarından biri, tek seansta tüm vücudun değerlendirilebilmesi ve metabolik yanıtın anatomik küçülmeden daha erken saptanabilmesidir. Bu özellik, etkisiz tedavilerin erken dönemde yeniden gözden geçirilmesine olanak sağlayabilmektedir. Bununla birlikte yöntemin bazı sınırlılıkları da bulunmaktadır. Uzaysal çözünürlüğün sınırlı olması nedeniyle küçük veya mikroskopik lezyonların saptanmasında duyarlılık azalabilmektedir. Ayrıca inflamasyon, enfeksiyon veya biyopsi sonrası iyileşme dokusu artmış FDG tutulumu nedeniyle yalancı pozitif sonuçlara yol açabilirken, düşük metabolik aktivite gösteren bazı tümör alt tiplerinde yalancı negatiflik görülebilmektedir (Akpınar ve ark., 2012). Bu nedenle PET/BT bulgularının klinik ve patolojik verilerle birlikte yorumlanması önerilmektedir.

2.10.2. Kantitatif Metabolik Parametreler: SUV, MTV ve TLG

PET/BT görüntülerinin yorumlanmasında, lezyondaki metabolik aktiviteyi sayısal olarak ifade eden yarı-kantitatif ölçümler kullanılmaktadır. Bu parametreler, NAK yanıtının erken dönemde izlenmesinde ve RCB riskinin değerlendirilmesinde araştırma odağı haline gelmiştir. En yaygın kullanılan parametrelerden biri Standardized Uptake Value (SUV)'dur. SUV, lezyondaki radyofarmasötik tutulumunun enjekte edilen doz ve hastaya ait biyometrik değişkenlere göre normalize edilmiş ölçüsünü ifade etmektedir. Klinik uygulamada en sık kullanılan alt parametre SUV_{max} olup, lezyon içindeki en yüksek tek voksel değeridir. Pratik ve tekrarlanabilirliği yüksek bir ölçüm olsa da gürültüye duyarlıdır (Boellaard, 2009). SUV_{mean} ise tanımlanan hacim içindeki ortalama tutulumu yansıtmaktadır. Bununla birlikte yalnızca metabolik yoğunluğun değerlendirilmesi, tümör yükünü tam olarak

yansıtmayabilmektedir. Bu nedenle volümetrik parametreler giderek daha fazla önem kazanmıştır. Metabolik Tümör Hacmi (MTV), belirli bir eşik değerin üzerinde metabolik aktivite gösteren tümör dokusunun hacmini ifade etmektedir.

Toplam Lezyon Glikolizi (TLG) ise $MTV \times SUV_{mean}$ olup, toplam glikolitik tümör yükünü temsil etmektedir (Larson ve ark., 1999).

Literatür, MTV ve TLG gibi volümetrik parametrelerin, NAK sonrası pCR ve RCB tahmininde tek nokta ölçümlerinden (SUV_{max}) daha güçlü birer belirteç olabileceğini göstermektedir.

2.10.3. Radyomik Analiz ve LIFEx Yazılımı

Geleneksel PET/BT parametrelerinin (SUV , MTV) ötesine geçen Radyomik (Radiomics), tıbbi görüntülerden insan gözünün algılayamayacağı nicel özelliklerin otomatik olarak çıkarılmasını sağlamaktadır. Bu yaklaşım, tümörün iç yapısını, heterojenliğini ve doku karakteristiğini matematiksel olarak modellemektedir (Gillies ve ark., 2016).

Radyomik yaklaşım, tıbbi görüntülerden sayısal özellikler çıkarılarak görünür bulguların ötesinde, dokusal ve heterojeniteye ilişkin nicel bilgilerin istatistiksel modellemeye taşınmasını amaçlar. Bu bağlamda LIFEx (Local Image Features Extraction) yazılımı, nükleer tıp ve radyoloji görüntülerinde ROI (Region of Interest) tanımlaması üzerinden birinci ve yüksek dereceli görüntü özelliklerinin sistematik biçimde hesaplanmasına olanak sağlayan araçlardan biridir.

LIFEx, tıbbi görüntülerden kantitatif radiomik özelliklerin çıkarılması amacıyla geliştirilmiş açık kaynaklı bir yazılım platformudur. Bu yazılım, çok modaliteli görüntüleme verilerinden (PET/BT, CT, MR) otomatik özellik çıkarma işlemlerini standardize etmek ve kolaylaştırmak için tasarlanmıştır (Nioche ve ark., 2018). Yazılımın temel avantajı, DICOM (Digital Imaging and Communications in Medicine) formatındaki görüntü dosyalarını doğrudan işleyebilme kapasitesi ve klinik rutinde kullanılan görüntüleme sistemleriyle tam uyumlu çalışabilmesidir.

LIFEx platformu, kullanıcı dostu grafik arayüzü sayesinde karmaşık görüntü işleme algoritmalarını erişilebilir hale getirmektedir. Bu özellik, nükleer Tıp uzmanları ve araştırmacıların teknik programlama bilgisi gerektirmeden gelişmiş radiomik analizler gerçekleştirebilmesine olanak tanımaktadır. Yazılım, histogram tabanlı özellikler, tekstür analizi parametreleri (GLCM, GLRLM, GLSZM) ve şekil özellikleri dahil

olmak üzere yüzlerce radiomik parametreyi otomatik olarak hesaplayabilme yeteneğine sahiptir (Nioche ve ark., 2018).

Histogram tabanlı özellikler; piksel yoğunluklarının dağılımını (Ortalama, Varyans, Çarpıklık, Basıklık) analiz etmekte iken, tekstür özellikleri tümör içi heterojenliği değerlendiren matris tabanlı parametrelerdir (Haralick ve ark., 1973).

Bu parametrelerden **GLCM (Gray-Level Co-occurrence Matrix)** piksel çiftleri arasındaki ilişkiyi analiz etmekte, **GLRLM (Gray-Level Run Length Matrix)** aynı yoğunluktaki piksel dizilerinin uzunluğunu incelemekte ve **GLSZM (Gray-Level Size Zone Matrix)** aynı yoğunluktaki komşu piksel bölgelerinin boyutlarını değerlendirmektedir. Şekil (morfolojik) özellikleri ise tümörün geometrik yapısını tanımlamaktadır (Hacim, Sferisite, Kompaktlık).

Bu özelliklerin, geleneksel SUV ölçümlerinin ötesinde tümör biyolojisi hakkında ek bilgiler sağladığı ve RCB sınıflarının öngörülmesinde modele özgün bir katkı sunduğu gösterilmiştir.

Radiomik özelliklerin klinik uygulamalara entegrasyonunda, farklı merkezler arasında tutarlı ve karşılaştırılabilir sonuçların elde edilmesi kritik öneme sahiptir. LIFEx yazılımı, Image Biomarker Standardization Initiative (IBSI) tarafından belirlenen standartlara uyumlu özellik çıkarma protokolleri uygulamaktadır. Bu uyumluluk, çok merkezli çalışmalarda veri karşılaştırılabilirliğini desteklemekte ve meta-analizlerin gerçekleştirilmesine olanak tanımaktadır (Zwanenburg ve ark., 2020). Bunun yanı sıra, yazılım farklı eşik değerleri ve segmentasyon yöntemleri için karşılaştırmalı analizler yapabilme imkânı sağlamaktadır (Nioche ve ark., 2018).

Yazılımın standartlaştırılmış veri çıktı formatları, çok merkezli araştırma projelerinde veri toplama ve analiz süreçlerinin koordinasyonunu kolaylaştırmaktadır. CSV (Comma-Separated Values) ve XML (eXtensible Markup Language) formatlarında çıktı alabilme özelliği, elde edilen radiomik özelliklerin istatistiksel analiz yazılımlarına (R, Python, SPSS (Statistical Package for the Social Sciences)) ve makine öğrenmesi platformlarına kolayca aktarılabilmesini sağlamaktadır (Nioche ve ark., 2018).

LIFEx yazılımının kullanımında bazı teknik ve metodolojik sınırlılıklar bulunmaktadır. ROI çizimi sürecinde operator deneyimi ve tutarlılığı, çıkarılan radiomik özelliklerin güvenilirliğini doğrudan etkilemektedir. Inter-observer ve intra-

observer variability, özellikle küçük lezyonlarda ve düşük kontrast görüntülerde artabilmektedir.

Görüntü kalitesi ve teknik parametreler (piksel boyutu, gürültü düzeyi, yeniden yapılandırma algoritması) radiomik özellikleri önemli ölçüde etkileyebilmektedir. Bu nedenle, çok merkezli çalışmalarda görüntüleme protokollerinin standardize edilmesi ve görüntü kalitesi kontrollerinin yapılması gerekmektedir (Zwanenburg ve ark., 2020). Bunun yanı sıra, yüksek boyutlu radiomik özellik uzaylarında “curse of dimensionality” problemi ile karşılaşılabilen, bu durum özellikle küçük örneklem boyutlarında overfitting riskini artırmaktadır. Bu nedenle, özellik seçimi ve boyut azaltma teknikleri, model genelleme performansının iyileştirilmesi açısından kritik öneme sahiptir.

2.10.4. Klinik Karar Destek Sistemleri

Klinik karar destek sistemlerinin (KKDS) etkinliği, yalnızca geliştirilen tahmin modellerinin doğruluğuna değil, aynı zamanda bu modellerin klinik pratiğe entegrasyon biçimine de bağlıdır. Günümüzde sağlık hizmetleri, farklı teknolojik altyapılara sahip kurumlar, çeşitli cihaz türleri ve değişken internet bağlantı koşulları içeren heterojen bir ortamda gerçekleşmektedir. Bu çeşitlilik, tek bir platforma bağımlı olmayan, esnek ve erişilebilir KKDS çözümlerinin geliştirilmesini gerektirmektedir (Bates ve ark., 2021; Osheroff ve ark., 2021).

Çok platformlu yaklaşım, web tabanlı, masaüstü ve mobil uygulamaların entegre bir şekilde kullanılmasını içermektedir. Bu yaklaşım, farklı klinik senaryolarda ve teknolojik kısıtlamalarda sistemin erişilebilirliğini ve kullanılabilirliğini artırmaktadır. Özellikle çok merkezli çalışmalarda ve farklı sağlık kurumlarının iş birliği gerektiren durumlarda, çok platformlu sistemler kritik öneme sahiptir (Rajkomar ve ark., 2019; Topol, 2019).

Web tabanlı KKDS’ler, modern sağlık hizmetlerinde en yaygın kullanılan platform türüdür. Bu sistemlerin temel avantajı, kurulum gerektirmeden herhangi bir cihazdan ve konumdan erişilebilir olmalarıdır. Modern web teknolojileri, karmaşık makine öğrenmesi modellerinin tarayıcı içinde çalıştırılmasına olanak tanımaktadır (Bates ve ark., 2021).

Masaüstü KKDS uygulamaları, internet bağlantısının sınırlı olduğu veya hasta verilerinin yerel olarak işlenmesinin tercih edildiği klinik senaryolarda kritik öneme sahiptir. Bu uygulamalar, tamamen offline çalışabilme yeteneği ve yüksek işlem gücü avantajları sunmaktadır (Sutton ve ark., 2020).

Akıllı telefon ve tabletlerin sağlık profesyonellerinin günlük pratiğine entegre olmasıyla birlikte, “Mobil Sağlık” (mHealth) kavramı, klinik karar destek mekanizmalarının sunumunda yeni bir paradigma oluşturmuştur. Mobil Klinik Karar Destek Sistemleri (mCDSS), karmaşık algoritmik hesaplamaların hasta başında (point-of-care) anlık olarak yapılabilmesine olanak tanıyarak, kanıta dayalı tıp uygulamalarının erişilebilirliğini artırmaktadır. Bu sistemlerin geliştirilmesinde, dünya genelinde mobil cihaz pazarını domine eden iki temel işletim sistemi olan Android ve iOS platformları, uygulama mimarisinin temelini oluşturmaktadır.

Google tarafından geliştirilen Android işletim sistemi, açık kaynak kodlu yapısı ve geniş cihaz yelpazesi (akıllı telefonlar, tabletler, giyilebilir cihazlar) nedeniyle mHealth uygulamaları için en yaygın dağıtım platformudur. Android uygulamaları, geleneksel olarak Java veya modern yaklaşımda Kotlin programlama dilleri kullanılarak geliştirilir. “Material Design” prensipleri, kullanıcı arayüzlerinin (UI) ergonomik ve sezgisel olmasını sağlayarak, klinisyenlerin yoğun iş akışı sırasında uygulamayı hatasız kullanmasına katkıda bulunmaktadır (Google Developers, 2024).

Platformun esnek yapısı, harici sensörler ve tıbbi cihazlarla (örneğin mobil EKG (Elektrokardiyografi) veya glukometreler) entegrasyonu kolaylaştırır. Bunun yanı sıra, APK (Android Package Kit) formatındaki uygulamaların uygulama mağazasına bağımlı kalmadan (sideloading) hastane içi cihazlara doğrudan yüklenebilmesi, kurumsal dağıtımda esneklik sağlamaktadır.

Apple tarafından geliştirilen iOS işletim sistemi, kapalı devre ekosistemi ve sıkı donanım-yazılım optimizasyonu sayesinde, özellikle yüksek performans ve veri güvenliği gerektiren tıbbi uygulamalarda tercih edilmektedir. iOS uygulamaları, Swift veya Objective-C dilleri kullanılarak geliştirilmektedir. Apple’ın “Human Interface Guidelines” (İnsan Arayüzü Yönergeleri), tıbbi uygulamalarda standardizasyonu ve kullanım kolaylığını garanti altına almaktadır (Apple Developer, 2024).

2.10.4.1. Klinik Karar Destek Sistemlerinde Veri Entegrasyonu, Güvenlik ve Etik Standartlar

Modern onkolojide KDSS başarısı, sadece tahmin algoritmalarının doğruluğuna değil, aynı zamanda bu sistemlerin farklı platformlar (Web, Mobil, Masaüstü) arasında güvenli ve kesintisiz veri akışı sağlayabilmesine bağlıdır. Çok merkezli çalışmaların ve multidisipliner tümör konseylerinin ihtiyaç duyduğu veri paylaşımı; birlikte çalışabilirlik (interoperability), veri güvenliği ve etik uyumluluk prensipleri üzerine inşa edilmelidir (Bates ve ark., 2021).

2.10.4.2. Çok Platformlu Entegrasyon ve Veri Standartları

Bu çalışmada olduğu gibi, Web, Masaüstü ve Mobil uygulamaların eş zamanlı kullanıldığı dijital sağlık ekosistemlerinde, verilerin platform bağımsız ve kayıpsız bir şekilde taşınması hayati önem taşımaktadır. Farklı sağlık kurumlarından veya aynı kurumun farklı birimlerinden gelen verilerin koordine edilmesi için uluslararası kabul görmüş standartlar kullanılmaktadır. Bu amaçla JSON (JavaScript Object Notation) ve XML (eXtensible Markup Language) gibi hem insan tarafından okunabilir hem de makine tarafından işlenebilir yapılar yaygın olarak tercih edilmektedir. Bu standartlar, farklı kaynaklardan gelen verilerin merkezi sistemler ve tahmin modelleri tarafından tutarlı biçimde yorumlanmasına olanak sağlamaktadır.

2.10.4.3. Çok Katmanlı Güvenlik Mimarisi

KDSS’de işlenen veriler, yasal olarak “Özel Nitelikli Kişisel Veri” statüsündedir. Bu nedenle, geliştirilen Web (Django), Masaüstü (.NET) ve Mobil (Android/iOS) uygulamaların güvenlik mimarisi, “savunma derinliği” (defense in depth) ilkesine göre tasarlanmalıdır.

Veri iletimi sırasında koruma (Encryption in Transit) kapsamında mobil veya masaüstü uygulamadan sunucuya giden tüm veri paketleri, TLS 1.3 (Transport Layer Security) protokolü ile şifrelenmelidir. Bu, verilerin ağ üzerinde dinlenmesini (Man-in-the-Middle saldırıları) engellemektedir.

Durağan veri güvenliği (Encryption at Rest) ise veritabanlarında, yedekleme sistemlerinde veya mobil cihaz hafızasında saklanan verilerin AES-256 gibi güçlü şifreleme algoritmaları ile korunmasını kapsamaktadır. Böylece cihaz kaybı, fiziksel erişim veya veri sızıntısı gibi durumlarda hassas hasta bilgilerinin açığa çıkma riski azaltılabilmektedir.

Uygulama düzeyinde güvenlik önlemleri de kritik öneme sahiptir. Web tabanlı sistemlerde siteler arası istek sahteciliğine (CSRF) ve SQL enjeksiyonuna karşı framework düzeyinde koruma mekanizmaları ile kullanıcı oturum yönetiminin güvenliği sağlanmaktadır. Mobil uygulamalarda ise biyometrik kimlik doğrulama (Parmak izi, FaceID) ve uygulamaların birbirinden izole çalıştığı “Sandbox” mimarisi, hasta verilerine yetkisiz erişimi engellemektedir. Uygulama marketlerinin (Google Play ve App Store) güvenlik denetimleri, zararlı yazılımlara karşı ek bir bariyer oluşturmaktadır (Osherooff ve ark., 2021).

2.10.4.4. Yasal ve Etik Çerçeve: KVKK ve GDPR Uyumu

Yapay zeka tabanlı sistemlerin klinik kullanımı, teknolojik bir meydan okuma olduğu kadar etik ve yasal bir sorumluluktur. Türkiye’de KVKK (Kişisel Verilerin Korunması Kanunu) ve Avrupa Birliği’nde GDPR (General Data Protection Regulation), hasta verilerinin işlenmesinde katı kurallar getirmektedir. Bu doğrultuda, CDSS (Clinical Decision Support System) yazılımlarının tasarımında “Tasarımda Gizlilik” (Privacy by Design) ilkesi esas alınmalıdır (Zapata ve ark., 2015).

Bu kapsamda veri minimizasyonu ilkesi önem taşımaktadır. Tahmin modellerinin çoğu zaman kimlik bilgilerine değil, yaş, tümör çapı, biyobelirteç durumu veya görüntüleme parametreleri gibi klinik değişkenlere ihtiyaç duyması nedeniyle, sistemlerin anonimleştirilmiş veya takma adlandırılmış veri ile çalışması tercih edilmelidir. Ayrıca kullanıcıların verilerin hangi amaçla işlendiği konusunda bilgilendirilmesi, açık rıza süreçlerinin tanımlanması ve veri kullanımında şeffaflığın sağlanması gerekmektedir.

Bir diğer kritik konu algoritmik adalettir. Geliştirilen modellerin belirli yaş grupları, cinsiyetler veya klinik alt gruplar açısından sistematik yanlılık (bias) üretmediğinin değerlendirilmesi gerekir. Bu nedenle performansın farklı alt gruplarda ayrı ayrı incelenmesi, açıklanabilir yapay zekâ yöntemlerinin kullanılması ve insan denetiminin sürdürülmesi önerilmektedir (Topol, 2019).

2.11. Klinik Yorum ve Ekonomik Değerlendirme

Neoadjuvan kemoterapi sonrası pCR ve RCB sınıflamasının doğru biçimde belirlenmesi, meme kanserinde uzun dönem sonuçlarla ilişkili prognostik bilgi sağlamanın yanı sıra adjuvan tedavi yoğunluğu ve tedavi sürekliliği gibi klinik yönetim kararlarının da temelini oluşturur (Symmans et al., 2017). Bu bağlamda yanıt

değerlendirmesinde görüntüleme ve diğer tamamlayıcı yaklaşımların sınırlılıkları gözetilmeli; çok sınıflı ve dengesiz veri yapılarında ise yüksek klinik ağırlıklı sınıfların (örneğin yüksek rezidüel yük) modelleme ve karar desteği açısından özel dikkat gerektirdiği bilinmektedir (Hylton ve ark., 2012; He & Garcia, 2009). Öte yandan klinik öngörü veya karar destek bileşenlerinin değerlendirilmesinde yalnızca ayırt edicilik gibi performans ölçütleri yeterli sayılmamakta; sağlık teknolojilerinin benimsenmesi ve kaynak kullanımının rasyonelleştirilmesi açısından maliyet-etkinlik ile raporlama/uygulanabilirlik boyutlarının birlikte ele alınması gerekir (Husereau ve ark., 2022).

2.11.1. pCR ve RCB'nin Klinik Kararlara Etkisi

NAK sonrasında pCR elde edilmesi, özellikle triple-negatif ve HER2 pozitif meme kanseri alt tiplerinde daha iyi uzun dönem klinik sonuçlarla ilişkilendirilmektedir. Geniş ölçekli meta-analizlerde pCR varlığının hastalarda olaysız sağkalım ve genel sağkalım sonuçlarının daha olumlu olduğu gösterilmiştir. CTNeoBC havuz analizinde (Cortazar ve ark. 2014), 11.955 hastayı içeren veri setinde pCR elde eden hastalarda 5 yıllık event-free survival (EFS) oranını %84,4, pCR elde etmeyenlerde ise %67,9 olarak bildirilmiştir; pCR ile olay riskinde belirgin azalma olduğunu göstermiştir (HR=0,48; %95 GA (Güven Aralığı) [0,43–0,54]; $p<0,001$). Bu bulgular, pCR'nin uzun dönem sonuçların öngörülmesinde yüksek klinik değer taşıdığını desteklemektedir.

Klinik uygulamada bu ayrım, adjuvan tedavide “gereğinden fazla tedavi” ile “yetersiz tedavi” arasındaki hassas dengeyi belirler. von Minckwitz ve ark. (2012), pCR elde eden hastalarda daha az yoğun (de-escalation) yaklaşımların gündeme gelebileceğini; rezidüel hastalık varlığında ise ek adjuvan stratejilerin gerekebileceğini vurgulamıştır. Bu perspektiften bakıldığında pCR'yi doğru tanımlamak, yalnızca sağkalım tahminini değil, tedavi yükünü ve tedaviye bağlı zararları da doğrudan etkilemektedir.

Adjuvan kemoterapinin gereksiz kullanımı ise hasta açısından klinik ve insani bir maliyet doğurmaktadır. Husereau ve ark. (2022), adjuvan kemoterapiyle ilişkili grade 3–4 toksisite riskinin anlamlı düzeyde olabildiğini raporlamıştır. pCR/RCB-0 olan hastalarda adjuvan tedavi gereksiniminin daha düşük olduğu klinik senaryolarda, bu toksisite riski “kaçınılabılır zarar” olarak önem kazanmaktadır. Spring ve ark. (2016) da pCR'nin doğru belirlenmesinin, gereksiz tedaviden kaçınma yanında yaşam

kalitesinin korunması ve sağlık kaynaklarının rasyonel kullanımı açısından kritik olduğunu belirtmiştir.

RCB sınıflaması ise pCR'nin ikili yapısının ötesine geçerek rezidüel hastalık miktarını nicel olarak derecelendirmektedir. Böylece pCR elde edemeyen hastalar arasında prognostik farklılıkların daha ayrıntılı biçimde ortaya konulması mümkün olmaktadır.

2.11.2. Yüksek Rezidüel Hastalık Yükü (RCB-III): Prognostik Ağırlık ve Tedavi Yoğunlaştırma İhtiyacı

RCB sınıflaması içinde RCB-III, NAK sonrasında yüksek düzeyde rezidüel tümör yükünü temsil eder ve klinik açıdan en olumsuz gidişatla ilişkilendirilen gruptur. Symmans ve ark. (2017), 3.756 hastalık kohortta RCB kategorileri arasında belirgin prognostik ayrışma olduğunu göstermiş; RCB-III hastalarında 5 yıllık uzak metastazsız sağkalımı %55 olarak bildirirken, RCB-0 grubunda bu oranı %95 düzeyinde raporlamıştır (HR=4,20; %95 GA [2,89–6,10]; $p<0,001$). Bu düzeyde bir ayrışma, RCB-III'ün doğru saptanmasının yalnızca “risk tahmini” değil, klinik yönetim açısından da yüksek önem taşıdığını göstermektedir.

Rezidüel hastalığın yüksek olduğu hastalarda adjuvan tedavinin sağkalım faydasına ilişkin randomize kanıtlar da bu klinik önemi pekiştirir. Örneğin CREATE-X çalışmasında Kris ve ark. (2017), yüksek rezidüel hastalık yüküne sahip HER2-negatif hastalarda adjuvan capecitabine tedavisinin hastalıksız sağkalımı iyileştirdiğini bildirmiştir (5 yıllık DFS: %74,1'e karşı %67,6; HR=0,70; $p=0,005$). Bu çerçevede RCB-III sınıfının doğru tanımlanması, yalnız prognostik bilgi sağlamaktan öte, tedavi yoğunlaştırma kararlarının dayanağı olabilmektedir.

2.11.2.1. NAK Sonrası Yanıt Değerlendirmesinde Görüntüleme: Sınırlılıklar ve Tamamlayıcı Yaklaşımlar

NAK yanıtının değerlendirilmesinde görüntüleme yöntemleri klinik pratikte önemli bir yer tutsa da, pCR/rezidüel hastalık ayırımında yanlış negatiflik ve yanlış pozitiflik olasılıkları klinik karar süreçlerini sınırlayabilir. ACRIN (American College of Radiology Imaging Network) 6657/I-SPY çalışmasında Hylton ve ark. (2012), MR'ın NAK sonrası rezidüel hastalık saptamadaki duyarlılığının sınırlı olabileceğini göstermiş ve bu durumun görüntüleme temelli değerlendirmelerin “doğal tavanına” işaret ettiğini ortaya koymuştur. Bu nedenle, tek bir modaliteye dayalı yaklaşımlar yerine, farklı veri kaynaklarını birleştiren tamamlayıcı stratejiler önem kazanmaktadır.

Coombes ve ark. (2019), dolaşımdaki tümör DNA'sı (ctDNA) gibi liquid biopsy temelli ölçümlerin minimal rezidüel hastalık bağlamında tamamlayıcı bilgi sağlayabileceğini ve izlem/erken saptama açısından potansiyel taşıdığını bildirmiştir. Benzer şekilde Braman ve ark. (2017), intratümöral ve peritümöral radyomik özelliklerin birlikte değerlendirilmesinin yanıt ve rezidüel hastalık yükünü yordamada katkı sağlayabileceğini göstermiştir. Bu bulgular, NAK sonrası yanıtın daha güvenilir biçimde sınıflanması için çoklu modalite ve zengin özellik temsili gereksinimini desteklemektedir.

2.11.2.2. Sınıf Dengesizliği ve Klinik Ağırlığı Yüksek Nadir Sınıflarda (Örn. RCB-III) Modelleme Güçlükleri

RCB gibi çok sınıflı çıktılarda, sınıfların popülasyondaki görülme sıklıkları genellikle eşit değildir. Özellikle RCB-III gibi daha düşük prevalanslı fakat klinik etkisi yüksek sınıflarda model performansı, standart eğitim stratejileriyle sınırlanabilmektedir. He ve Garcia (2009), dengesiz veri yapısının makine öğrenmesi algoritmalarında nadir sınıfların öğrenilmesini güçleştirdiğini ve performansın çoğunluk sınıflara “kayma” eğilimi gösterebileceğini tartışmıştır. Bu durum, klinik açıdan kritik olan sınıflarda duyarlılığın düşmesine ve karar destek sistemlerinin riskli hastaları kaçırmaya yol açabilmektedir. Bu problem, karar eşiklerinin ve hata maliyetlerinin klinik bağlamda yeniden tanımlanmasını gerektirebilmektedir. Elkan (2001), cost-sensitive learning yaklaşımının, farklı hata türlerine (özellikle yanlış negatiflere) farklı maliyetler atayarak modelin klinik önceliklere daha uygun davranmasını sağlayabileceğini göstermiştir. NAK sonrası yanıt tahmininde de benzer şekilde, yüksek riskli sınıfları kaçırmamanın klinik maliyeti yüksek olduğundan, modelleme stratejilerinin bu asimetriyi yansıtacak şekilde tasarlanması önemlidir.

2.11.3. Sağlık Ekonomisi Perspektifi: Maliyet-Etkinlik ve Uygulanabilirlik

Klinik karar destek yaklaşımlarının değerlendirilmesinde performans ölçütleri tek başına yeterli değildir; özellikle kaynak kısıtlı sistemlerde, ek testlerin ve müdahalelerin maliyet ve uygulanabilirlik boyutları birlikte ele alınmalıdır. Drummond ve ark. (2015), sağlık teknolojilerinin benimsenmesinde maliyet-etkinlik analizlerinin karar süreçlerinde belirleyici rol oynadığını vurgulamıştır.

Maliyet-etkinlik deęerlendirmesinde temel aralardan biri “incremental cost-effectiveness ratio, ICER” dır. Weinstein ve Stason (1977), ICER’ı yeni bir mřdahalenin standart uygulamaya gře ek maliyetinin, ek saęlık kazanımına oranı olarak tanımlamıştır. Saęlık kazanımı, sıklıkla “Quality-Adjusted Life Years” (QALY) ile ifade edilmektedir. Gold ve ark. (1996), QALY’nin yařam sřresi ile yařam kalitesini tek bir ölçřtte birleřtirdięini ve 1 QALY’nin “tam saęlıkta bir yıl”a karřılık geldięini ortaya koymuřtur.

Eřik deęerlerin belirlenmesinde farklı yaklařımlar bulunmaktadır. Marseille ve ark. (2015), GSYİH temelli eřiklerin literatřrde yaygın kullanıldıęını belirtmekle birlikte, eřiklerin baęlama duyarlı deęerlendirilmesi gerektięini tartıřmaktadır. Buna ek olarak Husereau ve ark. (2013), ekonomik deęerlendirmelerde doęrudan tıbbi maliyetlerin yanı sıra dolaylı maliyetlerin ve saęlık sistemi kapasitesi gibi uygulama faktörlerinin raporlanmasının řeffaflık aısından önemli olduęunu vurgulamıştır. Bu çereve, klinik fayda ile ekonomik sřrdřrřlebilirlięin birlikte ele alınmasını gerektirmektedir.

3. Gereç ve Yöntem

Bu bölümde; çalışma tasarımı ve araştırma ortamı, veri kaynakları ve veri toplama süreci, etik izinler, örneklem tanımı (dahil ve dışlama ölçütleri), sonlanımlar ve bağımsız değişkenler, veri kodlama ve eksik veri yönetimi, istatistiksel analiz planı, pCR için lojistik regresyon modellemesi, RCB kategorisi için makine öğrenmesi hattı, PET/BT radyomik alt analiz, yazılım ortamı, translasyonel karar destek prototipi ile sağlık ekonomisi ve maliyet-etkinlik çerçevesi sırasıyla sunulmaktadır.

3.1. Çalışma Tasarımı, Ortam ve Veri Kaynakları

Bu çalışma; NAK uygulanan meme kanseri hastalarında RCB ve patolojik tam yanıt (pCR) sonlanımlarının öngörülmesine yönelik tek merkezli, retrospektif ve gözlemsel kohort tasarımında yürütülmüştür. Çalışmada temel sonlanımlar olarak patolojik tam yanıt (pathological complete response, pCR) ve Rezidüel Kanser Yüğü (Residual Cancer Burden, RCB) değerlendirilmiştir. Klinikopatolojik ve görüntüleme temelli verilerin birlikte kullanılmasıyla, tedavi yanıtının istatistiksel ve makine öğrenmesi tabanlı yöntemlerle modellenmesi hedeflenmiştir.

Doktora tezi Ege Üniversitesi Sağlık Bilimleri Enstitüsü kapsamında yürütülmüş olmakla birlikte, klinik kohort verisi ve birincil saha kayıtları Dokuz Eylül Üniversitesi Hastanesi ile iş birliği çerisinde elde edilmiştir.

Klinik veriler; 2015–2024 yılları arasında Dokuz Eylül Üniversitesi Hastanesi Tıbbi Onkoloji Kliniği'nde meme kanseri tanısı alan, NAK tedavisi uygulanmış ve ardından cerrahi tedavi geçiren hastalara ait kayıtların retrospektif incelenmesiyle oluşturulmuştur. Veri kaynakları; Hastane Bilgi Yönetim Sistemi (HBYS), patoloji raporlama sistemi ve patoloji arşivi, nükleer tıp/PET arşivi (PACS/DICOM; SECTRA), radyoloji arşivi (mamografi, ultrasonografi, manyetik rezonans görüntüleme), onkoloji birimi arşiv dosyaları ile genel hastane arşivi ve fiziksel hasta dosyalarını kapsamaktadır.

Çoklu kaynaklardan elde edilen demografik, komorbidite, tedavi, laboratuvar, patoloji, radyoloji ve PET/BT bilgileri; tutarlılık ve doğruluk kontrolleri sonrasında tek bir analiz veri tabanında birleştirilmiş; istatistiksel analiz ve modelleme adımları Python ile yürütülmüştür.

Dahil etme ve dışlama ölçütleri sonrasında nihai klinik kohort $n = 328$ hasta olarak tanımlanmıştır. PET/BT radyomik alt grup ise görüntü uygunluğu ve segmentasyon elverişliliği kriterleri sonrası $n = 198$ hasta olarak belirlenmiştir. Kohortun oluşumu, tez metninde sunulan “Şekil 1. Tezin Metodolojik Akış Diyagramı” ile özetlenmiştir.

3.2. Etik Onay ve Veri Gizliliği

Çalışma; Dokuz Eylül Üniversitesi Girişimsel Olmayan Klinik Araştırmalar Etik Kurulu tarafından onaylanmıştır (Karar no: 2024/25-08, Tarih: 17.07.2024). Çalışmanın retrospektif tasarımı olması nedeniyle, bireysel aydınlatılmış onam alınması etik kurul tarafından gerekli görülmemiş ve araştırma bilgilendirilmiş onam muafiyeti kapsamında yürütülmüştür.

Araştırma kapsamında kullanılan tüm hasta verileri anonimleştirilmiş, kimlik belirleyici doğrudan tanımlayıcı bilgiler veri setinden çıkarılmıştır. Veri erişimi araştırma ekibi ile sınırlı tutulmuş; süreç Helsinki Deklarasyonu ve KVKK ilkeleri doğrultusunda yürütülmüştür (World Medical Association, 2013).

3.3. Popülasyon: Dahil Etme ve Dışlama Ölçütleri

3.3.1. Dahil Etme Kriterleri

Çalışmaya, histopatolojik olarak doğrulanmış invaziv meme karsinomu, NAK uygulanmış olması ve NAK sonrası cerrahi rezeksiyonun gerçekleşmiş hastalar dahil edilmiştir. Ayrıca planlanan NAK kürlerinin tolerans sınırları içinde tamamlanmış olması; örneklem bütünlüğü ve tedavi maruziyetinin standardizasyonu açısından zorunlu kabul edilmiştir. RCB skorunun hesaplanabilmesi için cerrahi patoloji raporunda gerekli parametrelerin (primer tümör boyutları, invaziv hücresellik oranı, in situ komponent oranı, pozitif lenf nodu sayısı ve en büyük metastatik odak çapı) eksiksiz olarak bulunması şartı aranmıştır..

3.3.2. Dışlama Ölçütleri: Klinik Kohort (Aşama 1)

Uzak metastatik hastalık varlığı (M1), NAK’ın hasta isteği, ciddi toksisite veya erken hastalık progresyonu gibi nedenlerle tamamlanamaması, cerrahi patoloji raporunun bulunmaması veya primer sonuçlarının hesaplanmasını engelleyecek düzeyde kritik veri eksikliği bulunan olgular çalışma dışı bırakılmıştır. Ayrıca, ikinci primer malignite varlığı gibi klinik sonuçları etkileyebilecek potansiyel karıştırıcı durumlar da dışlama

kriteri olarak değerlendirilmiştir. Bu ölçütler uygulandıktan sonra nihai klinik kohort $n = 328$ hastadan oluşturulmuştur.

3.3.3. Dışlama Ölçütleri: PET/BT Radyomik Alt Grup (Aşama 2)

PET/BT radyomik analiz alt grubuna dahil edilecek hastalar için ek görüntüleme kriterleri uygulanmıştır. Preoperatif PET/BT görüntüsünün DICOM formatında bulunmaması, şiddetli artefakt veya yetersiz görüntü kalitesi bulunması, primer tümör için segmentasyonun mümkün olmaması veya lezyon hacminin güvenilir radyomik analiz için yetersiz olması durumlarında hastalar bu alt analiz dışında bırakılmıştır. Bu değerlendirmelere sonrasında radyomik alt grup $n = 198$ olarak belirlenmiştir.

3.4. Sonlanımlar ve Bağımsız Değişkenler

3.4.1. Bağımlı Değişkenler

pCR, cerrahi sonrası patoloji raporları temelinde ypT0/Tis ypN0 kriterlerine göre tanımlanmıştır. RCB-0 kategorisi pCR ile eşdeğer kabul edilmiştir. Lojistik regresyon ve uygun karşılaştırmalarda ikili sonlanım değişkeni, pCR (RCB-0) = 1, non-pCR (RCB-I/II/III) = 0 olacak şekilde kodlanmıştır.

RCB; MD Anderson Cancer Center yaklaşımına göre hem sürekli skor hem de kategorik sınıflama (RCB-0, RCB-I, RCB-II, RCB-III) olarak ele alınmıştır. Hesaplama; merkezin çevrimiçi RCB hesaplayıcısı ile yürütülmüş, primer tümörün iki boyutunun çarpımı (mm^2), invaziv hücre yüzdesi (%), in situ komponent oranı (%), makrometastaz ($>2 \text{ mm}$) içeren pozitif aksiller lenf nodu sayısı ve lenf nodlarındaki en büyük metastatik odak çapı (mm) hesaplayıcıya girilmiştir. Elde edilen sürekli skor ve kategori, analiz veri tabanına işlenmiştir.

3.4.2. Bağımsız Değişkenler ve Tematik Yapı

Bağımsız değişkenler, retrospektif kayıt tarama ve ön analiz sürecinde 64 aday öngörücü olarak belirlenmiştir. Her değişken için tanım, ölçüm birimi, kaynak ve klinik anlamı veri sözlüğünde açık biçimde sabitlenmiştir. Çok boyutlu kovaryat uzayında hem yorumlanabilirliği korumak hem de çoklu doğrusal bağıntı ile gereksiz bilgi tekrarını sınırlamak amacıyla adaylar, klinik üst başlıklarla uyumlu altı tematik blok altında patolojik (P), onkolojik/tedavi (O), demografik (D), komorbidite (C), biyokimyasal (B) ve radyolojik (R) olmak üzere sınıflandırılmıştır. R bloğu yapısal görüntüleme raporlarına dayalı klinik radyolojik göstergeleri kapsamakta; PET/BT'den türetilen nicel

radıyomik ölçütler bu bloğa dahil edilmemekte, tam kohortta tamamlanan pCR lojistik regresyonu ve RCB makine öğrenmesi analizlerinden sonra $n = 198$ uygun alt kohortta ayrı bir alt analiz olarak ele alınmaktadır.

Bu modüler yapı, özellik setinin tek adımda genişletilmesi yerine bloklar halinde sırayla modele dahil edilmesine imkân tanımış; $P \rightarrow \dots \rightarrow ALL$ kurgusu yalnızca altı klinik blok için geçerli olup, karşılaştırmalı performans raporlaması bu çerçevede sistematik biçimde yürütülmüştür.

Ön işleme ve eksik veri tamamlama adımları sonrasında nihai analizlerde kullanılan bağımsız değişken sayısı 62 olarak belirlenmiştir. İki değişken, %50'nin üzerinde yüksek eksik veri oranı veya yetersiz imputasyon performansı (imputasyon doğruluğu 0,70'in altında ve/veya imputasyon doğruluğunun standart sapması 0,09 ve üzerinde) nedeniyle analiz dışı bırakılmıştır. Böylece modelleme hattına taşınan özellikler hem veri bütünlüğü hem de tahmin güvenilirliği açısından homojen bir kalite bandına çekilmiştir.

3.4.3. Veri Kodlama ve Standardizasyon

Kategorik değişkenler uygun biçimde ikili veya ordinal kodlarla temsil edilmiş; çok düzeyli değişkenlerde dummy kodlama uygulanmış ve referans kategoriler klinik yorumlanabilirlik esasıyla tanımlanmıştır. Sürekli değişkenlerde birimlerde ölçün birimleri (yaş: yıl, VKİ: kg/m^2 , boyut: mm vb.) standardize edilmiş; aykırı değer taraması kutu grafikleri ve çeyrekler arası aralık (interquartile range, IQR) yaklaşımı ile yürütülmüştür. Kategorik dağılımların hızlı izlenmesi için frekans tabloları ve sunburst görselleştirmeleri üretilmiştir.

3.5. Eksik Veri, İmputasyon ve Ölçekleme

3.5.1. Eksik Veri İncelemesi, Varsayımlar ve Genel Çerçeve

Bağımsız değişkenlerdeki eksik veri oranları ve eksiklik desenleri sistematik olarak incelenmiştir. Görsel inceleme ile rastgele ve kümelenmiş eksiklik ayrıştırılmıştır. Eksik veri mekanizması öncelikli olarak **Missing at Random (MAR)** doğrultusunda ele alınmış, gerekli durumlarda Little's MCAR testi ile destekleyici değerlendirmeler yapılmıştır.

pCR ve RCB sonlanımlarında eksiklik bulunan olgular, sonlanım güvenilirliği nedeniyle analiz dışı bırakılmıştır (Bölüm 3.3.2). Kalan kovaryat eksiklikleri için klasik MICE (çoklu imputasyon + Rubin birleştirme) yerine, tez kapsamında geliştirilen ve aşağıda

tanımlanan tek tamamlanmış analiz seti üreten hibrit, sıralı zincirleme KNN yaklaşımı kullanılmıştır. Bu tercih; (i) klinik tablolarda sık görülen blok-yapılı eksiklik örüntülerinde koşullu bilgi akışını açık biçimde modellemeyi, (ii) çoklu imputasyon analitik yükünü tez omurgası ile sınırlı tutmayı ve (iii) modelleme hattında tek bir tutarlı özellik matrisi ile karşılaştırılabilirliği korumayı hedeflemiştir.

3.5.2. Hibrit Sıralı Zincirleme KNN İmputasyonu

İlk adımda, eksiklik profili ve klinik–teknik uygunluk kriterleriyle eksiksiz veya yeterince tam kabul edilen değişkenler referans (primer) blok olarak bırakılmıştır. Ardından kalan aday değişkenler, önceden tanımlanan bir imputasyon sırasına göre tek tek tamamlanmıştır: sıra j 'deki değişken için eksik hücreler, yalnızca $1 \dots (j-1)$ sütunlarında yer alan (başlangıçta eksiksiz olan veya daha önceki adımlarda tamamlanmış) gözlemler özellik uzayı olarak kullanılarak k -en yakın komşu (KNN; çalışmada $k = 5$) yöntemiyle doldurulmuştur (sürekli değişkenlerde komşu tabanlı sayısal tahmin; kategorik değişkenlerde komşu kümesinden türetilen modal/marjinal kural ile uyumlu kategorik atama). Böylece örneğin ikinci değişken birinci sütuna, üçüncü değişken birinci ve ikinci sütunlara, on beşinci değişken ise önceki on dört sütunun tamamına koşullu olarak bağlanan bir artımlı (chained) imputasyon zinciri oluşturulmuştur. Yaklaşım, literatürdeki conditional imputation / chained equations fikrine paralel olmakla birlikte, burada her adımda tahminleyici çekirdek olarak mesafe tabanlı KNN kullanıldığı için “hibrit sıralı KNN imputasyon hattı” olarak adlandırılmıştır.

İmputasyon performansı, rastgele %5 maskeleme ile oluşturulan değerlendirme senaryolarında doğruluk ve belirsizlik özetleri üzerinden izlenmiş; önceden tanımlanan eşikleri aşamayan değişkenler modelleme hattından çıkarılmıştır (bağımsız değişkenler: 64 aday $\rightarrow$ 62 nihai özellik).

Eksik veri tamamlama, bu çalışmada eğitim–test bölünmesinden önce tüm analitik kohort üzerinde uygulanmış; böylece modelleme aşamasına tek bir tamamlanmış özellik matrisi ile girilmiştir. Ardından bu matris üzerinde sabitlenmiş %80 / %20 rastgele bölünme ile eğitim ve bağımsız test alt-kümeleri oluşturulmuş; hiperparametre araması ve model eğitimi yalnızca eğitim alt-kümesinde, son performans değerlendirmesi ise ayrılmış test alt-kümesinde yürütülmüştür.

3.5.3. Ölçekleme ve Dönüşümler

Lojistik regresyon analizlerinde sürekli değişkenler z-skor ile ölçeklendirilmiştir. Ağaç tabanlı yöntemler ölçeklemeye duyarsız olmakla birlikte, analitik hattın uçtan uca tutarlılığı için aynı ölçekleme adımları korunmuştur. Gerekli görülen sınırlı durumlarda çarpıklık için log dönüşümleri değerlendirilmiş; ana hat dönüşümleri minimal tutulmuştur.

3.6. İstatistiksel Analiz (Klinik ve Klinikopatolojik İlişkiler)

3.6.1. Tanımlayıcı ve Karşılaştırmalı Analizler

Sürekli değişkenler dağılım özelliklerine göre ortalama $\pm$ standart sapma (SS) veya medyan [IQR] şeklinde özetlenmiştir. Kategorik değişkenler n (%) olarak sunulmuştur. RCB skorunun betimlenmesi ve dağılım grafikleri (histogram, yoğunluk, violin vb.) oluşturulmuştur.

RCB ile ilişkiler; değişken türü ve hücre frekanslarına göre Ki-kare veya Fisher testi kullanılarak değerlendirilmiştir. Sürekli veya ordinal değişkenlerde, grup sayısına ve dağılım özelliklerine göre Student t-testi / ANOVA veya Mann–Whitney U / Kruskal–Wallis testleri uygulanmıştır. RCB bileşenleri ile skor arasındaki ilişki Spearman korelasyonu analizi ile incelenmiştir. Normallik ve varyans homojenliği sırasıyla Shapiro–Wilk, Q–Q grafikleri, gerekli durumlarda Kolmogorov–Smirnov ve Levene testleri ile desteklenmiş; buna göre parametrik veya non-parametrik alternatifler seçilmiştir. Etki büyüklükleri ise Cramer’s V, Cohen’s d / f, η^2 , point-biserial, eta katsayısı ile raporlanmıştır.

Çoklu karşılaştırmada tip-I hata riskini kontrol etmek için Bonferroni düzeltmesi ve Benjamini–Hochberg yanlış oran keşfi (False Discovery Rate, FDR) yöntemi uygulanmıştır. Keşifsel karşılaştırmalarda nominal anlamlılık düzeyi $p < 0,05$ olarak raporlanmıştır.

3.6.2. Güç, Sağkalım ve Duyarlılık Analizleri

Çalışma retrospektif tasarımda olduğundan örneklem büyüklüğü önceden belirlenmemiş, dahil etme ve dışlama ölçütleri sonrasında oluşan nihai kohort üzerinden değerlendirilmiştir. Bu nedenle güç analizleri, tasarım öncesi örneklem büyüklüğü planlanması amacıyla değil; mevcut örneklem büyüklüğünün seçili analizlerdeki istatistiksel yeterliliğini göstermek amacıyla a posteriori güç karakterizasyonu olarak yorumlanmıştır. Bu çerçevede, seçili parametrik ve kategorik senaryolarda $\alpha = 0,05$ ve

hedef güç 0,80 altında tespit edilebilir etki büyüklüğü veya mevcut n ile erişilen güç düzeyi raporlanmıştır.

RCB kategorilerinin DFS ve OS ile ilişkisi Kaplan–Meier yöntemi ve log-rank testi ile incelenmiştir.

Birincil çıkarımsal analizler, yukarıda tanımlanan imputasyon tamamlanmış veri seti üzerinde yürütülmüştür (Little & Rubin, 2019; van Buuren, 2018). Bu yaklaşım; liste bazlı çıkarmanın istatistiksel gücü düşürme olasılığı ve MAR varsayımı altında mevcut kovaryat bilgisini korunması gerekçeleriyle tercih edilmiştir.

3.7. pCR Tahmini İçin Lojistik Regresyon Modellemesi

3.7.1. Değişken Seçimi ve Model Kurulumu

Bu analizde; NAK öncesi ve tedavi sürecine ait klinikopatolojik parametreler ile pCR (RCB-0) vs non-pCR ikili sınıflamasını modellemektir.

Öncelikle her bir bağımsız değişken için tek değişkenli lojistik regresyon analizleri gerçekleştirilmiş; olasılık oranı (odds ratio, OR), %95 güven aralığı (GA), p değeri, McFadden pseudo R^2 ve likelihood ratio test (LLR) sonuçları elde edilmiştir.

Çok değişkenli modele dahil edilecek değişkenler; tek değişkenli analiz bulguları, klinik literatürde bildirilen önem düzeyi ve değişkenler arası olası kollinearite ilişkileri birlikte değerlendirilerek belirlenmiştir. Bu doğrultuda farklı değişken kombinasyonlarını içeren aday model yapıları oluşturulmuştur.

Kategorik değişkenler Dummy kodlama yöntemi ile modele dahil edilmiş ve referans seçimleri tanımlanmıştır. Değişkenler arası çoklu doğrusal bağlantı Pearson korelasyon katsayıları ve varyans şişme faktörü (Variance Inflation Factor, VIF) kullanılarak değerlendirilmiştir. Yüksek kollinearite saptanan durumlarda klinik anlamlılık ve istatistiksel uygunluk dikkate alınarak değişken azaltımı yapılmıştır.

Model kararlılığını artırmak ve aşırı uyumu azaltmak amacıyla L1 (Lasso) ve L2 (Ridge) regülerize lojistik regresyon kurulmuştur. Düzenlileştirme C hiperparametresi, GridSearchCV yöntemi ile beş katlı çapraz doğrulama üzerinden seçilmiştir.

3.7.2. Model Değerlendirme

Veri seti; sınıf dağılımı korunacak şekilde %80 eğitim / %20 test ve stratified bölme ile ayrılmıştır. Sınıflandırma eşiğinin belirlenmesinde ROC eğrisi kullanılmış, optimal kesim noktası Youden indeksi ile hesaplanmış, standart 0.5 eşik değeri ile birlikte raporlanmıştır.

Model performansı; ROC eğrisi altında kalan alan (AUC), doğruluk, dengelenmiş doğruluk (balanced accuracy), duyarlılık, özgüllük, pozitif prediktif değer (PPV), negatif prediktif değer (NPV), Brier skoru ve kalibrasyon grafikleri ile değerlendirilmiştir. : Nihai model seçimi; ayırt edicilik gücü, eğitim-test performans uyumu, duyarlılık-özgüllük dengesi ve model yalınlığı birlikte dikkate alınarak yapılmıştır.

3.7.3. Değişken Önem Skorlaması ve Önceliklendirme Çerçevesi

Tek değişkenli ikili lojistik regresyon (İLR) analizlerinden elde edilen istatistiksel bulguların klinik karar bağlamında sistematik biçimde önceliklendirilmesi amacıyla, bu çalışmada çok boyutlu bir **değişken önem skorlama** yaklaşımı uygulanmıştır. Skorlama çerçevesi, yalnızca istatistiksel anlamlılığa dayalı tek eksenli seçim yerine; (i) istatistiksel kanıt düzeyi, (ii) etki büyüklüğü, (iii) modelin tek başına açıklayıcılığı ve (iv) klinik öncelik değerini birlikte dikkate alacak şekilde tasarlanmıştır. Böylece, pCR (RCB-0) öngörüsünde her bir bağımsız değişkenin katkısı hem nicel hem de klinik-yorumlayıcı bir düzlemde karşılaştırılabilir hale getirilmiştir.

Bu kapsamda her değişken için toplam skor, dört alt boyutta verilen puanların toplamı olarak hesaplanmıştır. **İstatistiksel anlamlılık puanı**, ilgili İLR modelinde değerlendirilen katsayı(lar) arasında gözlenen en küçük p değerine göre atanmıştır; anlamlılık eşiğini karşılamayan durumlar en düşük puan bandında değerlendirilmiştir. **İlişki gücü puanı**, kategori düzeyindeki OR tahminlerinin büyüklüğüne göre belirlenmiş; $OR < 1$ olan etkilerde yorumlanabilirlik ve simetriyi korumak için gerektiğinde $1/OR$ dönüşümü kullanılmıştır. Böylece değişkenin yalnızca “anlamli” olup olmadığı değil, yanıtla olan bağının büyüklüğü de skora yansıtılmıştır. **Model açıklayıcılığı puanı**, McFadden pseudo R^2 ile model düzeyi likelihood ratio test (LLR) sonucunun birlikte değerlendirilmesiyle türetilmiştir; bu adım, değişkenin tek başına pCR ikilisini ayırt etme kapasitesini özetlemeyi hedeflemiştir. **Klinik önem puanı**; NCCN/ESMO/St. Gallen rehberleri, güncel literatür ve çalışmanın klinik karar akışındaki kullanım önceliği esas alınarak (temel/orta/sınırlı parametre) kodlanmıştır. Toplam önem skoru 5’in altında kalan değişkenler ayrıntılı olarak ***Ek Bölüm 1 (Bağımsız Değişkenlerin Klinikopatolojik Sınıflandırması)*** içinde sunulmuştur. Toplam skoru ≥ 5 olan ve çok güçlü, güçlü veya

orta düzey öngörücü olarak sınıflanan değişkenler ise tezin Bulgular bölümünde raporlanmıştır.

Toplam önem skoru, önceden tanımlı eşiklere göre kategorik öncelik düzeylerine (ör. çok güçlü, güçlü, orta düzey öngörücü) dönüştürülmüş ve çok değişkenli model adaylarının oluşturulmasında yardımcı bir seçim ölçütü olarak kullanılmıştır. Bununla birlikte, nihai değişken dahil etme/çıkarma kararları yalnızca toplam skora dayandırılmamış; kollinearite, klinik yorumlanabilirlik, örneklem yeterliliği, model yalınlığı ve genellenebilirlik göstergeleri ile birlikte çok ölçütlü olarak verilmiştir. Bu yaklaşım, istatistiksel olarak anlamlı ancak klinik karşılığı sınırlı değişkenlerin aşırı ağırlık kazanmasını engellerken, klinik açıdan kritik fakat istatistiksel gücü sınıra yakın değişkenlerin de şeffaf biçimde değerlendirilmesini sağlamıştır.

3.8. RCB Kategorisi İçin Makine Öğrenmesi Modellemesi

3.8.1. Veri Bölme ve Ön işleme

RCB, dört sınıflı sınıflama problemi olarak ele alınmıştır (RCB-0 / I / II / III). Kohortta hasta başına tek analitik kayıt kullanıldığından, tekrarlı ölçüm nedeniyle bölünme altında hasta düzeyinde çiftleşme riski bulunmamaktadır. Veri seti %80 / %20 stratified eğitim–test ayrımı ile bölünmüştür. Model seçimi ve karşılaştırma, eğitim setinde 5 katlı StratifiedKFold çapraz doğrulama ile yürütülmüştür.

Sınıflar arasındaki dengesiz dağılım nedeniyle sentetik azınlık örnekleme yöntemi (Synthetic Minority Over-sampling Technique, SMOTE) değerlendirilmiş ve karşılaştırmalı analizlerde kullanılmıştır. SMOTE işlemi yalnızca çapraz doğrulamanın eğitim katmanlarında uygulanmış; doğrulama ve test verisine müdahale edilmemiştir. SMOTENC teorik olarak değerlendirilmiş; ordinal yapı ve ağaç tabanlı algoritmaların bölme mantığı nedeniyle ana hatta SMOTE tercih edilmiştir.

3.8.2. Algoritmalar ve Model Geliştirme

Makine öğrenmesi analizlerinde Random Forest (Breiman, 2001), XGBoost (Chen & Guestrin, 2016) ve LightGBM (Ke et al., 2017) değerlendirilmiştir. Hiperparametre optimizasyonu GridSearchCV yöntemi ile gerçekleştirilmiş, model seçiminde özellikle macro-F1 skoru ve macro-AUC değerleri önceliklendirilmiştir.

Bağımsız değişkenler, daha önce tanımlanan tematik bloklar [patolojik (P), onkolojik/tedavi (O), demografik (D), komorbidite (C), biyokimyasal (B) ve

radyolojik (R)] temelinde ayrı ayrı ve birleşik şekilde analiz edilmiştir. Tüm klinik değişkenlerin birlikte kullanıldığı yapı Model ALL olarak tanımlanmıştır.

Her değişken bloğu için farklı algoritmalar ile modeller oluşturulmuş; SMOTE uygulanan ve uygulanmayan senaryolar karşılaştırmalı olarak değerlendirilmiştir. Bu bağlamda R bloğu yalnızca klinik radyolojik öngörücüleri ifade etmekte; olup PET/BT'ten çıkarılan radyomik özellikler blok birleşimlerine ve ALL tanımına dahil edilmemiştir.

3.8.3. Performans ve Güvenilirlik Analizi

Çok sınıflı model performansı; macro/micro ROC-AUC (one-vs-rest yaklaşımı, OvR), macro-F1, precision/recall, balanced accuracy, doğruluk ve karışıklık matrisi kullanılarak değerlendirilmiştir. RCB-I gibi düşük frekanslı sınıflarda duyarlılık ayrıca incelenmiştir. Uygun durumlarda DeLong testi ile AUC karşılaştırması değerlendirilmiştir. Bootstrap ile AUC güven aralığı üretiminde OvR yapısından kaynaklı tanımsızlık riski nedeniyle raporlama kısıtları belirlenmiştir.

Çapraz doğrulama performansı ile bağımsız test performansı arasındaki mutlak fark (CV–Test Gap), model genellenebilirliğinin göstergesi olarak değerlendirilmiştir.

Nihai Model ALL (LightGBM; SMOTE uygulanmayan senaryo) için, hiperparametre seçimi ile performans raporlamasının aynı veri alt kümesinde çakışmasını önlemek amacıyla iç içe (nested) çapraz doğrulama uygulanmıştır. Bu kapsamda dış döngüde beş5 katlı tabakalı ayırım; iç döngüde ise yine beş katlı tabakalı yapı ile hiperparametre değerlendirmesi gerçekleştirilmiştir. Dış test performansı ile iç doğrulama performansı arasındaki fark (inner–outer gap), aşırı uyum çısından ek bir güvenilirlik göstergesi olarak değerlendirilmiştir (Varma & Simon, 2006). Bu çerçevede, iç ve dış performans arasında belirgin ayrışma (çalışmada >0,10 bandı referans eşik olarak kullanılmıştır) yüksek varyans / overfitting riski yorumu ile ilişkilendirilmiştir.

Ek olarak, bağımsız test kümesinde B = 500 bootstrap yeniden örnekleme ile sınıf bazlı performans metrikleri için %95 güven aralıkları üretilmiştir; tek sınıf oluşması nedeniyle AUC'nin tanımsız kaldığı bootstrap tekrarlarında raporlama protokolü açıkça tanımlanmıştır (Efron & Tibshirani, 1994).

3.8.4. Model Yorumlanılabilirliği

Ana kohort çok sınıflı modelde nihai yapı için SHAP (TreeExplainer) analizi yürütülmüş; sınıf bazlı ve global önem sıralamaları elde edilmiştir.

PET/BT radyomik alt kohort hattında yorumlanabilirlik ve özellik seçimi ise bu ana hattan bağımsız protokolle permütasyon önemliliği ile desteklenmiş; performans olumsuz katkı veren özellikler ilgili adımlarda elenmiş veya model kararlılığı gözetilerek yeniden düzenlenmiştir.

3.9. PET/BT Radyomik İş Akışı (Alt Kohort)

Bu alt analizde, yalnızca preoperatif PET/BT görüntüleri uygun kalitede bulunan ve primer tümör segmentasyonu gerçekleştirilebilen 198 hastaya ait veriler değerlendirilmiştir. Amaç; yalnızca preoperatif PET/BT görüntüsü ve segmentasyonunun elverişli olduğu $n = 198$ alt kümede, nicel radyomik özelliklerin RCB ile ilişkisini incelemek ve bu özelliklerin klinik değişkenlerle birlikte kullanıldığı modeller (Model ALL+PET) ile birleştirildiğinde kazanımı değerlendirmektir. Böylece PET/BT radyomik öngörücüler, Bölüm 3.4.2’de tanımlanan klinik radyolojik (R) değişken bloğundan ayrı olarak ele alınmış ve bağımsız bir görüntüleme tabanlı alt analiz olarak değerlendirilmiştir.

3.9.1. Görüntüleme ve Segmentasyon

Preoperatif PET/BT uygulamalarının merkezde uygulanan standart klinik protokole uygunluğuhasta kayıtları üzerinden doğrulanmıştır. Bu kapsamda, görüntüleme öncesinde yaklaşık 6 saat açlık sağlanmış olması, kan glukozunun 140 mg/dL’nin altında olması, yaklaşık 3,7 MBq/kg 18F-FDG dozu uygulama yapılmış olması ve enjeksiyondan yaklaşık 60 dakika sonra görüntüleme alınmış olması incelenmiştir.

Tüm görüntülemeler Siemens Biograph mCT cihazı ile elde edilmiştir. Görüntüler DICOM formatında PACS arşivinden aktarılmış ve LIFEx yazılımı kullanılarak işlenmiştir.

Primer tümör hacmi (VOI), deneyimli iki nükleer tıp uzmanı tarafından manuel olarak konturlanmıştır. Segmentasyon için %40 SUVmax eşikleme standardize edilmiştir. Ölçümler arası uyumu değerlendirmek amacıyla 30 olguda intra-gözlemci ve inter-gözlemci analizleri yapılmış, intraclass correlation coefficient (ICC) değerleri hesaplanmıştır. ICC > 0.75 düzeyi yüksek güvenilirlik referansı olarak kabul edilmiştir.

3.9.2. Özellik Çıkarımı ve Ön İşleme

PET/BT görüntülerinden metabolik özet ölçütler (SUVmax, SUVmean, SUVpeak, MTV, TLG), birinci düzey histogram özellikleri, şekil (shape) özellikleri ve tekstür tabanlı parametreler (GLCM, GLRLM, GLSZM, NGTDM) elde edilmiştir. Gri seviye ayırıklaştırmada LIFEx önerileri doğrultusunda sabit yaklaşım korunmuştur.

PET/BT radyomik ölçütlerin tanımı ve raporlanmasında, nicel görüntü fenotiplemede yaygın kabul gören Image Biomarker Standardization Initiative (IBSI) çerçevesinde önerilen standardizasyon ilkeleri dikkate alınmıştır (Zwanenburg ve ark., 2020). Tek merkezli tasarım nedeniyle görüntüleme cihazı ve rekonstrüksiyon parametrelerinde standardizasyon korunmuştur. Özellik hesapları LIFEx yazılım dokümantasyonunda tanımlanan PET/radyomik çıktı seti ve önerilen ayırıklaştırma parametreleri üzerinden yürütülmüş; böylece hesapların yinelenebilirlik ve literatürle karşılaştırılabilirlik boyutu açıkça sabitlenmiştir.

Ön işleme aşamasında geçersiz veya eksik özelliklerin elemesi, düşük varyans filtresi ve $|r| > 0.9$ korelasyon temelli özellik azaltımı uygulanmıştır. Özellik seçiminde LASSO, minimum redundancy maximum relevance (mRMR) ve Boruta-benzeri yaklaşımlar karşılaştırmalı değerlendirilmiştir. Aykırı değerler önceden tanımlı eşiklerle işaretlenmiş ve analiz dışı bırakılma kuralları şeffaf biçimde raporlanmıştır.

3.9.3. Radyomik Modelleme

Radyomik analizlerde yalnızca görüntüleme değişkenlerini içeren Model PET (14 özellik), aynı $n = 198$ kohort için yalnızca klinik değişkenleri içeren Model ALL (62 klinik özellik) ve klinik ile radyomik değişkenlerin birlikte kullanıldığı Model ALL+PET (76 özellik) karşılaştırılmıştır.

Veri bölme, SMOTE ve çapraz doğrulama optimizasyonu prensipleri ana makine öğrenmesi analiz hattı ile uyumlu şekilde uygulanmıştır. Model performansı daha önce tanımlanan çok sınıflı performans ölçütleri kullanılarak değerlendirilmiş, model yorumlanabilirliği için SHAP analizinden yararlanılmıştır.

3.10. Yazılım Ortamı, Paketler ve Tekrarlanabilirlik

Tüm istatistiksel analizler, veri ön işleme adımları ve makine öğrenmesi modelleri ağırlıklı olarak Google Colaboratory ortamında Python programlama dili (sürüm 3.11–3.12) kullanılarak yürütülmüştür. Analiz sürecinde başlıca şu açık kaynak yazılım kütüphanelerinden yararlanılmıştır: pandas (2.0.3), NumPy (1.24.0), SciPy, statsmodels

(0.14.0), scikit-learn (1.3.0), XGBoost (2.0.0), LightGBM (4.1.0), imbalanced-learn (0.11.0), SHAP (0.42.0), Matplotlib (3.7.1), seaborn (0.12.2), Plotly, joblib (1.3.0).

Rastgelelik içeren veri bölme, yeniden örnekleme ve model eğitimi adımlarında tekrarlanabilirliği artırmak amacıyla sabit rastgele tohum değeri (`random_state = 42`) kullanılmıştır.

3.11. Klinik Karar Destek Sistemine Entegrasyon (Translasyonel Yöntem)

Bu tez kapsamında geliştirilen karar destek araçları, araştırma amaçlı prototip sistemler olarak tasarlanmış olup rutin klinik kullanım için onaylı tıbbi yazılım ürünü niteliği taşımamaktadır. Amaç, geliştirilen öngörü modellerinin dijital ortama aktarılabilirliğini ve klinik iş akışına entegrasyon potansiyelini yöntemsel olarak değerlendirmektir.

Bu doğrultuda, web tabanlı prototip BCRIS uygulama, Django MVT mimarisi kullanılarak geliştirilmiştir. Eğitilmiş model dosyaları ve değişken tanımları (`best_model.joblib`, `feature_list.json`, `class_order.json`) uygulama başlangıcında belleğe alınarak tahmin süreci standardize edilmiştir. Veri giriş ekranları, çalışmada tanımlanan tematik değişken blokları esas alınarak yapılandırılmıştır. Sunucu tarafında Django form validasyonu, istemci tarafında ise JavaScript doğrulamaları kullanılmıştır.

Masaüstü (EXE) sürümü PyQt5 ve gömülü web motoru yaklaşımı ile paketlenmiş; PyInstaller ile dağıtılabılır dosya üretilmiştir. Android HİP uygulaması; çok merkezli veri toplama senaryosu için alan bazlı veri girişi ve hasta bazlı benzersiz kod ile birleştirilmiş kayıt mantığı sunacak şekilde tasarlanmış; çıktıların BCRIS şemasına uygun Excel aktarımı desteklenmiştir. Tahmin üretimi Python tarafında `predict / predict_proba` ile yürütülmüştür.

Web arayüzünde bazı ara hesaplamaların JavaScript ile de üretilebilmesi nedeniyle, Python ve JS çıktıları arasında tutarlılık testi uygulanmıştır. Örneklem alt kümesinde olasılık farkları ve ortalama mutlak hata (mean absolute error, MAE) hesaplanmış; önceden tanımlı kabul eşiği (≤ 0.001) ile uyum değerlendirilmiştir.


Prototip sistemlerde hasta verilerinin kalıcı depolanması hedeflenmemiştir. Klinik kullanım senaryolarında kişisel verilerin korunması, yetkilendirme, kayıt izleme ve mevzuata uyum gerekliliklerinin ayrıca ele alınması gerektiği kabul edilmiştir. Bu nedenle üretim düzeyine geçiş için KVKK/HIPAA uyum, prospektif validasyon, ek etik izinler ve düzenleyici gerekliliklerin (ör. T.C. Sağlık Bakanlığı süreçleri; uluslararası

bağlamda CE/FDA gereklilikleri) ayrı bir ürünleştirme aşamasında tamamlanması öngörülmüştür.

3.12. Sağlık Ekonomisi ve Maliyet-Etkinlik Analizi

Sağlık ekonomisi analizi, klinik öngörü modelinin olası karar destek katkısını destekleyici bir alt analiz olarak değerlendirmek amacıyla yürütülmüştür. Analiz, Türkiye sağlık sistemi içinde SGK ödeyici perspektifi esas alınarak planlanmıştır. Karşılaştırılan iki strateji; model çıktısı kullanılmadan sürdürülen standart klinik yaklaşım ve model tabanlı karar destekli yaklaşım olarak tanımlanmıştır.

Maliyet hesaplamasında, her iki stratejide de ortak olan tanısal süreç bileşenleri ayrı bir artımlı maliyet kalemi olarak değerlendirilmemiştir. Bu kapsamda mamografi/radyoloji değerlendirme, biyopsi, histopatolojik inceleme ve immünohistokimyasal panel gibi standart işlemler ortak maliyetler olarak kabul edilmiştir. Artımlı maliyet, yalnızca model kullanımına bağlı ek operasyonel iş yükü üzerinden hesaplanmıştır (Şekil 5).




Şekil 5. Model Tabanlı RCB Tahmininin Klinik Karar Akış Şeması ve Maliyet Etkisi Bulunan Karar Noktaları

Model temelli yaklaşımda, radyolojik ve klinik değişkenlerin sistematik biçimde toplanması ve doğrulanması için gerekli personel zamanı marjinal maliyet kalemi olarak ele alınmıştır. Model kullanımının mevcut bilgi işlem altyapısı ile tümüyle entegrasyonunun mümkün olduğu senaryoda bu ek maliyetin sıfıra yaklaşacağı varsayılmış; daha manuel kullanım senaryosunda ise sınırlı düzeyde ek operasyonel maliyet öngörülmüştür. Böylece ekonomik analiz, gerçek klinik uygulamadaki iş akışı farklarını yansıtacak biçimde çerçevelenmiştir.

Etkinlik ölçütü olarak QALY kullanılmış ve kemoterapiye bağlı kısa dönem yaşam kalitesi kaybı ile toksisiteye bağlı fayda yitimi birlikte dikkate alınmıştır. Modelde toksisite görülmeyen ve ciddi toksisite gelişen olgular için farklı utility değerleri tanımlanmış, tedavi süreci boyunca oluşabilecek kısa ve uzun dönem kayıplar toplam fayda üzerinde modellenmiştir. Bu çerçevede, gereksiz tedavi maruziyetinin önlenmesi durumunda elde edilebilecek potansiyel fayda kazanımı değerlendirilmiştir.

Maliyet-etkinlik sonucu, artımlı maliyet-etkinlik oranı (ICER) üzerinden yorumlanmıştır. Karşılaştırma, yeni stratejinin ek maliyetinin ek etkinlik kazanımına oranı şeklinde kurulmuş ve sonuçlar, Türkiye için uygun kabul edilen eşik değerler bağlamında değerlendirilmiştir. Analiz, temel senaryonun yanı sıra pCR prevalansı, maliyet varsayımları ve triyaj oranlarındaki değişimleri içeren duyarlılık analizleriyle desteklenmiştir.


Operasyonel yükü azaltmaya yönelik olarak iki basamaklı bir hibrit değerlendirme yaklaşımı da tanımlanmıştır. İlk basamakta tüm olgular için model çıktısı kullanılmış, belirsiz kalan olgularda ikinci basamak doğrulama yaklaşımına geçilmiştir. Bu yapı, klinik doğruluk ile personel zamanı gereksinimi arasındaki dengeyi korumayı amaçlamıştır (Şekil 6).



Şekil 6. Hibrit Yaklaşım - Risk-Tabanlı Basamaklı Tanı Algoritması ve Operasyonel Yük Analizi

Bütçe etkisi analizi, yıllık kullanım ve kademeli benimsenme senaryoları üzerinden kurgulanmıştır. Teknoloji benimsenme oranları farklı düzeylerde test edilmiş, kısa ve orta dönem projeksiyonlarda toplam maliyet etkisi raporlanmıştır. Bu analiz, modelin yalnızca bireysel düzeyde değil, sistem düzeyinde de potansiyel etkisini göstermeyi amaçlamıştır.

Şekil 7’de, çalışmanın kavramsal çerçevesi ile yöntemsel akışı bütüncül bir şema halinde sunulmuştur. Veri setinin yapılandırılması, analiz bloklarının sıralı organizasyonu ve her aşamada üretilen temel çıktılar bu görsel üzerinden toplu olarak izlenebilmektedir.



Şekil 7. Tezin Metodolojik Akış Diyagramı

Bulgular

4.1. Rezidüel Kanser Yüğü (RCB) Skorunun Klinikopatolojik Özelliklerle İlişkisi

4.1.1. Hasta Popölasyonu ve RCB Dağılım Özellikleri

Bu çalışmada, 328 meme kanseri hastasının NAK sonrası RCB skorları ve RCB kategorileri ayrıntılı biçimde analiz edilmiştir. Ortalama RCB skoru $1,859 \pm 1,419$ olup medyan değeri 1,808 olarak hesaplanmıştır. Skorlar minimum 0,000 ile maksimum 5,022 arasında gözlenmiştir. Patolojik tam yanıtı (pCR) temsil eden RCB=0 skoru 90 hastada (%27,44) gözlendi. Bu oran, literatürde bildirilen pCR oranlarının (%20–30) aralığında uyumlu bulunmuştur.

Çeyreklik değerleri sırasıyla $Q1=0,000$, $Q2$ (medyan)=1,808 ve $Q3=3,032$ olarak hesaplanmış; IQR 3,032 olarak bulunmuştur. Birinci çeyrek değeri 0,000 olması ve pCR oranının %27,44 düzeyinde bulunması, dağılımın alt uçta yoğunlaştığını göstermektedir. RCB skoruna ilişkin tanımlayıcı istatistikler, tedavi yanıt düzeylerinin geniş bir aralıkta dağıldığını göstermektedir. RCB skorunun çarpıklık katsayısı (skewness) 0,022 olarak bulunmuş ve dağılımın belirgin bir asimetri göstermediği izlenmiştir.

Tablo 1

RCB Skor Tanımlayıcı İstatistikleri


Hasta Sayısı (n)	Ort.	Medyan	SS	Minimum-Maksimum	Q1 (25. Çeyrek)	Q2 (50. Çeyrek-medyan)	Çarpıklık (skewness)
328	1,859	1,808	1,419	0,000-5,022	0,000	1,808	0,022

RCB skorlarının yoğunluk dağılımı incelendiğinde, dağılımın tekdüze olmadığı ve belirgin bir iki tepeli (bimodal) yapı gözlenmiştir (Grafik 3). Yoğunluk eğrisi üzerinde tepe noktaları 1,65 ve 3,02 olarak saptanmıştır. 1,65 ($\pm\%15,0$) aralığında 43 hasta (%13,11), 3,02 ($\pm\%15,0$) aralığında ise 80 hasta (%24,39) yer almıştır. Eğrinin dip noktaları 0,79 ve 2,17 olarak belirlenmiştir. Buna göre, 0,79 ($\pm\%15,0$) aralığında 2 hasta (%0,61) ve 2,17 ($\pm\%15,0$) aralığında 32 hasta (%9,76) bulunmaktadır.

RCB skorlarının dağılımı Shapiro–Wilk testi ile değerlendirildiğinde normallik varsayımının sağlanmadığı saptanmıştır ($W=0,9149$; $p<0,0001$). Histogram ve Q–Q


plot incelemeleri (Grafik 3) de bu sonucu desteklemiş; dağılımın alt uça yoğunlaştığı ve üst uça 5,022'ye kadar uzanan geniş bir saçılım gösterdiği belirlenmiştir. Bu nedenle izleyen analizlerde değişkenlerin dağılım özelliklerine göre parametrik ve non-parametrik testlerin birlikte kullanılması uygun görülmüştür.

Histogram dağılımında, RCB skoru 0 olan olguların en yüksek frekansa sahip olduğu (n=90) görülmektedir. Ayrıca skorların 1 ile 5 arasında geniş bir aralıkta dağıldığı ve özellikle 1–3 aralığında belirgin bir yoğunlaşma olduğu gözlenmiştir. Bu kapsamda, 1,5–2,0 aralığında n=42 ve 2,5–3,0 aralığında n=50 hasta yer almaktadır.



Grafik 3. RCB Skorunun Frekans, Yoğunluk ve Modal Dağılımı

RCB skorlarının genel dağılımı violin plot analizinde incelendiğinde (Şekil 8) de RCB skorlarının geniş bir aralıkta dağıldığı görülmektedir. Violin plotun genişliği, ilgili skor düzeyindeki gözlem yoğunluğunu yansıtmaktadır. Buna göre, gözlem yoğunluğunun düşük (0–1 aralığı) ve orta RCB skor aralığında (2–3 aralığı) daha yüksek olduğu, üst skor düzeylerinde (4 ve üzeri) ise gözlem yoğunluğunun azaldığı gözlenmiştir.



Şekil 8. RCB Skor – Violin Plot İlişkisi

4.1.2. RCB Skoru ile Klinik ve Patolojik Faktörler Arasındaki İlişkiler

RCB skoru ile klinikopatolojik değişkenler arasındaki ilişkiler korelasyon analizleri ve boxplot dağılım incelemeleri ile değerlendirilmiştir. İlk olarak, RCB skoru ile RCB bileşenleri arasındaki ilişkiler Spearman korelasyon analizi ile değerlendirilmiştir (Tablo 2).

Analiz sonucunda, tüm değişkenler ile RCB skoru arasında istatistiksel olarak anlamlı pozitif korelasyon saptanmıştır (tüm karşılaştırmalar için $p < 0,0001$). En yüksek korelasyon, en büyük metastatik odak çapı (M) ile RCB skoru arasında bulunmuştur ($r=0,8288$). Bunu pozitif lenf nodu sayısı (N) ($r=0,8185$), primer tümör boyutu (d_prim) ($r=0,7789$) ve kanser hücreliliği faktörü (f_inv) ($r=0,7718$) izlemiştir.

Tablo 2

RCB Skoru ile RCB Bileşenleri Arasındaki Spearman Korelasyon Analizi Sonuçları

Değişken Adı	Korelasyon Katsayısı (r)	p Değeri
Pozitif lenf nodu sayısı (N)	0,8185	$p < 0,0001$
En büyük metastatik odak çapı (M)	0,8288	$p < 0,0001$
Primer tümör boyutu (d_prim)	0,7789	$p < 0,0001$
Kanser hücreliliği faktörü (f_inv)	0,7718	$p < 0,0001$

RCB skorunun seçili klinikopatolojik değişkenlere göre dağılımı boxplot analizleri ile değerlendirilmiştir. Bu kapsamda, RCB skoru ile ilişkisi önceki çalışmalarla desteklenen ve klinik prognostik değeri bulunan ilk 10 değişken değerlendirilmiştir.

Gruplara göre medyan RCB skorları aşağıda özetlenmiştir:

Ki-67 düzeylerine göre RCB skorunun dağılımında, düşük Ki-67 grubunda medyan RCB skoru yaklaşık 2,8, orta grupta 2,1 ve yüksek grupta 1,4 olarak gözlenmiştir. Düşük Ki-67 grubunda üst sınır 5'e ulaşırken, yüksek Ki-67 grubunda alt sınır 0'a yaklaşmaktadır.

Metastaz durumuna göre, metastazı olan hastalarda medyan RCB skoru 2,8 iken metastazı olmayan hastalarda bu değer yaklaşık 1,6 olarak saptanmıştır. Metastaz varlığında RCB skorunun üst sınırı 5'e kadar çıkarken, metastaz olmayan grupta üst sınır 3,8'de kalmaktadır.

Mitotik dereceye göre medyan RCB skoru, derece 1 grubunda 2,4; derece 2 olanlarda 1,7; derece 3 olanlarda ise 1,2'dir. Tüm gruplarda alt sınır 0'a yakınken, üst sınır 5'e ulaşmaktadır.

Moleküler alt tiplere göre medyan RCB skoru Luminal A grubunda 2,9, triple negatif grubunda ise yaklaşık 1,2'dir. HER2-zengin tipte medyan skor 1,8, HER2-düşük tipte ise 3,0 olarak gözlenmiştir. Diğer moleküler alt tiplerde medyan değerler 1,4 ile 3,2 arasında değişmektedir.

Progesteron reseptörü (PR) durumuna göre medyan RCB skoru negatif grupta 1,2, zayıf pozitif grubunda 2,7, güçlü pozitif grubunda ise 3,2 olarak saptanmıştır. Tam pozitif PR grubunda medyan değer 0,9'a kadar düşmektedir.

Tanı evresine göre medyan RCB skoru Evre IIA grubunda 1,5, Evre IIB grubunda 2,5 ve Evre IIIA grubunda 3,4 olarak bulunmuştur. Evre IV'te medyan değer 1,7 iken, Evre IIIC'de ise 0'dır. Diğer evrelerde medyan değerler 1,6 ile 3,6 arasında değişmektedir.


TIL düzeyine göre medyan RCB skoru <10 grubunda 2,2, 10-50 arası grupta 1,7, >50 grubunda ise 1,3 olarak gözlenmiştir. Alt sınır tüm gruplarda 0'a yakınken üst sınır 5'e ulaşmaktadır.

Estrojen reseptörü (ER) durumuna göre medyan RCB skoru negatif grupta 0,9, güçlü pozitif grupta 3,2 ve tam pozitif grupta 1,7 olarak saptanmıştır.

HER2 durumuna göre medyan RCB skoru negatif grupta RCB skor 2,3, pozitif grupta ise 1,1, HER2-düşük grupta 2,8, ekvokal grupta ise 2,6 olarak bulunmuştur.

Histolojik tipe göre medyan RCB skoru lobüler tipte 2,9, duktal karsinomda 2,7, nadir tiplerde ise 1,7 olarak gözlenmiştir. DCIS grubunda medyan değer 2,6'dır.

Bu değişkenlere ait boxplot dağılımlar Şekil 9'da toplu olarak gösterilmiştir. RCB skorunun özellikle tümör biyolojisi, reseptör durumu, metastatik yayılım ve tümör mikroçevresi ile ilişkili parametrelere göre farklı dağılım gösterdiği gözlenmiştir.



Şekil 9. RCB Skorunun Seçili Klinikopatolojik Değişkenlere Göre Boxplot Dağılımları

4.1.3. Tüm Değişkenlerde Grup Karşılaştırmaları ve Çoklu Test Analizi

RCB skoru ile klinikopatolojik değişkenler arasındaki ilişkilerin daha kapsamlı değerlendirilmesi amacıyla toplam 64 değişken için grup karşılaştırma analizleri gerçekleştirilmiştir. Varyans homojenliği varsayımı Levene testi ile değerlendirilmiş olup, bazı değişkenlerde homojenlik varsayımının sağlanmadığı saptanmıştır. Test sonuçları p-değerlerinin 0,000050 ile 0,982427 arasında değiştiğini göstermiştir (Tablo 3). En belirgin varyans heterojenliği Ki-67 ($p=0,000050$; 3 grup), nükleer derece ($p=0,000364$; 3 grup) ve E-kaderin durumu ($p=0,002809$; 2 grup) değişkenlerinde saptanmış; buna karşılık nöropati ($p=0,982427$; 2 grup), menopoz durumu ($p=0,970991$; 2 grup) ve kreatinin ($p=0,967592$; 3 grup) değişkenlerinde varyans homojenliği sağlanmıştır. Bu bulgular ışığında, değişkenlerin grup sayısı ve varyans yapısına göre t-testi, ANOVA ve Kruskal–Wallis testleri uygulanmıştır.

Tablo 3

Levene Testi Sonuçları (En İyi Heterojen ve En Beklenmedik Homojen Varyanslar)

Değişken	İstatistik	p-değeri	Grup sayısı
Ki-67	10,204609	0,000050	3
Nükleer derece	8,113980	0,000364	3
E-kaderin	9,064941	0,002809	2
Nöropati	0,017730	0,982427	2
Menopoz durumu	0,001324	0,970991	2
Kreatinin	0,001653	0,967592	3

Grup karşılaştırmalarında anlamlılık en belirgin biçimde metastaz yeri, metastaz durumu ve moleküler tip değişkenlerinde ortaya çıkmıştır. Metastaz yeri için yapılan ANOVA analizinde gruplar arasında ileri düzeyde anlamlı fark saptanmıştır ($F=38,98$; $p<0,0001$; 4 grup). Metastaz durumu için uygulanan t-testi sonucunda iki grup arasında anlamlı fark bulunmuştur ($t=10,24$; $p<0,0001$; 2 grup). Moleküler tip değişkeninde ise Kruskal–Wallis testi sonucunda gruplar arasında anlamlı farklılık belirlenmiştir ($\chi^2=52,15$; $p<0,0001$; 6 grup). Bu sonuçlar, RCB skorunun özellikle hastalık yayılımı ve tümör biyolojisi ile ilişkili değişkenlerde ayrıştığını göstermektedir (Tablo 4).

Tablo 4

Grup Testi Sonuçları (En İyi ve En Beklenmedik Sonuçlar)

Değişken	Test Adı	İstatistik	p-değeri	Grup Sayısı
Metastaz yeri	ANOVA	38,98	$p<0,0001$	4
Metastaz durumu	t-testi	10,24	$p<0,0001$	2
Moleküler tip	Kruskal–Wallis	52,15	$p<0,0001$	6
Kan grubu	t-testi	-2,44	0,015082	2
Meme başı retraksiyonu	Kruskal–Wallis	7,86	0,019665	3
Kitle şekli	ANOVA	3,30	0,038220	3
Tedavi rejimi	t-testi	0,03	0,976878	2

Buna karşılık kan grubu, meme başı retraksiyonu ve kitle şekli değişkenlerinde daha sınırlı düzeyde anlamlılık saptanmıştır ($p<0,05$). Tedavi rejimi değişkeni açısından ise gruplar arasında anlamlı fark gözlenmemiştir ($p=0,976878$). İlk aşama analizlerde $p<0,05$ düzeyinde anlamlı bulunan değişken sayısı 17 olarak belirlenmiştir

RCB'nin kategorik sınıflaması temel alınarak yürütülen ikinci analiz düzeyinde, 64 kategorik değişken ile RCB kategorileri arasındaki ilişkiler ki-kare veya Fisher's exact testleri ile değerlendirilmiştir. Metastaz durumu ile RCB kategorileri arasında anlamlı ilişki saptanmıştır ($\chi^2=43,32$; $p=4,65\times 10^{-11}$; 2 grup). ER durumu için Fisher's exact testi de anlamlı sonuç vermiştir ($p=1,00\times 10^{-4}$; 4 grup). Buna karşılık retinopati ($\chi^2=2,998$; $p=0,083363$) ve tedavi rejimi ($\chi^2=0,401$; $p=0,813871$) değişkenlerinde anlamlı ilişki izlenmemiştir (Tablo 5).

Tablo 5

Chi-kare/Fisher's Exact Testi Sonuçları (RCB Kategorize, En İyi ve En Beklenmedik Sonuçlar)

Değişken	Test Adı	İstatistik	p-değeri	Grup Sayısı
Metastaz durumu	Ki-kare	43,32091	$4,65\times 10^{-11}$	2
ER durumu	Fisher's Exact	—	$1,00\times 10^{-4}$	4
Retinopati	Ki-kare	2,998091	0,083363	2
Tedavi rejimi	Ki-kare	0,401238	0,813871	2

Çoklu hipotez testlerinden kaynaklanabilecek Tip I hata riskini kontrol etmek amacıyla toplam **128 test sonucu** üzerinde Bonferroni ve FDR düzeltmeleri uygulanmıştır. Bonferroni düzeltmesinde anlamlılık düzeyi yaklaşık 0,00039 olarak belirlenmiş ve bu eşiğe göre 16 değişken anlamlılığını korumuştur. FDR düzeltmesinde 24 değişken anlamlı kalmıştır. **Metastaz yeri** için özgün p-değeri $9,59 \times 10^{-12}$ iken Bonferroni sonrası $1,23 \times 10^{-10}$ ve FDR sonrası $1,11 \times 10^{-10}$ olarak hesaplanmıştır. **Metastaz durumu** için özgün p-değeri $2,38 \times 10^{-12}$, Bonferroni sonrası $3,04 \times 10^{-10}$ ve FDR sonrası $1,11 \times 10^{-10}$ bulunmuştur. **ER** durumu için özgün p-değeri $1,00 \times 10^{-4}$, Bonferroni sonrası $1,28 \times 10^{-2}$ ve FDR sonrası $8,00 \times 10^{-4}$ düzeyine yükselmiştir. **Kitle dansitesi** ve **HER2** durumu gibi bazı değişkenlerin yalnızca FDR düzeltmesi sonrasında anlamlı kalması, iki düzeltme yaklaşımı arasındaki duyarlılık farkını göstermektedir (Tablo 6).


Tablo 6

Bonferroni/FDR Düzeltilmiş Sonuçlar

Test Türü	Değişken (En İyi/Beklenmedik)	Orijinal p- değeri	Bonferroni p-değeri	FDR p- değeri	Anlamlı (Bonferro ni)	Anlamlı (FDR)
Kruskal-Wallis	Metastaz Yeri (En İyi: Her İki Düzeltmede Anlamlı)	$9,59 \times 10^{-12}$	$1,23 \times 10^{-10}$	$1,11 \times 10^{-10}$	Evet	Evet
Chi-kare	Metastaz Durumu (En İyi: Her İki Düzeltmede Anlamlı)	$2,38 \times 10^{-12}$	$3,04 \times 10^{-10}$	$1,11 \times 10^{-10}$	Evet	Evet
ANOVA	Moleküler Tip (Orta Güçlü: Her İki Düzeltmede Anlamlı)	0.053928	1.00	0.197223	Hayır	Hayır
ANOVA	Kitle Dansitesi (Beklenmedik: FDR Anlamlı, Klinik Şaşırtıcı)	0.000435	0.055731	0.003278	Hayır	Evet
Chi-kare	HER2 (Beklenmedik: FDR Anlamlı, Klinik Şaşırtıcı)	0.000718	0.091851	0.005103	Hayır	Evet
Chi-kare	Retinopati (Beklenmedik: FDR Anlamlı, Nadir Komorbidite)	0.083363	1.00	0.277601	Hayır	Hayır

4.1.4. RCB Kategorik Sınıflaması ve Klinik Profil

RCB skoruna ilişkin grup karşılaştırmalarında özellikle metastaz durumu ve moleküler tip tip değişkenlerinin daha güçlü bir ayrım oluşturduğu görülmüştür. Güç analizi de bu bulguyu desteklemiştir; metastaz durumu ve moleküler tip için örneklem büyüklüğü arttıkça istatistiksel gücün hızla yükseldiği ve hedef güç düzeyi olan 0,80'e ulaşıldığı izlenmiştir. Buna karşılık, tübül derecesi ve yaş grubu için güç eğrilerinin düşük düzeyde kaldığı, mevcut örneklem büyüklüğü içinde bu değişkenlerde yeterli istatistiksel güce ulaşılamadığı görülmüştür. Bu nedenle şekillerde, anlamlı ve ayırt edici örüntü sergileyen değişkenlerle birlikte, gücün sınırlı kaldığı örnekler de karşılaştırmalı olarak şekil 10'da sunulmuştur.



Şekil 10. Seçili Değişkenler İçin T-Testi ve Ki-Kare Testine Dayalı Güç Eğrileri


RCB skorları, neoadjuvan kemoterapi sonrası patolojik yanıtın kategorik olarak değerlendirilebilmesi amacıyla Symmans ve arkadaşları (2007) ölçütleri doğrultusunda RCB-0, RCB-I, RCB-II ve RCB-III olarak sınıflandırılmıştır. Toplam 328 hastanın 90'ı (%27,4) RCB-0, 34'ü (%10,4) RCB-I, 143'ü (%43,6) RCB-II ve 61'i (%18,6) RCB-III kategorisinde yer almıştır. En yüksek oran RCB-II grubunda izlenmiştir. Bu dağılım Tablo 7'de sayısal olarak, Grafik 4'de görsel olarak sunulmuştur.

Tablo 7

RCB Sınıf Dağılımı

RCB Sınıfı	Skor Aralığı	n	%	Mean	SD	IQR	Min	Max
RCB-0	0,0	90	27,4	0,0	0,0	0,0	0,0	0,0
RCB-I	0,1 – 1,36	34	10,4	0,68	0,34	0,48	0,0	1,36
RCB-II	1,37 – 3,28	143	43,6	2,30	0,56	0,82	1,37	3,28
RCB-III	>3,28	61	18,6	3,92	0,78	1,12	3,29	5,02


Not. n: Hasta sayısı; %: Yüzde; Mean: Ortalama; SD: Standart sapma; IQR: Çeyreklik aralığı; Min: Minimum; Max: Maksimum




Grafik 4. RCB Sınıf Dağılımı

Tanımlayıcı istatistikler, kategorik sınıflamanın nicel karşılığının da ayrıştığını göstermiştir. RCB-0 grubunda skorlar 0,0 değerinde sabitlenmiş, RCB-I grubunda ortalama 0,68 (SS=0,34; IQR=0,48), RCB-II grubunda 2,30 (SS=0,56; IQR=0,82) ve RCB-III grubunda 3,92 (SS=0,78; IQR=1,12) olarak hesaplanmıştır. RCB-III grubunda maksimum değer 5,02'ye ulaşması, bu kategorinin daha geniş rezidüel hastalık yükünü temsil ettiğini göstermektedir.


RCB kategorilerinin klinik profilini değerlendirmek amacıyla hasta özellikleri patolojik, onkolojik, demografik, komorbidite, biyokimyasal ve radyolojik model grupları altında sunulmuştur. Sunburst grafikler, her model grubunda alt kategorilerin görece baskınlığını ve hiyerarşik dağılım örüntülerini aynı anda görünür kıldığı için tercih edilmiştir; böylece RCB kategorilerinin yalnızca tekil değişkenlerle değil, çok katmanlı klinik yapılarla ilişkisi bütüncül olarak izlenebilmiştir. Bu nedenle sunburst görselleştirmeleri, RCB kategorilerinin hasta profili içinde nasıl kümelendiğini ve hangi alt grupların öne çıktığını göstermek amacıyla kullanılmıştır (Grafik 5-10).




Grafik 5. Model P Grubundaki Değişkenlerin Sunbrust Grafiği




Grafik 6. Model O Grubundaki Değişkenlerin Sunbrust Grafiği




Grafik 7. Model D Grubundaki Değişkenlerin Sunbrust Grafiği



Grafik 8. Model C Grubundaki Değişkenlerin Sunbrust Grafiği



Grafik 9. Model B Grubundaki Değişkenlerin Sunbrust Grafiği



GGT, ALP ve CA15-3 için normal değerler baskın bulunmuştur. Radyolojik profilde ise solid kitle, düzensiz şekil, yüksek dansite, BI-RADS 5 ve üst dış kuadran yerleşimi öne çıkan bulgulardır.

Bu dağılımlar birlikte değerlendirildiğinde, RCB-II ve RCB-III kategorilerinin toplamda baskın bir oran oluşturduğu, buna eşlik eden patolojik, onkolojik ve radyolojik örüntülerin ise rezidüel hastalık yükünün artışıyla uyumlu bir klinik arka plan sunduğu görülmektedir. Bu alt bölümde kullanılan sınıflama ve görsel özetler, RCB'nin hasta profili ile ilişkisinin çok boyutlu biçimde sunulmasını sağlamıştır.

4.1.5. Veri Kalitesi, Eksik Veri ve İmputasyon Analizi

Veri kalitesini değerlendirmek amacıyla eksik veri yapısı ve imputasyon performansı ayrı ayrı incelenmiştir. Orijinal veri setinde toplam 18 sütunda eksik veri bulunduğu saptanmıştır. En yüksek eksiklik oranları E-kaderin durumu (%65,55) ve menopoz durumu (%62,80) değişkenlerinde gözlenmiş; tübül sayısı durumu (%22,26), kan grubu (%20,43), metastaz durumu (%13,11), metastaz yeri (%13,11), rejim durumu (%9,45) ve kür yoğunluk durumu (%9,45) bunları izlemiştir. Diğer değişkenlerde eksiklik oranları görece düşük düzeyde kalmıştır (Tablo 8).


Tablo 8

Orijinal Sütunlarda Eksik Veri Oranları

Değişken	Eksik Oran (%)	Değişken	Eksik Oran (%)
E-kaderin durumu	65,55	Mitotik indeks durumu	6,10
Menopoz durumu	62,80	TIL durumu	6,10
Tübül sayısı durumu	22,26	Ki-67 durumu	5,49
Kan grubu	20,43	Histolojik grade	3,96
Metastaz durumu	13,11	Nükleer sayısı durumu	3,35
Metastaz yeri	13,11	ER durumu	2,13
Rejim durumu	9,45	PR durumu	2,13
Kür yoğunluk durumu	9,45	HER2 durumu	2,13

Değişken	Eksik Oran (%)	Değişken	Eksik Oran (%)
Moleküler tip	6,10	NAK öncesi klinik evre	1,52

Eksik veri matrisi, boşlukların değişkenler arasında eşit dağılmadığını ve belirli sütunlarda yoğunlaştığını göstermiştir. Özellikle E-kaderin ve menopoz değişkenlerinde yoğun eksik gözlem alanları dikkat çekmiştir. Hasta indekslerinin yaklaşık 100–150 aralığında bazı değişkenlerde kümelenen eksiklikler izlenmiştir. Bu görünüm, eksik veri yapısının yalnızca rastlantısal bir dağılım sergilemediğini, belirli değişkenler ve hasta alt kümelerinde yoğunlaşabildiğini göstermektedir (Şekil 11).



Şekil 11. Eksik Veri Isı

(Eksik veriler siyah, mevcut veriler beyaz olarak gösterilmiştir.)

İmputasyon sonrası doğruluk analizinde en yüksek performans NAK öncesi klinik evre ($0,9939 \pm 0,0182$), HER2 ($0,9879 \pm 0,0201$), PR ($0,9818 \pm 0,0201$), ER ($0,9727 \pm 0,0212$) ve nükleer sayısı ($0,9727 \pm 0,0286$) değişkenlerinde elde edilmiştir.

Moleküler tip, mitotik indeks, rejim, metastaz yeri, metastaz durumu, kan grubu ve tübül sayısı değişkenlerinde orta düzey performans izlenmiştir. Buna karşılık, menopo (0,3939±0,0996) ve E-kaderin (0,3879±0,0897) değişkenleri ise en düşük doğruluk oranlarına sahip olmuştur (Tablo 9).

Tablo 9

Özelliklerin Doğruluk Oranları ve Standart Sapmaları

Özellik	Doğruluk Oranı	Std	Özellik	Doğruluk Oranı	Std
NAK öncesi klinik evre	0,9939	0,0182	Moleküler tip	0,9242	0,0365
HER2	0,9879	0,0201	Mitotik indeks	0,9030	0,0466
PR	0,9818	0,0201	Rejim	0,8879	0,0730
ER	0,9727	0,0212	Metastaz yeri	0,8758	0,0417
Nükleer	0,9727	0,0286	Metastaz durumu	0,8545	0,0588
Histolojik grade	0,9606	0,0273	Kan grubu	0,8091	0,0408
Ki-67	0,9455	0,0378	Tübül sayısı	0,7788	0,0560
Kür yoğunluğu	0,9364	0,0370	Menopoz	0,3939	0,0996
TIL	0,9303	0,0490	E-kaderin	0,3879	0,0897

Masking testi ile doğrulanan imputasyon performansında TIL durumu, metastaz durumu, metastaz yeri ve NAK öncesi klinik evre değişkenlerinde %100,00 doğruluk elde edilmiştir. ER, PR, HER2 ve histolojik grade değişkenlerinde doğruluk oranı %93,75 düzeyinde bulunmuştur. E-kaderin durumu için doğruluk oranı %12,50, menopoz durumu için %43,75 düzeyinde kalmıştır. Tübül sayısı durumu (%68,75) ve mitotik indeks durumu (%81,25) ise orta düzey başarı göstermiştir (Tablo 10).

Tablo 10

%5 Maskeleye Doğruluk Testi Sonuçları

Değişken	Doğruluk (%)	Değişken	Doğruluk (%)
ER durumu	93,75	TIL durumu	100,00
PR durumu	93,75	Metastaz durumu	100,00
HER2 durumu	93,75	Metastaz yeri	100,00
Moleküler tip	87,50	NAK öncesi klinik evre	100,00
Ki-67 durumu	87,50	Rejim durumu	93,75
Tübül sayısı durumu	68,75	Kür yoğunluğu durumu	93,75
Nükleer sayısı durumu	93,75	Kan grubu	87,50
Mitotik indeks durumu	81,25	Menopoz durumu	43,75
Histolojik grade	93,75	E-kaderin durumu	12,50

Not. Doğruluk, maskelenen verilerin imputed değerlerle eşleşme oranı olarak hesaplanmıştır (n=328, %5 $\approx$ 16)

Bu bulgular, imputasyon başarısının tüm değişkenlerde eşit olmadığını, yüksek eksiklik oranına sahip ya da yapısal olarak daha heterojen değişkenlerde performansın belirgin biçimde düştüğünü göstermektedir. Menopoz durumu ve E-kaderin değişkenlerinde doğruluk oranları daha düşük bulunurken, klinik evre, HER2, ER ve PR değişkenlerinde daha yüksek doğruluk elde edilmiştir.

4.1.6. Değişkenler Arası Korelasyon Yapısı


RCB skoru ile klinik, histopatolojik ve radyolojik değişkenler arasındaki ilişkiler point-biserial korelasyon katsayısı ve eta katsayısı kullanılarak değerlendirilmiştir. En yüksek korelasyon katsayıları Tablo 11’de sunulmuş olup, en belirgin ilişkilerin metastazla ilişkili değişkenlerde toplandığı görülmüştür. Bu kapsamda metastaz durumu için point-biserial korelasyon katsayısı -0,493 ve eta katsayısı 0,243; metastaz yeri için ise sırasıyla 0,414 ve 0,265 olarak hesaplanmıştır. Ki-67, ER, HER2, histolojik grade ve mitotik derece değişkenleri de RCB skoru ile daha sınırlı düzeyde ilişki gösterdi (Tablo 11).

Tablo 11

RCB Skoru ile Klinik ve Patolojik Değişkenler Arasındaki En Yüksek Korelasyon Katsayıları

Değişken	Point-Biserial	Eta	Değişken	Point-Biserial	Eta
Metastaz Durumu	-0,493	0,243	Metastaz Yeri	0,414	0,265
Kitle Dansitesi	0,210	0,046	HER2	-0,227	0,078
Ki-67	-0,284	0,082	ER	-0,283	0,129
Moleküler Tip	-0,153	0,160	Histolojik Grade	-0,199	0,040
Mitotik Derece	-0,199	0,040	Kitle Konturu	0,123	0,028

Tüm değişkenlere ait korelasyon örüntüsü sı haritasında sunulmuştur (Şekil 12). Sı haritası, metastaz durumu ve metastaz yeri değişkenlerinin RCB skoru ile en belirgin ilişkiyi sergilediğini göstermiştir. Diğer değişkenlerin büyük bölümünde korelasyon katsayıları düşük veya sınırlı düzeyde kalmıştır.



Şekil 12. RCB Skoru ile Klinik, Histopatolojik ve Radyolojik Parametreler Arasındaki Korelasyon Isı Haritası

Kategorik değişkenler arasındaki bağımlılık yapısı Cramer's V katsayısı ile değerlendirilmiştir. Bonferroni düzeltmesi sonrasında 887 anlamlı ilişki saptanmıştır. En yüksek ilişki metastaz durumu ile metastaz yeri arasında bulundu (Cramer's $V=0,9742$); en düşük anlamlı değer ise kitle konturu ile multifokalite durumu arasında saptanmıştır (Cramer's $V=0,2513$). Bu ilişkiler Tablo 12 ve Tablo 13'te verilmiş, genel dağılım Şekil 13'te ve Cramer's $V > 0,40$ düzeyindeki ilişkiler ağ grafiğinde Şekil 14'te gösterilmiştir.

Tablo 12


En Yüksek 20 Cramer's V Korelasyon Çifti (Bonferroni anlamlı)

Değişken 1	Değişken 2	Cramer's V
Metastaz durumu	Metastaz yeri	0,9742
Hangi meme	Yaş grubu	0,8160
HER2	Moleküler tip	0,7696
Ameliyat öyküsü	Kozmetik implant	0,7188
Lezyon türü	Mimari yapı	0,6944
Osteoporoz	Depresyon	0,6639
ER	Moleküler tip	0,6122
Moleküler tip	Ki-67	0,5850
BI-RADS değeri	Kitle şekli	0,5724
Nükleer derece	Histolojik grade	0,5451
BI-RADS değeri	Lezyon türü	0,5096
BI-RADS değeri	Mimari yapı	0,5035
BI-RADS değeri	Kitle konturu	0,4969
Lezyon türü	Asimetri	0,4939
Mitotik derece	Histolojik grade	0,4738
Kalsifikasyon morfolojisi	Kalsifikasyon dağılımı	0,4592
ER	PR	0,4528
Ki-67	E-kaderin	0,4520
Metastaz yeri	Tanı evresi	0,4496
HT	DM	0,4481


Tablo 13

En Düşük 20 Cramer's V Korelasyon Çifti (Bonferroni anlamlı)


Değişken 1	Değişken 2	Cramer's V
Kitle konturu	Multifokalite durumu	0,2513
Kitle konturu	Asimetri	0,2635
Nükleer derece	Mitotik derece	0,2636
Meme dansitesi	Lezyon türü	0,2645
Ki-67	Histolojik grade	0,2682
BI-RADS değeri	Multifokalite durumu	0,2731
Lezyon türü	Kalsifikasyon morfolojisi	0,2772
Hangi meme	Meme dansitesi	0,2807
Lezyon türü	Kitle dansitesi	0,2820
Meme dansitesi	Kitle dansitesi	0,2820
Lokalizasyon	Multifokalite durumu	0,2848
Kitle şekli	Kitle dansitesi	0,2870
Kitle dansitesi	Asimetri	0,2871
ER	Mitotik derece	0,3084
Ki-67	Nükleer derece	0,3100
Lezyon türü	Kalsifikasyon dağılımı	0,3112
Ki-67	Mitotik derece	0,3161
CEA	TSH	0,3167
Moleküler tip	Nükleer derece	0,3264
Kitle şekli	Asimetri	0,3368




Şekil 13. Isı Haritası (Kategorik değişkenler arası Cramér's V Korelasyonlarının Dağılımı)




Şekil 15. Kategorik Risk Haritası - 1




Şekil 16. Kategorik Risk Haritası - 2



Şekil 17. Kategorik Risk Haritası - 3



Şekil 18. Kategorik Risk Haritası - 4




Şekil 19. Kategorik Risk Haritası - 5

4.1.7. RCB ve Sağkalım Sonuçları


RCB kategorilerinin prognostik değerini değerlendirmek amacıyla sağkalım analizleri gerçekleştirilmiştir. Çalışmaya dahil edilen 328 hastada ortalama takip süresi 86,2 ay olarak hesaplanmış, genel sağkalım için olay oranı %20,43 (67/328) bulunmuştur. Veri setinde nüks zamanı bilgisi yer almadığından hastalıksız sağkalım analizi yapılamamış; bu alt bölümde yalnızca genel sağkalım sonuçları sunulmuştur.

Kaplan–Meier analizi ilk olarak ikili sınıflama üzerinden değerlendirilmiştir. RCB-0 grubu ile RCB-I/II/III birleşik grubu karşılaştırıldığında log-rank testi sonucunda gruplar arasında anlamlı fark saptanmamıştır ($p=0,1308$). RCB-0 grubunda medyan genel sağkalım 164,0 ay; RCB-I/II/III grubunda ise 146,0 ay olarak hesaplanmıştır. Beş yıllık genel sağkalım oranları sırasıyla %93,1 ve %92,4 bulunmuştur. İkili eğriler Grafik 11’de sunulmuştur.



Grafik 11. RCB-0 (pCR) vs RCB I/II/III OS Kaplan-Meier Eğrileri

Dört kategorili Kaplan–Meier analizinde de RCB-0, RCB-I, RCB-II ve RCB-III grupları arasında genel sağkalım açısından anlamlı fark izlenmemiştir ($p=0,2668$). RCB-I grubunda medyan genel sağkalım hesaplanamamış; 5 yıllık genel sağkalım oranları sırasıyla %93,1, %89,9, %93,5 ve %91,3 olarak bulunmuştur. Dört kategorili sağkalım istatistikleri ise Grafik 12’de sunulmuştur.



Grafik 12. RCB Kategorilerine Göre OS Kaplan-Meier Eğrileri

RCB kategorisinin genel sağkalım üzerindeki bağımsız etkisi çok değişkenli Cox regresyon analizi ile ayrıca değerlendirilmiştir. Modele RCB kategorisi sürekli değişken olarak ve tanı yaşı birlikte dahil edilmiştir. RCB kategorisi için hazard oranı 1,119 (%95 GA: 0,897–1,397; $p=0,318$) bulunmuş, tanı yaşı için ise hazard oranı 1,027 (%95 GA: 1,006–1,049; $p=0,011$) hesaplanmıştır. Çok değişkenli Cox regresyon sonuçları Tablo 14’te sunulmuştur.

Tablo 14

Çok Değişkenli Cox Regresyon Analizi Sonuçları (OS)

Değişken	HR	95% GA	p
RCB Kategorisi (sürekli)	1.119	0.897-1.397	0.318
Tanı Yaşı (1 yıl artış)	1.027	1.006-1.049	0.011

HR: Hazard ratio; GA: Güven aralığı; OS: Genel sağkalım; p: p-değeri (istatistiksel anlamlılık düzeyi)

Bu bulgular, incelenen kohortta RCB’nin genel sağkalım açısından bağımsız ve güçlü bir belirleyici olarak doğrulanmadığını; buna karşılık tanı yaşının bağımsız etkisini koruduğu göstermektedir.

4.2. Neoadjuvan Yanıtın Klinikopatolojik Belirteçlerle Öngörülmesi: İkili ve Çoklu Lojistik Regresyon Yaklaşımı

4.2.1. Değişkenlerin Önem Skorlarına Göre Kategorize Edilmiş Özeti

Bu alt bölümde, pCR ile ilişkili olabilecek 64 bağımsız değişken tek değişkenli düzeyde değerlendirilmiş ve değişkenlerin pCR ayrıştırıcılığı önem skorlaması çerçevesinde sistematik biçimde sıralanmıştır. Değişkenlerin yalnızca istatistiksel anlamlılık düzeylerine göre değil, aynı zamanda etki büyüklüğü, model katkısı ve klinik uygulanabilirlik düzeylerine göre önceliklendirilebilmesi amacıyla, **Gereç ve Yöntem bölümünde tanımlanan** dört bileşenli değişken önem skorlama sistemi kullanılmıştır. Bu sistem kapsamında değişkenler toplam 0–9 puan aralığında değerlendirilmiş; çok güçlü (9), güçlü (7-8), orta, (5-6) zayıf (3-4) ve etkisiz (0-2) öngörücü sınıflarına ayrılmıştır.

Analiz sonucunda önem skoru ≥ 7 olan 17 değişken güçlü/çok güçlü öngörücü bandında, önem skoru ≥ 5 olan toplam 20 değişken ise orta ve üzeri öngörücü bandında yer almıştır. Bu değişkenler çoklu lojistik regresyon modeli için öncelikli aday değişken havuzunu oluşturmuştur.

Her değişken için kategori bazında hasta dağılımı ve pCR oranları ile tek değişkenli lojistik regresyon katsayıları, odds oranları ve %95 güven aralıkları ilgili alt tablolarda sunulmuştur.

4.2.1.1. Çok Güçlü Öngörücüler (9 puan)

En yüksek önem düzeyinde (9 puan; çok güçlü öngörücü) **ER durumu, PR durumu, Ki-67 indeksi, metastaz durumu ve metastaz yeri** yer almıştır. Bu değişkenler, pCR olasılığını en belirgin biçimde ayrıştıran temel öngörücü kümesini oluşturmuştur. Özellikle hormon reseptör profili ve proliferasyon göstergeleri ile hastalık yayılımını temsil eden metastatik değişkenlerin üst sıralarda yer alması dikkat çekmiştir.

ER durumu, pCR ile güçlü düzeyde ilişkili bulunmuştur. Güçlü pozitif ER grubunda pCR oranı en düşük düzeyde (%14.9) izlenirken, negatif (%48.2) ve zayıf pozitif (%46,2) gruplarda belirgin olarak daha yüksek oranlar saptanmıştır. Pozitif kategorisindeki pCR oranı %50,0 olmakla birlikte, bu gruptaki hasta sayısının oldukça sınırlı olması (n=4) nedeniyle bu bulgu istatistiksel açıdan temkinle yorumlanmalıdır.

ER durumunun *RCB* yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde model anlamlı bulunmuş (Pseudo $R^2=0.107$, LLR $p<0.001$). Referans kategori güçlü pozitif ER grubuna kıyasla, negatif (OR=0.188, $p<0.001$) ve zayıf pozitif (OR=0.203, $p<0.001$) kategorilerinde pCR olasılığı anlamlı düzeyde daha yüksek bulunmuştur. Buna göre, ER negatif hastalarda pCR olasılığı güçlü pozitif gruba göre yaklaşık 5.3 kat ($1/0.188$), zayıf pozitif grupta ise yaklaşık 4.9 kat ($1/0.203$) artmış görünmektedir. Pozitif kategori ise örneklem yetersizliği ve geniş güven aralıkları nedeniyle bireysel olarak anlamlı bulunmamıştır (OR=0.174, $p=0.087$). ER durumu değişkeni 9 puan alarak çok güçlü öngörücü sınıfında yer almış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir. Önem skorlamasında ER durumu, çok yüksek istatistiksel anlamlılık ($p<0.001$), güçlü ters yönlü ilişki düzeyi (OR<0.2) ve anlamlı model açıklayıcılığı (Pseudo $R^2=0.107$) kriterleri doğrultusunda 9 puan alarak “Çok güçlü düzeyde öngörücü” olarak sınıflandırılmış ve çoklu lojistik regresyon modeline dahil edilmiştir.

PR durumu da benzer şekilde güçlü öngörücü özellik göstermiştir. PR negatif hastalık grubunda pCR oranı %43.2 ile en yüksek düzeyde iken, güçlü pozitif grupta bu oran %9.9 ile en düşük düzeyde saptanmıştır. Pozitif kategorisinde pCR oranı %50.0 olarak saptanmış olsa da, hasta sayısının oldukça sınırlı olması ($n=2$) nedeniyle bu bulgu istatistiksel olarak güvenilir kabul edilemez. PR durumunun *RCB* yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0.090$, LLR $p<0.001$). Referans kategori negatif PR grubuna kıyasla güçlü pozitif grupta pCR olasılığı anlamlı düzeyde daha düşük bulunmuştur (OR=0.144, $p<0.001$). Bu bulgu, güçlü PR pozitifliğinin kısmi yanıt olasılığının yaklaşık 6.9 kat ($1/0.144$) arttığını, dolayısıyla güçlü PR pozitif hastalarda patolojik tam yanıt elde edilme odds'unun negatif PR grubuna göre yaklaşık 6.9 kat daha düşük olduğunu göstermektedir. Dolayısıyla güçlü PR pozitifliği, daha düşük patolojik tam yanıt olasılığı ile ilişkili bulunmuştur. Zayıf pozitif (OR=0.444, $p=0.068$) ve pozitif (OR=0.110, $p=0.131$) kategorileri, sınırlı örneklem büyüklükleri ve geniş güven aralıkları nedeniyle bireysel anlamlılığa ulaşmamıştır. Önem skorlaması, PR durumu için çok yüksek istatistiksel anlamlılık ($p<0.001$), güçlü etki büyüklüğü ($1/OR>5$) ve orta düzey model açıklayıcılığı (Pseudo $R^2=0.090$) sonucunda toplamda

9 puanla “Çok güçlü düzeyde öngörücü” kategorisine işaret etmiş ve PR değişkeni çoklu lojistik regresyon modeline alınmıştır.

Ki-67 indeksine göre pCR oranları belirgin bir doz-yanıt ilişkisi göstermiştir. Yüksek proliferasyon indeksine sahip tümörlerde pCR oranı %37.7 iken, orta ve düşük kategorilerde bu oran sırasıyla %26.1 ve %3.9 olarak saptanmıştır. Hasta grubunun yaklaşık yarısından fazlasını (%55.8) yüksek Ki-67 kategorisi oluşturmaktadır. İkili lojistik regresyon analizinde Ki-67 indeksinin *pCR öngörüsünde* anlamlı olduğu gösterilmiştir (Pseudo $R^2=0.100$, LLR $p<0.001$). Referans kategori olan yüksek Ki-67 grubuna kıyasla düşük Ki-67 grubunda pCR olasılığı anlamlı ve çarpıcı düzeyde azalmıştır (OR=14.728, $p<0.001$). Bu değer, düşük proliferasyonlu tümörlerde kısmi yanıt olasılığının yaklaşık 14.7 kat arttığını, dolayısıyla pCR olasılığının benzer oranda azaldığını düşündürmektedir. Orta düzey Ki-67 kategorisi (OR=1.716, $p=0.086$) ise istatistiksel açıdan anlamlılık eşiğinin üzerinde kalmış, yalnızca eğilim düzeyinde bir artış göstermiştir. Ki-67 indeksi, önem skorlamasında çok yüksek istatistiksel anlamlılık, çok güçlü etki büyüklüğü (OR>10) ve kayda değer model açıklayıcılığı (Pseudo $R^2\approx 0.100$) nedeniyle toplam 9 puan almış ve “Çok güçlü öngörücü” kategorisinde değerlendirilerek çoklu lojistik regresyon modeline dahil edilmiştir.

Metastaz durumuna göre pCR oranları, metastazı olan hastalarda %14.6, metastazı olmayan grupta ise %48.8 olarak saptanmıştır. Hasta grubunun yaklaşık üçte ikisini metastazı olan hastalar (%62.5, $n=205$) oluşturmaktadır. Metastaz durumunun RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak oldukça anlamlı olduğu görülmüştür (Pseudo $R^2=0.115$, LLR $p=2.785\times 10^{-11}$). Referans kategori Referans kategori olan metastaz varlığına kıyasla, metastaz bulunmayan hastalarda pCR olasılığı anlamlı ve belirgin düzeyde artmaktadır (OR=5.556, $p<0.001$). Bu bulgu, metastazı olmayan hastalarda patolojik tam yanıt olasılığının metastazı olan hastalara göre yaklaşık 5.6 kat daha yüksek olduğunu göstermektedir. Önem skorlamasında metastaz durumu, çok yüksek istatistiksel anlamlılık, güçlü ilişki gücü (OR>5) ve kayda değer model açıklayıcılığı (Pseudo $R^2=0.115$) nedeniyle toplam 9 puan alarak “Çok güçlü öngörücü” kategorisinde değerlendirilmiş ve çoklu lojistik regresyon modeline dahil edilmiştir.

Metastaz yeri dağılımında hasta grubunun çoğunluğunu (%58.8, $n=193$) lenf nodu metastazı olan hastalar oluşturmakta; pCR oranları dermal lenfatik tutulumda %0.0,

uzak metastazda %14.3, lenf nodu metastazında %14.0, metastaz olmayan grupta ise %49.6'dır. Dermal lenfatik ve uzak metastaz gruplarında hasta sayısının oldukça sınırlı olduğu (sırasıyla n=3 ve n=7) dikkate alınmalıdır. Metastaz yerinin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde model genel olarak anlamlı bulunmuştur (Pseudo $R^2=0.130$, LLR $p=7.29 \times 10^{-11}$). Referans kategori Lenf Nodu'na kıyasla metastazı olmayan hastalarda pCR olasılığı anlamlı düzeyde artmıştır (OR=6.051, $p<0.001$). Bu bulgu, metastazı olmayan olgularda pCR olasılığının lenf nodu metastazı olanlara göre yaklaşık 6.1 kat daha yüksek olduğunu göstermektedir. Uzak metastaz (OR=1.025, $p=0.982$) kategorisi anlamlılık göstermemiş; dermal lenfatik grup ise çok küçük örneklem ve hiç pCR olmaması nedeniyle complete separation'a bağlı olarak güvenilir OR hesaplamasına elverişli olmamıştır. Önem skorlamasında metastaz yeri değişkeni, çok yüksek istatistiksel anlamlılık, güçlü ilişki gücü (OR>5) ve anlamlı model açıklayıcılığı (Pseudo $R^2=0.130$) ile 9 puan alarak "Çok güçlü öngörücü" kategorisinde değerlendirilmiş ve çoklu lojistik regresyon modeline dahil edilmiştir.

Çok güçlü öngörücü kategorisinde sınıflanan değişkenlere (ER durumu, PR durumu, Ki-67 indeksi, metastaz durumu ve metastaz yeri) ait tek değişkenli lojistik regresyon sonuçları Tablo 15'te, bu değişkenlerin önem skoru değerlendirmesi ise Tablo 16'da toplu olarak sunulmuştur.

Tablo 15

Çok Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

	n	pCR (iyi yanıt) n (%)	non-pCR (kısmi yanıt) n (%)	B	Std. hata	Wald (z)	p	OR	%95 GA
ER durumu									
Güçlü pozitif (referans)	202	30 (14.9)	172 (85.1)	—	—	—	—	1.00	—
Negatif	83	40 (48.2)	43 (51.8)	- 1.6740	0.296	-5.662	<.001	0.188	[0.105, 0.335]
Zayıf pozitif	39	18 (46.2)	21 (53.8)	- 1.5921	0.377	-4.220	<.001	0.203	[0.097, 0.426]
Pozitif*	4	2 (50.0)	2 (50.0)	- 1.7463	1.019	-1.713	.087	0.174	[0.024, 1.286]
Toplam / sabit	328	90 (27.4)	238 (72.6)	1.7463	0.198	8.826	<.001	5.733	[3.890, 8.449]
PR durumu									
Negatif (referans)	139	60 (43.2)	79 (56.8)	—	—	—	—	1.00	—
Zayıf pozitif	106	21 (19.8)	85 (80.2)	- 0.8129	0.445	-1.826	.068	0.444	[0.185, 1.061]
Güçlü pozitif	81	8 (9.9)	73 (90.1)	- 1.9359	0.410	-4.723	<.001	0.144	[0.065, 0.322]
Pozitif*	2	1 (50.0)	1 (50.0)	- 2.2110	1.462	-1.512	.131	0.110	[0.006, 1.926]

Tablo 15 (Devamı)

Çok Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

Toplam / sabit	328	90 (27.4)	238 (72.6)	2.2110	0.372	5.937	<.001	9.125	[4.398, 18.934]
Ki-67 indeksi									
Yüksek (referans)	183	69 (37.7)	114 (62.3)	—	—	—	—	1.00	—
Orta	69	18 (26.1)	51 (73.9)	0.5394	0.314	1.719	.086	1.716	[0.929, 3.172]
Düşük	76	3 (3.9)	73 (96.1)	2.6898	0.609	4.420	<.001	14.728	[4.468, 48.555]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-0.5021	0.153	-3.292	.001	0.605	[0.449, 0.816]
Metastaz durumu	n	pCR (iyi yanıt) n (%)	non-pCR (kısmi yanıt) n (%)	B	Std. hata	Wald (z)	p	OR	%95 GA
Var (referans)	205	30 (14.6)	175 (85.4)	—	—	—	—	1.00	—
Yok	123	60 (48.8)	63 (51.2)	1.7148	0.268	6.409	<.001	5.556	[3.287, 9.391]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.7636	0.198	-8.925	<.001	0.171	[0.117, 0.252]
Metastaz yeri									
Lenf nodu (referans)	193	27 (14.0)	166 (86.0)	—	—	—	—	1.00	—
Yok	125	62 (49.6)	63 (50.4)	1.8002	0.274	6.570	<.001	6.051	[3.546, 10.328]
Uzak metastaz	7	1 (14.3)	6 (85.7)	0.0244	1.100	0.022	.982	1.025	[0.119, 8.845]
Dermal lenfatik*	3	0 (0.0)	3 (100.0)	-26.7662	9.29×10 ⁵	-0.000	1.000	0.000	[0.000, inf]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.8162	0.208	-8.752	<.001	0.163	[0.108, 0.244]

Not:

1. OR: Odds ratio; GA: Güven aralığı; pCR: Patolojik tam yanıt.
2. McFadden Pseudo R² değerleri sırasıyla ER=0.107, PR=0.090, Ki-67=0.100, Metastaz durumu=0.115, Metastaz yeri=0.130
3. *Küçük örneklem büyüklüğü nedeniyle temkinli yorumlanmalıdır.
4. Dermal lenfatik grupta complete separation nedeniyle güvenilir OR tahmini elde edilememiştir.

Tablo 16

Çok Güçlü Düzeyde Öngörücü Değişkenlerin Önem Skoru Değerlendirmesi

Değişken	İstatistiksel	İlişki gücü	Model	Klinik	Genel
ER	3	3	1	2	9
PR	3	3	1	2	9
Ki-67	3	3	1	2	9
Metastaz	3	3	1	2	9
Metastaz Yeri	3	3	1	2	9

Not.

¹ En küçük p-değeri < .001 (çok yüksek anlamlılık).² En büyük anlamlı etki (<0.2, güçlü ters ilişki veya >5, güçlü ilişki).³ Pseudo R² durumu ve LLR p < .01.⁴ Temel parametre olarak tanımlandı**4.2.1.2. Güçlü Öngörücüler (7-8 puan)**

Güçlü öngörücü sınıfında (7–8 puan), pCR öngörüsüne anlamlı katkı sağlayan çok sayıda klinikopatolojik ve radyolojik değişken yer almıştır. Bu grupta Histolojik Tip, HER2 durumu, moleküler tip, histolojik tip, histolojik tip, nükleer derece, mitotik derece, TIL düzeyi ve tanı evresi gibi klinikopatolojik değişkenler öne çıkmıştır. Ayrıca radyolojik değişkenlerden kitle konturu, kitle şekli, kitle dansitesi ve kalsifikasyon morfolojisi de bu grupta yer almıştır. Bu bulgu, görüntüleme parametrelerinin tedavi yanıtı öngörüsüne katkı sağlayabileceğini göstermektedir.

Histolojik tip dağılımında en sık görülen alt tip invaziv duktal karsinom olup, en yüksek pCR oranı da bu grupta izlenmiştir (%35.8). İkili lojistik regresyon analizinde, referans kategori olan nvaziv duktal karsinoma kıyasla, mikst (duktal + lobüler) histoloji (OR=0.305, p=0.005) ve İnvaziv Lobüler Karsinom (OR=0.341, p=0.011) alt tiplerinde patolojik tam yanıt olasılığında anlamlı azalma ile ilişkili bulunmuştur. Diğer nadir histolojik alt tiplerde örneklem sayılarının sınırlı olması nedeniyle istatistiksel olarak anlamlı fark saptanmamıştır. Modelin kısmi açıklayıcılığı sınırlı düzeyde olmakla birlikte (Pseudo R²=0.037), genel model anlamlılığı (LLR p=0.007) histolojik tipin RCB yanıtında bağımsız bir belirleyici olduğunu desteklemektedir. Önem skorlamasında Histolojik Tip değişkeni 7 puan olarak “güçlü öngörücü” kategorisinde yer almış ve çoklu lojistik regresyon modeline dahil edilmiştir.

HER2 durumu, tedavi yanıtı ile güçlü ilişki gösteren değişkenlerden biri olmuştur. En düşük pCR oranı HER2-düşük grupta (%12,5), en yüksek oran HER2 pozitif grupta (%45,5) saptanmıştır. HER2 negatif ve ekvokal kategorilerde pCR oranları sırasıyla %21,1 ve %33,3'tür. Hasta popülasyonunun yaklaşık üçte ikisini HER2 negatif hastalar oluşturmakta olup, bu dağılım kategori karşılaştırmalarında denge ve güç açısından dikkate alınmalıdır. HER2 durumunun RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,054$, LLR $p<0,001$). İkili lojistik regresyon analizinde referans kategori olan HER2 negatif gruba kıyasla, HER2 pozitiflik pCR olasılığını anlamlı düzeyde artırmaktadır (OR=3,120, $p<0,001$); bu bulgu, HER2 pozitif hastalarda patolojik tam yanıt olasılığının negatif gruba kıyasla yaklaşık 3,1 kat daha yüksek olduğunu göstermektedir. HER2-düşük (OR=0,535, $p=0,329$) ve ekvokal (OR=1,872, $p=0,324$) kategorilerinde ise bireysel olarak anlamlılık sağlanamamış; bu sonuçlar özellikle sınırlı örneklem büyüklükleri ve geniş güven aralıkları ile uyumludur. Önem skorlamasında HER2 durumu değişkeni, çok yüksek istatistiksel anlamlılık ($p<0,001$), orta düzey ilişki gücü (OR $\approx$ 3,1) ve anlamlı model açıklayıcılığı (Pseudo $R^2=0,054$) kriterleri doğrultusunda toplamda 8 puan alarak “güçlü öngörücü” olarak sınıflandırılmış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Moleküler alt tiplere göre pCR oranları belirgin heterojenlik göstermiştir. En yüksek pCR oranı HER2-zengin alt tipte (%53,3); bunu sırasıyla triple negatif (%42,1) ve Luminal B (HER2 pozitif) (%39,1) alt tipleri izlemiştir. Luminal A (%5,5) ve HER2-düşük (%4,8) alt tiplerinde pCR oranları belirgin biçimde düşüktür. HER2-düşük grupta yalnızca tek hastada pCR gözlenmesi, bu kategorideki bulguların istatistiksel açıdan temkinle yorumlanmasını gerektirmektedir. Moleküler tipin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,128$, LLR $p<0,001$). Referans kategori Luminal B (HER2 negatif) alındığında, HER2-zengin (OR=4,571, $p<0,001$), triple negatif (OR=2,909, $p=0,009$) ve Luminal B (HER2 pozitif) (OR=2,564, $p=0,008$) alt tipleri pCR olasılığını anlamlı düzeyde artırmaktadır; HER2-zengin alt tipte bu artış yaklaşık 4,6 kat düzeyindedir. Luminal A alt tipinde pCR olasılığı anlamlı biçimde azalmıştır (OR=0,231, $p=0,022$). Ters yönden değerlendirildiğinde, Luminal A'da güçlü pozitif gruba kıyasla pCR olasılığında yaklaşık 4,3 katlık (1/0,231) bir azalma eğilimi söz

konusudur. HER2-düşük alt tipinde anlamlılığa ulaşamaması çok küçük örneklem büyüklüğü ile uyumludur. Önem skorlamasında moleküler tip değişkeni, çok yüksek istatistiksel anlamlılık, orta-yüksek ilişki gücü (özellikle HER2-zengin için $OR > 4$) ve göreceli yüksek model açıklayıcılığı (Pseudo $R^2 = 0,128$) sonucunda toplamda 8 puan alarak “güçlü öngörücü” kategorisine işaret etmiş ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Nükleer dereceye, pCR ile anlamlı ilişki göstermiştir. En yüksek pCR oranı derece 3 tümörlerde (%35,3), en düşük oran ise derece 1 tümörlerde (%8,3) saptanmıştır. Hasta grubunun yaklaşık yarısını derece 3 tümörler oluştururken, derece 1 kategorisi oldukça sınırlı örneklem içermektedir ($n=12$). Nükleer derecenin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2 = 0,031$, LLR $p=0,0025$). Referans kategori derece 3 alındığında, derece 2 tümörler pCR olasılığında anlamlı azalma ile ilişkilidir ($OR=0,461$, $p=0,003$). Ters yönden değerlendirildiğinde, derece 2’de pCR olasılığının derece 3’e göre yaklaşık 2,2 kat ($1/0,461$) daha düşük olduğu söylenebilir. Derece 1 kategorisi düşük OR (0,166) ile belirgin bir azalma eğilimi göstermesine karşın, geniş güven aralığı ve küçük örneklem nedeniyle bireysel olarak anlamlı bulunmamıştır ($p=0,090$). Önem skorlamasında nükleer derece değişkeni, yüksek istatistiksel anlamlılık ($p < 0,01$), orta düzey ilişki gücü ($1/OR \approx 2,2$) ve sınırlı fakat anlamlı model açıklayıcılığı (Pseudo $R^2 = 0,031$) kriterleri doğrultusunda toplamda 7 puan alarak “güçlü öngörücü” olarak sınıflandırılmış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Mitotik derece, artan proliferatif aktivite ile daha yüksek pCR oranları göstermiştir. Derece 1, 2 ve 3 gruplarında pCR oranları sırasıyla %18.5, %29.4 ve %47.1 olarak saptanmıştır. Hasta grubunun yaklaşık yarısından fazlasını mitotik derece 1 tümörler oluşturmaktadır (%52,7). Mitotik derecenin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2 = 0,052$, LLR $p < 0,001$). Referans kategori mitotik derece 1 seçildiğinde, derece 2 için $OR=0,545$ ($p=0,049$) ve derece 3 için $OR=0,254$ ($p < 0,001$) bulunmuştur. Kaba oranların gösterdiği yön ile bu tek değişkenli OR tahminleri arasında uyumsuzluk bulunduğundan, bulgular tablo kodlaması ve referans tanımı ile birlikte temkinle yorumlanmalıdır. Genel model anlamlılığı (LLR $p < 0,001$) mitotik derece

bloğunun olasılığı anlamlı biçimde iyileştirdiğini göstermektedir. Önem skorlamasında mitotik derece değişkeni, yüksek istatistiksel anlamlılık, ilişki gücü ölçütleri ve anlamlı model performansı (Pseudo $R^2=0,052$) sonucunda toplamda 8 puan alarak “güçlü öngörücü” kategorisine yerleştirilmiş ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Histolojik grade, pCR ile güçlü düzeyde ilişkili bulunmuştur. G3 tümörlerde pCR oranı %39.9 ile en yüksek düzeyde izlenirken, G2 grubunda %19.9 ve G1 grubunda %5.3 olarak saptanmıştır. Hasta grubunun yaklaşık yarısından fazlasını G2 tümörler oluştururken, G1 kategorisi görece düşük sayıdadır (n=19). Histolojik grade’in RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,056$, LLR $p<0,001$). Referans kategori G2 alındığında, G3 tümörler pCR olasılığını anlamlı düzeyde artırmaktadır (OR=2,670, $p<0,001$); bu bulgu, yüksek gradeli tümörlerde patolojik tam yanıt olasılığının G2’ye göre yaklaşık 2,7 kat daha yüksek olduğunu göstermektedir. G1 kategorisi düşük OR (0,224) ile olumsuz yönde bir profil sergilemekle birlikte, geniş güven aralığı ve sınırlı örneklem nedeniyle bireysel olarak anlamlı bulunmamıştır ($p=0,152$). Önem skorlamasında histolojik grade değişkeni, çok yüksek istatistiksel anlamlılık ($p<0,001$), orta düzey ilişki gücü (OR $\approx$ 2,7) ve anlamlı model açıklayıcılığı (Pseudo $R^2=0,056$) kriterleri doğrultusunda toplamda 8 puan alarak “güçlü öngörücü” olarak sınıflandırılmış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

TIL seviyesi, pCR ile pozitif yönlü ilişki göstermiştir. $<10\%$, $10\%–50\%$ ve $>50\%$ gruplarında pCR oranları sırasıyla %20.9, %34.2 ve %46.2 olarak saptanmıştır. Hastaların yaklaşık %58,2’si $<10\%$ TIL kategorisinde yer almakta olup, düşük stromal immün infiltrasyon baskın bir dağılım göstermektedir. TIL seviyesinin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,028$, LLR $p=0,0044$). Referans kategori $<10\%$ seçildiğinde, $10\%–50\%$ TIL grubunda pCR olasılığı anlamlı düzeyde artmaktadır (OR=1,965, $p=0,012$); $>50\%$ TIL grubunda ise artış daha belirgindir (OR=3,236, $p=0,007$). Bu bulgular, orta düzey TIL’de pCR olasılığının yaklaşık iki kat, yüksek TIL seviyesinde ise yaklaşık 3,2 kat arttığını göstermektedir. Önem skorlamasında TIL seviyesi değişkeni, yüksek istatistiksel anlamlılık (en küçük $p=0,007$), orta düzey ilişki gücü (OR $\approx$ 3,2) ve düşük–orta düzey model açıklayıcılığı (Pseudo $R^2=0,028$)

sonucunda toplamda 7 puan alarak “güçlü öngörücü” kategorisine işaret etmiş ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Tanı evresine göre pCR oranları geniş bir aralıkta değişmektedir; Evre IIIC’de %100, Evre IIIB’de %0 saptanmıştır. Evre IIA (%37,9) ve Evre IB (%35,3) görece olarak yüksek pCR oranları sergilerken, Evre IIB (%20,4) ve Evre IIIA (%12,1) daha düşüktür. Evre IIIB (n=7, hiç pCR yok) ve Evre IIIC (n=2, tümü pCR) gruplarında complete separation riski ve çok küçük örneklem nedeniyle bulgular temkinle yorumlanmalıdır. Tanı evresinin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,060$, LLR $p=0,0017$). Referans kategori Evre IIA alındığında, Evre IIB (OR=0,420, $p=0,006$) ve Evre IIIA (OR=0,226, $p=0,009$) pCR olasılığını anlamlı düzeyde azaltmaktadır. Ters yönden değerlendirildiğinde, Evre IIIA’da pCR olasılığı Evre IIA’ya göre yaklaşık 4,4 kat ($1/0,226$), Evre IIB’de ise yaklaşık 2,4 kat ($1/0,420$) daha düşüktür. Evre IIIB ve IIIC için güvenilir OR tahmini sınırlıdır; diğer evre kategorileri bireysel olarak anlamlılığa ulaşmamıştır. Önem skorlamasında tanı evresi değişkeni, yüksek istatistiksel anlamlılık (en küçük $p=0,006$), orta düzey ilişki gücü ($1/OR \approx 4,4$) ve anlamlı model açıklayıcılığı (Pseudo $R^2=0,060$) kriterleri doğrultusunda toplamda 7 puan alarak “güçlü öngörücü” olarak sınıflandırılmış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Kitle şekli, radyolojik değişkenler arasında anlamlı ilişki gösteren parametrelerden biri olmuştur. Düzensiz, oval ve yuvarlak kitlelerde pCR oranları sırasıyla %21,7, %34,2 ve %57,1 olarak saptanmıştır. Hasta grubunun yaklaşık %61,9’unu düzensiz, %33,8’ini oval ve %4,3’ünü yuvarlak kitleler oluşturmaktadır. Kitle şeklinin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,030$, LLR $p=0,0033$). Referans kategori düzensiz seçildiğinde, oval kitleler pCR olasılığını anlamlı düzeyde artırmaktadır (OR=1,881, $p=0,016$); yuvarlak kitlelerde bu artış daha belirgindir (OR=4,818, $p=0,005$). Yuvarlak kitlelerde pCR olasılığının düzensiz kitlelere göre yaklaşık 4,8 kat, oval kitlelerde ise yaklaşık 1,9 kat daha yüksek olduğu söylenebilir. Önem skorlamasında kitle şekli değişkeni, anlamlı istatistiksel etki ($p<0,05$), orta düzey ilişki gücü (OR $\approx 4,8$) ve sınırlı fakat anlamlı model açıklayıcılığı (Pseudo $R^2 \approx 0,03$)

sonucunda toplamda 7 puan alarak “güçlü öngörücü” kategorisine işaret etmiş ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Kitle konturu, güçlü radyolojik öngörücüler arasında öne çıkmıştır. Spiküle konturlu lezyonlarda pCR oranı %14.6 ile en düşük düzeyde izlenirken, belirsiz (%50.0), mikrobüle (%36.1) ve düzensiz (%32.8) konturlu lezyonlarda daha yüksek oranlar saptanmıştır. Hasta grubunun belirgin kısmını spiküle kitleler oluşturmaktadır (n=89). Kitle konturunun RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,0395$, LLR $p=0,0043$). Referans kategori spiküle alındığında, belirsiz konturlu kitleler pCR olasılığını anlamlı düzeyde artırmaktadır (OR=5,846, $p=0,004$). Mikrobüle (OR=3,304, $p=0,002$) ve düzensiz konturlu (OR=2,858, $p=0,008$) kitleler de pCR olasılığında anlamlı artış ile ilişkilidir; belirsiz konturda yaklaşık 5,8 kat, mikrobülede 3,3 kat ve düzensiz konturda 2,9 kat daha yüksek pCR olasılığı özetlenebilir. Düzgün kontur için OR=2,010 ($p=0,073$) anlamlılığa yakın bir eğilim göstermektedir. Önem skorlamasında kitle konturu değişkeni, çok yüksek istatistiksel anlamlılık ($p<0,01$), güçlü ilişki gücü (OR>5) ve anlamlı model katkısı (Pseudo $R^2=0,0395$) sonucunda toplamda 8 puan alarak “güçlü öngörücü” olarak sınıflandırılmış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Kitle dansitesine göre pCR oranları yüksek dansiteli kitlelerde %20,1, eş dansiteli kitlelerde %36,4 ve düşük dansiteli kitlede %100,0 olarak saptanmıştır; düşük dansiteli kategori yalnızca tek hastayı (n=1) içermektedir. Popülasyonun yaklaşık %56,1’i yüksek dansiteli, %43,6’sı eş dansiteli kitlelerden oluşmaktadır. Kitle dansitesinin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,0345$, LLR $p=0,0013$). Referans kategori yüksek dansite alındığında, eş dansite pCR olasılığını anlamlı düzeyde artırmaktadır (OR=2,270, $p=0,001$); bu bulgu, eş dansiteli kitlelerde patolojik tam yanıt olasılığının yüksek dansiteli kitlelere göre yaklaşık 2,3 kat daha yüksek olduğunu göstermektedir. Düşük dansiteli tek hasta complete separation nedeniyle güvenilir biçimde değerlendirilememektedir. Önem skorlamasında kitle dansitesi değişkeni, istatistiksel anlamlılık, orta düzey ilişki gücü (OR $\approx$ 2,3) ve anlamlı model katkısı (Pseudo $R^2=0,0345$) kriterleri doğrultusunda toplamda 7 puan alarak “güçlü öngörücü” kategorisine işaret etmiş ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Kalsifikasyon morfolojisi, pCR ile sınırlı ancak anlamlı ilişki göstermiştir. pCR oranları kalsifikasyon olmayan hastalarda %30,7; pleomorfik, ince lineer, amorf, kesin benign, coarse/popcorn ve yuvarlak/punctate morfolojilerde sırasıyla %14,0, %34,4, %25,8, %9,1, %28,6 ve %50,0 olarak saptanmıştır. Yaklaşık yarısını kalsifikasyon olmayan hastalar oluşturmaktadır (n=176; %53,7). Kalsifikasyon morfolojisinin RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde modelin genel olarak anlamlı olduğu görülmüştür (Pseudo $R^2=0,0339$, LLR $p=0,0419$). Referans kategori “kalsifikasyon yok” alındığında, pleomorfik kalsifikasyonlar pCR olasılığını anlamlı düzeyde azaltmaktadır (OR=0,366, $p=0,032$). Ters yönden değerlendirildiğinde, pleomorfik kalsifikasyon varlığında pCR olasılığının yaklaşık 2,7 kat ($1/0,366$) daha düşük olduğu söylenebilir. Kesin benign kalsifikasyonlarda da azalma eğilimi bulunmakta (OR=0,226, $p=0,050$), ancak bu bulgu sınırda anlamlılık düzeyindedir. Yuvarlak/punctate ve ince lineer morfolojilerde OR>1 olmakla birlikte bireysel anlamlılık sağlanamamıştır. Önem skorlamasında kalsifikasyon morfolojisi değişkeni, anlamlı istatistiksel etki ($p<0,05$), orta düzey ilişki gücü ($1/OR\approx 2,7$) ve sınırlı ama anlamlı model açıklayıcılığı (Pseudo $R^2=0,0339$) sonucunda toplamda 7 puan alarak “güçlü öngörücü” olarak sınıflandırılmış ve çok değişkenli lojistik regresyon modeline dahil edilmiştir.

Güçlü öngörücü kategorisinde sınıflanan değişkenlere ait tek değişkenli lojistik regresyon sonuçları Tablo 17’de, bu değişkenlerin önem skoru değerlendirmesi ise Tablo 18 ve 19’da toplu olarak sunulmuştur.

Tablo 17

Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

	n	pCR n (%)	non-pCR n (%)	B	Std. hata	Wald (z)	p	OR	%95 GA
Histolojik tip									
İnvaziv duktal karsinom (referans)	148	53 (35.8)	95 (64.2)	—	—	—	—	1.00	—
DCIS*	5	2 (40.0)	3 (60.0)	0.1781	0.929	0.192	0.848	1.195	[0.194, 7.379]
Diğer nadir tipler	70	19 (27.1)	51 (72.9)	-0.4038	0.319	-1.267	0.205	0.668	[0.357, 1.247]
Mikst (duktal + lobüler)	55	8 (14.5)	47 (85.5)	-1.1871	0.419	-2.832	0.005	0.305	[0.134, 0.693]
İnvaziv lobüler karsinom	50	8 (16.0)	42 (84.0)	-1.0746	0.422	-2.546	0.011	0.341	[0.149, 0.781]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-0.5836	0.171	-3.404	0.001	0.558	[0.399, 0.781]
HER2 durumu									
Negatif (referans)	204	43 (21.1)	161 (78.9)	—	—	—	—	1.00	—
Pozitif	88	40 (45.5)	48 (54.5)	1.1379	0.274	4.147	<0.001	3.120	[1.822, 5.342]
HER2-düşük	24	3 (12.5)	21 (87.5)	-0.6257	0.641	-0.977	0.329	0.535	[0.150, 1.904]
Ekvokal	12	4 (33.3)	8 (66.7)	0.6271	0.636	0.986	0.324	1.872	[0.538, 6.511]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.3202	0.172	-7.691	<0.001	0.267	[0.191, 0.374]
Moleküler tip									

Tablo 17(Devamı)

Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

Luminal B (HER2 negatif) (referans)	105	21 (20.0)	84 (80.0)	—	—	—	—	1.00	—
Luminal B (HER2 pozitif)	64	25 (39.1)	39 (60.9)	0.9416	0.354	2.662	0.008	2.564	[1.281, 5.132]
Luminal A	55	3 (5.5)	52 (94.5)	-1.4663	0.642	-2.284	0.022	0.231	[0.065, 0.812]
HER2-zengin	45	24 (53.3)	21 (46.7)	1.5198	0.386	3.940	<0.001	4.571	[2.147, 9.735]
Triple negatif	38	16 (42.1)	22 (57.9)	1.0678	0.409	2.609	0.009	2.909	[1.305, 6.489]
HER2-düşük	21	1 (4.8)	20 (95.2)	-1.6094	1.053	-1.528	0.127	0.200	[0.025, 1.576]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.3863	0.244	-5.682	<0.001	0.250	[0.155, 0.404]
Nükleer derece									
Derece 3 (referans)	167	59 (35.3)	108 (64.7)	—	—	—	—	1.00	—
Derece 2	149	30 (20.1)	119 (79.9)	-0.7733	0.261	-2.967	0.003	0.461	[0.277, 0.769]
Derece 1	12	1 (8.3)	11 (91.7)	-1.7933	1.057	-1.697	0.090	0.166	[0.021, 1.321]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-0.6046	0.162	-3.735	<0.001	0.546	[0.398, 0.751]
Mitotik derece									
Derece 1 (referans)	173	32 (18.5)	141 (81.5)	—	—	—	—	1.00	—
Derece 2	85	25 (29.4)	60 (70.6)	-0.6076	0.308	-1.971	0.049	0.545	[0.298, 0.997]
Derece 3	70	33 (47.1)	37 (52.9)	-1.3686	0.309	-4.425	<0.001	0.254	[0.139, 0.467]

Tablo 17(Devamı)

Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

Toplam / sabit	328	90 (27.4)	238 (72.6)	1.4830	0.196	7.574	<0.001	4.406	[3.002, 6.468]
Histolojik grade									
G2 (referans)	171	34 (19.9)	137 (80.1)	—	—	—	—	1.00	—
G1	19	1 (5.3)	18 (94.7)	-1.4968	1.045	-1.432	0.152	0.224	[0.029, 1.736]
G3	138	55 (39.9)	83 (60.1)	0.9821	0.259	3.796	<0.001	2.670	[1.609, 4.433]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.3936	0.192	-7.274	<0.001	0.248	[0.171, 0.361]
TIL seviyesi									
<%10 (referans)	191	40 (20.9)	151 (79.1)	—	—	—	—	1.00	—
%10–%50	111	38 (34.2)	73 (65.8)	0.6755	0.268	2.524	0.012	1.965	[1.163, 3.321]
>%50	26	12 (46.2)	14 (53.8)	1.1742	0.432	2.720	0.007	3.236	[1.388, 7.539]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.3284	0.178	-7.470	<0.001	0.265	[0.187, 0.375]
Tanı Evresi									
Evre IIA (referans)	103	39 (37.9)	64 (62.1)	—	—	—	—	1.00	—
Evre IA	58	17 (29.3)	41 (70.7)	-0.3850	0.353	-1.091	0.275	0.680	[0.341, 1.358]
Evre IB	17	6 (35.3)	11 (64.7)	-0.1108	0.547	-0.203	0.839	0.895	[0.307, 2.614]
Evre IIB	103	21 (20.4)	82 (79.6)	-0.8669	0.318	-2.727	0.006	0.420	[0.225, 0.783]

Tablo 17 (Devamı)

Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

Evre IIIA	33	4 (12.1)	29 (87.9)	-1.4857	0.571	-2.603	0.009	0.226	[0.074, 0.693]
Evre IIIB*	7	0 (0.0)	7 (100.0)	-20.9518	1.715×10^4	≈ 0	0.999	0.000	[0.000, ∞]
Evre IIIC*	2	2 (100.0)	0 (0.0)	21.2024	2.22×10^4	≈ 0.001	0.999	1.615×10^9	[0.000, ∞]
Evre IV*	5	1 (20.0)	4 (80.0)	-0.8910	1.136	-0.784	0.433	0.410	[0.044, 3.806]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-0.4953	0.203	-2.438	0.015	0.609	[0.409, 0.907]
Kitle Şekli									
Düzensiz (referans)	203	44 (21.7)	159 (78.3)	—	—	—	—	1.00	—
Oval	111	38 (34.2)	73 (65.8)	0.6318	0.263	2.405	0.016	1.881	[1.124, 3.150]
Yuvarlak	14	8 (57.1)	6 (42.9)	1.5724	0.566	2.777	0.005	4.818	[1.587, 14.628]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.2847	0.170	-7.542	<0.001	0.277	[0.198, 0.386]
Kitle Konturu									
Spiküle (referans)	89	13 (14.6)	76 (85.4)	—	—	—	—	1.00	—
Düzgün	86	22 (25.6)	64 (74.4)	0.6979	0.389	1.795	0.073	2.010	[0.938, 4.309]
Mikrolobüle	72	26 (36.1)	46 (63.9)	1.1952	0.388	3.083	0.002	3.304	[1.545, 7.068]
Düzensiz	67	22 (32.8)	45 (67.2)	1.0502	0.397	2.644	0.008	2.858	[1.312, 6.227]
Belirsiz	14	7 (50.0)	7 (50.0)	1.7658	0.613	2.880	0.004	5.846	[1.757, 19.449]

Tablo 17 (Devamı)

Güçlü Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.7658	0.300	-5.883	<0.001	0.171	[0.095, 0.308]
Kitle Dansitesi									
Yüksek dansite (referans)	184	37 (20.1)	147 (79.9)	—	—	—	—	1.00	—
Eş dansite	143	52 (36.4)	91 (63.6)	0.8199	0.253	3.240	0.001	2.270	[1.383, 3.727]
Düşük dansite*	1	1 (100.0)	0 (0.0)	29.4392	1.24×10^6	≈ 0	1.000	0.000	[0.000, ~0.000]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.3795	0.184	-7.500	<0.001	0.252	[0.176, 0.361]
Kalsifikasyon Morfolojisi									
Kalsifikasyon yok (referans)	176	54 (30.7)	122 (69.3)	—	—	—	—	1.00	—
Pleomorfik	43	6 (14.0)	37 (86.0)	-1.0041	0.469	-2.139	0.032	0.366	[0.146, 0.919]
İnce lineer	32	11 (34.4)	21 (65.6)	0.1684	0.407	0.414	0.679	1.183	[0.534, 2.624]
Amorf	31	8 (25.8)	23 (74.2)	-0.2410	0.442	-0.546	0.585	0.786	[0.331, 1.868]
Kesin benign	22	2 (9.1)	20 (90.9)	-1.4875	0.759	-1.959	0.050	0.226	[0.051, 1.001]
Coarse / popcorn	14	4 (28.6)	10 (71.4)	-0.1013	0.614	-0.165	0.869	0.904	[0.272, 3.008]
Yuvarlak / punctate	10	5 (50.0)	5 (50.0)	0.8150	0.653	1.248	0.212	2.259	[0.628, 8.124]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-0.8150	0.163	-4.987	<0.001	0.443	[0.322, 0.610]

Not:

1. OR: Odds ratio; GA: Güven aralığı; pCR: Patolojik tam yanıt.
2. McFadden Pseudo R² değerleri sırasıyla Histolojik tip=0.037, HER2 durumu=0.054, Moleküler tip=0.128, Nükleer derece=0.031, Mitotik derece=0.052, Histolojik grade=0.056, TIL seviyesi=0.028, Tanı evresi=0.060, Kitle şekli=0.030, Kitle konturu=0.040, Kitle dansitesi=0.035, Kalsifikasyon morfolojisi=0.034.
3. *Küçük örneklem büyüklüğüne sahip alt gruplar temkinli yorumlanmalıdır.
4. Çok kategorili değişkenlerde referans gruplar tabloda ayrıca belirtilmiştir.

Tablo 18

Güçlü düzeyde öngörücü Değişkenlerin Önem Skoru Değerlendirmesi (7-8 Puan)

Değişken	İstatistiksel	İlişki gücü (etki)	Model	Klinik önem	Genel Skor
HER2 durumu	3	2	1	2	8
Moleküler Tip	3	2	1	2	8
Mitotoik Derece	3	2	1	2	8
Histolojik Grade	3	2	1	2	8
Kitle Konturu	3	3	1	1	8
Histolojik Tip	2	2	1	2	7
Nükleer Derece	2	2	1	2	7
TIL seviyesi	2	2	1	2	7
Tanı Evresi	2	2	1	2	7
Kitle Şekli	3	2	1	1	7
Kitle dansitesi	3	2	1	1	7
Kalsifikasyon	3	2	1	1	7

¹ En küçük p-değeri < .001 (çok yüksek anlamlılık).

² En büyük anlamlı etki (<0.2, güçlü ters ilişki veya >5, güçlü ilişki).

³ Pseudo R² durumu ve LLR p < .01.

⁴ Temel parametre olarak tanımlandı

Orta düzey öngörücü sınıfta (5–6 puan) BI-RADS kategorisi, E-kaderin durumu, kan grubu ve bazı ek radyolojik parametreler yer almıştır. Buna karşılık yaş, menopoz durumu, vücut kitle indeksi, komorbidite değişkenleri ve çeşitli biyokimyasal parametrelerin tek değişkenli düzeyde daha sınırlı ayırt edici güce sahip olduğu izlenmiştir.

E-kadherin durumuna göre pCR oranları pozitif grupta %29,9, negatif grupta %14,0 olarak saptanmıştır. Hasta grubunun büyük çoğunluğunu E-kadherin pozitif hastalar oluşturmaktadır (%84,8). E-kadherin durumunun RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde genel model sınırda anlamlılık göstermektedir (Pseudo $R^2=0,016$; LLR $p=0,014$). Referans kategori pozitif alındığında, negatif grup için $OR=2,615$ ($p=0,025$) olarak tahminlenmiştir; referans kodlamasına göre bu ifade, negatif kategorideki hastaların pCR odds'unun pozitif referansa kıyasla yaklaşık 2,6 kat olarak modelde görüldüğünü gösterir. Kaba oranlarda pozitif grupta pCR oranının daha yüksek olması ile bu tek değişkenli OR tahmini aynı yönde değildir; bulgular kodlama, konfüzyon veya örneklem yapısı açısından birlikte ve temkinle yorumlanmalıdır. Model açıklayıcılığı düşük düzeydedir (Pseudo $R^2=0,016$); değişkenin katkısı daha çok sınırlı, tek değişken düzeyinde bir etkiyi yansıtmaktadır. Önem skorlamasında E-kadherin durumu; istatistiksel anlamlılık ($p<0,05$), orta düzey ilişki gücü ($OR\approx 2,6$) ve düşük model açıklayıcılığı (Pseudo $R^2=0,016$) dikkate alınarak toplamda 5 puan almış ve “orta düzeyde öngörücü” olarak sınıflandırılmıştır; çok değişkenli modele yalnızca kısmi katkı sağlayan bir parametre olarak konumlandırılmıştır.

Kan grubuna göre pCR oranları A(+) grubunda %21,5, 0(+) grubunda %34,6, B(+) grubunda %21,1, A(-) grubunda %10,0, B(-) grubunda %52,9, 0(-) grubunda %50,0, AB(+) grubunda %36,4 ve AB(-) grubunda %66,7 olarak saptanmıştır. Hasta grubunun en büyük kısmını A(+) hastalar oluşturmaktadır (%45,4; $n=149$). Nadir görülen Rh negatif alt gruplarda (özellikle AB(-), $n=3$) küçük örneklem hacmi, bu gruplara ait pCR oranlarının güvenilirliğini kısıtlamaktadır. Kan grubunun RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde model genel olarak anlamlı bulunmuştur (Pseudo $R^2=0,050$; LLR $p=0,0073$). Referans kategori A(+) alındığında, B(-) ($OR=4,113$; $p=0,007$), 0(-) ($OR=3,656$; $p=0,034$) ve 0(+)

(OR=1,936; $p=0,033$) gruplarında pCR olasılığı anlamlı düzeyde referansa göre daha yüksek odds ile ilişkilendirilmiştir; yorumda B(-) için yaklaşık 4,1 kat, 0(-) için 3,7 kat ve 0(+) için 1,9 katlı referans üstü odds artışı özetlenebilir. AB(-) grubunda OR yüksek olmakla birlikte (7,313), geniş güven aralıkları ve $p>0,05$ ($p=0,109$) nedeniyle istatistiksel anlamlılık sağlanamamıştır. Önem skorlamasında kan grubu değişkeni; istatistiksel anlamlılık ($p<0,01$), orta düzey etki büyüklüğü ($OR\approx 4,1$) ve sınırlı model açıklayıcılığı (Pseudo $R^2=0,050$) doğrultusunda 5 puan almış ve “orta düzeyde öngörücü” kategorisinde yer almıştır.

BI-RADS kategorilerine göre pCR oranları BI-RADS 1’de %0,0, 2’de %20,0, 4A’da %40,7, 4B’de %27,7, 4C’de %25,3, 5’te %20,8 ve kategori 0’da %40,8 olarak saptanmıştır. Hasta grubunun en büyük kısmını BI-RADS 5 hastalar oluşturmaktadır (%36,6; $n=120$). BI-RADS 1 kategorisinde yalnızca bir hasta bulunmakta ve bu grupta pCR gözlenmemiştir. BI-RADS sınıflandırmasının RCB yanıtını öngörmesine yönelik ikili lojistik regresyon analizinde genel model için LLR $p=0,123$ olup, klasik $\alpha=0,05$ anlamlılık eşiğinde genel model anlamlılığı zayıftır; Pseudo $R^2=0,026$ ile açıklayıcılık da sınırlıdır. Referans kategori BI-RADS 5 alındığında, BI-RADS 0 ($OR=2,621$; $p=0,009$) ve BI-RADS 4A ($OR=2,612$; $p=0,033$) kategorileri pCR olasılığını anlamlı düzeyde artırmaktadır; bu sonuçlar, bu iki kategorinin BI-RADS 5’e kıyasla yaklaşık 2,6 kat daha yüksek pCR odds’u ile ilişkili olabileceğini düşündürür. BI-RADS 1 kategorisinde complete separation ($n=1$, hiç pCR yok) nedeniyle güvenilir OR tahmini yapılamamış; diğer ara kategorilerde istatistiksel anlamlılık sağlanamamıştır. Önem skorlamasında BI-RADS sınıflandırması; istatistiksel anlamlılık (en küçük $p=0,009$), orta düzey ilişki gücü ($OR\approx 2,6$) ve sınırlı model açıklayıcılığı (Pseudo $R^2=0,026$) nedeniyle 6 puan almış ve “orta düzeyde öngörücü” kategorisinde değerlendirilmiştir.

Güçlü öngörücü kategorisinde sınıflanan değişkenlere ait tek değişkenli lojistik regresyon sonuçları Tablo 20’de, bu değişkenlerin önem skoru değerlendirmesi ise Tablo 21’de toplu olarak sunulmuştur.

Önem skoru 5’in altında kalan değişkenlere ait tablolar ekler bölümünde “Ek Bölüm 2: Tamamlayıcı İkili Lojistik Regresyon Çıktıları ve Düşük Öngörü Gücüne Sahip Değişkenlerin Betimleyici-Çıkarımsal Tabloları” altında, değişken ve grup adı bazında sistematik biçimde sunulmuştur.

Tablo 19

Orta Düzey Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

Faktör	n	pCR n (%)	non-pCR n (%)	B	Std. hata	Wald (z)	p	OR	%95 GA
E-kadherin durumu									
Pozitif (referans)	278	83 (29.9)	195 (70.1)	—	—	—	—	1.00	—
Negatif	50	7 (14.0)	43 (86.0)	0.9611	0.428	2.245	0.025	2.615	[1.130, 6.051]
Toplam / sabit	328	90 (27.4)	238 (72.6)	0.8542	0.118	7.250	<0.001	2.349	[1.866, 2.957]
Kan grubu									
A+ (referans)	149	32 (21.5)	117 (78.5)	—	—	—	—	1.00	—
0+	78	27 (34.6)	51 (65.4)	0.6604	0.311	2.127	0.033	1.936	[1.053, 3.558]
B+	38	8 (21.1)	30 (78.9)	-0.0253	0.445	-0.057	0.955	0.975	[0.407, 2.336]
A-	20	2 (10.0)	18 (90.0)	-0.9008	0.772	-1.167	0.243	0.406	[0.090, 1.845]
B-	17	9 (52.9)	8 (47.1)	1.4142	0.525	2.692	0.007	4.113	[1.470, 11.517]
0-	12	6 (50.0)	6 (50.0)	1.2964	0.611	2.122	0.034	3.656	[1.104, 12.105]
AB+	11	4 (36.4)	7 (63.6)	0.7368	0.658	1.120	0.263	2.089	[0.576, 7.578]
AB-	3	2 (66.7)	1 (33.3)	1.9896	1.241	1.603	0.109	7.313	[0.642, 83.250]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.2964	0.199	-6.499	<0.001	0.274	[0.185, 0.405]
BI-RADS sınıflandırması									
5 (referans)	120	25 (20.8)	95 (79.2)	—	—	—	—	1.00	—

Tablo 19 (Devamı)

Orta Düzey Öngörücü Kategorisindeki Değişkenlere Göre pCR İçin Tek Değişkenli Lojistik Regresyon Sonuçları (n = 328)

4C	79	20 (25.3)	59 (74.7)	0.2532	0.343	0.739	0.460	1.288	[0.658, 2.523]
0	49	20 (40.8)	29 (59.2)	0.9634	0.367	2.622	0.009	2.621	[1.275, 5.387]
4B	47	13 (27.7)	34 (72.3)	0.3736	0.396	0.943	0.346	1.453	[0.669, 3.158]
4A	27	11 (40.7)	16 (59.3)	0.9603	0.452	2.126	0.033	2.612	[1.078, 6.334]
2	5	1 (20.0)	4 (80.0)	-0.0513	1.140	-0.045	0.964	0.950	[0.102, 8.884]
1	1	0 (0.0)	1 (100.0)	-26.7188	1.24×10 ⁶	-0.000	1.000	0.000	[0.000, ~0.000]
Toplam / sabit	328	90 (27.4)	238 (72.6)	-1.3350	0.225	-5.939	<0.001	0.263	[0.169, 0.409]

*Notlar*¹ E-Kaderin Referans kategori E-kaderin pozitifdir. Model istatistikleri: McFadden Pseudo R² = 0.016; LLR p = .01435.² Kan Grubu Referans kategori A+'dır. Model istatistikleri: McFadden Pseudo R² = 0.050; LLR p = .0073³ BI-RADS Referans kategori 5'tir. Model İstatistikleri: Pseudo R² = 0.026, Model LLR p-değeri = 0.1231.

Tablo 20

Orta Düzeyde Öngörücü Değişkenlerin Önem Skoru Değerlendirmesi (5-6 Puan)

Değişken	İstatistiksel anlamlılık ¹	İlişki gücü (etki büyüklüğü) ²	Model açıklayıcılığı ³	Klinik önem (kullanıcı girdisi) ⁴	Genel Skor
BI-RADS Sınıflandırması	3	2	0	1	6
E-Kaderin Durumu	1	2	1	1	5
Kan Grubu	2	2	1	0	5

¹ En küçük p-değeri < .001 (çok yüksek anlamlılık).² En büyük anlamlı etki (<0.2, güçlü ters ilişki veya >5, güçlü ilişki).³ Pseudo R² durumu ve LLR p < .01.⁴ Temel parametre olarak tanımlandı

Tek değişkenli ikili lojistik regresyon (İLR) analizleri ile uygulanan dört bileşenli önem skora sistemi sonucunda, 64 bağımsız değişken pCR (iyi yanıt; RCB-0) ayrıştırıcılığına göre 0–9 puan aralığında sıralanmış ve öngörü gücü düzeylerine göre sınıflanmıştır (Tablo 22). Bu sınıflama, değişkenlerin yalnızca istatistiksel anlamlılık düzeyini değil; etki büyüklüğünü (OR bandı), tek değişkenli model açıklayıcılığını (McFadden pseudo R² ve LLR p) ve klinik önem girdisini birlikte yansıtan bileşik bir önceliklendirme yaklaşımını yansıtmaktadır.

Skor dağılımı incelendiğinde, en yüksek düzeyde (9 puan; çok güçlü) ER durumu, PR durumu, Ki-67 indeksi, metastaz durumu ve metastaz yeri yer almıştır. Güçlü bantta (8 puan) HER2 durumu, moleküler tip, mitotik derece, histolojik grade ve kitle konturu öne çıkarken; 7 puan düzeyinde histolojik tip, nükleer derece, TIL seviyesi, kitle şekli, kitle dansitesi, kalsifikasyon morfolojisi ve tanı evresi yer almıştır. BI-RADS sınıflandırması 6 puan, E-kadherin durumu ve kan grubu 5 puan ile orta düzey banda yakın sınıflandırılmıştır. Buna karşılık hangi meme, çocukluk çağında güneşten yararlanma, diyabet, osteoporoz ve tiroid hastalığı gibi bazı değişkenler 0 puan bandında kalmıştır (Tablo 22).

Önem skoru ≥ 5 olan değişkenler için referans kategoriye göre en güçlü karşılaştırma düzeyi esas alınarak OR, en düşük p-değeri [p(min)], McFadden pseudo R², LLR p, önem sınıfı ve çoklu modele dahil edilme durumu birlikte özetlenmiştir (Tablo 23). Bu tabloda en baskın örüntü, pCR öngörüsünde tümör biyolojisini temsil eden patolojik/moleküler değişkenlerin öne çıkmasıdır. Özellikle Ki-67 (OR=14.728, p<0.001), metastaz durumu (OR=5.556, p<0.001) ve metastaz yeri (OR=6.051, p<0.001) yüksek ayırt edicilik göstermiştir. HER2 pozitiflik (OR=3.120, p<0.001), HER2-zengin moleküler tip (OR=4.571, p<0.001), G3 histolojik grade

(OR=2.670, $p<0.001$) ve belirsiz kitle konturu (OR=5.846, $p=0.002$) da güçlü öngörücü profili desteklemiştir.

Birlikte değerlendirildiğinde, Tablo 22 değişkenlerin skor-temelli hiyerarşisini; Tablo 23 ise bu hiyerarşinin univariate İLR metrikleriyle analitik karşılığını göstermektedir. Bu iki tablo, çoklu modelleme öncesi değişken önceliklendirmesini yöntemsel ve klinik açıdan tamamlayıcı biçimde özetlemektedir.

Tablo 21

Bağımsız Değişkenlerin Önem Skorlarına Göre Toplu Sıralaması (Değişken Havuzu)

Sıra	Değişken Adı	Puan	Etiket	Kategori	Sıra	Değişken Adı	Puan	Etiket	Kategori	Sıra	Değişken Adı	Puan	Etiket	Kategori
1	ER Durumu	9	Çok Güçlü	Model P	2	PR Durumu	9	Çok Güçlü	Model P	3	Ki-67 İndeksi	9	Çok Güçlü	Model P
4	Metastaz Durumu	9	Çok Güçlü	Model O	5	Metastaz Yeri	9	Çok Güçlü	Model O	6	HER2 Durumu	8	Güçlü	Model P
7	Moleküler Tip	8	Güçlü	Model P	8	Mitotik Derece	8	Güçlü	Model P	9	Histolojik Grade	8	Güçlü	Model P
10	Kitle Konturu	8	Güçlü	Model R	11	Histolojik Tip	7	Güçlü	Model P	12	Nükleer Derece	7	Güçlü	Model P
13	TIL Seviyesi	7	Güçlü	Model P	14	Kitle Şekli	7	Güçlü	Model R	15	Kitle Dansitesi	7	Güçlü	Model R
16	Kalsifikasyon Morfolojisi	7	Güçlü	Model R	17	Tanı Evresi	7	Güçlü	Model O	18	BI-RADS Sınıflandırması	6	Orta	Model R
19	E-Kaderin Durumu	5	Orta	Model P	20	Kan Grubu	5	Orta	Model D	21	Rejim Grubu	4	Zayıf	Model O
22	Asimetri Durumu	3	Zayıf	Model R	23	Kozmetik İmplant	3	Zayıf	Model D	24	Tübül Derecesi	3	Zayıf	Model P
25	Meme Başı Retraksiyonu	2	Etkisiz	Model R	26	ALP Düzeyi	2	Etkisiz	Model B	27	ALT Düzeyi	2	Etkisiz	Model B
28	AST Düzeyi	2	Etkisiz	Model B	29	BUN Düzeyi	2	Etkisiz	Model B	30	CA15-3 Düzeyi	2	Etkisiz	Model B
31	CEA Düzeyi	2	Etkisiz	Model B	32	CRP Düzeyi	2	Etkisiz	Model B	33	Kreatinin Düzeyi	2	Etkisiz	Model B

Tablo 21 (Devamı)

Bağımsız Değişkenlerin Önem Skorlarına Göre Toplu Sıralaması (Değişken Havuzu)

34	LDH Düzeyi	2	Etkisiz	Model B	35	TSH Düzeyi	2	Etkisiz	Model B	36	e-GFR Düzeyi	2	Etkisiz	Model B
37	Meme Dansitesi	2	Etkisiz	Model R	38	Tümör Lokalizasyonu	2	Etkisiz	Model R	39	Lezyon Türü	2	Etkisiz	Model R
40	Mimari Yapı	2	Etkisiz	Model R	41	Kalsifikasyon Dağılımı	2	Etkisiz	Model R	42	Multifokalite Durumu	2	Etkisiz	Model R
43	2 Yıldır Stabil Lezyon	2	Etkisiz	Model R	44	Cilt Çekintisi	2	Etkisiz	Model R	45	Ameliyat Öyküsü	2	Etkisiz	Model D
46	Kür Yoğunluğu	2	Etkisiz	Model O	47	VKI Sınıfı	2	Etkisiz	Model D	48	Yaş Grubu	2	Etkisiz	Model D
49	Menapoz Durumu	1	Etkisiz	Model D	50	Hipertansiyon	1	Etkisiz	Model C	51	KOAH	1	Etkisiz	Model C
52	Sigara Kullanımı	1	Etkisiz	Model C	53	Ailede Meme Kanseri	1	Etkisiz	Model D	54	Depresyon	1	Etkisiz	Model D
55	GGT Düzeyi	1	Etkisiz	Model B	56	Glukoz Düzeyi	1	Etkisiz	Model B	57	HbA1c Düzeyi	1	Etkisiz	Model B
58	Retinopati Varlığı	1	Etkisiz	Model C	59	Nöropati	1	Etkisiz	Model C	60	Hangi Meme	0	Etkisiz	Model D
61	Çocukluk Çağında Güneşten Yararlanma	0	Etkisiz	Model D	62	Diyabet	0	Etkisiz	Model C	63	Osteoporoz	0	Etkisiz	Model C
64	Tiroid Hastalığı	0	Etkisiz	Model C										

Not: Model P=Patoloji, Model R=Radyoloji, Model O=Onkoloji/Klinik, Model B=Biyokimya, Model C=Korbidite, Model D=Demografi.

Tablo 22

Univariate İkili Lojistik Regresyon Analizine Göre pCR Öngörücü Değişkenlerin Önem Sınıflarına Göre Özeti (Skor ≥ 5)

Değişken	En Güçlü Anlamlı Kategori (Ref'e göre)	OR	p(min)	Pseudo R ²	LLR p	Skor	Önem Sınıfı	Çoklu Model
ER Durumu	ER Negatif vs Güçlü Pozitif	0.188 (pCR↑)	<0.001	0.107	<0.001	9	Çok Güçlü	Evet
PR Durumu	Negatif vs Güçlü Pozitif	0.144 (pCR↑)	<0.001	0.090	<0.001	9	Çok Güçlü	Evet
Ki-67 İndeksi	Yüksek vs Düşük	14.728 (pCR↑)	<0.001	0.100	<0.001	9	Çok Güçlü	Evet
Metastaz Durumu	Yok vs Var	5.556 (pCR↑)	<0.001	0.115	<0.001	9	Çok Güçlü	Evet
Metastaz Yeri	Yok vs Lenf Nodu Metastazı	6.051 (pCR↑)	<0.001	0.130	<0.001	9	Çok Güçlü	Evet
HER2 Durumu	Pozitif vs Negatif	3.120 (pCR↑)	<0.001	0.054	<0.001	8	Güçlü	Evet
Moleküler Tip	HER2-Zengin vs Luminal B (HER2-)	4.571 (pCR↑)	<0.001	0.128	<0.001	8	Güçlü	Evet
Mitotik Derece	Derece 1 vs Derece 3	0.254 (pCR↓)	<0.001	0.052	<0.001	8	Güçlü	Evet
Histolojik Grade	G3 vs G2	2.670 (pCR↑)	<0.001	0.056	<0.001	8	Güçlü	Evet
Kitle Konturu	Belirsiz vs Spiküle	5.846 (pCR↑)	0.002	0.0395	0.0043	8	Güçlü	Evet

Tablo 22 (Devamı)

Univariate İkili Lojistik Regresyon Analizine Göre pCR Öngörücü Değişkenlerin Önem Sınıflarına Göre Özeti (Skor ≥ 5)

Histolojik Tip	Mikst vs İnvaziv Duktal Karsinom	0.305 (pCR↓)	0.005	0.037	0.007	7	Güçlü	Evet
Nükleer Derece	Derece 2 vs Derece 3	0.461 (pCR↓)	0.003	0.031	0.0025	7	Güçlü	Evet
TIL Seviyesi	>%50 vs <%10	3.236 (pCR↑)	0.007	0.028	0.0044	7	Güçlü	Evet
Kitle Şekli	Yuvarlak vs Düzensiz	4.818 (pCR↑)	0.005	0.030	0.0033	7	Güçlü	Evet
Kitle Dansitesi	Eş Dansite vs Yüksek Dansite	2.270 (pCR↑)	0.001	0.0345	0.0013	7	Güçlü	Evet
Kalsifikasyon Morfolojisi	Pleomorfik vs Yok	0.366 (pCR↓)	0.032	0.0339	0.0419	7	Güçlü	Evet
Tanı Evresi	Evre IIIA vs Evre IIA	0.226 (pCR↓)	0.009	0.060	0.0017	7	Güçlü	Evet
BI-RADS Sınıflandırması	BI-RADS 0 vs BI-RADS 5	2.621 (pCR↑)	0.009	0.026	0.1231	6	Orta	Hayır
E-Kaderin Durumu	Negatif vs Pozitif	2.615 (pCR↑)	0.025	0.016	0.0144	5	Orta	Hayır
Kan Grubu	B(-) vs A(+)	4.113 (pCR↑)	0.007	0.050	0.0073	5	Orta	Hayır

4.2.2. Çoklu Lojistik Regresyon Analizi Bulguları

Bu bölümde, NAK uygulanan 328 meme kanseri hastasında pCR öngörülmesine yönelik geliştirilen çok değişkenli lojistik regresyon modellerinin bulguları sunulmaktadır. Tek değişkenli ikili lojistik regresyon analizlerden elde edilen önem skorları temel alınarak iki farklı değişken seti (Model 1 ve Model 2) oluşturulmuş ve bu havuzlar üzerinde farklı regülarizasyon stratejileri uygulanarak modellerin ayırt edicilik gücü, genellenebilirliği ve aşırı uyum eğilimleri karşılaştırmalı olarak değerlendirilmiştir.

Modelleme sürecinde, önem skoru ≥ 7 olan değişkenlerden oluşan daha parsimoniyöz yapı **Model 1**, önem skoru ≥ 5 olan değişkenleri içeren daha kapsamlı yapı ise **Model 2** olarak tanımlanmıştır. Her iki model için **L1 (Lasso)** ve **L2 (Ridge)** regülarizasyon yöntemleri uygulanmış; böylece toplam dört farklı model varyasyonu karşılaştırılmıştır. Model performansları ROC-AUC, doğruluk, duyarlılık, özgüllük, pozitif öngörü değeri (PPV), negatif öngörü değeri (NPV), çapraz doğrulama sonuçları ve eğitim-test AUC farkı (AUC gap) kullanılarak çok boyutlu biçimde değerlendirilmiştir. Ayrıca klinik duyarlılığı artırmak amacıyla varsayılan sınıflandırma eşiği (0,50) ile Youden's J indeksine göre belirlenen optimal eşik değerleri karşılaştırılmıştır.

4.2.2.1. Veri Setinin Yapılandırılması ve Değişken Seçimi

Analiz kapsamına alınan 328 hastaya ait veriler, pCR oranını koruyacak şekilde katmanlı (stratifiye) örnekleme yöntemi ile %80 eğitim seti (n=262) ve %20 test seti (n=66) olarak ikiye ayrılmıştır. Tüm veri setindeki pCR oranı %27,4 iken; bu oran eğitim setinde %27,5, test setinde ise %27,3 olarak gerçekleşmiştir (Tablo 56). Eğitim ve test setleri arasında pCR dağılımı açısından istatistiksel olarak anlamlı bir fark saptanmamış ($p>0,05$) ve veri dağılımının homojenliği korunmuştur.

Değişken seçim sürecinde; önem skoru ≥ 7 olan 17 değişken "Model 1" başlangıç havuzuna, önem skoru ≥ 5 olan 19 değişken ise "Model 2" başlangıç havuzuna dahil edilmiştir. Model 1 daha parsimoniyöz (tutumlu), Model 2 ise daha kapsamlı bir değişken yapısına sahiptir.

Tablo 23

Veri Seti Özellikleri ve Eğitim-Test Ayrımı

Özellik	Eğitim Seti	Test Seti	Toplam
Toplam Hasta Sayısı	262	66	328
pCR Sayısı (n, %)	72 (%27,5)	18 (%27,3)	90 (%27,4)
non-pCR Sayısı (n, %)	190 (%72,5)	48 (%72,7)	238 (%72,6)
Model 1 Başlangıç Değişken Sayısı	17	17	17
Model 2 Başlangıç Değişken Sayısı	19	19	19

4.2.2.2. Çoklu Bağlantı (Multicollinearity) Analizi ve Dummy Değişken Kodlama

Modelde yer alan kategorik değişkenler, lojistik regresyon analizine uygunluk sağlamak amacıyla kukla değişken (dummy) kodlaması ile sayısal forma dönüştürülmüştür. Referans kategoriler, en sık gözlenen kategori ve pCR oranları dikkate alınarak belirlenmiştir. Kodlama işlemi neticesinde Model 1 için 50, Model 2 için 63 adet dummy değişken türetilmiştir. Referans kategoriler analiz dışı bırakılarak, diğer kategorilerin katsayıları bu referanslara göre hesaplanmıştır.

Değişkenler arası çoklu doğrusal bağıntı riskini değerlendirmek amacıyla tüm dummy değişkenler için varyans şişme faktörü (Variance Inflation Factor, VIF) hesaplanmıştır. VIF değeri aşırı yüksek olan (örn. ≥ 999) veya hesaplanamaz (inf/nan) çıkan dummy değişkenler, çoğunlukla veri setinde düşük gözlem sayısı (sparse kategori), complete separation veya diğer değişkenlerle yüksek çakışma nedeniyle numerik olarak kararsız (unstable) hale gelmektedir. Bu tür değişkenler, modelin yakınsamasını ve katsayı tahminlerinin güvenilirliğini bozabileceği için analizden çıkarılmıştır.

Bu işlem, referans kategori seçimiyle değil; VIF hesaplaması sırasında ortaya çıkan numerik stabilite sorunlarının giderilmesi amacıyla uygulanmıştır. Sonuç olarak, her iki modelden de 3 değişken tam çoklu doğrusal bağıntı, 2 değişken ise yüksek korelasyon nedeniyle elimine edilmiştir. Böylece nihai modelleme aşamasında **Model 1 için 45, Model 2 için 58** değişken kullanılmıştır (Tablo 25).

Multicollinearity nedeniyle modelden çıkarılan değişkenler Tablo 26'da özetlenmiştir. Bu tabloda, tam çoklu doğrusal bağıntı nedeniyle çıkarılan değişkenler (ER Durumu: Negatif; Moleküler Tip: HER2-Zengin ve Triple Negatif) ile yüksek korelasyon

nedeniyle çıkarılan değişkenler (Metastaz Yeri: Yok ve HER2 Durumu: HER2-düşük) birlikte gösterilmiştir.

Tablo 24

Çoklu Doğrusal Bağıntı Kontrolü Sonuçları

Model	Başlangıç Dummy Değişken Sayısı	Tam Çoklu Doğrusal Bağıntı Nedeniyle Çıkarılan	Yüksek Korelasyon Nedeniyle Çıkarılan	Nihai Değişken Sayısı
Model 1	50	3 değişken	2 değişken	45
Model 2	63	3 değişken	2 değişken	58

Tablo 25

Multicollinearity Nedeniyle Modelden Çıkarılan Değişkenler

Değişken Kodu	Değişken Adı	Kategori	Çıkarılma Gerekçesi / İlişkili Değişken	İstatistiksel Değer
Tam Çoklu Doğrusal Bağıntı (Perfect Multicollinearity)				
i2_cat2	ER Durumu	Negatif	Diğer ER kategorileriyle tam lineer bağımlılık	VIF $\geq$ 999
i5_cat2	Moleküler Tip	HER2-Zengin	Veri setinde yetersiz hasta sayısı / diğer kategorilerle lineer bağımlılık	VIF $\geq$ 999
i5_cat6	Moleküler Tip	Triple Negatif	Veri setinde yetersiz hasta sayısı / veri setinde mevcut olmama olasılığı	VIF $\geq$ 999
Yüksek Korelasyon (High Correlation)				
i14_cat1	Metastaz Yeri	Yok	İlişkili değişken: i13_cat2 (Metastaz Durumu: Yok)	r = 0,974; VIF = 23,13
i4_cat2	HER2 Durumu	HER2-düşük	İlişkili değişken: i6_cat1 (Ki-67 İndeksi: Düşük)	r = 0,931; VIF = 15,77

4.2.2.3. Regülerizasyon Tekniklerinin Karşılaştırılması

Model 1 ve Model 2'nin L1 ve L2 regülerizasyon teknikleri ile oluşturulan dört farklı varyasyonunun performans metrikleri, eşik optimizasyonu ve aşırı uyum analizleri aşağıda sunulmuştur. Her model için GridSearchCV ile optimal C parametresi belirlenmiştir.


Test veri seti üzerindeki analizlerde en yüksek ayırt edicilik gücü, **Model 1-L2** varyantında elde edilmiş olup, test AUC değeri **0,803** olarak hesaplanmıştır. Bu modeli sırasıyla **Model 2-L2 (AUC=0,795)**, **Model 2-L1 (AUC=0,760)** ve **Model 1-L1 (AUC=0,743)** izlemiştir. Modellerin optimal eşik değerlerine göre hesaplanan performans metrikleri Tablo 27'de sunulmuştur.

Tablo 26


Modellerin Performans Karşılaştırması (Optimal Eşik Değerleri ile)

Performans Metriği	Model 1 (Lasso)	Model 1 (Ridge)	Model 2 (Lasso)	Model 2 (Ridge)
Regülerizasyon Tipi	L1	L2	L1	L2
Optimal C Değeri	1.000	0.050	0.500	0.050
Optimal Eşik	0.247	0.277	0.353	0.296
CV AUC (Ort. $\pm$ SS)	0.813 $\pm$ 0.045	0.826 $\pm$ 0.054	0.800 $\pm$ 0.058	0.823 $\pm$ 0.055
Train AUC	0.907	0.882	0.894	0.892
Test AUC	0.743	0.803	0.760	0.795
AUC Gap (Fark)	0.163	0.078	0.134	0.097
Test Accuracy	0.682	0.697	0.727	0.712
Sensitivity	0.611	0.722	0.556	0.667
Specificity	0.708	0.688	0.792	0.729
PPV	0.440	0.464	0.500	0.480
NPV	0.829	0.868	0.826	0.854

Regülerizasyon tekniklerinin Test AUC ve Eğitim-Test AUC farkı (Gap) üzerindeki etkileri Şekil 28’de; modellerin test veri seti üzerindeki ROC eğrileri ise Şekil 29’da sunulmuştur. Görsel değerlendirmede de L2 regülerizasyonunun her iki modelde de L1’e kıyasla daha yüksek AUC ve daha düşük Gap değerleri sağladığı görülmüştür.



Şekil 20. Regularization Etkisi Karşılaştırması



Şekil 21. ROC Eğrileri Karşılaştırması (Tüm Modeller)


4.2.2.4. Eşik Değeri (Threshold) Optimizasyonu

Varsayılan sınıflandırma eşiği olan 0,50 ile her model için Youden's J indeksine göre belirlenen optimal eşik değerlerinin duyarlılık üzerindeki etkileri karşılaştırılmıştır. Optimal eşik kullanımı sonrasında özellikle L2 modellerinde duyarlılıkta belirgin artış gözlenmiştir. Model 1-L2 varyantında duyarlılık 0,056'dan 0,722'ye; Model 2 L2 varyantında ise 0,056'dan 0,667'ye yükselmiştir. Eşik optimizasyonunun performans metriklerine etkisi Tablo 27'de ve Şekil 22'de sunulmuştur.

Tablo 27

Eşik Optimizasyonu ve Performansa Etkisi

Model	Varsayılan Eşik (0.5) Duyarlılık	Optimal Eşik (Youden's J)	Optimal Eşik Duyarlılık	Değişim (Kazanç)
Model 1 L1	0.222	0.247	0.611	+0.389
Model 1 L2	0.056	0.277	0.722	+0.666
Model 2 L1	0.167	0.353	0.556	+0.389
Model 2 L2	0.056	0.296	0.667	+0.611



Şekil 22. Optimal Eşik Karşılaştırması (Default vs Optimal)

4.2.2.5. Çapraz Doğrulama Sonuçları ve Genellenebilirlik

Modellerin genellenebilirliği, 5 katlı stratifiye çapraz doğrulama (5-fold CV) yöntemi ile test edilmiştir. En yüksek ortalama CV AUC değeri 0,826 ($\pm 0,054$) ve en dar %95 güven aralığı (0,772–0,880) Model 1 L2 varyantında hesaplanmıştır (Tablo 29).

Tablo 28

Çapraz Doğrulama Sonuçları

Model	Regülerizasyon	CV AUC (Ortalama)	CV AUC (SS)	CV AUC (%95 GA)
Model 1	L1	0,813	0,045	0,768–0,858
Model 1	L2	0,826	0,054	0,772–0,880
Model 2	L1	0,800	0,058	0,742–0,858
Model 2	L2	0,823	0,055	0,768–0,878


4.2.2.6. Aşırı Uyum (Overfitting) Analizi

Aşırı uyum riskinin değerlendirilmesi amacıyla Eğitim AUC ve Test AUC değerleri arasındaki farklar (AUC Gap) incelenmiştir. En düşük fark 0,078 ile Model 1 L2’de saptanmış, en yüksek fark ise 0,163 ile Model 1 L1’de gözlenmiştir. Aşırı uyum analizi sonuçları Tablo 29 ve Şekil 23’te, modellerin genel performans karşılaştırması ise Şekil 24’te verilmiştir.


Tablo 29

Aşırı Uyum Analizi (Eğitim vs. Test AUC)

Model	Regülerizasyon	Eğitim AUC	Test AUC	AUC Farkı	Aşırı Uyum Riski
Model 1	L1	0,907	0,743	0,163	Orta-Yüksek
Model 1	L2	0,882	0,803	0,078	Düşük
Model 2	L1	0,894	0,760	0,134	Orta
Model 2	L2	0,892	0,795	0,097	Düşük-Orta



Şekil 23. Overfitting Analizi (Train vs Test AUC)



Şekil 24. Model Performans Karşılaştırması (Optimal Eşik ile)

4.2.3. Final Model Seçimi: Model 1 (L2 – Ridge)

Çoklu lojistik regresyon modellerinin performans ölçütleri birlikte değerlendirildiğinde, **Model 1 (L2–Ridge)** varyantı nihai model olarak belirlenmiştir. Bu model, bağımsız test veri setinde elde edilen 0,803 AUC değeri ile tüm aday modeller arasında en iyi düzeyde ayırt edici performans sergilediğini göstermektedir. ROC eğrisi altında kalan alanın 0,80'in üzerinde olması, modelin pCR ve non-pCR olgularını iyi düzeyde ayırt edebildiğini göstermektedir.

Modelin genellenebilirliği açısından çapraz doğrulama sonuçları da destekleyici bulunmuştur. Eğitim verisi üzerinde hesaplanan ortalama **CV AUC değeri $0,826 \pm 0,054$** olup, bu değer test AUC ile uyumlu seyretmesi model performansının farklı veri alt kümelerinde tutarlı olduğunu göstermektedir. Ayrıca çapraz doğrulama ortalaması ile test AUC arasındaki farkın sınırlı kalması (**AUC Gap=0,023**), modelin belirgin bir aşırı uyum eğilimi göstermediğini ve bağımsız veri üzerinde performansını koruyabildiğini düşündürmektedir.

Sınıflandırma performansı açısından değerlendirildiğinde, optimal karar eşiğinde modelin duyarlılığı %72,2, özgüllüğü %68,8 ve genel doğruluk oranı %69,7 olarak hesaplanmıştır. Duyarlılık ve özgüllük değerlerinin birbirine yakın düzeyde seyretmesi, modelin sınıflar arasında dengeli performans sunduğunu desteklemektedir. Model 1'in nihai model olarak seçilmesinde yalnızca performans üstünlüğü değil, aynı zamanda parsimonyöz (tutumlu) model yapısı da etkili olmuştur. Model 1, Model 2'ye göre daha az sayıda başlangıç değişkeni içermesine rağmen benzer hatta daha yüksek performans göstermiştir.

Final model için optimal eşik değeri 0,277 olarak belirlenmiştir. Bu optimal eşik değeri, ROC analizi üzerinden Youden's J istatistiğini (duyarlılık + özgüllük – 1) maksimize edecek şekilde belirlenmiş olup yanlış pozitif ve yanlış negatif sonuçlar arasındaki dengeyi optimize etmeyi amaçlamaktadır.

Final modele ait özet performans metrikleri Tablo 31'de, test veri seti üzerinde optimal eşik değeri (0,277) kullanılarak elde edilen sınıflandırma başarısını gösteren karışıklık matrisi ise Şekil 25'te sunulmuştur.


Tüm performans ölçütleri birlikte değerlendirildiğinde, **Model 1 (L2-Ridge)**; en yüksek test AUC değeri, düşük aşırı uyum riski, dengeli duyarlılık-özellik profili ve daha yalın değişken yapısı nedeniyle pCR öngörüsünde en uygun çok değişkenli lojistik regresyon modeli olarak seçilmiştir.

Tablo 30

Final Model Performans Özeti (Model 1 L2-Ridge)

Metrik	Değer	Yorum
Optimal Eşik (Youden's J)	0,277	Eğitim seti üzerinde belirlenen ve klinik performansı dengeleyen eşik
Test AUC	0,803	İyi düzeyde ayırt edici performans
CV AUC (Ort±SS)	0,826±0,054	Güçlü ve tutarlı genelleme yeteneği
Eğitim AUC	0,882	Modelin eğitim verisi üzerindeki yüksek uyum performansı
AUC Farkı	0,023	Düşük aşırı uyum riski
Test Doğruluk	0,697	%69,7 oranında doğru sınıflandırma
Duyarlılık	0,722	pCR vakalarının %72,2'si doğru tespit edildi
Özellik	0,688	non-pCR vakalarının %68,8'i doğru tespit edildi
Pozitif Öngörü Değeri (PPV)	0,464	Modelin "pCR olacak" dediği hastaların %46,4'ü gerçekten pCR geliştirmiştir
Negatif Öngörü Değeri (NPV)	0,868	Modelin "pCR olmayacak" dediği hastaların %86,8'i gerçekten non-pCR olarak sonuçlanmıştır
Optimal C Parametresi	0,050	GridSearchCV ile saptanan en uygun regülerizasyon gücü

Not: Doğruluk, duyarlılık ve özellik değerleri tabloda oran (0–1) formatında; metin içinde ise yüzde (%) formatında raporlanmıştır



Şekil 25. Test Veri Seti Üzerinde Model 1 L2 (Ridge) için Optimal Eşik Değeri (0,277) Kullanılarak Elde Edilen Karışıklık Matrisi.)

4.2.4. Final Model Katsayıları ve Değişkenlerin Etki Düzeyleri

Final model olarak seçilen **Model 1 (L2–Ridge)** varyantında yer alan değişkenlerin pCR üzerindeki etkileri, regresyon beta katsayıları (β) ve buna karşılık gelen odds oranları (**OR**) üzerinden değerlendirilmiştir.

Mutlak beta katsayılarına göre en yüksek etkiye sahip ilk 15 değişken Tablo 31’de sıralanmıştır. Modelde yer alan tüm değişkenlere ait beta katsayıları ve odds oranları ise “**Ek 3: pCR Öngörüsünde Çoklu Lojistik Regresyon (Final Model: L2-Ridge) Katsayıları ve Odds Oranları**” başlığı altında sunulmuştur.


Tablo 31

Final Modelde En Yüksek Etkiye Sahip İlk 15 Değişken (Mutlak Beta Katsayısına Göre)

Sıra	Değişken Kodu	Beta Katsayı (β)	OR	Kategori Açıklaması	Değişken Adı
1	i13_cat2	0.569	1.767	Metastaz Durumu: Yok (Ref: Var)	Metastaz Durumu
2	i4_cat4	0.355	1.426	HER2 Durumu: Pozitif (Ref: Negatif)	HER2 Durumu
3	i6_cat1	-0.322	0.725	Ki-67 İndeksi: Düşük (Ref: Yüksek)	Ki-67 İndeksi
4	i3_cat4	-0.270	0.763	PR Durumu: Zayıf Pozitif (Ref: Negatif)	PR Durumu
5	i5_cat3	-0.258	0.773	Moleküler Tip: Luminal A (Ref: Luminal B HER2 Neg)	Moleküler Tip
6	i3_cat1	-0.242	0.785	PR Durumu: Güçlü Pozitif (Ref: Negatif)	PR Durumu
7	i56_cat6	-0.231	0.794	Kalsifikasyon Morfolojisi: Pleomorfik	Kalsifikasyon Morfolojisi
8	i55_cat2	0.268	1.308	Kitle Dansitesi: Eş Dansite (Ref: Yüksek Dansite)	Kitle Dansitesi
9	i15_cat3	0.225	1.253	Tanı Evresi: Evre IIA (Ref: Evre IIB)	Tanı Evresi
10	i10_cat3	0.214	1.239	Histolojik Grade: G3 (Ref: G2)	Histolojik Grade
11	i5_cat5	0.177	1.193	Moleküler Tip: Luminal B HER2 Pozitif	Moleküler Tip
12	i12_cat3	0.142	1.152	TIL Seviyesi: >%50 (Ref: <%10)	TIL Seviyesi
13	i53_cat2	-0.147	0.863	Kitle Şekli: Oval (Ref: Düzensiz)	Kitle Şekli
14	i8_cat2	-0.134	0.875	Nükleer Derece: 2 (Ref: 3)	Nükleer Derece
15	i2_cat4	0.116	1.123	ER Durumu: Zayıf Pozitif (Ref: Güçlü Pozitif)	ER Durumu

Analiz bulgularına göre, pCR olasılığı ile en güçlü pozitif ilişkili değişkenler “Metastaz Durumu: Yok” ($\beta=0,569$; OR=1,767) ve “HER2 Durumu: Pozitif” ($\beta=0,355$; OR=1,426) olarak saptanmıştır. Buna karşılık, pCR olasılığı ile en güçlü negatif ilişkili değişkenler “Ki-67 İndeksi: Düşük” ($\beta=-0,322$; OR=0,725), “PR Durumu: Zayıf Pozitif” ($\beta=-0,270$; OR=0,763) ve “Moleküler Tip: Luminal A” ($\beta=-0,258$; OR=0,773) olarak belirlenmiştir.

Değişkenlerin etki yönleri ve büyüklükleri Şekil 22’de görselleştirilmiştir. Şekil incelendiğinde, metastaz durumu ve HER2 pozitifliğinin en güçlü pozitif katkıyı sağladığı; düşük Ki-67, Luminal A fenotipi ve progesteron reseptör pozitifliğinin ise daha düşük pCR olasılığı ile ilişkili olduğu görülmektedir.



Şekil 26. Değişkenlerin Etki Düzeyleri (Beta Katsayıları)

4.3. Makine Öğrenmesi Kapsamında Modüler ve Kademeli Modelleme Yaklaşımı

Bu bölümde, neoadjuvan kemoterapi sonrası rezidüel kanser yükü (Residual Cancer Burden, RCB) kategorisini öngörmek amacıyla geliştirilen modüler ve kademeli makine öğrenmesi modellerine ilişkin bulgular sunulmaktadır.

Toplam 328 hastadan oluşan kohort, sınıf dağılımı korunacak biçimde %80 eğitim (n=262) ve %20 test (n=66) olarak ayrılmış; RCB-0, RCB-I, RCB-II ve RCB-III sınıflarının dağılımı iki kümede mümkün olduğunca dengeli tutulmuştur. Analitik çerçeve, patolojik (P), onkolojik (O), demografik (D), komorbidite (K), biyokimyasal (B) ve radyolojik (R) veri bloklarının tekil ve kademeli birleşimlerinin etkilerini karşılaştıracak şekilde yapılandırılmıştır.

Bu kapsamda Model P, Model O, Model P+O, Model D, Model P+O+D, Model K, Model P+O+D+K, Model B, Model P+O+D+K+B, Model R ve tüm blokların birleşimini temsil eden Model ALL değerlendirilmiştir. Her model için Random Forest, XGBoost ve LightGBM algoritmaları SMOTE uygulanmış ve uygulanmamış senaryolarda karşılaştırılmış; en uygun konfigürasyon test ROC-AUC, test macro-F1, çapraz doğrulama performansı, CV-test uyumu ve klinik yorumlanabilirlik birlikte değerlendirilerek belirlenmiştir. Tüm modellere ait karışıklık matrisi, ROC ve precision–recall eğrileri, kalibrasyon analizi, kümülatif kazanç ve lift grafikleri ile SHAP tabanlı özellik önem çıktıları, ana metnin akışını korumak amacıyla **Ek 4 Modüler ve Kademeli Makine Öğrenmesi Modellerine İlişkin Tamamlayıcı Görsel ve Çıktılar** altında model bazında sunulmuştur.

4.3.1. Kademeli Özellik Entegrasyonu ve Model Performansı

Tüm modeller birlikte değerlendirildiğinde, veri bloklarının RCB öngörüsüne katkısının homojen olmadığını göstermiştir. Tekil modeller arasında patolojik değişkenlerle geliştirilen **Model P**'de en iyi test AUC değeri 0.550 olarak elde edilmiş ve bu düzey, patolojik bloğun tek başına sınırlı ayırt edicilik sunduğunu göstermiştir. Buna karşılık yalnız onkolojik özellikleri içeren **Model O**'da test AUC 0.670'e yükselmiş; bu artış, metastaz durumu, metastaz yeri, tanı evresi ve tedavi yoğunluğu gibi klinik değişkenlerin patolojik bloktan daha güçlü bir sinyal taşıdığını göstermiştir.


Patolojik ve onkolojik blokların birleştirildiği **Model P+O**'da test AUC'nin 0.702'ye yükselmesi, bu veri bloklarının tamamlayıcı doğasını ortaya koymaktadır..

Demografik değişkenlerin eklenmesiyle oluşturulan **Model P+O+D**'de en iyi test AUC 0.718 olarak saptanmış ve bu düzey, demografik blokun global performansa marjinal ancak olumlu bir katkı sunduğunu göstermiştir. Buna karşın komorbidite verilerinin eklenmesiyle kurulan **Model P+O+D+K**'da test AUC'nin 0.664'e gerilemesi, bu bloğun entegrasyon düzeyinde yararlı olmaktan çok model karmaşıklığını artırabildiğini düşündürmüştür.

Biyokimyasal blokun tek başına performansı belirgin biçimde sınırlı kalmış; **Model B**'de en iyi test AUC yalnız 0.516 düzeyinde bulunmuştur. P+O+D+K yapısına biyokimyanın eklenmesiyle oluşturulan **Model P+O+D+K+B**'de test AUC 0.669'a yükselse de bu düzey, Model P+O+D performansını aşamamıştır. Buna karşılık yalnız radyolojik özellikleri içeren **Model R**, test AUC 0.838 ile tüm tekil bloklar arasında en yüksek performansı sağlamış; tüm veri bloklarının birlikte değerlendirildiği **Model ALL** de aynı test AUC düzeyine ulaşarak radyolojinin model başarısındaki merkezi rolünü ve entegre yaklaşımın genel denge açısından gücünü ortaya koymuştur.

Bu genel örüntü, özellik seti genişledikçe performansın doğrusal biçimde artmadığını; aksine bazı blokların tamamlayıcı katkı sağlarken bazılarının sınırlı veya karmaşıklık artırıcı etki üretebildiğini göstermektedir. Bu nedenle kademeli entegrasyonun performansa etkisi yalnız test AUC ile değil, test macro-F1 ve CV–test gap göstergeleri birlikte değerlendirilerek ele alınmıştır.

Bu yaklaşım doğrultusunda, model performansının farklı entegrasyon aşamalarındaki değişimini ortaya koymak amacıyla Şekil 23'te kademeli özellik kümelerine göre test AUC, test macro-F1 ve çapraz doğrulama ortalama±standart sapma değerleri birlikte sunulmuştur. Bu görsel, veri entegrasyonunun model performansına etkisini hem ayırt edicilik hem de genellenebilirlik boyutlarıyla karşılaştırmalı olarak özetlemektedir.



Şekil 27. Kademeli özellik kümelerine göre test AUC, test macro-F1 ve CV ortalama±Std değişimi

Tablo 32’de, kademeli model entegrasyonunda en iyi algoritma, SMOTE durumu, test AUC, test macro-F1, CV-test gap birlikte sunulmaktadır. Tablo incelendiğinde, en yüksek performansın Model ALL ve Model R’de elde edildiği; Model ALL’in düşük CV-test gap değeri ile genellenebilirlik açısından en dengeli yapı olarak öne çıktığı, Model R’nin ise benzer test AUC düzeyine rağmen daha yüksek gap nedeniyle görece daha kırılgan bir profil sergilediği görülmektedir. P+O, P+O+D ve P+O+D+K+B gibi birleşik modellerin, tekil bloklara kıyasla daha güçlü sonuçlar üretmekle birlikte, entegrasyonun her aşamasında artışın doğrusal olmadığı izlenmiştir. Bu bulgular, model başarısının yalnızca özellik sayısındaki artışla değil, bloklar arasındaki tamamlayıcılığın niteliği ve genellenebilirlik dengesiyle belirlendiğini göstermektedir.

Tablo 32

Kademeli RCB Modellerinde Algoritma $\times$ SMOTE'ye Göre Test AUC, F1 ve CV-Test Gap Özeti.

Model	Smote	RF Test AUC	RF Test Makro F1	RF CV-Test Gap	XGB Test AUC	XGB Test Makro F1	XGB CV Test Gap	LGBM Test AUC	LGBM Test Makro F1	LGBM CV Test Gap
P	Var	0,550	0,255	0,059	0,542	0,281	0,053	0,538	0,305	0,049
P	Yok	0,523	0,364	0,063	0,515	0,358	0,057	0,521	0,378	0,053
O	Var	0,629	0,305	0,042	0,654	0,281	0,071	0,632	0,255	0,061
O	Yok	0,646	0,378	0,065	0,670	0,358	0,098	0,636	0,364	0,060
P+O	Var	0,685	0,305	0,060	0,678	0,281	0,060	0,682	0,305	0,051
P+O	Yok	0,702	0,378	0,042	0,691	0,358	0,046	0,695	0,378	0,043
D	Var	0,615	0,305	0,113	0,627	0,359	0,140	0,621	0,281	0,131
D	Yok	0,592	0,378	0,097	0,598	0,358	0,123	0,595	0,358	0,113

Tablo 33 (Devamı)

Kademeli RCB Modellerinde Algoritma × SMOTE'ye Göre Test AUC, F1 ve CV–Test Gap Özeti.

Model	Smote	RF Test AUC	RF Test Makro F1	RF CV–Test Gap	XGB Test AUC	XGB Test Makro F1	XGB CV Test Gap	LGBM Test AUC	LGBM Test Makro F1	LGBM CV Test Gap
P+O+D	Var	0,712	0,305	0,074	0,710	0,281	0,089	0,718	0,412	0,092
P+O+D	Yok	0,698	0,378	0,056	0,692	0,358	0,074	0,705	0,378	0,090
K	Var	0,553	0,256	0,040	0,545	0,281	0,040	0,549	0,281	0,039
K	Yok	0,528	0,378	0,030	0,521	0,358	0,029	0,525	0,378	0,030
P+O+D+K	Var	0,658	0,305	0,006	0,655	0,281	0,007	0,657	0,305	0,002
P+O+D+K	Yok	0,664	0,356	0,023	0,661	0,358	0,014	0,659	0,378	0,021
B	Var	0,512	0,305	0,010	0,516	0,233	0,021	0,514	0,281	0,015
B	Yok	0,498	0,378	0,003	0,502	0,358	0,014	0,501	0,378	0,009
P+O+D+K+B	Var	0,665	0,305	0,007	0,664	0,281	0,011	0,669	0,386	0,008
P+O+D+K+B	Yok	0,661	0,378	0,011	0,658	0,358	0,010	0,662	0,378	0,007

Tablo 34 (Devamı)

Kademeli RCB Modellerinde Algoritma × SMOTE'ye Göre Test AUC, F1 ve CV–Test Gap Özeti.

Model	Smote	RF Test AUC	RF Test Makro F1	RF CV–Test Gap	XGB Test AUC	XGB Test Makro F1	XGB CV Test Gap	LGBM Test AUC	LGBM Test Makro F1	LGBM CV Test Gap
R	Var	0,825	0,305	0,113	0,819	0,281	0,114	0,822	0,305	0,112
R	Yok	0,838	0,598	0,099	0,832	0,358	0,104	0,835	0,378	0,100
ALL	Var	0,829	0,305	0,039	0,831	0,281	0,036	0,832	0,305	0,034
ALL	Yok	0,835	0,378	0,020	0,837	0,358	0,017	0,838	0,602	0,015

Not

¹ Test AUC farkı $|\Delta AUC| \leq 0.01$ olan modeller eşdeğer kabul edilmiş; bu durumda sıralama Test Macro-F1 değerine göre yapılmıştır.² “SMOTE=VAR” ifadesi, SMOTE'nin yalnızca eğitim setinde ve her çapraz doğrulama katının eğitim kısmında uygulandığını; doğrulama/test katmanlarında hiçbir yeniden örnekleme yapılmadığını belirtir. Ön işleme adımlarında kullanılan parametreler yalnızca eğitim verisiyle belirlenmiş; doğrulama ve test verilerine aynı parametrelerle uygulanmıştır.³ ‘Nihai Özellik Sayısı’, ön işleme sonrası modele dahil edilen nihai değişken sayısını göstermektedir; bu sayı, başlangıç aday değişken sayılarından düşük olabilir.⁴ Çok sınıflı ROC AUC, One-vs-Rest yaklaşımı ile macro ortalama olarak hesaplanmıştır.⁵ En İyi Algoritma, ilgili model konfigürasyonunda 5-katlı çapraz doğrulamada ortalama macro-AUC değerini en yükseğe çıkaran algoritmadır.⁶ CV–Test Gap: 5 katlı çapraz doğrulamada elde edilen ortalama (mean) CV AUC ile bağımsız test kümesi AUC değeri arasındaki mutlak fark.

4.3.2. Tekil Modellerin Sınıf Bazlı Örüntüsü

Sınıf bazlı bulgular, tekil veri bloklarının farklı RCB sınıflarında eşit derecede etkili olmadığını göstermiştir. Model P’de RCB-0 sınıfı için görece daha iyi bir performans elde edilmiş (recall 0.500, F1=0.462, AUC 0.789), ancak RCB-I sınıfında belirgin düşüş gözlenmiştir (AUC 0.374, F1=0.154). Bu durum, patolojik değişkenlerin özellikle pCR’ye karşılık gelen RCB-0 sınıfını tanımlamada görece yararlı, ancak minimal rezidüel hastalığı ayırt etmede sınırlı kaldığını göstermektedir.

Model O’da RCB-0 (AUC 0.763) ve RCB-II (F1=0.385) sınıflarında daha dengeli bir örüntü ortaya çıkmış; ancak RCB-I sınıfı yine düşük precision (0.125), recall (0.143) ve AUC (0.456) değerleri ile zayıf kalmıştır. Model D’de ise RCB-I sınıfında recall değerinin 0.429’a yükselmesi ve RCB-II sınıfında precision 0.650 ile F1-skorunun 0.531’e ulaşması, demografik değişkenlerin belirli sınıflarda seçici katkı sunabileceğini göstermektedir.

Model K ve Model B’nin sınıf bazlı örüntüleri daha sınırlı kalmıştır. Model K’de en yüksek F1-skoru RCB-II sınıfında 0.356 olarak bulunmuş; RCB-I sınıfında ise AUC 0.448 ile referans düzeyin altına inmiştir. Model B’de RCB-II sınıfında görece daha iyi bir performans (F1=0.509, AUC=0.670) elde edilmesine rağmen, diğer sınıflarda özellikle RCB-I için performans düşük kalmıştır (AUC=0.397). Bu bulgular, komorbidite ve biyokimyasal blokların tek başına karar üretici ana eksenler olmaktan çok, belirli alt örüntülere katkı sunan ikincil veri kaynakları olduğunu göstermektedir. Buna karşılık Model R, tüm sınıflar arasında en dengeli performansı sunmuş ve özellikle RCB-I sınıfında belirgin üstünlük göstermiştir (F1=0.857, AUC=0.993). Tekil modellerin RCB sınıflarına göre performans dağılımı Tablo 34’de ayrıntılı olarak gösterilmiştir.

Tablo 35 Tekil Modellerin RCB Sınıflarına Göre Precision, Recall, F1-score, AUC ve Specificity Performansları

RCB Sınıfı	Precision	Recall	F1-Score	AUC	Specificity
Model P	RandomForest SMOTE VAR				
RCB-0	0.429	0.500	0.462	0.789	0.750
RCB-I	0.167	0.143	0.154	0.374	0.915
RCB-II	0.364	0.276	0.314	0.464	0.622
RCB-III	0.118	0.167	0.138	0.574	0.722
Model O	XGBoost SMOTE YOK				
RCB-0	0.438	0.389	0.412	0.763	0.812
RCB-I	0.125	0.143	0.133	0.456	0.881
RCB-II	0.435	0.345	0.385	0.649	0.649
RCB-III	0.158	0.250	0.194	0.747	0.704
Model D	XGBoost SMOTE VAR				
RCB-0	0.438	0.389	0.412	0.572	0.812
RCB-I	0.188	0.429	0.261	0.648	0.780
RCB-II	0.650	0.448	0.531	0.675	0.811
RCB-III	0.214	0.250	0.231	0.613	0.796
Model K	RandomForest SMOTE VAR				
RCB-0	0.294	0.278	0.286	0.568	0.750
RCB-I	0.133	0.286	0.182	0.448	0.780
RCB-II	0.500	0.276	0.356	0.566	0.784
RCB-III	0.167	0.250	0.200	0.630	0.722
Model B	XGBoost SMOTE VAR				
RCB-0	0.250	0.222	0.235	0.524	0.750
RCB-I	0.059	0.143	0.083	0.397	0.729
RCB-II	0.538	0.483	0.509	0.670	0.676
RCB-III	0.143	0.083	0.105	0.471	0.889
Model R	RandomForest SMOTE YOK				
RCB-0	0.632	0.667	0.649	0.771	0.854
RCB-I	0.857	0.857	0.857	0.993	0.983
RCB-II	0.677	0.724	0.700	0.732	0.730
RCB-III	0.444	0.333	0.381	0.662	0.907

4.3.3. Kombine Modellerin Sınıf Bazlı Örüntüsü

Birleşik modellerin sınıf bazlı sonuçları, veri bloklarının birlikte kullanılmasının tüm RCB sınıflarında eşit düzeyde bir kazanım üretmediğini göstermiştir. Model P+O'da RCB-0 ve RCB-II sınıflarında görece dengeli bir performans elde edilmiş (RCB-0 $F1=0.634$, $AUC=0.817$), ancak RCB-I sınıfında düşük precision ve recall değerleri korunmuştur. Bu durum, minimal rezidüel hastalığın yalnız patolojik ve onkolojik blokların birleşimi ile güvenilir biçimde ayrıştırılamadığını göstermiştir.

Model P+O+D ile demografik bilginin eklenmesi, özellikle RCB-I ve RCB-II sınıflarında sınıf içi dengeyi kısmen iyileştirmiştir (RCB-I recall=0.286 ve $AU=0.654$, RCB-II recall=0.655 ve $F1=0.633$). Bununla birlikte RCB-III sınıfındaki recall değerinin 0.083 düzeyinde kalması, ileri rezidüel hastalık grubunun bu birleşimde hâlâ kırılgan bir alan olmaya devam ettiğini göstermiştir.

Komorbidite ve biyokimya bloklarının eklenmesiyle oluşturulan modellerde performans artışı homojen olmamıştır. Model P+O+D+K'da RCB-0 ($F1=0.667$) ve RCB-II ($F1=0.600$) sınıflarında iyileşme gözlenirken, RCB-I sınıfında performans düşük kalmıştır ($AUC=0.407$). Model P+O+D+K+B'de RCB-II sınıfında daha dengeli bir yapı oluşmuş (recall=0.724 ve $F1=0.656$), ancak RCB-I sınıfında precision, recall ve $F1$ -skorunun sıfıra yakın seyretmesi, minimal rezidüel hastalığın bu birleşimde de korunmuş bir güçlük alanı olduğunu göstermiştir.

Tüm veri bloklarının entegre edildiği Model ALL, sınıflar arası en dengeli performansı sunmuştur. Özellikle RCB-I sınıfında precision 1.000, recall 0.714 ve $AUC=1.000$ ile belirgin bir iyileşme sağlanmış; RCB-II sınıfında yüksek recall (0.828) ve RCB-III sınıfında yüksek specificity (0.982) değerleri elde edilmiştir.

Bu sonuçlar, çok kaynaklı veri entegrasyonunun belirli sınıflarda sinerjik etki oluşturduğunu, ancak sınıflar arası performansın tamamen homojenleşmediğini ortaya koymaktadır. Birleşik modellere ait sınıf bazlı performans dağılımları Tablo 35'te sunulmuştur.



Tablo 36 Birleşik Modellerin RCB Sınıflarına Göre Precision, Recall, F1-score, AUC ve Specificity Performansları

RCB Sınıfı	Precision	Recall	F1-Score	AUC	Specificity
Model PO	RandomForest SMOTE YOK				
RCB-0	0.565	0.722	0.634	0.817	0.792
RCB-I	0.167	0.143	0.154	0.576	0.915
RCB-II	0.462	0.414	0.436	0.586	0.622
RCB-III	0.273	0.250	0.261	0.741	0.852
Model POD	LightGBM SMOTE VAR				
RCB-0	0.632	0.667	0.649	0.816	0.854
RCB-I	0.250	0.286	0.267	0.654	0.898
RCB-II	0.613	0.655	0.633	0.705	0.676
RCB-III	0.125	0.083	0.100	0.696	0.870
Model PODK	RandomForest SMOTE YOK				
RCB-0	0.619	0.722	0.667	0.841	0.833
RCB-I	0.167	0.143	0.154	0.407	0.915
RCB-II	0.581	0.621	0.600	0.677	0.649
RCB-III	0.250	0.167	0.200	0.707	0.889
Model PODKB	LightGBM SMOTE VAR				
RCB-0	0.647	0.611	0.629	0.799	0.875
RCB-I	0.000	0.000	0.000	0.567	0.949
RCB-II	0.600	0.724	0.656	0.686	0.622
RCB-III	0.273	0.250	0.261	0.627	0.852
Model ALL	LightGBM SMOTE YOK				
RCB-0	0.611	0.611	0.611	0.866	0.854
RCB-I	1.000	0.714	0.833	1.000	1.000
RCB-II	0.600	0.828	0.696	0.758	0.568
RCB-III	0.667	0.167	0.267	0.728	0.982

4.3.4. Nihai Modelin Seçimi

Tüm veri bloklarını içeren Model ALL, patoloji, onkoloji, demografi, komorbidite, biyokimya ve radyoloji alanlarından gelen bilgiyi bütüncül biçimde entegre eden en kapsamlı yapı olarak değerlendirilmiştir. Bu modelde LightGBM algoritmasının SMOTE uygulanmayan senaryosu, test AUC (0.838), test accuracy (0.636) ve test macro-F1 (0.602) değerleri ile en dengeli performansı sunmuştur. Model R de test AUC bakımından aynı düzeye ulaşmış olmakla birlikte, nihai seçim yalnızca diskriminasyon gücüne dayandırılmamıştır. CV-test gap, test macro-F1 ve değişken kapsamının bütünlüğü birlikte değerlendirildiğinde Model ALL'in daha dengeli ve genellenebilir bir profil sergilediği görülmüştür. Nitekim Model ALL'de CV-test gap 0.015 düzeyinde bulunurken, Model R'de bu değer 0.099 olarak hesaplanmıştır. Bu fark, Model ALL'in bağımsız test verisine daha tutarlı biçimde aktarılan bir performans sergilediğini göstermektedir. Ayrıca macro-F1 değerlerinin Model ALL (0.602) ve Model R (0.598) arasında yakın olmasına rağmen, entegre modelin sınıflar arası dengeyi daha iyi sağladığı görülmektedir. Bu nedenle Model ALL, yalnızca en yüksek performanslı değil, aynı zamanda en güvenilir ve klinik iş akışıyla en uyumlu final model olarak belirlenmiştir.

Şekil 28'de Model R ve Model ALL için test metrikleri ile çapraz doğrulama ortalama±standart sapma değerleri karşılaştırmalı olarak sunulmakta; bu karşılaştırma Model ALL'in benzer ayırt ediciliğe karşın daha düşük varyasyon ile daha güvenilir bir yapı sunduğunu desteklemektedir.



Şekil 28. Model R ve Model ALL İçin Test Metrikleri İle Çapraz Doğrulama Ortalama±Standart Sapma Değerlerinin Karşılaştırılması

4.3.4.1. Özellik Kategorilerinin Katkı Analizi

Model ALL'in performansı, tekil veri bloklarının katkısının aynı düzeyde olmadığını göstermiştir. Radyolojik özellikler, 0.838 test AUC ile en yüksek ayırt edici gücü sağlamış ve final modelin performansında belirleyici rol üstlenmiştir. Patolojik özellikler 0.550 test AUC ile daha sınırlı bir performans sergilemiş, buna karşın pCR öngörüsünde modelin temel bileşenlerinden biri olmuştur. Onkolojik özellikler 0.670 test AUC ile orta düzeyde performans göstermiş ve metastaz ile tedaviye ilişkin klinik bilgileri modele dahil etmiştir. Demografik özellikler 0.627 test AUC ile sınırlı düzeyde katkı sunmuş, komorbidite ve biyokimyasal değişkenler ise sırasıyla 0.553 ve 0.516 test AUC değerleriyle düşük ayırt edicilik göstermiştir.

Bu dağılım, entegre modelin başarısının tek bir veri bloğuna dayanmadığını, farklı özellik kategorilerinin birbirini tamamlayan bilgi yapıları oluşturduğunu göstermektedir. Radyolojik ve onkolojik veriler modelin ayırt edici omurgasını oluştururken, patolojik değişkenler temel kurucu katkı sağlamış; demografik, komorbidite ve biyokimyasal değişkenler ise belirli sınıflarda destekleyici rol üstlenmiştir. Böylece Model ALL'in yapısal üstünlüğü, çoklu veri bloklarının birlikte sağladığı tamamlayıcı etkileşimle ortaya çıkmıştır.

4.3.4.2. SMOTE'un Genel Etkisi

SMOTE uygulanmasının performans üzerindeki etkisi model yapısına ve veri bloğu bileşimine bağlı olarak değişkenlik göstermiştir. Daha zayıf ve orta düzey performans gösteren bazı modellerde SMOTE sınıf dengesini iyileştirerek performans artışı sağlamış; buna karşılık güçlü modellerde aynı etki gözlenmemiştir. Bu nedenle SMOTE, bu veri setinde genel bir üstünlük sağlayan bir yaklaşım olarak öne çıkmamıştır.

Özellikle Model ALL ve Model R için SMOTE uygulanmayan senaryolarda daha yüksek ve daha dengeli performans elde edilmiştir. Bu durum, güçlü modellerde doğal veri dağılımının korunmasının daha uygun olduğunu göstermektedir. Bu bulgular, SMOTE'un genel bir iyileştirme aracı olmadığını ve model konfigürasyonuna bağlı olarak değerlendirilmesi gerektiğini ortaya koymaktadır (Tablo 33).

4.3.4.3. Algoritma Karşılaştırmaları

Üç ağaç tabanlı algoritmanın karşılaştırmalı değerlendirmesinde, tek bir yöntemin tüm model konfigürasyonlarında tutarlı biçimde üstün performans göstermediği saptanmıştır. Performans düzeyi, veri bloğunun yapısına ve özellik uzayının bileşimine göre değişmiştir. Bu kapsamda RandomForest, patoloji temelli ve bazı birleşik konfigürasyonlarda daha yüksek performans göstermiş; XGBoost, onkoloji/tedavi, demografi ve biyokimya odaklı setlerde öne çıkmış; LightGBM ise daha geniş ve çok bileşenli değişken setlerinde en yüksek performansa ulaşmıştır.

Bu örüntü, algoritma performansının sabit olmadığını ve konfigürasyona bağımlı olduğunu göstermiştir. Her bir özellik kümesi için farklı algoritmaların test edilmesi, yalnızca en yüksek test performansını belirlemeyi değil, aynı zamanda modelin genellenebilirlik ve denge düzeyini değerlendirmeyi de sağlamıştır. Elde edilen bulgular, algoritma seçiminde tekil bir üstünlükten çok, veri yapısı ile algoritma mimarisi arasındaki uyumun belirleyici olduğunu ortaya koymuştur (Tablo 33).

4.3.5. Sınıf Bazlı Performans, Ayırıştırma ve Güvenilirlik Analizleri

Model ALL'in sınıf bazlı sonuçları, final model seçimini destekleyen ikinci bir kanıt katmanını sunmuştur.

RCB-I sınıfında precision 1.000, recall 0.714, F1-skoru 0.833 ve AUC 1.000 elde edilmiş olup, modelin minimal rezidüel hastalığı ayırt etmede yüksek performans sergilediği görülmüştür. RCB-0 sınıfında AUC 0.866 ve F1-skoru 0.611 bulunmuş; modelin pCR öngörüsünde dengeli ve yüksek ayırt edici performans sergilediği görülmüştür. RCB-II sınıfında recall 0.828, F1-skoru 0.696 ve AUC 0.758 elde edilmiş; bu sınıfta klinik olarak kullanılabilir düzeyde bir performans sağlanmıştır.


Buna karşılık RCB-III sınıfı, modelin en zayıf performans gösterdiği sınıf olmuştur. Bu sınıfta precision 0.667 olmasına karşın recall 0.167'ye düşmüş ve F1-skoru 0.267'de kalmıştır. Bu sonuç, modelin RCB-III olgularının önemli bir bölümünü daha düşük rezidüel hastalık sınıflarına atadığını göstermektedir. Böylece Model ALL, genel olarak güçlü bir performans sunmakla birlikte, ileri rezidüel hastalık grubunda sınırlı kalmıştır. Tablo 37'da sınıf bazlı performans metrikleri sunulmuştur.

Tablo 37

Model ALL - Sınıf Bazında Detaylı Metrikler (LightGBM SMOTE YOK)


RCB Sınıfı	Precision	Recall	F1-Score	AUC	Specificity
RCB-0	0.611	0.611	0.611	0.866	0.854
RCB-I	1.000	0.714	0.833	1.000	1.000
RCB-II	0.600	0.828	0.696	0.758	0.568
RCB-III	0.667	0.167	0.267	0.728	0.982

Karışıklık matrisi (Şekil 29) incelendiğinde, yanlış sınıflamaların büyük ölçüde komşu sınıflar arasında gerçekleştiği görülmektedir. Örneğin, RCB-0 sınıfında 11 örnek doğru sınıflanmış, 6 örnek RCB-II ve 1 örnek RCB-III olarak tahmin edilmiştir. Dolayısıyla, RCB-0 sınıfında bazı olguların RCB-II olarak sınıflandırıldığı, RCB-II sınıfında ise sınırlı sayıda örneğin RCB-0 ile karıştığı izlenmiştir. En belirgin hata deseni, RCB-III olgularının büyük kısmının RCB-II olarak sınıflandırılmasıdır. Bu durum, modelin ileri hastalık grubunu daha düşük rezidüel hastalık düzeyi olarak yorumlama eğilimi gösterdiğini ortaya koymaktadır. Buna karşılık RCB-I sınıfında doğru sınıflandırma oranının yüksek olması, bu grubun model tarafından daha iyi tanındığını göstermektedir. Böylece Model ALL'in genel performansı desteklenmekle birlikte, sınıf bazında özellikle ileri hastalık grubunda kırılganlık bulunduğu görülmektedir.




Şekil 29. Model ALL RCB Sınıfları için Karışıklık Matrisi

ROC eğrileri (Şekil 30), Model ALL'un sınıflar arasında değişen düzeylerde ayırıştırma gücüne sahip olduğunu göstermektedir. RCB-I sınıfında AUC 1.000 ile mükemmel yakın bir ayırıştırma performansı elde edilirken, RCB-0 sınıfında AUC 0.866 ile güçlü bir performans izlenmiştir. RCB-II (AUC 0.758) ve RCB-III (AUC 0.728) sınıflarında ise ayırıştırma gücü daha düşük olmakla birlikte, rastgele sınıflamaya kıyasla anlamlı düzeyde üstünlük korunmuştur.



Şekil 30. Model ALL RCB Sınıfları İçin ROC Eğrileri


Precision–Recall eğrileri (Şekil 30), modelin sınıf dengesizliği altındaki performansını daha ayrıntılı biçimde ortaya koymaktadır. RCB-I sınıfında precision ve recall değerlerinin yüksek olması, bu sınıfta güçlü bir denge sağlandığını göstermektedir. RCB-0 ve RCB-II sınıflarında kabul edilebilir düzeyde bir performans sürdürülürken, RCB-III sınıfında hem precision hem de recall değerlerinin düşük kalması bu sınıfa ilişkin belirsizliği desteklemektedir.



Şekil 31. Model ALL Kesinlik Duyarlılık Eğrisi


Kalibrasyon eğrileri (Şekil 31), Model ALL'in ürettiği olasılık tahminlerinin güvenilirliğini sınıf bazında değerlendirme imkânı sunmuştur. RCB-I sınıfında tahmin edilen olasılıkların gerçek oranlarla yüksek uyum gösterdiği izlenirken, RCB-0 sınıfında bu uyumun genel olarak korunduğu görülmüştür. Buna karşılık RCB-II sınıfında orta olasılık aralıklarında hafif sapmalar izlenmiş, RCB-III sınıfında ise referans çizgisinden daha belirgin uzaklaşma saptanmıştır.

Bu sonuçlar, Model ALL'in kalibrasyon açısından en güçlü performansı RCB-I sınıfında gösterdiğini ortaya koymaktadır. RCB-0 sınıfında uyum korunurken, RCB-II ve özellikle RCB-III sınıflarında tahminlerin gerçek oranlardan daha fazla sapma gösterdiği görülmüştür. Kalibrasyon eğrileri, modelin olasılık tahminlerinin sınıfa göre değişen düzeylerde güvenilir olduğunu göstermiştir.




Şekil 32. Model ALL RCB Sınıfları Kalibrasyon Eğrisi

Kümülatif kazanç analizi (Şekil 32), Model ALL'in yüksek olasılıklı örnekleri sıralama başarısını ortaya koymaktadır. RCB-I ve RCB-0 sınıflarında eğrilerin erken popülasyon dilimlerinde referans çizgisinin belirgin şekilde üzerine çıkması, bu sınıflara ait olguların erken aşamada başarılı biçimde yakalanabildiğini göstermektedir. RCB-II sınıfında kazanç eğrisi referans çizgisinin üzerinde seyretmekle birlikte, RCB-I ve RCB-0 sınıflarına kıyasla daha ılımlı bir artış göstermiştir. RCB-III sınıfında ise kazanç düzeyi daha düşük kalmış ve modelin bu sınıf için önceliklendirme gücü sınırlı olmuştur. Eğrilerin son dilimlerde üst sınıra yaklaşması, popülasyonun tamamı değerlendirildiğinde tüm pozitif örneklerin yakalandığını göstermektedir. Bu bulgular birlikte değerlendirildiğinde, Model ALL'in özellikle RCB-I ve RCB-0 sınıflarında erken sıralama başarısı gösterdiği, RCB-II'de orta düzeyde, RCB-III'te ise daha sınırlı bir kazanç sağladığı görülmektedir.




Şekil 33. RCB Sınıfları Kümülatif Kazanç Analizi: Model ALL

Lift analizi (Şekil 33), Model ALL'in sınıfları yüksek olasılıklı örnekler arasında önceliklendirme performansını doğrulamaktadır. RCB-I ve RCB-0 sınıflarında erken dilimlerde yüksek lift değerleri elde edilirken, RCB-II sınıfında lift değerleri orta düzeyde seyretmiş, erken popülasyonda rastgele seçime göre daha iyi bir performans izlenmiştir. RCB-III sınıfında ise lift değerleri daha düşük kalmış ve bu sınıf için önceliklendirme gücü sınırlı olmuştur. Popülasyon payı arttıkça lift değerlerinin 1'e yaklaşması, modelin avantajının özellikle erken seçim aşamalarında belirgin olduğunu göstermektedir. Bu bulgular, Model ALL'in özellikle RCB-I ve RCB-0 sınıflarında erken sıralama başarısı gösterdiğini, RCB-II'de orta düzeyde, RCB-III'te ise daha sınırlı bir performans sergilediğini göstermektedir. Lift analizi, modelin pozitif olguları erken aşamada ayırma kapasitesini ortaya koymuştur.



Şekil 34. Model ALL RCB Sınıflarının Lift Analizi

Açıklanabilirlik analizi, Model ALL + LightGBM (NO SMOTE) için değişken önem düzeylerini sunmaktadır. Açıklanabilirlik analizi, model kararlarının büyük ölçüde radyolojik değişkenlere dayandığını ortaya koymuştur. BI-RADS, lokalizasyon ve kitle konturu en yüksek katkıyı sağlayan değişkenler olarak öne çıkarken, yaş grubu ve kalsifikasyon morfolojisi de önemli katkı sunmuştur. Orta-yüksek önem düzeyinde Lezyon Türü, Meme Dansitesi, Kalsifikasyon Dağılımı, Moleküler Tip ve Tanı Evresi yer almıştır. Daha düşük önem düzeylerinde PR, Histolojik Tip ve Mitotik Derece bulunmuş; DM ve Kitle Dansitesi en düşük önem değerlerini almıştır.



Grafik 13. Model ALL Değişkenlerin Önem Düzeyleri

4.3.6. Model Doğrulama ve Güvenilirlik Analizleri

Bu alt bölümde, final model olarak belirlenen Model ALL için gerçekleştirilen ileri doğrulama ve güvenilirlik analizleri sunulmaktadır. Amaç, modelin yalnız bağımsız test kümesindeki başarısını değil, aynı zamanda yeniden örnekleme ve iç içe çapraz doğrulama altında ne ölçüde kararlı kaldığını, sınıf bazında belirsizliğin nasıl dağıldığını, klinik net fayda üretip üretmediğini ve hangi değişkenlere dayanarak karar verdiğini çok katmanlı biçimde ortaya koymaktır. Bu kapsamda nested cross-validation, bootstrap güven aralıkları, karar eğrisi analizi, kalibrasyon değerlendirmesi, SHAP temelli açıklanabilirlik, klinik ağırlıklandırılmış hata analizi ve SMOTE etkisinin bütüncül değerlendirmesi sırasıyla değerlendirilmiştir.

Nested Cross-Validation Sonuçları

Model ALL için nested cross-validation analizi, dış döngüde 5-fold ve iç döngüde 5-fold olacak şekilde yürütülmüştür. Her outer fold için inner CV AUC ortalaması ve outer test AUC hesaplanmış; iki değer arasındaki fark gap olarak tanımlanmıştır.

Tablo 37, sınıf bazında inner CV AUC, outer test AUC ve gap değerlerini göstermektedir. RCB-I sınıfında inner CV AUC (0.975 ± 0.018) ve outer test AUC (0.981 ± 0.015) değerlerinin birbirine çok yakın olması ve gap değerinin sıfıra yakın seyretmesi (-0.006 ± 0.030), bu sınıfta model performansının yüksek ve tutarlı olduğunu göstermektedir.

RCB-0 sınıfında gap değerinin sıfıra yakın kalması ($+0.008 \pm 0.136$), genel olarak dengeli bir genelleme yapısına işaret etmektedir. Buna karşılık RCB-II (-0.042 ± 0.109) ve RCB-III (-0.077 ± 0.095) sınıflarında daha yüksek varyasyon gözlenmiş, bu sınıflarda performansın fold'lar arasında daha değişken olduğu anlaşılmıştır. Bu sonuçlar, RCB-II ve RCB-III sınıflarında dış test performansının bazı fold'larda iç doğrulama düzeyinin üzerine çıkabildiğini, ancak performans değişkenliğinin RCB-I sınıfına kıyasla daha yüksek seyrettiğini göstermektedir.

Tablo 38

Nested CV Sonuçları – Sınıf Bazlı Özet İstatistikler (Model ALL, LightGBM, SMOTE yok)

RCB Sınıfı	Inner CV AUC (Mean $\pm$ Std)	Outer Test AUC (Mean $\pm$ Std)	Gap (Mean $\pm$ Std)
RCB-0	0.791 ± 0.037	0.783 ± 0.103	$+0.008 \pm 0.136$
RCB-I	0.975 ± 0.018	0.981 ± 0.015	-0.006 ± 0.030
RCB-II	0.696 ± 0.037	0.738 ± 0.075	-0.042 ± 0.109
RCB-III	0.714 ± 0.043	0.791 ± 0.054	-0.077 ± 0.095

Tablo 38'da sunulan global karşılaştırma, SMOTE uygulanmayan modelin hem inner CV AUC (0.794 ± 0.022) hem de outer test AUC (0.823 ± 0.052) açısından SMOTE uygulanan varyanta (0.778 ± 0.024 ve 0.806 ± 0.035) göre daha yüksek performans gösterdiğini ortaya koymaktadır. Her iki senaryoda da gap değerlerinin sıfır çevresinde kümelenmesi, modelin aşırı öğrenme eğilimi göstermediğini desteklemektedir.

Tablo 39

Nested CV Sonuçları – Global Özet (Model ALL, LightGBM; SMOTE yok vs SMOTE var)

Metrik	SMOTE YOK	SMOTE VAR
Inner CV AUC (Mean $\pm$ Std)	0.794 $\pm$ 0.022	0.778 $\pm$ 0.024
Outer Test AUC (Mean $\pm$ Std)	0.823 $\pm$ 0.052	0.806 $\pm$ 0.035
Gap (Mean $\pm$ Std)	-0.029 $\pm$ 0.074	-0.028 $\pm$ 0.057


Tablo 39’te verilen outer fold bazlı sonuçlar, outer test AUC değerlerinin 0.751–0.883 aralığında değiştiğini göstermektedir. Fold 2’de en yüksek performans (0.883), Fold 4’te ise en düşük performans (0.751) elde edilmiştir. Gap değerlerinin -0.115 ile $+0.072$ aralığında değişmesi, belirli bir varyasyon bulunduğunu, ancak ortalama düzeyde genelleme dengesinin korunduğunu göstermektedir.

Tablo 40

Nested CV Sonuçları – Outer Fold Bazlı Detay (Model ALL, LightGBM; SMOTE yok)

Outer Fold	Inner CV AUC (Mean $\pm$ Std)	Outer Test AUC	Gap
1	0.776 $\pm$ 0.051	0.860	-0.084
2	0.768 $\pm$ 0.040	0.883	-0.115
3	0.804 $\pm$ 0.053	0.828	-0.024
4	0.823 $\pm$ 0.045	0.751	+0.072
5	0.801 $\pm$ 0.055	0.796	-0.005
Ortalama	0.794 $\pm$ 0.022	0.823 $\pm$ 0.052	-0.029 $\pm$ 0.074

Şekil 35’te sunulan gap dağılımı, her iki senaryoda da değerlerin sıfır çevresinde kümелendiğini doğrulamaktadır. SMOTE uygulandığında varyasyonun bir miktar daraldığı görülmekle birlikte, daha düşük AUC değerleri nedeniyle genel performans avantajının SMOTE uygulanmayan modelde olduğu anlaşılmaktadır.




Şekil 35. Nested CV Gap Analizi (Global AUC; 5 Outer Fold; SMOTE yok vs SMOTE var)

Bootstrap Güven Aralıkları Sonuçları

Bootstrap analizi, model performansının örnekleme değişkenliğine karşı kararlılığını değerlendirmek amacıyla 500 yineleme, %95 güven aralığı ve stratified resampling yaklaşımı ile yürütülmüştür. Bu analiz, Model ALL'in yalnızca tek bir test bölünmesine bağlı olarak değil, yeniden örnekleme altında da benzer performans örüntüsünü koruyup korumadığını incelemektedir.

SMOTE uygulanmayan ve SMOTE uygulanan varyantlarda bootstrap AUC dağılımlarını karşılaştırmalı olarak Grafik 14'te gösterilmiştir. SMOTE uygulanmayan modelde test kümesi AUC değeri (0.8380) ile bootstrap ortalaması (0.8387) arasındaki yüksek uyum, modelin ayırt edicilik performansının yeniden örnekleme altında korunduğunu göstermektedir. Aynı analizde AUC için %95 güven aralığının 0.767–0.910 arasında yer alması, model performansının orta-yüksek düzeyde ve kabul edilebilir sınırlar içinde değiştiğine işaret etmektedir.

SMOTE uygulanan modelde test AUC (0.8281) ve bootstrap ortalaması (0.8269) benzer bir uyum sergilemekle birlikte, her iki ölçüt açısından daha düşük değerler elde edilmiştir. Dolayısıyla bootstrap analizi, test kümesinde gözlenen performans farkının tesadüfi bir dalgalanmadan ibaret olmadığını; aksine modelin örnekleme tekrarı altında da SMOTE'suz yapıyı desteklediği bilgisini vermektedir.



Grafik 14. Model ALL İçin Bootstrap AUC Dağılımının SMOTE Uygulanma Durumuna Göre Karşılaştırılması (B=500, stratified resampling)

Tablo 40, RCB-0, RCB-I, RCB-II ve RCB-III sınıfları için precision, recall ve F1-score test değerleri ile bootstrap ortalamaları ve güven aralıklarını göstermektedir. **RCB-0** sınıfında precision, recall ve F1-score değerlerinin her biri 0.611 olup bootstrap ortalamaları sırasıyla 0.6127, 0.6046 ve 0.6013 olması, metrikler arasında genel bir uyum bulunduğunu göstermektedir. Bununla birlikte, %95 güven aralıklarının görece geniş olması (precision: 0.383–0.857; recall: 0.375–0.842; F1-score: 0.400–0.789), bu sınıfta performansın orta düzeyde ama örnekleme varyasyonuna belirli ölçüde açık olduğunu göstermektedir. **RCB-I** sınıfında precision test değeri 1.000 olup bootstrap ortalaması 0.9960’dır; recall test değeri 0.714 iken bootstrap ortalaması 0.7235, F1-score ise test değeri 0.833 iken bootstrap ortalaması 0.8251 olarak hesaplanmıştır. Bu sınıfta güven aralıkları görece geniş olmakla birlikte, merkezi eğilim yüksek performansın korunduğunu görülmektedir.

RCB-II sınıfı, final modelin en dengeli performans gösterdiği sınıflardan biri olarak öne çıkmıştır. Precision test değeri 0.600 ve bootstrap ortalaması 0.5950, recall test değeri 0.828 ve bootstrap ortalaması 0.8285, F1-score test değeri 0.696 ve bootstrap ortalaması 0.6896 bulunmuştur. Güven aralıklarının precision için 0.4419–0.7429, recall için 0.6909–0.9649 ve F1-score için 0.5758–0.8116 aralığında kalması, bu sınıfta performansın özellikle recall açısından güçlü ve görece kararlı olduğunu göstermektedir.

Buna karşılık **RCB-III** sınıfı belirgin biçimde en kırılgan sınıf olarak öne çıkmıştır. Bu sınıfta precision test değeri 0.667 ve bootstrap ortalaması 0.6521, recall test değeri 0.167 ve bootstrap ortalaması 0.1698, F1-score test değeri 0.267 ve bootstrap ortalaması 0.2587 olarak hesaplanmıştır. Özellikle recall ve F1-score için güven aralıklarının alt sınırının 0.000 düzeyine kadar inmesi (recall: 0.000–0.400; F1-score: 0.000–0.540), bu sınıfın performansının örnekleme bileşimine son derece duyarlı olduğunu göstermektedir.

Tablo 41

Sınıf Bazlı Bootstrap %95 Güven Aralıkları – Precision, Recall ve F1-Score

RCB Sınıfı	Metrik	Test	Bootstrap Ort.	Medyan	%95 GA
RCB-0	Precision	0.611	0.613	0.615	0.383–0.857
	Recall	0.611	0.605	0.600	0.375–0.842
	F1-Skor	0.611	0.601	0.600	0.400–0.789
RCB-I	Precision	1.000	0.996	1.000	1.000–1.000
	Recall	0.714	0.724	0.750	0.333–1.000
	F1-Skor	0.833	0.825	0.857	0.500–1.000
RCB-II	Precision	0.600	0.595	0.595	0.442–0.743
	Recall	0.828	0.829	0.833	0.691–0.965
	F1-Skor	0.696	0.690	0.693	0.576–0.812
RCB-III	Precision	0.667	0.652	0.667	0.000–1.000
	Recall	0.167	0.170	0.167	0.000–0.400
	F1-Skor	0.267	0.259	0.255	0.000–0.540

Sınıf bazında AUC ve specificity ölçütlerinin test değerleri, bootstrap ortalamaları ve güven aralıkları Tablo 41’de sunulmuştur. **RCB-0** sınıfında AUC test değeri 0.866, bootstrap ortalaması 0.8639 ve %95 güven aralığı 0.7697–0.9430 olarak bulunurken; specificity test değeri 0.854, bootstrap ortalaması 0.8558 ve %95 güven aralığı 0.7500–0.9556 düzeyinde hesaplanmıştır. **RCB-I** sınıfında specificity tüm örneklemlerde 1.000 düzeyinde korunmuştur; buna karşılık bootstrap örneklemlerinin bir kısmında ROC eğrisi hesaplanmasına yetecek sınıf dağılımı oluşmadığı için AUC özetleri sınırlı kalmıştır. **RCB-II** sınıfında AUC 0.758, bootstrap ortalaması 0.7559 ve güven aralığı


0.6413–0.8604 olarak bulunurken; specificity 0.568 test değeri, 0.5614 bootstrap ortalaması ve 0.4103–0.7258 aralığı ile daha sınırlı görünmüştür. **RCB-III** sınıfında AUC test değeri 0.728 ve bootstrap ortalaması 0.7364 olarak hesaplanmış; specificity ise 0.982 test değeri ve 0.9818 bootstrap ortalaması ile çok yüksek bulunmuştur. Bu desen, modelin RCB-III dışındaki olguları dışlamada güçlü olduğunu; ancak gerçek RCB-III olgularını yakalamada yetersizlik taşıdığını doğrulamaktadır.

Tablo 42

Sınıf Bazlı Bootstrap %95 Güven Aralıkları – AUC ve Specificity

RCB Sınıfı	Metrik	Test Değeri	Bootstrap Ortalaması	Medyan	%95 GA
RCB-0	AUC	0.866	0.864	0.869	0.770–0.943
	Spesifisite	0.854	0.856	0.857	0.750–0.956
RCB-I	AUC	1.000	—	—	—
	Spesifisite	1.000	1.000	1.000	1.000–1.000
RCB-II	AUC	0.758	0.756	0.760	0.641–0.860
	Spesifisite	0.568	0.561	0.561	0.410–0.726
RCB-III	AUC	0.728	0.736	0.739	0.567–0.876
	Spesifisite	0.982	0.982	0.982	0.940–1.000

Grafik 15, sınıf bazlı bootstrap güven aralıklarını görsel olarak karşılaştırmalı biçimde göstermektedir. Grafikte sınıflar arasında güven aralıklarının genişlik farkını görselleştirerek **RCB-III sınıfının en yüksek belirsizliğe** sahip grup olduğunu açık biçimde ortaya koymaktadır. Özellikle recall ve F1-score eksenlerinde RCB-III için görülen geniş dağılım, modelin bu sınıfa ilişkin performansının örnekleme kompozisyonundan güçlü biçimde etkilendiğini göstermektedir. Buna karşılık RCB-I ve RCB-II sınıflarında daha dar ve daha yüksek merkezli dağılımlar, bu sınıflarda performansın hem güçlü hem de daha tutarlı olduğunu düşündürmektedir.




Grafik 15. Sınıf Bazlı Bootstrap Güven Aralıkları – Precision, Recall ve F1-Score

Genel olarak bootstrap bulguları, Model ALL’in ayırt edicilik performansının örnekleme değişkenliğine karşı büyük ölçüde dayanıklı olduğunu, ancak sınıf bazında özellikle RCB-III grubunda belirsizliğin daha yüksek seyrettiğini göstermektedir. SMOTE’suz senaryonun hem test AUC hem bootstrap ortalaması açısından hafif üstünlük göstermesi, final model seçiminde doğal örnek dağılımının korunmasının daha uygun olduğunu desteklemektedir.

Karar Eğrisi Analizi

Karar eğrisi analizi, Model ALL’in farklı olasılık eşiklerinde klinik net fayda üretip üretmediğini değerlendirmek amacıyla gerçekleştirilmiştir. Bu analiz, modelin yalnızca ayırtma gücünü değil, aynı zamanda karar destek bağlamında kullanılabilirliğini de ortaya koymasından önemlidir.

Şekil 36, RCB-0, RCB-I, RCB-II ve RCB-III sınıfları için modelin net fayda eğrilerini, “treat-all” ve “treat-none” stratejileri ile karşılaştırmalı olarak göstermektedir. RCB-0 ve RCB-II sınıflarında model eğrilerinin düşük ve orta eşik aralıklarında aralıklarında “treat-none” çizgisinin üzerinde seyretmesi, bu sınıflarda pozitif net fayda üretildiğini göstermektedir. RCB-I ve RCB-III sınıflarında ise net fayda eğrileri daha sınırlı ve daha dar eşik aralıklarında elde edilmekte; özellikle daha yüksek eşik olasılıklarında RCB-III için net faydanın belirgin biçimde azaldığı izlenmektedir.



Şekil 36. Model ALL için Sınıf Bazlı Karar Eğrisi Analizi


Not: X eksen: Eşik olasılığı, Y eksen: Net fayda

Bu sonuç, final modelin klinik kullanım potansiyelinin sınıfa göre değiştiğini ve eşik olasılığının sabit bir karar kuralı olarak değil, klinik bağlama göre optimize edilmesi gereken bir parametre olduğunu göstermektedir. Genel olarak modelin klinik katkısı düşük–orta eşik aralıklarında daha belirgindir.

Kalibrasyon Değerlendirmesi

Kalibrasyon analizi, modelin ürettiği olasılıkların gözlenen olay sıklıkları ile ne ölçüde uyumlu olduğunu değerlendirmek amacıyla gerçekleştirilmiştir. Bu analiz, Model ALL'in yalnızca doğru sınıflandırma değil, aynı zamanda güvenilir olasılık tahmini üretme kapasitesini de ortaya koymaktadır.

Şekil 37, ham model ile yeniden kalibre edilmiş varyantların olasılık tahminlerini gözlenen olay frekanslarıyla karşılaştırmalı olarak göstermektedir. Ham modelin düşük olasılık bölgesinde bir miktar aşırı tahmin eğilimi gösterdiği, orta-yüksek olasılık aralığında ise bazı sapmaların ortaya çıktığı görülmektedir. Bu durum, modelin diskriminasyon gücü yüksek olmakla birlikte, olasılık tahminlerinin tam kalibre olmadığını göstermektedir. Micro-average Brier skoru ham model için 0.147 olarak hesaplanmıştır. Yeniden kalibrasyon sonrasında bu değer Platt scaling ile 0.133'e, isotonic regression ile 0.129'a düşmüştür. Ham modele göre mutlak iyileşmenin Platt için 0.014, isotonic için 0.018 düzeyinde olması, olasılık tahminlerinin özellikle klinik risk iletişimi ve karar desteği amacıyla kullanılacağı senaryolarda yeniden kalibrasyonun anlamlı katkı sağlayabileceğini göstermektedir.



Şekil 37. Model ALL için Kalibrasyon Eğrileri (Ham Model, Platt Scaling, İstotonic Regression)


Not: X eksen: Tahmin edilen olasılık (bin ortalaması), Y eksen: Ampirik olasılık)

Kalibrasyon sonuçları, Model ALL'in sınıflandırma başarısının yanında olasılık tahminlerinde de klinik kullanım açısından geliştirmeye açık fakat genel olarak güçlü bir yapı sunduğunu göstermektedir. Özellikle isotonic regression sonrası elde edilen daha düşük Brier skoru, yeniden kalibrasyonun uygulama düzeyinde değerli olabileceğini desteklemektedir.

SHAP Özellik Önem Analizi


Açıklanabilirlik analizi kapsamında, Model ALL + LightGBM (SMOTE yok) için çok sınıflı SHAP çıktıları incelenmiştir. Bu analiz, modelin karar yapısının hangi değişkenlere dayandığını hem global düzeyde hem de sınıf özgül biçimde ortaya koymak amacıyla gerçekleştirilmiştir.

Şekil 38, global SHAP dağılımını göstermekte ve BI-RADS, metastaz yeri, Ki-67, kalsifikasyon morfolojisi, lezyon türü, lokalizasyon ve meme dansitesi gibi değişkenlerin en yüksek katkıyı sağladığını ortaya koymaktadır. Bu dağılım, modelin özellikle görüntüleme temelli bilgi ile tümör biyolojisini yansıtan belirteçlerden yoğun biçimde yararlandığını göstermektedir. Ayrıca kitle konturu, kalsifikasyon dağılımı, tanı evresi ve yaş grubu gibi değişkenlerin de orta-yüksek önem düzeyi göstermesi, modelin tek bir veri bloğuna indirgenemeyecek çok katmanlı bir karar yapısı kurduğunu ortaya koymaktadır.




Şekil 38. Model ALL İçin Global SHAP Özellik Önem Özeti


Sınıf bazlı analizler (Şekil 38–42), her RCB sınıfının farklı özellik örüntülerine dayandığını göstermektedir. RCB-0 sınıfında metastaz yeri, Ki-67, PR, moleküler tip, lokalizasyon ve yaş grubu gibi biyolojik ve klinik değişkenler öne çıkarken; RCB-I sınıfında BI-RADS, meme dansitesi, lezyon türü, kalsifikasyon dağılımı, mimari ve lokalizasyonun gibi radyolojik özellikler baskındır. RCB-II sınıfında VKİ, yaş, nükleer derece ve metabolik değişkenlerin birlikte etkili olduğu daha karma bir yapı gözlenmiştir. RCB-III sınıfında ise tanı evresi, metastaz, histolojik tip ve bazı klinik değişkenler ön plana çıkmıştır.




Şekil 39. RCB-0 Sınıfı İçin SHAP Özellik Önem Analizi



Şekil 40. RCB-I Sınıfı İçin SHAP Özellik Önem Analizi



Şekil 41. RCB-II Sınıfı İçin SHAP Özellik Önem Analizi



Şekil 42. RCB-III Sınıfı İçin SHAP Özellik Önem Analizi

Bu açıklanabilirlik örüntüsü, nihai modelin “kara kutu” niteliğini azaltan önemli bir bulgu olarak değerlendirilebilir. Global SHAP sıralaması ile tek başına en yüksek performansı veren radyolojik modelin sonuçları arasındaki uyum, görüntüleme değişkenlerinin karar yapısındaki merkezi rolünü doğrulamaktadır. Buna karşılık sınıf bazlı SHAP sonuçları, entegre modelin başarısının radyolojik verilere dayanmadığını; metastaz, histopatoloji, yaş, metabolik durum ve bazı komorbidite göstergelerinin de sınıf özgül katkılar sunduğunu göstermektedir. Bu bulgular, Model ALL’in klinik uygulanabilirliği, yalnız performans metrikleriyle sınırlı olmadığını, aynı zamanda

karar mekanizmasının hangi değişkenlere dayandığının gösterilebilmesiyle daha da güçlendiğini göstermektedir.

4.3.7. Karşılaştırmalı Sentez: Model Sinerjisi, Klinik Hata Desenleri ve SMOTE Etkisi

4.3.7.1. Model Sinerjisi ve Özellik Etkileşimi

Kombine modellerin test performansı, dahil edilen tekil model bloklarının beklenen ortalama performansı ile karşılaştırıldığında tüm birleşik yapılarda pozitif sinerjik etki gözlenmiştir. Model P+O için gözlenen test AUC 0.702 iken beklenen AUC 0.610 olarak hesaplanmış ve sinerjik etki +0.092 bulunmuştur. Model P+O+D’de bu fark +0.102’ye yükselmiş; bu durum onkolojik ve demografik blokların, patolojik verilerle bir araya geldiğinde salt doğrusal toplamdan daha yüksek bir fayda ürettiği görülmüştür (Tablo 43).

Model P+O+D+K’da sinerjik etki +0.064’e gerileyerek komorbidite eklenmesinin görece faydasının sınırlı olduğunu göstermiştir. Model P+O+D+K+B’de +0.086 düzeyinde yeniden artış gözlenmekle birlikte, en güçlü sinerjik etki tüm veri bloklarını içeren Model ALL’de ortaya çıkmıştır. Model ALL için test AUC 0.838, beklenen AUC 0.626 ve sinerjik etki +0.212 olarak hesaplanmıştır. Bu sonuç, tüm veri bloklarının entegrasyonunun yalnız toplamsal değil, etkileşimsel bir avantaj ürettiğini ve final model başarısının çok boyutlu veri füzyonundan beslendiğini göstermektedir.

Tablo 43

Kombine Modellerde Sinerjik Kazanç/Kayıp Analizi

Model	Özellik Sayısı	Test AUC	Beklenen AUC*	Sinerjik Etki (Gözlenen–Beklenen)
Model P+O	16	0.702	0.610	+0.092
Model P+O+D	21	0.718	0.616	+0.102
Model P+O+D+K	31	0.664	0.600	+0.064
Model P+O+D+K+B	45	0.669	0.583	+0.086
Model ALL	62	0.838	0.626	+0.212

*Beklenen AUC (basit ortalama): dahil edilen modüllerin tekil Test AUC değerlerinin eşit ağırlıklı ortalaması.

4.3.7.2. Klinik Açıdan Ağırlıklandırılmış Hata Desenleri

Klinik odaklı hata analizi, modellerin yalnız toplam hata sayısı açısından değil, hata türlerinin klinik ağırlığı bakımından da belirgin farklılıklar gösterdiğini ortaya koymuştur. Bu değerlendirme, özellikle RCB-III'ün daha düşük rezidüel yük kategorilerine kaydırılmasının ve RCB-0'ın ileri rezidüel yük sınıflarına yanlış atanmasının klinik açıdan en kritik hata örüntüleri olduğunu ortaya koymuştur.

Tablo 44 incelendiğinde, en kritik hata türünün RCB-III olgularının RCB-II olarak sınıflandırılması olduğu görülmektedir. Bu hata, Model ALL'de 10 olgu (%41.7), Model P+O+D+K'da 11 olgu (%37.9), Model P+O'da 12 olgu (%36.4) ve Model R'de 8 olgu (%33.3) ile dikkat çekici öne çıkmaktadır. Bu durum, ileri rezidüel hastalık grubunun daha düşük rezidüel yük kategorilerine kaydırılmasının klinik açıdan en önemli kırılganlıklardan biri olduğunu göstermektedir.

Tablo 44

Klinik Açıdan Ağırlıklandırılmış Hata Türlerinin Model Bazında Dağılımı

Model	Gerçek Toplam Hata	RCBIII →RCB II Kritik	RCB0 →RCB III Kritik	RCB0→ RCBII Önemli	RCBII →RCB 0 Öne mli	RCBI →RC B0 K abul
Model P (RF, SMOTE)	46	5 (10.9%)	4 (8.7%)	5 (10.9%)	7 (15.2%)	2 (4.3%)
Model O (XGB, No SMOTE)	33	8 (24.2%)	0 (0.0%)	7 (21.2%)	7 (21.2%)	4 (12.1%)
Model P+O (RF, No SMOTE)	33	12 (36.4%)	0 (0.0%)	7 (21.2%)	5 (15.2%)	3 (9.1%)
Model D (XGB, SMOTE)	40	3 (7.5%)	5 (12.5%)	3 (7.5%)	4 (10.0%)	2 (5.0%)
Model P+O+D (LGBM, SMOTE)	32	8 (25.0%)	3 (9.4%)	3 (9.4%)	3 (9.4%)	3 (9.4%)

Tablo 44 (Devamı)

Klinik Açıdan Ağırlıklandırılmış Hata Türlerinin Model Bazında Dağılımı

Model K (RF, SMOTE)	48	2 (4.2%)	7 (14.6%)	4 (8.3%)	7 (14.6%)	2 (4.2%)
Model P+O+D+K (RF, No SMOTE)	29	11 (37.9%)	0 (0.0%)	7 (24.1%)	4 (13.8%)	3 (10.3%)
Model B (XGB, SMOTE)	46	3 (6.5%)	2 (4.3%)	8 (17.4%)	7 (15.2%)	2 (4.3%)
Model P+O+D+K+ B (LGBM, SMOTE)	31	8 (25.8%)	2 (6.5%)	5 (16.1%)	2 (6.5%)	3 (9.7%)
Model R (RF, No SMOTE)	24	8 (33.3%)	0 (0.0%)	11 (45.8%)	1 (4.2%)	1 (4.2%)
Model ALL (LGBM, No SMOTE)	24	10 (41.7%)	1 (4.2%)	6 (25.0%)	5 (20.8%)	2 (8.3%)

Tablo 45, modellerin toplam hata yükünü klinik öneme göre sınıflandırılmış biçimde özetlemektedir. Diğer kritik hata türü olan RCB-0'ın RCB-III olarak sınıflandırılması genel olarak daha seyrek görülmekle birlikte, bazı düşük performanslı modellerde anlamlı oranlara ulaşmıştır. Buna karşılık Model O, Model P+O, Model P+O+D+K ve Model R'de bu hata türünün gözlenmemesi, her modelin kritik hata profilinin yönsel olarak farklılaştığını göstermektedir.

Önemli hata kategorisinde ise RCB-0→RCB-II ve RCB-II→RCB-0 geçişleri öne çıkmıştır. Özellikle Model R'de RCB-0→RCB-II geçişinin 11 olgu (%45.8) ile en yüksek düzeye ulaşması, yüksek global performansa rağmen pCR ile orta rezidüel yük ayrımında klinik risk taşıyan bir hata örüntüsüne işaret etmektedir.

Toplulaştırılmış hata kategorileri incelendiğinde, kritik hata oranının en yüksek modelin Model ALL olduğu görülmüştür. Model ALL'de kritik hata 11 olgu (%45.8), önemli hata 11 olgu (%45.8) ve kabul edilebilir hata 2 olgu (%8.3) olarak kaydedilmiştir. Bu sonuç ilk bakışta paradoksal görünmekle birlikte, final modelin

toplam performansının yüksek olmasının klinik olarak tüm hata yönlerini eşit derecede güvenli kılmadığını göstermektedir. Benzer şekilde Model R'nin önemli hata oranının %50.0 düzeyine ulaşması, toplam hata sayısı düşük olan bir modelin dahi klinik karar açısından riskli hata desenleri sergileyebileceğini göstermektedir. Bu bulgular, model değerlendirmesinde yalnız AUC veya toplam hata sayısının değil, hata türlerinin klinik ağırlığının da dikkate alınması gerektiğini göstermektedir.

Tablo 45

Kritik, Önemli Ve Kabul Edilebilir Hata Kategorilerine Göre Karşılaştırmalı Özet

Model	Gerçek Toplam Hata	Kritik Hata (Adet, %)	Önemli Hata (Adet, %)	Kabul Edilebilir Hata (Adet, %)
Model P	46	9 (19.6%)	12 (26.1%)	2 (4.3%)
Model O	33	8 (24.2%)	14 (42.4%)	4 (12.1%)
Model P+O	33	12 (36.4%)	12 (36.4%)	3 (9.1%)
Model D	40	8 (20.0%)	7 (17.5%)	2 (5.0%)
Model P+O+D	32	11 (34.4%)	6 (18.8%)	3 (9.4%)
Model K	48	9 (18.8%)	11 (22.9%)	2 (4.2%)
Model P+O+D+K	29	11 (37.9%)	8 (27.6%)	3 (10.3%)
Model B	46	5 (10.9%)	15 (32.6%)	2 (4.3%)
Model P+O+D+K+B	31	10 (32.3%)	7 (22.6%)	3 (9.7%)
Model R	24	8 (33.3%)	12 (50.0%)	1 (4.2%)
Model ALL	24	11 (45.8%)	11 (45.8%)	2 (8.3%)

SMOTE Etkisinin Model Bazlı Değerlendirilmesi

Tablo 46'te görüldüğü üzere SMOTE etkisi model bazında değişkenlik göstermiştir. SMOTE uygulanması Model P, Model D, Model P+O+D, Model K, Model B ve Model P+O+D+K+B'de test AUC'yi artırmıştır. Bu bulgular, daha zayıf veya orta düzey performans gösteren bazı model yapılandırmalarında SMOTE'un yararlı olduğunu ortaya koymuştur.

Buna karşılık SMOTE uygulanması Model O, Model P+O, Model P+O+D+K, Model R ve Model ALL'de test AUC'yi düşürmüştür. Özellikle Model R ve Model ALL gibi

güçlü modellerde SMOTE'un performansı azaltması, sentetik örnekleme her zaman genellenebilirliği artırmadığını göstermiştir. Bu nedenle SMOTE'un etkisi, modelin özellik yapısına ve öğrenme dinamiğine bağlı olarak değerlendirilmiştir.

Tablo 46

Tüm Modellerde SMOTE Etkisi Özeti

Model	SMOTE YOK Test AUC	SMOTE VAR Test AUC	Δ AUC (VAR-YOK)	Net Etki
Model P	0.523	0.550	+0.027	Faydalı
Model O	0.670	0.654	-0.016	Zararlı
Model P+O	0.702	0.685	-0.017	Zararlı
Model D	0.598	0.627	+0.029	Faydalı
Model P+O+D	0.705	0.718	+0.013	Faydalı
Model K	0.528	0.553	+0.025	Faydalı
Model P+O+D+K	0.664	0.658	-0.006	Zararlı
Model B	0.502	0.516	+0.014	Faydalı
Model P+O+D+K+B	0.662	0.669	+0.007	Faydalı
Model R	0.838	0.825	-0.013	Zararlı
Model ALL	0.838	0.832	-0.006	Zararlı

Bulgular birlikte değerlendirildiğinde, RCB kategorisinin öngörülmesinde en güçlü tekil sinyalin radyolojik özelliklerden geldiği; ancak en dengeli ve genellenebilir performansın tüm veri bloklarını entegre eden Model ALL'de elde edildiği görülmektedir. Patolojik, onkolojik ve demografik bloklar belirli düzeylerde katkı sağlamakta; komorbidite ve biyokimyasal blokların katkısı ise daha sınırlı ve bağlama bağımlı görünmektedir. Buna karşın bu zayıf bloklar dahi entegre yapı içinde bazı sınıf özgül örüntülere katkı sunabildiğinden, model başarısı salt tekil blok performansları üzerinden değerlendirilmemelidir.

Nested CV ve bootstrap bulguları, final modelin yalnız test kümesi üzerinde değil, yeniden örnekleme ve dış doğrulama katmanlarında da genel olarak kararlı kaldığını

göstermektedir. Kalibrasyon, karar eğrisi ve SHAP analizleri bu sayısal başarıyı klinik yorumlanabilirlik ile desteklemiş; klinik ağırlıklı hata analizi ise yüksek performanslı modellerin dahi belirli hata yönlerinde kırılma kalabileceğini göstermiştir. Sonuç olarak, bu tezde geliştirilen modüller ve kademeli modelleme çerçevesi, RCB öngörüsünde çok kaynaklı veri entegrasyonunun değerini açık biçimde ortaya koymakta; aynı zamanda hangi sınıflarda ve hangi hata örüntülerinde ek iyileştirmelere ihtiyaç bulunduğunu görünür hale getirmektedir.

4.4.PET-BT Verilerinin RCB Öngörüsüne Katkısı

Bu bölümde, PET-BT verisi bulunan 198 hastalık alt örnekleme metabolik görüntüleme değişkenlerinin rezidüel kanser yükü (RCB) öngörüsüne katkısına ilişkin bulgular sunulmaktadır. Analitik çerçeve, yalnızca PET-BT türevli değişkenleri içeren Model PET, ana çalışmada kullanılan klinik-radyolojik-entegre yapıyı temsil eden Model ALL ve bu yapıya PET-BT değişkenlerinin eklendiği Model ALL+PET üzerinden kurgulanmıştır. Tüm modellerde Random Forest, LightGBM ve XGBoost algoritmaları SMOTE uygulanmış ve uygulanmamış senaryolarda değerlendirilmiş; model performansı test AUC, test accuracy, test macro-F1, çapraz doğrulama bulguları ve ek güvenilirlik analizleri ile incelenmiştir.

4.4.1. PET-BT Alt Örnekleminde Model Performansı


PET-BT alt örnekleminde algoritma ve yeniden örnekleme koşullarına göre elde edilen temel performans bulguları Tablo 46’de sunulmuştur. Tablo incelendiğinde, yalnızca PET-BT değişkenleriyle kurulan Model PET’in tüm algoritmalarda görece düşük bir ayırıştırma gücü sergilediği ve test AUC değerlerinin 0.529–0.551 aralığında kaldığı görülmektedir. Buna karşılık, PET değişkenlerini içermeyen Model ALL yapısında en yüksek test AUC değeri SMOTE uygulanan Random Forest algoritması ile 0.871 olarak elde edilmiştir. Aynı koşullarda Model ALL+PET için en yüksek test AUC değeri LightGBM ile 0.856 düzeyinde bulunmuştur. Bu dağılım, PET-BT alt örnekleminde en güçlü performansın yine entegre klinik-radyolojik yapıdan elde edildiğini göstermektedir. PET-BT değişkenlerinin eklenmesi bazı algoritmalarda benzer performans düzeyleri üretmiş olsa da, bağımsız test seti üzerinde belirgin ve tutarlı (Tablo 47).

Algoritma bazlı karşılaştırma değerlendirildiğinde, Model ALL altında Random Forest test AUC açısından en yüksek performansı gösterirken, LightGBM ise benzer ayrıştırma gücüyle test accuracy bakımından daha iyi performans vermiştir. Model ALL+PET yapısında LightGBM test AUC ve test accuracy açısından öne çıkarken, Random Forest test macro-F1 bakımından daha yüksek değer üretmiştir. Buna karşın Model PET’te algoritmalar arası farklılıklar sınırlı kalmış; tüm yöntemler benzer ve düşük performans bandında kümelenmiştir. Dolayısıyla, PET-BT türevli değişkenle tek başına kurulan modelde sınırlı sinyal taşıdığı, çok kaynaklı yapıların ise daha güçlü bir öngörü çerçevesi sunduğunu görülmektedir (Tablo 47, Grafik 16).

Tablo 47

PET/BT Analizi Model Performans Karşılaştırması - Tüm Algoritmalar ve SMOTE Koşulları

Model	Algorithm	SMOTE	CV AUC (Mean±Std)	Test AUC	CV Accuracy (Mean±Std)	Test Accuracy	CV F1 (Mean±Std)	Test F1
Model PET	RandomForest	Hayır	0.616±0.043	0.538	0.469±0.071	0.400	0.309±0.068	0.173
Model PET	RandomForest	Evet	0.836±0.059	0.551	0.624±0.098	0.400	0.615±0.106	0.338
Model PET	LightGBM	Hayır	0.610±0.060	0.542	0.424±0.058	0.375	0.298±0.068	0.291
Model PET	LightGBM	Evet	0.853±0.052	0.531	0.651±0.079	0.350	0.649±0.084	0.284
Model PET	XGBoost	Hayır	0.621±0.085	0.538	0.419±0.063	0.375	0.330±0.096	0.268
Model PET	XGBoost	Evet	0.849±0.055	0.529	0.631±0.081	0.350	0.625±0.091	0.281
Model ALL	RandomForest	Hayır	0.827±0.078	0.867	0.615±0.066	0.550	0.512±0.075	0.417
Model ALL	RandomForest	Evet	0.956±0.021	0.871	0.843±0.031	0.625	0.840±0.032	0.602
Model ALL	LightGBM	Hayır	0.811±0.026	0.822	0.570±0.059	0.575	0.522±0.042	0.476
Model ALL	LightGBM	Evet	0.957±0.012	0.866	0.843±0.016	0.675	0.838±0.019	0.577
Model ALL	XGBoost	Hayır	0.793±0.057	0.844	0.513±0.119	0.600	0.448±0.082	0.517
Model ALL	XGBoost	Evet	0.948±0.014	0.831	0.767±0.022	0.550	0.761±0.026	0.449
Model ALL + PET	RandomForest	Hayır	0.818±0.058	0.851	0.570±0.068	0.525	0.434±0.119	0.424
Model ALL + PET	RandomForest	Evet	0.958±0.016	0.818	0.812±0.056	0.575	0.809±0.060	0.564
Model ALL + PET	LightGBM	Hayır	0.804±0.043	0.828	0.564±0.077	0.625	0.507±0.096	0.567
Model ALL + PET	LightGBM	Evet	0.956±0.015	0.856	0.829±0.050	0.625	0.824±0.055	0.519
Model ALL + PET	XGBoost	Hayır	0.813±0.041	0.846	0.551±0.069	0.600	0.489±0.038	0.529
Model ALL + PET	XGBoost	Evet	0.950±0.024	0.831	0.812±0.047	0.525	0.810±0.048	0.443



Grafik 16. SMOTE'lu Koşulda Algoritma Karşılaştırması (Test AUC, Accuracy, F1-Macro)

4.4.2. PET-BT Değişkenlerinin Ek Katkısı ve SMOTE Etkisi

PET-BT değişkenlerinin entegre modele katkısını değerlendirmek amacıyla Model ALL ve Model ALL+PET performansları karşılaştırılmış; ayrıca SMOTE uygulamasının model bazlı etkileri incelenmiştir.


SMOTE uygulaması bazı modellerde performans artışı sağlamıştır. Özellikle Model PET'te Random Forest kullanıldığında SMOTE sonrası test AUC değeri 0.538'den 0.551'e, test macro-F1 değeri ise 0.173'ten 0.338'e yükselmiştir. Benzer şekilde, Model ALL'de Random Forest ile test AUC 0.867'den 0.871'e, test accuracy 0.550'den 0.625'e ve test macro-F1 0.417'den 0.602'ye çıkmıştır. Buna karşılık Model ALL+PET yapısında LightGBM ile test AUC 0.828'den 0.856'ya yükselmesine rağmen test accuracy sabit kalmış, test macro-F1 ise 0.567'den 0.519'a gerilemiştir. Dolayısıyla, SMOTE etkisinin model yapısına ve değerlendirme metriğine göre farklılaştığı; bazı yapılarda ayrıştırma gücünü artırırken sınıflar arası dengeyi aynı ölçüde iyileştirmediği izlenmiştir (Tablo 48, Grafik 17).

Tablo 48

SMOTE Etkisi Karşılaştırması - En İyi Algoritmalar İçin

Model	Algorithm	Metrik	SMOTE'suz	SMOTE'lu	Değişim	Değişim (%)
Model PET	RandomForest	CV AUC	0.616±0.043	0.836±0.059	+0.220	+35.7%
Model PET	RandomForest	Test AUC	0.538	0.551	+0.013	+2.4%
Model PET	RandomForest	Test Accuracy	0.400	0.400	+0.000	+0.0%
Model PET	RandomForest	Test F1	0.173	0.338	+0.165	+95.4%
Model ALL	RandomForest	CV AUC	0.827±0.078	0.956±0.021	+0.129	+15.6%
Model ALL	RandomForest	Test AUC	0.867	0.871	+0.004	+0.5%
Model ALL	RandomForest	Test Accuracy	0.550	0.625	+0.075	+13.6%
Model ALL	RandomForest	Test F1	0.417	0.602	+0.185	+44.4%
Model ALL+PET	LightGBM	CV AUC	0.804±0.043	0.956±0.015	+0.152	+18.9%
Model ALL+PET	LightGBM	Test AUC	0.828	0.856	+0.028	+3.4%
Model ALL+PET	LightGBM	Test Accuracy	0.625	0.625	+0.000	+0.0%
Model ALL+PET	LightGBM	Test F1	0.567	0.519	-0.048	-8.5%

Not: Yüzde değişimler (SMOTE'lu – SMOTE'suz) / SMOTE'suz şeklinde hesaplanmıştır. CV AUC satırlarında ortalama±standart sapma korunmuş; değişim hesabı ortalama değerler üzerinden yapılmıştır.



Grafik 17. SMOTE Etkisi Performansı Karşılaştırması

PET-BT değişkenlerinin doğrudan katkısı değerlendirildiğinde ise, aynı alt örneklem içinde Model ALL ile Model ALL+PET performansları karşılaştırılmıştır. SMOTE uygulanan koşullarda Random Forest algoritmasında PET-BT değişkenlerinin eklenmesi test AUC değerini 0.871'den 0.818'e düşürmüştür; LightGBM'de aynı ekleme 0.866'dan 0.856'ya sınırlı bir azalma ile sonuçlanmıştır. XGBoost'ta ise test AUC değişmemiştir. Test accuracy ve test macro-F1 değerleri de çoğu algorithmada Model ALL+PET lehine bir iyileşme göstermemiştir. Bu nedenle PET-BT değişkenlerinin tümü birlikte eklendiğinde, mevcut entegre model üzerinde tutarlı ve yönlü bir performans kazanımı gözlenmemiştir (Tablo 48).

Tablo 49

PET Verilerinin Katkısı - Model ALL vs Model ALL+PET Karşılaştırması (SMOTE'lu)

Algorithm	Metrik	Model ALL	Model ALL+PET	Değişim	Değişim (%)
RandomForest	Test AUC	0.871	0.818	-0.053	-6.09%
RandomForest	Test Accuracy	0.625	0.575	-0.050	-8.00%
RandomForest	Test F1	0.602	0.564	-0.038	-6.31%
LightGBM	Test AUC	0.866	0.856	-0.010	-1.15%
LightGBM	Test Accuracy	0.675	0.625	-0.050	-7.41%
LightGBM	Test F1	0.577	0.519	-0.058	-10.05%
XGBoost	Test AUC	0.831	0.831	+0.000	+0.00%
XGBoost	Test Accuracy	0.550	0.525	-0.025	-4.55%
XGBoost	Test F1	0.449	0.443	-0.006	-1.34%

4.4.3. Nested Cross-Validation ve Bootstrap Analizleri


Model performansının yalnız bağımsız test setindeki başarısını değil, yeniden örnekleme ve farklı doğrulama stratejileri altında ne ölçüde korunduğunu değerlendirmek amacıyla nested cross-validation, bootstrap ve kalibrasyon analizleri gerçekleştirilmiştir.

Test seti büyüklüğünün sınırlı olması nedeniyle, modellerin genellenebilirliğini değerlendirmek amacıyla 5-fold nested cross-validation analizi gerçekleştirilmiştir. Nested çapraz doğrulama sonuçları Tablo 49 ve Şekil 39'da sunulmakta olup, nested CV AUC değerleri Model PET için 0.629 ± 0.049 , Model ALL için 0.832 ± 0.060 ve Model ALLPET için 0.839 ± 0.047 olarak hesaplanmıştır. Buna göre Model ALL+PET, nested CV AUC bakımından Model ALL'e göre 0.007 puanlık sınırlı bir artış göstermiş; ancak nested CV accuracy ve nested CV F1-macro değerlerindeki farklar oldukça küçük kalmıştır. Şekil 55'te görülen boxplot dağılımları da Model ALL ile Model ALL+PET performanslarının büyük ölçüde örtüştüğünü, Model PET'in ise diğer iki modelden belirgin biçimde ayrıldığını desteklemektedir.

Tablo 50

Nested Cross-Validation Performans Metrikleri

Model	Özellik Sayısı	Nested CV AUC (Ort±SD)	Nested CV Accuracy (Ort±SD)	Nested CV F1-Macro (Ort±SD)
Model PET	14	0.629 ± 0.049	0.465 ± 0.025	0.294 ± 0.036
Model ALL	62	0.832 ± 0.060	0.602 ± 0.098	0.507 ± 0.121
Model ALL+PET	76	0.839 ± 0.047	0.601 ± 0.069	0.517 ± 0.085




Şekil 43. Nested Cross-Validation Sonuçlarının Boxplot Karşılaştırması

Model ALL ile Model ALLPET arasındaki farkın istatistiksel düzeyde değerlendirilmesi için hem paired bootstrap hem de nested CV temelli karşılaştırmalar yapılmıştır. Test seti üzerinde yürütülen paired bootstrap analizinde Model ALL'in ortalama AUC değeri 0.8709 ± 0.0358 , Model ALL+PET'in ortalama AUC değeri ise 0.8564 ± 0.0458 olarak hesaplanmıştır; Wilcoxon signed-rank testi ile fark istatistiksel olarak anlamlı bulunmuştur. Buna karşılık nested CV fold'ları üzerinden yapılan paired t-test sonucunda modeller arasındaki fark anlamlı bulunmamıştır ($p=0.5384$; Cohen's $d=-0.127$). Bu bulgular birlikte değerlendirildiğinde, test seti üzerinde Model ALL lehine izlene bir performans farkı gözlenmesine rağmen, dış doğrulama benzeri nested CV çerçevesinde bu farkın kararlı ve belirgin bir üstünlük olarak ortaya çıkmadığı anlaşılmaktadır (Tablo 51, Grafik 18, Şekil 44).


Tablo 51

PET-BT Katkısının İstatistiksel Anlamlılık Testleri

Test Yöntemi	Veri Kaynağı	Test İstatistiği	P-değeri	Cohen's d	Etki Büyüklüğü	Sonuç
Wilcoxon Signed-Rank Test	Bootstrap ile üretilen AUC Farkları (B=5000; n=4914 geçerli)	2,436,514.0	3.82×10^{-287}	0.592	Orta	Anlamlı
Paired t-test	Nested CV (n=5)	-0.672	0.5384	-0.127	İhmal edilebilir	Anlamlı değil



Şekil 44. Nested CV AUC Karşılaştırması



Grafik 18. Bootstrap AUC Dağılımları ve Karşılaştırması


Bootstrap güven aralığı a analizine ait sonuçlar Tablo 51 ve Şekil 41’de sunulmuştur. Model ALL için bootstrap AUC ortalaması 0.871 ± 0.036 ve %95 güven aralığı 0.794–0.934 iken, Model ALL+PET için bootstrap AUC ortalaması 0.856 ± 0.046 ve %95 güven aralığı 0.758–0.937 olarak bulunmuştur. Her iki modelin güven aralıklarının belirgin biçimde örtüşmesi, test seti düzeyindeki farkın sınırlı olduğunu göstermektedir. Model PET için bootstrap AUC ortalamasının 0.551 ± 0.069 ve güven aralığının 0.409–0.681 düzeyinde kalması ise, yalnızca PET-BT değişkenleriyle kurulan yapının daha düşük ve daha belirsiz performans sergilediğini ortaya koymaktadır (Tablo 51, Şekil 41)

Tablo 52

Test Seti Performansı ve Bootstrap Güven Aralıkları

Model	Test AUC	Test	Test F1-	Bootstrap	95% Güven	CI
Model	0.871	0.625	0.602	$0.871 \pm$	[0.794–0.934]	0.140
Model	0.856	0.625	0.519	$0.856 \pm$	[0.758–0.937]	0.179
Model	0.551	0.400	0.338	$0.551 \pm$	[0.409–0.681]	0.272

Not: Test Accuracy / Test F1-Macro satırları Tablo 49’da SMOTE’lu “seçilen” kurulumlarla uyumludur (ALL=RF, ALL+PET=LGBM, PET=RF).



Şekil 45. Bootstrap Güven Aralıkları Görselleştirmesi


4.4.4. Sınıf Bazlı Performans ve ROC Analizi

Sınıf bazlı ayırıştırma performansını değerlendirmek amacıyla one-vs-rest yaklaşımı ile ROC analizi gerçekleştirilmiş; sınıf bazlı AUC değerleri Tablo 52 ve Şekil 42’de sunulmuştur. Model ALL’de RCB-0, RCB-I, RCB-II ve RCB-III için AUC değerleri sırasıyla 0.784, 0.972, 0.886 ve 0.827 olarak hesaplanırken Model ALLPET’te bu değerler sırasıyla 0.768, 0.958, 0.881 ve 0.797 olarak bulunmuştur. Tüm sınıflarda Model ALL lehine küçük fakat yönü aynı kalan farklar izlenmiştir. En yüksek AUC değerlerinin her iki modelde de RCB-I sınıfında elde edilmesi, bu sınıfın diğer RCB gruplarına göre daha güçlü biçimde ayırıştırılabildiğini göstermektedir. Buna karşılık PET-BT değişkenlerinin eklenmesi, sınıf bazlı ayırıştırma performansında belirgin bir artış oluşturmamıştır.

Tablo 53


Sınıf Bazında AUC Değerleri

RCB Sınıfı	Model ALL	Model ALL+PET	Fark
RCB-0	0.784	0.768	-0.016
RCB-I	0.972	0.958	-0.014
RCB-II	0.886	0.881	-0.005
RCB-III	0.827	0.797	-0.030



Şekil 46. Sınıf Bazında ROC Eğrileri Karşılaştırması

Şekil 46’te sunulan genel ROC eğrileri incelendiğinde, Model PET, Model ALL ve Model ALLPET için genel ROC eğrileri karşılaştırıldığında, entegre modellerin PET temelli modele göre daha yüksek ayrıştırma gücü sergilediği ve Model ALL ile Model ALLPET’in birbirine çok yakın performans verdiği izlenmektedir.




Şekil 47. ROC Eğrileri - En İyi Algoritmalar İçin Her Model

SMOTE uygulanmayan koşullarda Random Forest ile yapılan sınıf bazlı test değerlendirmesi Tablo 54 ve Şekil 47’de sunulmuştur. RCB-0 sınıfında her iki modelin F1-skoru 0.400 düzeyinde kalırken, Model ALL+PET daha yüksek precision fakat daha düşük recall profili göstermiştir. RCB-I sınıfında Model ALL+PET precision bakımından daha yüksek değer üretmiş olup, RCB-II sınıfında ise Model ALL daha yüksek F1-skoruna ulaşmıştır. Her iki modelde de RCB-III sınıfı için precision, recall ve F1-skorunun 0.000 düzeyinde kalması, bu sınıfın ayırt edilmesinin alt örneklem düzeyinde belirgin güçlük taşıdığını göstermektedir.

Tablo 54

Sınıf Bazında Test Seti Performans Metrikleri


RCB Sınıfı	Model	Precision	Recall	F1-Score	Support
RCB-0	Model ALL	0.444	0.364	0.400	11
	Model ALL+PET	0.750	0.273	0.400	11
RCB-I	Model ALL	0.667	0.500	0.571	4
	Model ALL+PET	1.000	0.500	0.667	4
RCB-II	Model ALL	0.571	0.889	0.696	18
	Model ALL+PET	0.485	0.889	0.627	18
RCB-III	Model ALL	0.000	0.000	0.000	7
	Model ALL+PET	0.000	0.000	0.000	7




Not. Support sütunu, her RCB sınıfı için test setindeki gerçek (ground truth) örnek sayısını temsil etmektedir. Her iki model de aynı test setini kullandığı için, Support değerleri her iki model için de aynıdır. Toplam test seti boyutu 40 hastadır ($11+4+18+7=40$).

Şekil 48. Sınıf Bazında Performans Metrikleri Karşılaştırması

Karışıklık matrisi bulguları, model performansının yalnızca özet metriklerle değil, hata yönleri açısından da değerlendirilmesini sağlamıştır. Şekil 49’da sunulan karışıklık matrisi karşılaştırması, Model ALL’in sınıflar arasında daha dengeli bir sınıflandırma örüntüsü sergilediğini göstermektedir. Buna karşılık Model ALL+PET’te bazı sınıflarda precision artışı gözlenmekle birlikte, toplam sınıf dengesi açısından belirgin bir üstünlük izlenmemiştir. Bu örüntü, özet performans metriklerinde gözlenen sınırlı farklarla uyumludur (Şekil 49).





Şekil 49. Confusion Matrix Karşılaştırması

4.4.5. Özellik Önem Analizi ve Yorumlanabilirlik


PET-BT değişkenlerinin model içindeki göreceli ağırlığı, feature importance analizi ile incelenmiştir. Tablo 54'e göre PET-BT değişkenleri, Model ALL+PET içindeki toplam feature importance değerinin %20.4'ünü oluşturmuştur. En yüksek öneme sahip PET-BT değişkenleri SUV varyans, GLCM entropi ve asferisite olarak sıralanmıştır. Bununla birlikte Şekil 46'da sunulan ilk 20 özellik sıralamasında ilk dokuz sıranın klinik-radyolojik değişkenler tarafından işgal edilmesi, PET-BT değişkenlerinin modele katkı verdiğini ancak karar yapısının ana omurgasını oluşturmadığını göstermektedir. İlk PET-BT değişkeninin ancak 10. sırada yer alması da bu dağılımı desteklemektedir (Tablo 55, Şekil 50).

Tablo 55

PET/BT Özelliklerinin Feature Importance Değerleri

Sıra	PET/BT Özelliği	Feature Importance	Kümülatif Önem Payı (%)
1	SUV Varyansı	0.0235	11.5
2	GLCM Entropi	0.0231	22.8
3	Asferisite	0.0195	32.4
4	SUVmean	0.0175	40.9
5	GLRLM Non-Uniformite	0.0164	48.9
6	GLSZM Entropi	0.0141	55.8
7	SUVmax	0.0133	62.3
8	NGTDM Coarseness	0.0125	68.4
9	Küresellik	0.0123	74.4
10	Yüzey/Hacim Oranı	0.0118	80.2
11	TLG	0.0112	85.7
12	MTV	0.0103	90.7
13	SUV Eğriligi	0.0098	95.5
14	GLCM Kontrast	0.0092	100.0
TOPLAM	14 PET Özelliği	0.2042	20.4%

Not. Tablolardaki yüzdeler, özellik önem skorlarının toplamının %100'e normalize edilmesiyle hesaplanan **görelî önem paylarını** ifade eder; model performansına (AUC/Accuracy/F1) doğrudan nedensel katkı olarak yorumlanmamalıdır.



Şekil 50. Feature Importance Analizi

Permutation importance analizi, PET-BT değişkenlerinin performansa gerçek katkı yönünü daha ayrıntılı olarak ortaya koymuştur. Tablo 55'e göre 14 PET-BT değişkeninin 8'i pozitif, 5'i negatif ve 1'i nötr katkı örüntüsü sergilemiştir. En yüksek pozitif katkı SUVmax değişkeninde gözlenirken, en belirgin negatif katkı GLRLM non-uniformite değişkeninde saptanmıştır. Tablo 56'da özetlendiği üzere, PET-BT değişkenlerinin %57.1'i pozitif, %42.9'u ise negatif veya nötr katkı göstermiştir. Bu bulgular, tüm PET-BT değişkenlerinin birlikte modele eklenmesinin her zaman faydalı olmayabileceğini ve katkının değişken bazında heterojen dağıldığını göstermektedir (Tablo 56-57, Şekil 51).

Tablo 56


PET/BT Özelliklerinin Permutation Importance Değerleri

PET Özelliği	Permutation Importance (Ort±SD)	Katkı Türü
SUVmax	0.0060 ± 0.0037	Pozitif
Asferisite	0.0039 ± 0.0114	Pozitif
Küresellik	0.0012 ± 0.0055	Pozitif
TLG	0.0010 ± 0.0015	Pozitif
Yüzey/Hacim Oranı	0.0009 ± 0.0038	Pozitif
GLCM Kontrast	0.0004 ± 0.0024	Pozitif
SUVmean	0.0002 ± 0.0027	Pozitif
SUV Varyansı	0.0001 ± 0.0049	Pozitif
SUV Eğriliği	-0.0000 ± 0.0014	Nötr
MTV	-0.0001 ± 0.0039	Negatif
NGTDM Coarseness	-0.0023 ± 0.0034	Negatif
GLCM Entropi	-0.0045 ± 0.0051	Negatif
GLSZM Entropi	-0.0046 ± 0.0028	Negatif
GLRLM Non-Uniformite	-0.0077 ± 0.0040	Negatif

Tablo 57

PET/BT Özelliklerinin Katkı Özeti

Katkı Türü	Özellik Sayısı	Yüzde	Örnekler
Pozitif katkı	8	57.1%	SUVmax, Asferisite, Küresellik
Negatif/Nötr katkı	6	42.9%	GLRLM Non-Uniformite, GLSZM Entropi, GLCM Entropi, NGTDM Coarseness, MTV, SUV Eğriliği
TOPLAM	14	100%	-




Şekil 51. Permutation Importance Analizi

PET değişkenleri genel olarak katkı sunmakla birlikte, katkı örüntüsü heterojendir; bu nedenle bir sonraki aşamada (Bölüm 4.4.7) bu değişkenlerin tümüyle değil, seçici biçimde kullanımının performans açısından daha rasyonel olup olmadığı değerlendirilmiştir.

4.4.6. Kalibrasyon, Öğrenme Eğrileri ve CV-Test Uyumu


Kalibrasyon analizi, Model ALL ve Model ALL+PET olasılık tahminlerinin sınıf bazında gözlenen olay oranları ile uyumunu değerlendirmek amacıyla yapılmıştır. Şekil 48’de sunulan kalibrasyon eğrileri, her iki modelin özellikle RCB-II sınıfında referans çizgisine daha yakın seyrettiğini; daha küçük örneklem büyüklüğüne sahip RCB-0, RCB-I ve RCB-III sınıflarında ise sapmaların daha belirgin olduğunu göstermektedir. Model ALL ile Model ALL+PET arasında kalibrasyon örüntüsü bakımından büyük bir ayrışma gözlenmemiş, ancak bazı orta olasılık bölgelerinde Model ALL+PET’in daha değişken bir görünüm sergilediği izlenmiştir. Bu sonuçlar,

PET-BT eklenmesinin kalibrasyon düzeyinde de belirgin ve tutarlı bir iyileşme oluşturmadığını göstermektedir (Şekil 48).



Şekil 52. Kalibrasyon Eğrileri

Öğrenme eğrisi analizi, modellerin eğitim verisi ile çapraz doğrulama performansı arasındaki fark üzerinden aşırı öğrenme örüntüsünü incelemiştir. Şekil 49 ve Tablo 57'ye göre Model ALL için final train AUC 0.947, final CV AUC 0.832 ve overfitting gap 0.115; Model ALL+PET için ise final train AUC 0.953, final CV AUC 0.839 ve overfitting gap 0.114 olarak hesaplanmıştır. Her iki modelin benzer büyüklükte train-CV farkı göstermesi, PET-BT değişkenlerinin eklenmesinin aşırı öğrenme örüntüsünü belirgin şekilde değiştirmediğini ortaya koymaktadır. Eğrilerin genel seyri de her iki modelin benzer öğrenme dinamiğine sahip olduğunu göstermektedir (Şekil 53, Tablo 58).



Şekil 53. Learning Curve Analizi

Tablo 58 Learning Curve Final Değerleri


Model	Final Train AUC	Final CV AUC	Overfitting Gap	Değerlendirme
Model ALL	0.947	0.832	0.115	Hafif overfitting
Model ALL+PET	0.953	0.839	0.114	Hafif overfitting

CV-test gap ve bootstrap güven aralığı bulguları birlikte ele alındığında, Model ALL için CV AUC ile test AUC arasındaki fark 0.085, Model ALL+PET için 0.100 olarak hesaplanmıştır. Ayrıca bootstrap %95 güven aralığı genişliğinin Model ALL+PET’te 0.179, Model ALL’de ise 0.140 olması, PET-BT değişkenlerinin eklenmesiyle test AUC tahmininin daha değişken hale gelebildiğini göstermektedir. Model PET’te ise hem CV-test farkının daha yüksek olması hem de güven aralığının belirgin biçimde genişlemesi, bu yapının daha kırılgan bir performans profili taşıdığını ortaya koymaktadır (Tablo 59, Şekil 53).

Tablo 59

CV-Test Gap ve Bootstrap CI Analizi

Metrik/Parametre	Model PET	Model ALL	Model ALL+PET
Seçilen Algoritma (SMOTE'lu)	RandomForest	RandomForest	LightGBM
CV AUC (Mean±Std)	0.836±0.059	0.956±0.021	0.956±0.015
Test AUC	0.551	0.871	0.856
CV-Test Farkı (CV AUC – Test AUC)	+0.285	+0.085	+0.100
Bootstrap Test AUC (Ort±SD)	0.551 ± 0.069	0.871 ± 0.036	0.856 ± 0.046
95% CI	[0.409–0.681]	[0.794–0.934]	[0.758–0.937]
CI Genişliği	0.272	0.140	0.179



Şekil 54. CV-Test Gap ve Bootstrap CI Görselleştirmesi

4.4.7. Seçici PET Değişkeni Senaryoları

Tüm performans göstergeleri birlikte değerlendirildiğinde, Model PET'in hem test seti hem de nested çapraz doğrulama düzeyinde en düşük performansı sergilediği; Model ALL ile Model ALL+PET'in ise birbirine yakın fakat farklı yönlerde üstünlükler taşıdığı görülmektedir. Tablo 59'a göre Model ALL+PET, nested CV AUC ve nested CV F1-macro açısından Model ALL'e çok sınırlı düzeyde üstünlük gösterirken; test

AUC, test F1-macro ve bootstrap AUC bakımından Model ALL daha yüksek değerler üretmiştir. Bu nedenle, PET-BT değişkenlerinin tümüyle entegrasyonu alt örneklem düzeyinde bazı çapraz doğrulama ölçütlerinde marjinal kazanımlar sunsa da, bağımsız test performansı ve belirsizlik profili bakımından belirgin bir üstünlük sağlamamıştır.

Tablo 60

Model Performanslarının Kapsamlı Karşılaştırması

Metrik	Model PET	Model ALL	Model ALL+PET	Fark (ALL+PET - ALL)
Özellik Sayısı	14	62	76	+14
Nested CV AUC	0.629 ± 0.049	0.832 ± 0.060	0.839 ± 0.047	+0.007
Nested CV Accuracy	0.465 ± 0.025	0.602 ± 0.098	0.601 ± 0.069	-0.001
Nested CV F1-Macro	0.294 ± 0.036	0.507 ± 0.121	0.517 ± 0.085	+0.011
Test AUC	0.551	0.871	0.856	-0.015
Test Accuracy	0.400	0.625	0.625	+0.000
Test F1-Macro	0.338	0.602	0.519	-0.083
Bootstrap AUC	0.551 ± 0.069	0.871 ± 0.036	0.856 ± 0.046	-0.015
Bootstrap 95% CI	[0.409-0.681]	[0.794-0.934]	[0.758-0.937]	-
İstatistiksel Anlamlılık (Nested CV)	-	-	-	p=0.5384
Cohen's d (Nested CV)	-	-	-	-0.127
PET/BT Katkı Yüzdesi	100%	0%	20.4%	-
CV-Test Farkı (CV AUC – Test AUC)	0.285	0.085	0.100	+0.015

Permutation importance bulguları doğrultusunda geliştirilen özellik seçimi senaryoları, PET-BT değişkenlerinin seçici kullanımının daha dengeli sonuçlar verebildiğini göstermiştir. Tablo 60'a göre tüm 14 PET-BT değişkenini içeren temel

Model ALL+PET yapısında test AUC 0.856 ve test F1-macro 0.519 iken, negatif ve nötr etkili değişkenlerin çıkarıldığı Senaryo 2’de test AUC 0.862 ve test F1-macro 0.639 değerlerine ulaşılmıştır. Yalnızca SUVmax, TLG ve MTV değişkenlerini içeren Senaryo 3’te ise test AUC 0.856 düzeyinde korunurken test F1-macro 0.554 olarak elde edilmiştir. Bu bulgular, PET-BT verisinin katkısının tüm değişkenlerin birlikte eklenmesinden çok, değişken seçimi ile yapılandırılmış daha rafine bir entegrasyon yaklaşımında ortaya çıktığını göstermektedir (Tablo 61-62).

Tablo 61

Özellik Seçimi Senaryoları ve Performans Karşılaştırması

Model Tanımı	Algoritma	SMOTE	Özellik Sayısı (PET)	CV AUC (Mean±Std)	Test AUC	Test Accuracy	Test F1-Macro
Ana Makine Öğrenmesi Modeli	LightGBM	Yok	0	0.823 ± 0.047	0.838	0.636	0.602
Model PET	RandomForest	Evet	14	0.836 ± 0.059	0.551	0.400	0.338
Model ALL	RandomForest	Evet	0	0.956 ± 0.021	0.871	0.625	0.602
Model ALL	LightGBM	Evet	0	0.957 ± 0.012	0.866	0.675	0.577
Model ALL+PET	LightGBM	Evet	14	0.956 ± 0.015	0.856	0.625	0.519
Senaryo 1 (Konservatif)	LightGBM	Evet	10	0.947 ± 0.024	0.833	0.650	0.563
Senaryo 2 (Agresif)	LightGBM	Evet	8	0.951 ± 0.022	0.862	0.675	0.639
Senaryo 3 (3 PET)	LightGBM	Evet	3	0.952 ± 0.016	0.856	0.625	0.554

Not: Tablo 61'deki değerler, özellik seçimi/alternatif deney akışı kapsamında elde edilmiştir; Model ALL olarak raporlanan “seçilen SMOTE’lu nihai kurulum” birebir aynı train-test bölünmesi ve pipeline’ı temsil etmeyebilir

Tablo 62

Senaryolarda Çıkarılan ve Kalan PET Özellikleri

Senaryo	Çıkarılan Özellikler	Çıkarılan Özellik Sayısı	Kalan PET/BT Özellikleri	Kalan Özellik Sayısı	Seçim Kriteri
Baseline	-	0	Tüm 14 PET özelliği	14	Referans model (tüm özellikler)
Senaryo 1 (Konservatif)	GLRLM Non-Uniformite, GLSZM Entropi, GLCM Entropi, NGTDM Coarseness	4	SUVmax, SUVmean, TLG, Yüzey/Hacim Oranı, Küresellik, Asferisite, SUV Varyansı, GLCM Kontrast, MTV, SUV Eğriliği	10	Net negatif özellikler (importance < 0)
Senaryo 2 (Agresif)	GLRLM Non-Uniformite, GLSZM Entropi, GLCM Entropi, NGTDM Coarseness, MTV, SUV Eğriliği	6	SUVmax, SUVmean, TLG, Yüzey/Hacim Oranı, Küresellik, Asferisite, SUV Varyansı, GLCM Kontrast	8	Negatif ve nötr özellikler (importance ≤ 0)
Senaryo 3 (3 PET)	SUVmean, Yüzey/Hacim Oranı, Küresellik, Asferisite, SUV Varyansı, SUV Eğriliği, GLCM Entropi, GLCM Kontrast, GLRLM Non-Uniformite, NGTDM Coarseness, GLSZM Entropi	11	SUVmax, TLG, MTV	3	En yaygın kullanılan geleneksel PET/BT metrikleri

Not. Senaryo 3, klinik pratikte en yaygın kullanılan üç geleneksel PET/BT metriğini (SUVmax, TLG, MTV) içermektedir. Senaryo 3, Baseline (14 PET/BT özelliği) ile karşılaştırıldığında, 11 özellik çıkarılmasına rağmen benzer performans göstermiştir (Test AUC: 0.8560 vs 0.8543).

Sonuç olarak bu alt örnekleme elde edilen bulgular, yalnızca PET-BT türevli değişkenlerle kurulan modelin RCB öngörüsünde sınırlı performans sergilediğini, PET-BT değişkenlerinin tümüyle mevcut entegre yapıya eklenmesinin ise bağımsız test performansında tutarlı bir iyileşme sağlamadığını göstermektedir. Buna karşılık seçilmiş PET-BT değişkenleriyle oluşturulan daha sade senaryolarda sınıf dengesi ve genel performans açısından daha elverişli sonuçlar elde edilmiştir. Bu çerçevede, metabolik görüntüleme verisinin katkısı tüm değişkenlerin toplu eklenmesinden ziyade, bilgi değeri yüksek parametrelerin seçici entegrasyonu bağlamında ortaya konmuştur.

4.5. Makine Öğrenmesi Modellerinin Klinik Karar Destek Sistemine Entegrasyonu ve Çevirimsel Tıp Uygulamaları

Bu bölümde geliştirilen klinik karar destek sistemleri, makine öğrenmesi modellerinin klinik iş akışlarına entegrasyonunu değerlendirmek üzere çok katmanlı bir prototip mimari çerçevesinde tasarlanmıştır. Geliştirilen yapılar; pCR tahmini için istemci-tabanlı karar destek aracı, web tabanlı BCRIS platformu, masaüstü BCRIS uygulaması ve HİP mobil uygulamasından oluşmaktadır. Sistemler doğrudan klinik kullanım amacıyla değil, metodolojik doğrulama, yazılım mimarisi analizi, kullanıcı deneyimi ve performans değerlendirmesi amacıyla geliştirilmiştir. Bu nedenle bu bölümde sunulan bulgular, klinik uygulamaya geçişten önceki teknik olgunluk düzeyini ortaya koyan ara değerlendirme çıktıları olarak yorumlanmalıdır.

Makine öğrenmesi tabanlı RCB tahmin modeli ile çoklu lojistik regresyon tabanlı pCR tahmin modeli, farklı platformlara entegre edilerek ortak bir karar destek ekosistemi altında birleştirilmiştir. Bu yaklaşım, yalnızca tahmin doğruluğunu değil, aynı zamanda veri giriş biçimi, erişim modeli, çıktı sunumu, güvenlik ve platformlar arası veri akışı gibi çok boyutlu bileşenleri birlikte ele alan bir çevirimsel tıp uygulaması sunmaktadır. Tablo 62, pCR hesaplayıcı, web, masaüstü ve mobil uygulamaların işlevsel kapsamlarını karşılaştırmalı olarak özetlemektedir.

Tablo 63

Geliştirilen Sistemlerin Karşılaştırmalı Özellikleri

Özellik	pCR Hesaplayıcı	Web Uygulaması (BCRIS)	Masaüstü Uygulaması (BCRIS)	Mobil Uygulama (HİP)
Platform	HTML5 / PyQt5 (.exe)	Django (Python)	PyQt5 (Python)	Android (Java)
Erişim	Offline çalışabilir	İnternet bağlantısı gerekli	Offline çalışabilir	İnternet bağlantısı gerekli
RCB Tahmini	Yok	Var	Var	Yok (Sadece Veri toplama)
pCR Tahmini	Var	Var	Var	Yok
Excel Yükleme	Yok	Var	Var	Yok
Excel Oluşturma	Yok	Yok	Yok	Var
Çoklu Dil Desteği	Yok	Var (TR/EN)	Var (TR/EN)	Var (TR/EN)
PDF İndirme	Yok	Var	Var	Yok

Tablo 63 (Devamı) Geliştirilen Sistemlerin Karşılaştırmalı Özellikleri

Hasta Verisi Saklama	Yok (Hiç saklanmaz)	Yok (Geçici)	Yok (Geçici)	Var (Sunucuda)
Hekim Kayıt Sistemi	Yok	Var (Veri paylaşımı için)	Yok	Var
Benzersiz Kod Sistemi	Yok	Yok	Yok	Var
Çoklu Hekim Desteği	Yok	Yok	Yok	Var
Dosya Formatı	HTML / .exe	Web sitesi	.exe	APK
Kurulum Gereksinimi	Yok (portable)	Yok (tarayıcı)	Yok (portable)	Google Play Store

4.5.1. pCR Klinik Karar Destek Aracı

Tezin ikinci bölümünde elde edilen çoklu lojistik regresyon bulguları esas alınarak pCR tahmini için istemci-tabanlı bir klinik karar destek aracı geliştirilmiştir. Araç, RCB-0 ile diğer sınıflar arasında ikili bir sınıflandırma çıktısı üretmekte ve internet bağlantısı gerektirmeden çalışacak biçimde yapılandırılmaktadır. Bu tasarım, hasta verisinin sunucuya aktarılmadan yerel ortamda işlenmesini mümkün kılarak mahremiyet ve erişilebilirlik açısından önemli bir avantaj sağlamaktadır. Şekil 51’de sunulan arayüz, 17 klinik değişken için dinamik seçim alanları, optimal eşik değeri, hesaplama detayları ve kullanıcı etkileşimini destekleyen yardımcı bileşenler içermektedir.

 **pCR Olasılığı Hesaplayıcı**

Neoadjuvan Kemoterapi Sonrası Patolojik Tam Yanıt Tahmini
Model 1 - L2 Regularization | Optimal Eşik: 27.7%

 Hasta Bilgileri

Histolojik Tip

İnvaziv Duktal Karsinom (Referans)

ER Durumu

Güçlü Pozitif (Referans)

PR Durumu

Negatif (Referans)

HER2 Durumu

Negatif (Referans)

Moleküler Tip

Luminal B (HER2 Negatif) (Referans)

Ki-67 İndeksi

Yüksek (Referans)

Tübül Derecesi

3 (Referans)

Nükleer Derece

3 (Referans)

Histolojik Grade

G2 (Referans)

TIL Seviyesi

<%10 (Referans)

Metastaz Durumu

Var (Referans)

Metastaz Yeri

Lenf Nodu (Referans)

Tanı Evresi

Evre IIB (Referans)

Kitle Şekli

Düzensiz (Referans)

Kitle Konturu

Düzgün (Referans)

Kitle Dansitesi

Yüksek Dansite (Referans)

Kalsifikasyon Morfolojisi

Kalsifikasyon Yok (Referans)

 Yüksek pCR Kombinasyonu Seç

Şekil 55. pCR Klinik Karar Destek Aracı – Kullanıcı Arayüzü

Tablo 64’te web ve masaüstü sürümlerin teknik özelliklerini ortaya koymaktadır. Web sürümünün tek HTML5 dosyası olarak çalışması, dağıtım ve güncelleme açısından yüksek esneklik sağlamaktadır. Masaüstü sürümünün PyInstaller ile paketlenmiş bağımsız bir yürütülebilir dosya olması ise internet erişiminin sınırlı olduğu klinik ortamlarda sistemin kullanılabilirliğini artırmaktadır. Tablo 65’te yer alan model parametreleri, sabit terim, optimal eşik değeri, beta katsayıları ve referans kategoriler üzerinden karar mekanizmasının şeffaf biçimde yeniden üretilebildiğini göstermektedir. Bu bulgular, karar destek aracının yalnızca

kullanıcı dostu bir arayüz değil, aynı zamanda izlenebilir ve yeniden kurulabilir bir istatistiksel model sunduğunu ortaya koymaktadır.

Tablo 64

pCR Klinik Karar Destek Aracı – Kullanıcı Arayüzü

Özellik	Web Arayüzü (HTML)	Desktop Uygulama (.exe)
Dosya formatı	Tek HTML5 dosyası	Tek Windows executable
Dosya boyutu	24,2 KB	106,5 MB
İnternet bağlantısı gereksinimi	Yok	Yok
Sunucu gereksinimi	Yok	Yok
Kurulum/Python gereksinimi	Yok	Yok
Hesaplama ortamı	Tarayıcı (client-side)	Yerel (QtWebEngine)
Paketleme aracı	–	PyInstaller 6.16
GUI (Graphical User Interface) framework	Vanilla JS + CSS (Cascading Style Sheets)	PyQt5 5.15.9 + QtWebEngine
Responsive tasarım	Evet (mobil–masaüstü)	Sabit 1400×900 pencere
Güncelleme süresi (yeni model)	< 30 saniye	< 5 dakika

Tablo 65

pCR Model Parametreleri

Parametre	Değer	Kaynak
β_0 (Intercept)	-1.295	model_results.json
Optimal Eşik Değeri	0.277	model_results.json
Toplam Beta Katsayısı Sayısı	45	model_results.json
Referans Kategori Sayısı	17	dummy_coding_info.json
Kategori İsimleri	Dinamik	coklu_lr_hazirlık.json

4.5.2. BCRIS Web Uygulaması

BCRIS web uygulaması, RCB ve pCR tahminlerini aynı çevrimiçi platform içinde birleştiren ana sistem olarak geliştirilmiştir. Uygulama, www.bcris.site alan adı üzerinden erişime açılmış ve 7/24 ulaşılabilir bir yapı kazanmıştır. Şekil 52’de gösterilen ana sayfa arayüzü, kullanıcıyı

ilgili tahmin modüllerine yönlendiren sade ve işlevsel bir giriş katmanı sunmaktadır. Bu yaklaşım, farklı cihazlardan erişimi kolaylaştıran duyarlı tasarım yaklaşımı ile desteklenmiştir.

Breast Cancer Response Intelligence System (BCRIS)
Neoadjuvant Chemotherapy Post-Treatment RCB Category Prediction System

TR EN Login Sign Up Thanks Admin

© 2025 Dağdeviren Vaz 1.0

Contact

Load Features from Excel (.xlsx, .xls) Download Sample Excel File Download Variable Format Info File PCR Hesaplayın Frequently Asked Questions Technical Details Download for Desktop

Model automatically loaded (LGBMClassifier)

Pathology Oncology Demographics Comorbidity Biochemistry Radiology

Histological Type (I): Seçiniz

ER (I2): Seçiniz

PR (I3): Seçiniz

HER2 (I4): Seçiniz

Molecular Type (I5): Seçiniz

Ki-67 (I6): Seçiniz

Tubule Grade (I7): Seçiniz

Nuclear Grade (I8): Seçiniz

Mitotic Grade (I9): Seçiniz

Histological Grade (I10): Seçiniz

TIL Value (I12): Seçiniz

Predict RCB Category

Şekil 56. BCRIS Web Uygulaması Ana Sayfa Ekran Görüntüsü

Uygulamanın kullanıcı arayüzü; patoloji, onkoloji, demografi, komorbidite, biyokimya ve radyoloji olmak üzere altı tematik sekme üzerinden yapılandırılmıştır. Şekil 56’da gösterilen buorganizasyon, çok sayıda klinik değişkenin uzmanlık temelli gruplar halinde sunulmasını sağlayarak hem bilişsel yükü azaltmakta hem de veri girişinin sistematik biçimde yapılmasına olanak tanımaktadır. Form alanlarında kullanılan açılır menüler ve doğrulama mekanizmaları, kullanıcı hatalarını en aza indirmeyi hedefleyen bir arayüz stratejisini yansıtmaktadır.

Tablo 66 (Devamı)

BCRIS Web Uygulaması Kullanıcı Kullanım İstatistikleri ve Memnuniyet Düzeyi

En Hızlı Tamamlanma Süresi (Manuel)	5.2 dakika	Deneyimli kullanıcı, tüm değişkenleri bilerek
En Yavaş Tamamlanma Süresi (Manuel)	14.8 dakika	İlk kez kullanan kullanıcı, değişkenleri araştırarak
En Hızlı Tamamlanma Süresi (Excel)	<1 dakika	Hazır Excel dosyası ile
En Yavaş Tamamlanma Süresi (Excel)	2.5 dakika	Excel formatını öğrenme süreci dahil
Öğrenme Eğrisi	Orta	Kullanıcıların %76'sı (n=40) 2. kullanımdan sonra rahatça kullanabiliyor
Manuel Giriş Tercih Eden Kullanıcı	%38.5 (n=20)	Excel yükleme yerine manuel giriş tercih edenler
Excel Yükleme Tercih Eden Kullanıcı	%61.5 (n=32)	Toplu veri girişi için Excel tercih edenler
Hata Oranı (Manuel Giriş)	%42.3 (n=22 kullanıcı)	Yanlış kategori seçimi, eksik veri girişi veya format hatası
Hata Oranı (Excel Yükleme)	%19.2 (n=10 kullanıcı)	Excel format hatası, sütun uyumsuzluğu
Toplam Hata Sayısı	35 hata	22 manuel giriş kullanıcısında 25 hata, 10 Excel kullanıcısında 10 hata
RCB Tahmin Sonucu Memnuniyeti	4.5/5.0 (ortalama, SS: 0.5)	Likert ölçeği (1-5), n=52
pCR Tahmin Sonucu Memnuniyeti	4.4/5.0 (ortalama, SS: 0.6)	Likert ölçeği (1-5), n=52
Görselleştirme Memnuniyeti	4.6/5.0 (ortalama, SS: 0.4)	Gauge chart ve olasılık dağılımları için
Genel Kullanıcı Memnuniyeti	4.5/5.0 (ortalama, SS: 0.5)	Likert ölçeği (1-5), n=52
	Çok Memnun (5/5)	%61.5 (n=32)
	Memnun (4/5)	%28.8 (n=15)
	Orta (3/5)	%7.7 (n=4)
	Memnun Değil (2/5)	%1.9 (n=1)
Teknik Destek İhtiyacı	%92.3 (n=48)	İlk kullanımda, Excel formatı ve form alanları hakkında sorular
PDF İndirme Kullanım Oranı	%73.1 (n=38)	Tahmin sonuçlarını PDF olarak indiren kullanıcılar
Çoklu Dil Desteği Kullanımı	%19.2 (n=10)	İngilizce dil seçeneğini kullanan kullanıcılar

Excel yükleme altyapısı, sistemin pratik kullanımını belirleyen temel bileşenlerden biri olarak öne çıkmıştır. Tablo 67, PDF çıktısının klinik dokümantasyon açısından hızlı ve hafif bir format sunduğunu göstermektedir. Şekil 58–59’da sırasıyla Excel dosyası yükleme arayüzü, RCB sonuçlarının gauge chart ile görselleştirilmesi ve pCR sonuç ekranı sunulmaktadır. Özellikle gauge chart tabanlı görselleştirme yaklaşımı, kullanıcıların olasılık çıktısını yalnızca sayısal değer olarak değil, aynı zamanda hızlı yorumlanabilir bir grafik biçiminde değerlendirmesine olanak tanımaktadır. Kullanıcı memnuniyeti verilerinde görselleştirme bileşeninin yüksek puan alması, bu tasarımın işlevsel olarak karşılık bulduğunu göstermektedir.

Tablo 67

PDF İndirme Özelliği Özellikleri

Özellik	Değer
PDF Formatı	A4 boyut
İçerik	Tahmin sonuçları, olasılık dağılımları, grafikler
Oluşturma Süresi	< 3 saniye
Dosya Boyutu	Ortalama 200-500 KB



Şekil 58. BCRIS Web Uygulaması - Excel Dosyası Yükleme Arayüzü



Şekil 59. BCRIS Web Uygulaması - RCB Tahmin Sonuçları Görselleştirilmesi

Hasta Bilgileri

Histolojik Tip

İnvaziv Duktal Karsinom (Referans)

ER Durumu

Zayıf Pozitif ($\beta=0.1161$)

PR Durumu

Negatif (Referans)

HER2 Durumu

Pozitif ($\beta=0.3553$)

Moleküler Tip

Luminal B (HER2 Pozitif) ($\beta=0.1765$)

Ki-67 İndeksi

Yüksek (Referans)

Tübül Derecesi

3 (Referans)

Nükleer Derece

3 (Referans)

Histolojik Grade

G3 ($\beta=0.2144$)

TIL Seviyesi

>%50 ($\beta=0.1417$)

Metastaz Durumu

Yok ($\beta=0.5690$)

Metastaz Yeri

Lenf Nodu (Referans)

Tanı Evresi

Evre IIA ($\beta=0.2254$)

Kitle Şekli

Düzensiz (Referans)

Kitle Konturu

Mikrolobüle ($\beta=0.0911$)

Kitle Dansitesi

Eş Dansite ($\beta=0.2683$)

Kalsifikasyon Morfolojisi

İnce Lineer ($\beta=0.0858$)

Yüksek pCR Kombinasyonu Seç

Sonuçlar

pCR Olasılığı

72.09%

Optimal


pCR Pozitif

Bilgi Bu model, neoadjuvan kemoterapi sonrası patolojik tam yanıt (pCR) olasılığını tahmin etmek için geliştirilmiştir. Optimal epik değeri (27.7%) Youden's J indeksi kullanılarak belirlenmiştir.

Hesaplama Detayları

Şekil 60. BCRIS Web Uygulaması - pCR Tahmin Sonuçları Görselleştirmesi

Şekil 61’de sunulan çoklu dil yapısı, uygulamanın Türkçe ve İngilizce olarak kullanılabilmesini sağlamaktadır. Bu özellik, sistemin farklı kullanıcı profillerine uyarlanabilirliğini artıran önemli bir erişilebilirlik bileşenidir. Web uygulamasında tahmin işlemi için kayıt gerekmemesi, veri paylaşımı modülünden ayrı olarak değerlendirilmiş; hekim kayıt ve doğrulama altyapısı yalnızca gönüllü veri katkısı için konumlandırılmıştır. Bu ayrım, sistemin kullanım kolaylığı ile veri yönetişimi arasında dengeli bir mimari kurduğunu göstermektedir.



Şekil 61. BCRIS Web Uygulaması - Dil Seçimi Arayüzü

Web uygulamasının güvenlik ve veri koruma altyapısı ayrıca değerlendirilmiştir. Sistem altyapısı, SSL/TLS yapılandırması, güvenlik başlıkları, istemci uyumluluğu ve potansiyel güvenlik açıklarına ilişkin analizler Tablo 68–75 arasında sunulmaktadır. Bu bulgular, sistemin yalnızca işlevsel bir prototip olmadığını, aynı zamanda operasyonel olarak da olgun bir web

mimarisi sunduğunu göstermektedir. Bununla birlikte HSTS, CSP ve KVKK/GDPR dokümantasyonu gibi bazı alanlarda geliştirme gereksinimlerinin bulunması, sistemin klinik kullanıma geçiş öncesinde ileri güvenlik ve uyumluluk optimizasyonlarına ihtiyaç duyduğunu ortaya koymaktadır. Bu yaklaşım, sistemin güçlü yönleri kadar mevcut sınırlılıklarının da şeffaf biçimde değerlendirilmesini sağlamaktadır.

Tablo 68

Sistem Altyapısı ve DNS Konfigürasyonu

Parametre	Değer
Domain Adı	bcris.site
IP Adresi	82.25.101.93
Sunucu Konumu	srv891530.hstgr.cloud
Kayıt Tarihi	4 Aralık 2025
Bitiş Tarihi	4 Aralık 2026
Registrar	HOSTINGER operations, UAB (IANA ID: 1636)
Ortalama Yanıt Süresi	78 ms (min: 75 ms, max: 80 ms)
Paket Kaybı	%0 (4/4 paket başarılı)

Tablo 69

SSL/TLS Sertifika Özellikleri

Özellik	Değer
Sertifika Türü	RSA 4096 bits (SHA256withRSA)
Common Name	bcris.site
Sertifika Otoritesi	Let's Encrypt (R12)
Geçerlilik Başlangıcı	8 Aralık 2025, 06:07:35 UTC
Geçerlilik Bitişi	8 Mart 2026, 06:07:34 UTC
Sertifika Parmak İzi (SHA256)	36dd1b1682780c97e0edbd5a04c482bc66e11f96ecf94c6240bd4e8730188ad0
İptal Durumu	İyi (iptal edilmemiş)
DNS CAA (Certification Authority Authorization) Politikası	Evet (12 farklı CA onaylanmış)

Tablo 70

SSL Labs Güvenlik Skoru

Kategori	Skor	Açıklama
Sertifika	100/100	RSA 4096 bit, güvenilir CA, geçerli süre
Protokol Desteği	100/100	TLS 1.3 ve TLS 1.2, eski protokoller devre dışı
Anahtar Değişimi	90/100	ECDH x25519 ve secp521r1, Forward Secrecy
Cipher Gücü	90/100	256-bit ve 128-bit AES-GCM, ChaCha20
Genel Not	A	Güçlü güvenlik konfigürasyonu

Tablo 71

Güvenlik Açıkları Tarama Sonuçları

Güvenlik Açığı	Test Sonucu	Açıklama
BEAST Attack	Korumalı	Sunucu tarafında mitigasyon mevcut
POODLE (SSLv3)	Korumalı	SSL 3 desteklenmiyor
POODLE (TLS)	Korumalı	Savunmasız cipher suite yok
Heartbleed (CVE-2014-0160)	Korumalı	Açık tespit edilmedi
Ticketbleed (CVE-2016-9244)	Korumalı	Açık tespit edilmedi
ROBOT Attack	Korumalı	Açık tespit edilmedi
Downgrade Attack	Korumalı	TLS_FALLBACK_SCSV destekleniyor
SSL/TLS Compression	Korumalı	Sıkıştırma devre dışı
RC4	Korumalı	RC4 cipher suite yok

Tablo 72

HTTP Güvenlik Başlıkları Değerlendirmesi

Güvenlik Başlığı	Durum	Değer	Açıklama
X-Frame-Options	Mevcut	DENY	Clickjacking saldırılarına karşı koruma
X-Content-Type-Options	Mevcut	nosniff	MIME-type sniffing saldırılarını engeller
Referrer-Policy	Mevcut	same-origin	Referrer bilgisinin sadece aynı origin'e gönderilmesi
Cross-Origin-Opener-Policy	Mevcut	same-origin	Cross-origin window etkileşimlerini kısıtlar
Strict-Transport-Security	Eksik	-	HTTPS kullanımını zorunlu kılar
Content-Security-Policy	Eksik	-	XSS saldırılarına karşı ek koruma
Permissions-Policy	Eksik	-	Tarayıcı API (Application Programming Interface)'lerine erişimi kontrol eder

Tablo 73

Django Güvenlik Önlemleri ve Uygulama Durumu

Güvenlik Önlemi	Durum	Açıklama
CSRF Koruması	Aktif	Tüm form gönderimlerinde token kontrolü
SQL Injection Koruması	Aktif	Django ORM ile otomatik koruma
XSS Koruması	Aktif	Template sisteminde otomatik escape
HTTPS Protokolü	Aktif	SSL sertifikası ile şifreli bağlantı (TLS 1.3)
Veri Saklama	Geçici	Tahmin sonrası otomatik temizleme
Veri Minimizasyonu	Uygulanıyor	Sadece gerekli veriler işleniyor
Session Yönetimi	Aktif	Güvenli session cookie ayarları

Tablo 74

İstemci Uyumluluğu Test Sonuçları (Seçilmiş Örnekler)

İstemci	TLS Versiyonu	Cipher Suite	Forward Secrecy
Android 9.0	TLS 1.3	TLS_CHACHA20_POLY1305_SHA256	OK
Chrome 80 / Win 10	TLS 1.3	TLS_AES_128_GCM_SHA256	OK
Firefox 73 / Win 10	TLS 1.3	TLS_AES_128_GCM_SHA256	OK
Safari 12.1.2 / MacOS	TLS 1.3	TLS_CHACHA20_POLY1305_SHA256	OK
Edge 18 / Win 10	TLS 1.2	TLS_ECDHE_RSA_WITH_AES_128_GCM_SHA256	OK
IE (Internet Explorer)11 / Win 10	TLS 1.2	TLS_ECDHE_RSA_WITH_AES_128_GCM_SHA256	OK

Tablo 75

Tespit Edilen Güvenlik Açıkları ve Risk Değerlendirmesi

Açık	Risk Seviyesi	CVSS Puanı	Öncelik	Açıklama
KVKK/GDPR Uyumsuzluk	Kritik	9.5/10	P0	Gizlilik politikası, KVKK aydınlatma metni eksik
HSTS Eksik	Kritik	8.0/10	P0	SSL stripping saldırılarına açık
CSP Eksik	Kritik	8.5/10	P0	XSS saldırılarına karşı ek koruma yok
Dosya Upload Güvenliği	Kritik	8.0/10	P0	Dosya yükleme güvenlik kontrolleri belirsiz
Django Admin Varsayılan Konum	Yüksek	7.5/10	P1	/admin/ adresi varsayılan konumda
Cookie Güvenlik Flags	Yüksek	7.0/10	P1	HttpOnly ve Secure flags eksik
Versiyon Bilgisi Açığa Çıkması	Orta	5.5/10	P2	Footer'da "Ver.1.0" bilgisi görünür
DNS Yapılandırması	Orta	6.0/10	P2	www subdomain farklı IP'ye işaret ediyor

4.5.3. BCRIS Masaüstü Uygulaması

BCRIS masaüstü uygulaması, web sisteminin işlevsel karşılığı olarak bağımsız ve taşınabilir bir .exe sürümü şeklinde geliştirilmiştir. Bu yapı, özellikle internet bağlantısının sınırlı olduğu veya veri aktarımının tercih edilmediği klinik ortamlarda kullanım avantajı sağlamaktadır. Tablo 76, uygulamanın yazılım bileşenlerini, paketleme yaklaşımını ve teknik çerçevesini özetlemektedir. Masaüstü sürümün web sürümüyle benzer işlevselliği paylaşması, platformlar arası tutarlılığı güçlendiren bir tasarım kararı olarak değerlendirilebilir.

Tablo 76

BCRIS Masaüstü Uygulaması Teknik Özellikleri

Özellik	Değer
Framework	PyQt5
Python Sürümü	3.11 (gömülü)
Executable Boyutu	~150 MB
Dosya Adı	BCRIS.exe
Paketleme Aracı	PyInstaller
Bağımlılıklar	Dahil (joblib, pandas, numpy, lightgbm)
İşletim Sistemi	Windows 10/11 (64-bit)
Minimum İşletim Sistemi	Windows 7 (64-bit)
Kurulum Gereksinimi	Yok (portable)
Python Kurulumu Gereksinimi	Yok (gömülü)
Offline Çalışma	Var Tam destek
RCB Tahmini	Var
pCR Tahmini	Var (Entegre)

Tablo 77, masaüstü sürümün performans özelliklerini göstermektedir. Başlatma süresi, tahmin hesaplama süresi ve bellek kullanımı kabul edilebilir düzeylerde raporlanmış, bu da uygulamanın yerel donanım üzerinde hafif bir işlem yükü oluşturduğunu göstermiştir. Bu sonuç, masaüstü sürümün yalnızca yedek bir dağıtım kanalı değil, aynı zamanda bağımsız bir kullanım ortamı olarak da işlev görebildiğini düşündürmektedir. Yerel çalışmanın sağladığı ek avantaj, veri gizliliği ve çevrimdışı kullanılabilirliktir.

Tablo 77

BCRIS Masaüstü Uygulaması Performans Metrikleri

Metrik	Değer	Test Ortamı
Başlangıç Süresi	< 3 saniye	Windows 11, SSD (Model yükleme dahil)
RCB Tahmin Süresi	< 1 saniye	64 değişken için
pCR Tahmin Süresi	< 50 ms	17 değişken için
Excel Yükleme Süresi	< 2 saniye	10 MB dosya için
Görselleştirme Süresi	< 0.5 saniye	Chart.js render
Bellek Kullanımı (Başlangıç)	120-150 MB	Windows 11
Bellek Kullanımı (Çalışma)	150-180 MB	Windows 11
CPU Kullanımı (Boşta)	< 1%	Windows 11
CPU Kullanımı (Tahmin)	3-8%	Windows 11
Disk Kullanımı	~150 MB	-

4.5.4. HİP Mobil Uygulaması

HİP mobil uygulaması, doğrudan tahmin üreten bir sistemden çok, çok merkezli veri toplama ve hekimler arası koordinasyonu destekleyen bir ara platform olarak kurgulanmıştır. Şekil 62–65 arasında gösterilen kod sistemi, ana giriş ekranı, yeni hasta kayıt yapısı ve kod üretme arayüzü, hasta kimliğinden ayrıştırılmış veri yönetimi yaklaşımını desteklemektedir. Bu mimari, aynı hastaya ait verilerin farklı hekimler tarafından ayrı ayrı girilip sonra tek bir kod üzerinden bütünleştirilmesini mümkün kılmaktadır. Böylece mobil uygulama, yalnızca veri giriş aracı değil, aynı zamanda dağıtık veri toplama altyapısı haline gelmektedir.



Şekil 62. Benzersiz ID (Kimlik) Atama (Deneme Hastası na atanan ID ve ID Paylaşım Seçenekleri)



Şekil 63. HİP Ana Giriş Ekranı

Şekil 64. Yeni Hasta Kaydı Oluşturma Ekranı

Şekil 65. HİP Mobil Uygulaması - Hasta Oluşturma ve Kod Üretme Arayüzü

Şekil 66 ve 67, veri toplama ve birleştirme akışını göstermektedir. Uzmanlık alanlarına göre ayrılmış veri giriş yapısı, veri kalitesini artırmayı ve görev ayrışmasını desteklemeyi hedeflemektedir.

The image displays two mobile application screens. The left screen, titled 'Hasta Bilgileri', shows a form for entering patient information. It includes fields for ID (7PiX3gyc76TWoMQfhr7o), Adı (Deneme), Soyadı (Hastası), and Protokol No (123456). Below the form are three sections for data entry: 'BEKLEYEN', 'Patoloji verilerinin girişini yapın', 'Onkoloji verilerinin girişini yapın', and 'Demografik verilerinin girişini yapın'. Each section has a 'VERİ GİR' button. The right screen, titled 'Hasta Kaydı', shows a 'HASTA EKLE' section with a 'Mevcut Hasta Ekle' button. Below this is a 'HASTA LİSTESİ' section. The 'Deneme Hastası' entry is highlighted, showing the same ID and a list of 'Mevcut Veriler' (Patoloji, Onkoloji, Demografik, Komorbite, Biyokimya, Radyoloji) with status indicators (red 'X' for missing, green checkmark for present). A 'VERİ GİRİŞİ' button is at the bottom.

Şekil 66. Veri Toplama Ana Ekranı ve Veri Girişi Arayüzü

The image shows a mobile application screen titled 'cevdet havalı' with ID 'qhjNgQEJlfawHLctUqKD'. It displays a 'Protokol No' of 0102345 and a list of 'Mevcut Veriler' (Patoloji, Onkoloji, Demografik, Komorbite, Biyokimya, Radyoloji) with status indicators (red 'X' for missing, green checkmark for present). A 'VERİ GİRİŞİ' button is at the bottom.

Şekil 67. HİP Veri Birleştirme ve Durum Takibi Arayüzü

Şekil 68 ve Şekil 69, kayıt, dışa aktarma ve dağıtım sürecini temsil ederek uygulamanın operasyonel kullanım döngüsünü tamamlamaktadır. Tablo 78, benzersiz kod sisteminin işlevsel özelliklerini; Tablo 79, Excel dışa aktarma işlevini; Tablo 80, hekim doğrulama sürecini; Tablo 81 ise güvenlik mimarisini ve veri koruma yaklaşımını özetlemektedir. Bu bulgular, mobil platformun veri toplama, anonimleştirme, doğrulama ve aktarım aşamalarını tek bir kontrollü iş akışına dönüştürdüğünü göstermektedir.



Şekil 68. HİP Mobil Uygulaması – Hekim Kayıt Arayüzü



Şekil 69. HİP Android Uygulaması - Google Play Store Ekran Görüntüsü

Not: Uygulama, Google Play Store'da
[https://play.google.com/store/apps/details?id=com.flutter_medical_app.android]
adresinden erişilebilir durumdadır.

Tablo 78

Benzersiz Kod Sistemi Özellikleri

Özellik	Değer
Kod Formatı	Alfanumerik (20 karakter)
Benzersizlik	%100 garanti
Güvenlik	Hasta kimliği sadece ilgili konsultan hekimler arasında
Paylaşım Yöntemi	E-posta, WhatsApp, SMS

Tablo 79

Excel Dosyası Oluşturma Özellikleri

Özellik	Değer
Format	.xlsx
Sütun Yapısı	2 sütun (değişken adları, değerleri)
Oluşturma Süresi	< 2 saniye (64 değişken için)
Uyumluluk	BCRIS masaüstü ve web uygulaması

Tablo 80

Hekim Doğrulama Süreci Metrikleri

Aşama	Ortalama Süre	Durum
Kayıt Formu Doldurma	5-10 dakika	Manuel
Sistem Yöneticisi İnceleme	1-3 iş günü	Manuel
Doğrulama Onayı	Anında	Otomatik
Toplam Süre	1-3 iş günü	-

Tablo 81

HİP Uygulaması Güvenlik Önlemleri


Güvenlik Önlemi	Durum	Açıklama
Benzersiz Kod Sistemi	Var Aktif	Hasta kimliği gizli
HTTPS Protokolü	Var Aktif	Şifreli veri aktarımı
Veri Şifreleme	Var Aktif	AES-256 algoritması
JWT Kimlik Doğrulama	Var Aktif	Güvenli oturum yönetimi
KVKK Uyumluluğu	Var Uyumlu	Kişisel veri koruma
GDPR Uyumluluğu	Var Uyumlu	Avrupa veri koruma

Mobil uygulamanın güvenlik mimarisinde benzersiz kod sistemi, HTTPS bağlantısı, AES-256 şifreleme ve JWT kimlik doğrulama mekanizması temel bileşenler olarak yapılandırılmıştır. KVKK ve GDPR uyumluluğu, sistemin yalnızca teknik değil aynı zamanda etik ve hukuki gereklilikleri de dikkate aldığını göstermektedir. Bu yapı, mobil platformun klinik veri üretiminde güvenli ara katman olarak konumlandırılmasını sağlamaktadır. Google Play Store erişimiyle dağıtım aşamasına taşınması, sistemin prototip seviyesinin ötesine geçerek uygulanabilir bir ürün haline geldiğini göstermektedir.

4.5.5. Platformlar Arası Entegrasyon

Şekil 69, HİP mobil uygulaması, BCRIS masaüstü sürümü ve web uygulaması arasındaki veri akışını bütüncül biçimde göstermektedir. Buna göre mobil platformda toplanan veriler Excel formatına dönüştürülmekte, ardından masaüstü ya da web uygulamasına aktarılmakta ve burada RCB ile pCR tahminleri çalıştırılmaktadır. Son aşamada sonuçlar PDF olarak dışa aktarılabilmektedir. Bu süreç, veri toplama, model uygulama ve sonuç raporlama aşamalarını tek bir karar destek zinciri içinde birleştiren modüler bir altyapı oluşturmaktadır.

Genel değerlendirme yapıldığında, geliştirilen sistemler yalnızca bir yazılım seti değil, aynı zamanda klinik veri akışını yapılandıran çok katmanlı bir dijital ekosistem niteliği taşımaktadır. pCR aracının istemci-tabanlı güvenli yapısı, web ve masaüstü BCRIS sistemlerinin tahmin ve raporlama kapasitesi, HİP mobil uygulamasının veri toplama ve yönetim işlevi ile ele alındığında, bu mimarinin teknik olarak tutarlı, işlevsel olarak entegre ve kullanım açısından ölçeklenebilir olduğu görülmektedir. Bu sonuçlar, makine öğrenmesi modellerinin klinik karar destek sistemlerine aktarılmasının yalnızca algoritmik doğrulukla değil, arayüz tasarımı, güvenlik, performans ve veri organizasyonu ile değerlendirilmesi gerektiğini açık biçimde göstermektedir.




Şekil 70 Sistem Entegrasyonu ve Veri Akışı Diyagramı

4.6. Sağlık Ekonomisi ve Maliyet-Etkinlik Analizi Perspektifi

4.6.1. Model Performansının Sağlık Ekonomisi Açısından Karşılaştırılması

Bu çalışmada RCB-0 tespiti, sağlık ekonomisi değerlendirmesine girdi sağlayan temel karar problemi olarak “RCB-0 versus Diğer” biçiminde ikili sınıflama çerçevesinde ele alınmıştır. Test kümesi (n=66) üzerinden elde edilen performans metrikleri, 100 hastalık hipotetik bir kohort simülasyonuna uyarlanarak modellerin klinik ve ekonomik etkilerinin ölçeklenebilir biçimde değerlendirilmesi amaçlanmıştır. Bu simülasyonda, %27 pCR prevalansı esas alınarak 27 hastanın gerçek RCB-0 grubunda yer aldığı varsayılmıştır.

Model R, 0,389 duyarlılık ile yaklaşık 10,5 hastayı doğru tespit ederken 16,5 hastayı yanlış negatif olarak kaçırmıştır. Buna karşılık Model ALL, 0,611 duyarlılık düzeyine ulaşarak yaklaşık 16,5 hastayı doğru tespit etmiş ve kaçırılan hasta sayısını 10,5’e indirgemıştır. Bu fark, Model ALL’ın mutlak duyarlılıkta 0,222 puanlık artış sağladığını ve 100 hastalık kohort düzeyinde ek 6 hastanın doğru sınıflandırılmasına karşılık geldiğini göstermektedir. Şekil 71, bu projeksiyonu görsel olarak sunmakta ve Model R ile Model ALL arasındaki TP/FN dağılımını karşılaştırmaktadır.



Şekil 71. 100 Hastalık Kohortta Model R ve Model ALL’ın RCB-0 Tespitindeki Hasta Sayısı Karşılaştırması

4.6.2. 100 Hastalık Hipotetik Kohortta Maliyet-Etkinlik Simülasyonu

Maliyet-etkinlik simülasyonunda test kümesinden elde edilen duyarlılık değerleri, literatür temelli birim maliyetlerle birleştirilmiştir. Simülasyonda 100 hastalık varsayımsal kohort içinde 27 hastanın gerçek pCR, 73 hastanın ise rezidüel hastalık grubunda olduğu kabul

edilmiştir. Kullanılan ekonomik parametreler, doğrudan gerçek yaşam maliyet analizi niteliğinde olmayıp, geliştirilen karar destek stratejilerinin potansiyel sağlık sistemi etkisini öngörmeye yönelik translasyonel projeksiyonlar olarak değerlendirilmelidir


Model R senaryosunda düşük duyarlılık nedeniyle 16,5 hastanın yanlış negatif olarak kalması, bu hastalarda gereksiz adjuvan kemoterapi yükü oluşmasına yol açmıştır. Model R, operasyonel ek maliyet oluşturmeyen bir strateji gibi görünmekle birlikte, yanlış negatif hastalar üzerinden oluşan adjuvan kemoterapi yükü nedeniyle toplam yönetim maliyeti bakımından dezavantajlı bir profil sergilemiştir. Buna karşılık Model ALL ise hasta başına 300 TL düzeyinde operasyonel maliyet oluşturmaya karşın, yanlış negatif hasta sayısını azaltarak adjuvan kemoterapi maliyetini düşürmüştür.

Tablo 82’de, iki strateji arasındaki duyarlılık, TP/FN dağılımı, operasyonel maliyet, FN kaynaklı adjuvan kemoterapi yükü, artımlı yönetim maliyeti ve QALY kaybını tek bir karşılaştırmalı çerçevede özetlemektedir. Simülasyon sonuçları, Model ALL yaklaşımının Model R’ye göre yaklaşık 330.000 TL düzeyinde net maliyet avantajı ve yaklaşık 0,75 QALY kazancı sağladığını göstermektedir. Şekil 84 ve Şekil 85 sırasıyla sınıf bazlı hata örüntülerini ve 100 hastalık kohortta TP/FN projeksiyonunu göstermektedir. Şekil 86 ise toplam maliyet bileşenlerinin Model R ve Model ALL arasında nasıl farklılaştığını ortaya koymaktadır.


Tablo 82

Model R ve Model ALL Senaryolarının Karşılaştırmalı Sonuçları (100 Hasta Kohortu Simülasyonu)


Gösterge (100 Hasta Kohortu)	Model R (Otomasyon)	Model ALL (Entegre)	Fark (Model ALL Etkisi)
Recall (Duyarlılık)	0,389	0,611	+0,222
Doğru Tespit Edilen RCB-0 (TP)	10,5 Hasta	16,5 Hasta	+6 Hasta
Yanlış Negatif (FN)	16,5 Hasta	10,5 Hasta	-6 Hasta
Operasyonel İş Gücü Maliyeti (Veri Girişi)	0 TL	30.000 TL	+30.000 TL (Yük)
FN Kaynaklı Adjuvan KT Maliyeti (FN × 60.000)	990.000 TL	630.000 TL	-360.000 TL (Tasarruf)
Artımlı Yönetim Maliyeti (Operasyonel + FN-KT)	990.000 TL	660.000 TL	-330.000 TL (Net Tasarruf)
Toplam QALY Kaybı (100 Hasta Kohortu; Toksisite Kaynaklı)	2,06 QALY	1,31 QALY	+0,75 QALY



Şekil 72. Model R ve Model ALL'ın RCB-0 ve RCB-III Tespit Karşılaştırması



Şekil 73. 100 Hastalık Kohortta TP ve FN Projeksiyonu




Şekil 74. Maliyet Bileşenlerinin Karşılaştırılması - Model R vs Model ALL


4.6.3. ICER ve Artımlı Analiz

Artımlı analiz sonuçlarına göre Model ALL, Model R'ye kıyasla 0,75 QALY ek kazanç sağlamış, buna karşılık toplam maliyet farkı 380.000 TL olarak hesaplanmıştır. Tablo 139'da yer alan artımlı yönetim maliyeti bileşenleri ile toplam maliyet farkı birlikte değerlendirildiğinde, ICER hesabında kullanılan maliyet tanımının yalnızca operasyonel iş gücü ve FN kaynaklı adjuvan kemoterapi yükünü değil, stratejiler arasındaki toplam tedavi maliyet farkını temsil ettiği görülmektedir. Bu değerler kullanılarak hesaplanan ICER 506.667 TL/QALY düzeyine ulaşmıştır. Bu oran, çalışmada kullanılan WHO-CHOICE temelli eşik değerleriyle karşılaştırıldığında maliyet-etkin sınırlar içinde değerlendirilmektedir.

Şekil 87, gereksiz adjuvan kemoterapiye bağlı QALY kaybını ve hasta sayısını karşılaştırmalı olarak sunarken, Şekil 75 Model ALL'in Model R'ye göre artımlı maliyet-etkinlik düzlemindeki konumunu göstermektedir. Bu bulgular, Model ALL'ın daha yüksek maliyet üretmesine karşın sağlık kazanımı açısından anlamlı bir üstünlük sağladığını göstermektedir. Dolayısıyla model, sağlık sistemi perspektifinden ekonomik açıdan savunulabilir bir strateji olarak ortaya çıkmıştır.



Şekil 75. Model R ve Model ALL İçin Gereksiz Adjuvan Kemoterapi Nedeniyle QALY Kaybı ve Hasta Sayısı Karşılaştırması




Şekil 76. Model ALL'in Model R'ye göre artımlı maliyet-etkinlik düzlemi (ICER analizi)

4.6.4. Hibrit Basamaklı Strateji


Hibrit yaklaşım, tüm hastalara öncelikle Model R'nin uygulanması ve yalnızca belirli risk profiline sahip veya şüpheli olgularda Model ALL'ın devreye alınması prensibine dayanmaktadır. Bu yapı, daha düşük kaynak kullanımı ile daha seçici bir modelleme yaklaşımı sunmakta ve klinik karar zincirinde basamaklı bir tarama mantığı oluşturmaktadır. Bu

senaryoda gereksiz adjuvan kemoterapi alan hasta sayısı Model R ile Model ALL arasında ara bir düzeye yerleşmiştir.


Model R, hibrit yaklaşım ve Model ALL için karşılaştırmalı sonuçlar Şekil 77–79’da sunulmuştur. Özellikle Şekil 77, basamaklı algoritmanın maliyet yapısını ve karar akışını şematik olarak göstermektedir. Şekil 78 ve Şekil 79 ise gereksiz adjuvan kemoterapi kaynaklı QALY kaybı ile artımlı maliyet-etkinlik ilişkisini birlikte ortaya koymaktadır. Hibrit yaklaşımın, tamamen radyoloji temelli stratejiye göre belirgin sağlık kazanımı sunduğu ancak tam çoklu veri yaklaşımına kıyasla daha sınırlı etkinlik ürettiği görülmektedir.



Şekil 77. Hibrit Yaklaşım - Risk-Tabanlı Basamaklı Tanı Algoritması Ve Maliyet Analizi



Şekil 78. Model R, Hibrit Yaklaşım ve Model ALL İçin Gereksiz Adjuvan Kemoterapi Nedeniyle QALY Kaybı ve Hasta Sayısı Karşılaştırması




Şekil 79. Model R, Hibrit Yaklaşım ve Model ALL için Incremental Maliyet-Etkinlik Analizi


4.6.5. Duyarlılık Analizi

Duyarlılık analizi, pCR prevalansı değiştiğinde modelin maliyet-etkinlik davranışının anlamlı biçimde değiştiğini göstermiştir. Düşük pCR prevalansı senaryosunda dahi Model ALL maliyet-etkinlik profilini koruduğu, yüksek pCR prevalansı senaryosunda ise “çok maliyet-etkin” bölgeye yaklaştığı gözlenmiştir. Bu sonuç, modelin hasta profili ve epidemiyolojik dağılıma duyarlı bir ekonomik performans sergilediğini göstermektedir.

Şekil 80, pCR prevalansına göre ICER değişimini ve WHO eşikleriyle karşılaştırmayı sunmaktadır. Şekil 81 ise tornado diyagramı ile ICER üzerinde en etkili değişkenleri göstermekte; pCR prevalansı, NAK maliyeti, adjuvan kemoterapi maliyeti ve modele özgü operasyonel maliyetin başlıca belirleyiciler olduğunu ortaya koymaktadır. Bu bulgular, ekonomik modelin belirsizlik karşısında hangi parametrelerden en fazla etkilendiğini göstermesi açısından önemlidir.



Şekil 80. Duyarlılık Analizi - pCR Prevalansına Göre Model ALL ve Hibrit Yaklaşımın ICER Değerleri ve WHO Maliyet-Etkinlik Eşikleri ile Karşılaştırması



Şekil 81. Model Sonuçları Üzerindeki Belirsizliklerin Değerlendirilmesi: Tornado Diyagramı

4.6.6. Ulusal Perspektiften Bütçe Etkisi

Türkiye sağlık sistemi perspektifinden yapılan bütçe etkisi analizi, literatür temelli varsayımsal epidemiyolojik ve ekonomik projeksiyonlar üzerine kurgulanmıştır. Yıllık yaklaşık 20.000 yeni meme kanseri vakası olduğu ve bu hastaların yaklaşık %25'inin neoadjuvan kemoterapi adayı oluşturduğu kabul edilmiştir. Bu varsayım doğrultusunda teorik yıllık hedef popülasyon

yaklaşık 5.000 hasta olarak tanımlanmış, teknoloji benimsenme oranı (uptake) ise baz senaryoda %30 olarak alınmıştır. Böylece yıllık analiz 1.500 hasta üzerinden yürütülmüştür. Maliyet hesaplamalarında, çalışma kapsamında tanımlanan birim maliyetler ilgili maliyet yılına sabitlenmiş ve tüm stratejiler aynı zaman ufku içinde karşılaştırılmıştır.

Bu çerçevede Model R, Hibrit yaklaşım ve Model ALL için yıllık toplam maliyet, QALY kaybı, QALY kazancı ve maliyet-etkinlik durumları Tablo 83'te özetlenmiştir. Tablo 83, ulusal bütçe etkisinin sayısal omurgasını oluşturarak stratejiler arasındaki maliyet ve sağlık kazanımı farklarını karşılaştırmalı biçimde göstermektedir. Bulgular, Model ALL'in daha yüksek toplam maliyet üretmesine karşın daha yüksek QALY kazancı sağladığını; Hibrit yaklaşımın ise Model R'ye göre sınırlı ek maliyetle orta düzey bir sağlık kazanımı sunduğunu ortaya koymaktadır.


Tablo 83

Türkiye Sağlık Sistemi Perspektifinden Yıllık Perspektifte Bütçe Etkisi ve QALY Analizi
(uptake %30; n=1.500)


Metrik	Model R	Hibrit	Model ALL
Yıllık Toplam Maliyet (Hasta Başı)	64.190 TL	65.740 TL	67.990 TL
Yıllık Toplam Maliyet (1.500 hasta)	96.285.000 TL	98.610.000 TL	101.985.000 TL
Ek Bütçe (Model R'ye göre)	Referans	+2.325.000 TL	+5.700.000 TL
QALY Kaybı (Hasta Başı)	0,0206	0,0176	0,0131
Yıllık Toplam QALY Kaybı (1.500 hasta)	30,90 QALY	26,40 QALY	19,65 QALY
QALY Kazancı (Model R'ye göre)	Referans	+4,50 QALY	+11,25 QALY
ICER (Model R'ye göre)	Referans	516.667 TL/QALY	506.667 TL/QALY
Maliyet-Etkinlik Durumu	Referans	✓ Maliyet-Etkin	✓ Maliyet-Etkin

Şekil 82, yıllık bütçe etkisini; Şekil 83, beş yıllık projeksiyonu; Şekil 84 ise kümülatif bütçe etkisi ve QALY kazancı dağılımını göstermektedir. Bu görseller birlikte değerlendirildiğinde, Model ALL'in daha yüksek toplam bütçe gerektirmesine karşın daha yüksek sağlık kazanımı sağladığı; Hibrit yaklaşımın ise daha sınırlı ek bütçeyle orta düzey sağlık kazanımı sunduğu


anlaşılmaktadır. Bu sonuçlar, sağlık ekonomisi açısından karar vericilere farklı kaynak kullanımını profilleri sunmaktadır.



Şekil 82. Türkiye ulusal perspektifinde yıllık bütçe etkisi karşılaştırması - Model R, Hibrit ve Model ALL



Şekil 83. Türkiye sağlık sistemi perspektifinde 5 yıllık projeksiyonda Model R'ye göre ek bütçe etkisi ve QALY kazancı (5.000 hasta/yıl)



Şekil 84. Türkiye sağlık sistemi perspektifinde 5 yıllık kümülatif bütçe etkisi ve QALY kazancı projeksiyonu

4.5.6. Bulguların Bütüncül Yapısı

Genel değerlendirme yapıldığında, geliştirilen stratejiler yalnızca tanısal performans açısından değil, aynı zamanda kaynak kullanımı ve sağlık kazanımı dengesi bakımından da anlamlı farklılıklar göstermektedir. Model ALL, daha yüksek operasyonel maliyet üretmesine karşın daha az yanlış negatif sonuç ve daha düşük gereksiz kemoterapi yükü nedeniyle klinik ve ekonomik açıdan üstün bir profil sergilemiştir. Hibrit yaklaşım ise daha dengeli bir kaynak kullanımı sunarak ara bir çözüm üretmiş, ancak tam çoklu veri stratejisinin sağladığı etkinlik düzeyine ulaşamamıştır.

Bu bulgular, makine öğrenmesi tabanlı karar destek sistemlerinin klinik doğruluk kadar sağlık sistemi sürdürülebilirliği açısından da değerlendirilmesi gerektiğini göstermektedir. Özellikle pCR tespitinde duyarlılığın artması, yalnızca doğru sınıflandırma oranını yükseltmekle kalmamakta; aynı zamanda gereksiz tedavi yükünü azaltarak maliyet ve yaşam kalitesi üzerinde anlamlı etki oluşturmaktadır.

Tartışma

5.1. Rezidüel Kanseri Yükü (RCB) Skorunun Klinikopatolojik Özelliklerle İlişkisi

Bu bölümde, neoadjuvan kemoterapi sonrası RCB'nin klinik, histopatolojik, moleküler, biyokimyasal, radyolojik ve demografik değişkenlerle ilişkisi, 328 hastalık görece homojen bir Türk meme kanseri kohortunda çok katmanlı istatistiksel yöntemlerle değerlendirmiştir (Symmans ve ark., 2007; Yau ve ark., 2022). Bulgular, RCB'nin yalnızca tümör hücreliliği ve nodal yükü özetleyen bir skor olmadığını; tedavi yanıtı, tümör biyolojisi, immün mikroçevre ve sistemik yayılım eğilimini birlikte yansıtan bütüncül bir klinik-biyolojik gösterge olduğunu ortaya koymaktadır (Symmans ve ark., 2007; Yau ve ark., 2022). Bu nedenle tartışmanın odağı, bu çok değişkenli yapının biyolojik temeli, literatürle uyumu ve ayrıştığı yönler ile translasyonel karşılığı olmalıdır (Cortazar ve ark., 2014; Yau ve ark., 2022).

Çalışmada saptanan pCR oranı %27,4 olup, bu oran neoadjuvan meme kanseri serilerinde bildirilen yaklaşık %20–30 aralığıyla uyumludur (Cortazar ve ark., 2014; von Minckwitz ve ark., 2012; Spring ve ark., 2020). Bununla birlikte, bu uyum yalnızca sayısal bir paralellik olarak değil, kohortun biyolojik bileşimiyle birlikte yorumlanmalıdır. pCR oranı alt tip dağılımı, kullanılan kemoterapi rejimi, HER2-pozitif olgularda hedefe yönelik tedavi kullanımı ve hormon reseptörü pozitif olguların oranından anlamlı biçimde etkilenmektedir (Cortazar ve ark., 2014; von Minckwitz ve ark., 2012). Kohortta Luminal B alt tipinin baskın olması, antrasiklin-taksan temelli rejimin yaygın kullanımı ve yüksek proliferatif aktivitenin görece sık görülmesi, gözlenen pCR oranının beklenen aralıkta kalmasını açıklamaktadır (Rouzier ve ark., 2005; von Minckwitz ve ark., 2012). Bu çerçevede pCR, yalnızca bir başarı oranı değil, kohortun genel biyolojik yanıt kapasitesini yansıtan bilinen fakat değerli bir göstergedir (Cortazar ve ark., 2014).

RCB dağılımının bimodal yapı göstermesi, çalışmanın en dikkat çekici biyolojik bulgularından biridir (Symmans ve ark., 2007; Yau ve ark., 2022). Yaklaşık 1,65 ve 3,02 çevresindeki yoğunlaşmalar, neoadjuvan tedaviye yanıtın tek bir süreklilik içinde değil, en az iki baskın rezidüel hastalık fenotipi şeklinde ortaya çıkabildiğini düşündürmektedir (Symmans ve ark., 2007; Yau ve ark., 2022). Bu görünüm, bir uçta daha kemoterapi-duyarlı, yüksek proliferatif ve sıklıkla triple-negatif ya da HER2-pozitif biyoloji taşıyan hastaları; diğer uçta ise daha dirençli, çoğunlukla hormon

reseptörü pozitif/luminal fenotipleri akla getirir (Rouzier ve ark., 2005; von Minckwitz ve ark., 2012). Dağılımın normal olmaması, biyolojik olarak heterojen ama istatistiksel olarak görece dengeli bir yapıya işaret etmektedir. Bu nedenle RCB'nin tek bir sürekli değişken gibi değil, alt grup duyarlılığı gözetilerek yorumlanması daha anlamlıdır (Yau ve ark., 2022).

RCB'nin kendi bileşenleriyle gösterdiği güçlü korelasyon, sistemin iç tutarlılığını desteklemektedir. En büyük metastatik odak çapı ile RCB arasındaki güçlü ilişki, pozitif lenf nodu sayısının yüksek korelasyonu ve primer tümör boyutunun invaziv hücresellik faktörüyle olan katkısı, RCB formülünün temel aldığı patolojik parametrelerin skoru pratikte de belirgin biçimde şekillendirdiğini göstermektedir (Peintinger ve ark., 2015). Özellikle nodal bileşenlerin primer tümör boyutuna kıyasla daha güçlü ilişki göstermesi, rezidüel hastalık yükünün yalnızca primer tümör regresyonuyla açıklanamayacağını; aksiller rezidüel yükün ve mikrometastatik bileşenin toplam skor üzerindeki ağırlığının yüksek olduğunu düşündürmektedir (Symmans ve ark., 2007; Peintinger ve ark., 2015; Yau ve ark., 2022). Bu durum, RCB'nin lokal patolojik yanıtın ötesinde sistemik hastalık biyolojisini de yansıtabildiğini desteklemektedir (Yau ve ark., 2022).

Moleküler alt tipler açısından elde edilen sonuçlar, modern meme kanseri biyolojisiyle uyumludur. Triple-negatif ve HER2-pozitif gruplarda daha düşük RCB skorlarının görülmesi, bu alt tiplerin daha yüksek proliferatif kapasiteye ve/veya hedefe yönelik tedavi duyarlılığına bağlı olarak sitotoksik tedaviye daha derin yanıt verebilmesiyle açıklanabilir (Rouzier ve ark., 2005; von Minckwitz ve ark., 2012; Carey ve ark., 2007). Buna karşılık Luminal A ve HER2-düşük gruplarda daha yüksek rezidüel hastalık yükü saptanması, bu alt tiplerin daha sınırlı kemoterapi duyarlılığı göstermesiyle uyumludur (Tarantino ve ark., 2020; Modi ve ark., 2022). Bu nedenle RCB temelli alt tip karşılaştırmaları, pCR temelli klasik ayırmadan daha ince bir biyolojik ayrışma sunmaktadır (Cortazar ve ark., 2014; Yau ve ark., 2022).

Hormon reseptörü ekseninde de benzer bir biyolojik örüntü izlenmektedir. ER ve PR pozitifliğinin artmasıyla rezidüel hastalık yükünün genel olarak artma eğilimi göstermesi, hormon bağımlı tümörlerin sitotoksik kemoterapiye daha sınırlı yanıt verme eğiliminin bir yansımasıdır (Rouzier ve ark., 2005; Colleoni ve ark., 2010). Buna karşılık bazı alt gruplarda beklenmedik biçimde düşük RCB görülmesi,

örneklem içi heterojenite ve reseptör biyolojisinin bağlama duyarlı doğası ile açıklanabilir. Bu nedenle hormon reseptörü biyolojisi doğrusal değil, eşiklere ve alt grup özelliklerine duyarlı bir yapı olarak değerlendirilmelidir (Kim ve ark., 2019; Ghezzawi ve ark., 2025).

Ki-67 ve mitotik derece ile RCB arasındaki ters yönlü ilişki, proliferatif tümörlerin kemoterapiye daha duyarlı olabileceğine ilişkin temel biyolojik modeli desteklemektedir (von Minckwitz ve ark., 2012; Yoshioka ve ark., 2015). Yüksek Ki-67 ekspresyonu, hücre döngüsünde aktif hücre oranının daha fazla olduğunu ve bu hücrelerin antrasiklin-taksan etkisine daha açık olabileceğini düşündürür (Yoshioka ve ark., 2015). Bununla birlikte bu bulgu, yalnızca kısa dönem tedavi yanıtı açısından olumlu bir işaret olarak değil, aynı zamanda agresif doğal seyir ve yüksek metastatik potansiyel ile birlikte değerlendirilmelidir (Cortazar ve ark., 2014; Yau ve ark., 2022). Bu nedenle düşük RCB, her zaman biyolojik olarak “iyi huylu” bir tümörü değil, bazen tedaviye duyarlı fakat intrinsik olarak agresif bir fenotipi de yansıtabileceği unutulmamalıdır.

Tümör immün mikroçevresi açısından TIL düzeyi ile düşük RCB arasındaki ilişki, neoadjuvan yanıtın yalnızca tümör hücre içi mekanizmalarla açıklanamayacağını göstermektedir (Salgado ve ark., 2015; Schmid ve ark., 2020). Yüksek TIL düzeylerinin özellikle triple-negatif ve HER2-pozitif meme kanserinde daha yüksek pCR ve daha iyi sağkalım sonuçlarıyla ilişkili olduğu bilinmektedir. Bu çalışmada TIL arttıkça RCB skorunun azalması da immün yanıtın rezidüel hastalık derinliğini azaltıcı etkisini desteklemektedir (Salgado ve ark., 2015; Schmid ve ark., 2020). Bu bulgu, immün belirteçlerin yalnızca pCR düzeyinde değil, sürekli bir değişken olarak RCB üzerinde de prognostik katkı sağlayabileceğini düşündürmektedir.

Metastaz varlığı ve metastaz yerinin RCB ile güçlü ilişkisi, rezidüel hastalığın lokal tümör yatağıyla sınırlı olmadığını göstermesi açısından önemlidir (Symmans ve ark., 2007; Yau ve ark., 2022). Özellikle lenf nodu metastazının baskın metastatik alan olması, aksiller rezidüel yükün RCB üzerindeki ağırlığını artırmış olabilir (Symmans ve ark., 2007; Peintinger ve ark., 2015). Uzak metastaz oranlarının düşük olması, kohortun büyük ölçüde lokal ileri hastalıktan oluşmadığını düşündürmekte; bu da çalışmanın klinik gerçekliğini artırırken, ileri evre metastatik popülasyonlara genellenebilirliğini sınırlamaktadır (Cortazar ve ark., 2014; Yau ve ark., 2022).

Çoklu test düzeltmeleri, bulguların metodolojik güvenilirliğini artırmıştır. Bonferroni ve FDR düzeltmelerinin birlikte uygulanması, hem tip I hata oranını kontrol etmeyi hem de keşifsel sinyalleri bütünüyle kaybetmemeyi mümkün kılmıştır (Benjamini & Hochberg, 1995). Bonferroni sonrası 16, FDR sonrası 24 değişkenin anlamlılığını koruması, özellikle metastaz eksenini, moleküler tip ve temel biyolojik belirteçlerin dayanıklı sinyaller verdiğini göstermektedir (Benjamini & Hochberg, 1995). Buna karşılık yalnızca FDR düzeltmesi sonrası anlamlı kalan değişkenler, klinik olarak ilgi çekici ancak doğrulama gerektiren adaylar olarak değerlendirilmelidir.

Eksik veri yapısı da önemli bir metodolojik boyuttur. E-kaderin ve menopoz durumunda yüksek eksiklik oranları bulunurken, ER, PR, HER2 ve klinik evre gibi biyolojik olarak merkezi değişkenlerde daha yüksek imputasyon doğrulukları elde edilmesi, veri setindeki ilişkisel ağına bazı değişkenler için daha sağlam, bazıları için ise daha kırılgan olduğunu göstermektedir (Sterne ve ark., 2009; Ibrahim J.G. ve ark., 2012). Bu nedenle bu iki değişkene dayanarak yapılacak biyolojik yorumlar temkinli olmalıdır. Eksik verilerin belirli hasta kümelerinde yoğunlaşması, mekanizmanın tamamen rastgele eksiklikten ziyade MAR desenine daha yakın olabileceğini düşündürmektedir (Sterne ve ark., 2009; Ibrahim J.G. ve ark., 2012).

Kategorik bağımlılık yapısı da dikkate değerdir. Metastaz durumu ile metastaz yeri arasındaki güçlü ilişki, ayrıca HER2–moleküler tip ve ER–moleküler tip eksenlerinde saptanan bağımlılıklar, veri setinin biyolojik olarak beklenen bir örgütlenmeye sahip olduğunu gösterirken aynı zamanda çoklu doğrusal bağlantı riskine işaret etmektedir (Peintinger ve ark., 2015; Yau ve ark., 2022). Benzer biçimde kitle dansitesi ile RCB arasında saptanan ilişki, radyolojik fenotiplerin patolojik yanıtı öngörmede ek bilgi sağlayabileceğini düşündürmektedir (Sutton ve ark., 2021).

RCB kategorilerinin klinik dağılımı da önemli bir anlam taşımaktadır. RCB-II ve RCB-III gruplarının baskın olması, neoadjuvan tedavi sonrasında klinik açıdan anlamlı rezidüel hastalık taşıyan hasta grubunun azımsanmayacak büyüklükte olduğunu göstermektedir (Symmans ve ark., 2007; Yau ve ark., 2022). Bu grup, risk katmanlandırması ve adjuvan tedavi yoğunlaştırması açısından en fazla karar gerektiren klinik segmenti oluşturmaktadır (Yau ve ark., 2022; von Minckwitz ve ark., 2019; Masuda ve ark., 2017). Bu nedenle RCB-II grubunun gelecekte alt tip, proliferasyon, immün mikroçevre ve görüntüleme parametreleriyle daha ayrıntılı

biçimde alt sınıflandırılması, kişiselleştirilmiş karar süreçleri açısından değerli olabilir (Yau ve ark., 2022).

Sağkalım analizleri ise dikkatli yorumlanmalıdır. RCB kategorileri arasında genel sağkalım açısından anlamlı fark saptanmamış ve çok değişkenli Cox modelinde RCB bağımsız bir belirleyici olarak doğrulanmamıştır; buna karşılık yaş anlamlı kalmıştır (Yee ve ark., 2020; Yau ve ark., 2022). Bu sonuç, RCB'nin prognostik değerinin olmadığını değil, kullanılan sonlanım penceresinin genel sağkalım olması nedeniyle etkinin yeterince yakalanamamış olabileceğini düşündürmektedir (Yee ve ark., 2020; Yau ve ark., 2022). Literatürde RCB'nin özellikle event-free survival ve hastalıksız sağkalım gibi nüks-duyarlı sonlanımlarla daha güçlü ilişkili olduğu gösterilmiştir (Yee ve ark., 2020; Yau ve ark., 2022).

Bu çalışmanın en önemli katkılarından biri, RCB'nin tek boyutlu bir patolojik ölçüt değil, çok katmanlı bir klinik-biyolojik gösterge olduğunu ortaya koymasındadır (Symmans ve ark., 2007; Yau ve ark., 2022). Metastatik yük, moleküler alt tip, hormon reseptör durumu, proliferatif aktivite ve immün mikroçevre ile kurduğu ilişkiler, RCB'nin gerçek yaşam pratiğinde tedavi yanıtını ve hastalık biyolojisini birlikte yansıttığını göstermektedir (Symmans ve ark., 2007; Yau ve ark., 2022). Bu nedenle RCB, neoadjuvan tedavi sonrası rezidüel hastalığın nicel değerlendirilmesinde ve adjuvan tedavi yoğunlaştırma stratejilerinin belirlenmesinde merkezi bir yere sahiptir (Masuda ve ark., 2017; von Minckwitz ve ark., 2019; Yau ve ark., 2022).

Çalışmanın sınırlılıkları arasında tek merkezli retrospektif tasarım, bazı alt gruplardaki düşük hasta sayısı, belirli değişkenlerde yüksek eksiklik oranı ve sağkalım analizinin yalnızca genel sağkalım ile sınırlı olması yer almaktadır (Sterne ve ark., 2009; Yau ve ark., 2022). Buna karşın geniş değişken yelpazesi, çoklu test düzeltmeleri ve eksik veri yaklaşımı, çalışmanın metodolojik şeffaflığını güçlendirmektedir (Benjamini & Hochberg, 1995; Sterne ve ark., 2009). Gelecek araştırmalarda RCB'nin genomik imzalar, dolaşımdaki tümör DNA'sı, immün mikroçevre profilleri ve radyomik özelliklerle entegre edilmesi, neoadjuvan yanıtın daha hassas öngörülmesini sağlayabilir (Sutton ve ark., 2021; Yau ve ark., 2022).

Sonuç olarak bu bölüm, RCB'nin meme kanserinde yalnızca postoperatif patolojik bir ölçüt olmadığını, tümör biyolojisi, metastatik yayılım, immün yanıt ve klinik davranışın birleşik bir göstergesi olduğunu ortaya koymaktadır (Symmans ve ark.,

2007; Yau ve ark., 2022). Elde edilen bulgular, rezidüel hastalığın nicel değerlendirilmesinin gelecekte daha kişiselleştirilmiş tedavi stratejilerinin merkezinde yer alacağını düşündürmektedir (Yau ve ark., 2022; von Minckwitz ve ark., 2019).

5.2. Neoadjuvan Yanıtın Klinikopatolojik Belirteçlerle Öngörülmesi: İkili ve Çoklu Lojistik Regresyon Yaklaşımı

Bu bölümde, NAK'ye verilen patolojik tam yanıtın (pCR/RCB-0) öngörülmesinde klinikopatolojik, radyolojik ve biyokimyasal değişkenlerin bireysel katkıları ve çok değişkenli öngörü modellerine entegrasyonu değerlendirilmiştir. Bulgular, meme kanserinde tedavi yanıtının tek bir değişkenle açıklanamayacağını; proliferatif aktivite, hormon reseptörü durumu, immün mikroçevre özellikleri ve tümörün yapısal fenotipinin birlikte belirleyici olduğunu göstermektedir (Cortazar ve ark., 2014; von Minckwitz ve ark., 2012). Bu bölümün temel katkısı, 5.1'de tanımlanan biyolojik ilişkilerin ötesine geçerek bu değişkenlerin birlikte kullanıldığında bireysel hasta düzeyinde güvenilir bir öngörü çerçevesi oluşturup oluşturamayacağını test etmesidir. Bu yönüyle istatistiksel ilişki ile klinik öngörü değeri arasındaki ayrımın vurgulanması TRIPOD çerçevesiyle uyumludur (Collins ve ark., 2015). Ayrıca değişkenler arası etkileşimlerin ve model kalıcılığının klinik yorumlanabilirliğe katkısına odaklanılması, güncel prediktif modelleme literatürüyle de örtüşmektedir (Steyerberg, 2019).

5.1'de ayrıntılı biçimde gösterildiği üzere, hormon reseptörü durumu, Ki-67 düzeyi ve moleküler alt tip, RCB skoru ile güçlü ilişki sergilemekte; proliferatif ve reseptör-negatif tümörler daha derin tedavi yanıtı verme eğilimindedir (Cortazar ve ark., 2014; Rouzier ve ark., 2005; von Minckwitz ve ark., 2012). Bu bölümün odağı bu ilişkileri yinelemek değil; söz konusu değişkenlerin öngörü modeli mimarisinde nasıl konumlandığını, birbirleriyle etkileşim içinde model katkısını nasıl paylaştığını ve model içi ağırlıklarının biyolojik yorumla ne ölçüde örtüştüğünü incelemektir. Bu perspektiften bakıldığında, ER ve PR negatifliği ile yüksek Ki-67'nin model içindeki baskın katkısı, bu değişkenlerin yalnızca anlamlı birer belirteç olmadığını, aynı zamanda birleşik öngörü yapısının belkemiğini oluşturduğunu göstermektedir. Buna karşılık, bu iki boyutun modele birlikte girilmesi durumunda ortaya çıkan çoklu doğrusal bağlantı riski, katsayı yorumlarının bireysel değişken düzeyinde değil, model

bütünü düzeyinde ele alınması gerektiğine işaret etmektedir (Steyerberg, 2019; Hastie ve ark., 2009).

Moleküler alt tip bağlamında, TNBC ve HER2-pozitif gruplarda pCR olasılığının daha yüksek olması ve HER2-düşük grubunun ayrı bir biyolojik kategori olarak değerlendirmeye başlanması, öngörü modelinin statik bir alt tip sınıflandırmasına değil, biyolojik özelliklerin sürekli bir spektrumuna dayandırılması gerektiğini düşündürmektedir (Modi ve ark., 2022; Tarantino ve ark., 2020). Özellikle HER2-düşük grubunun modeldeki davranışı, bu kategorinin klinik pratikte hem prognostik hem de prediktif açıdan yeniden tanımlanmasını destekler niteliktedir. Bu nedenle alt tip temelli ayrımın modele katılma biçimi —ikili kodlama mı, sıralı yapı mı, referans kategorisi seçimi mi— öngörü doğruluğu ve klinik uygulanabilirlik açısından belirleyici bir metodolojik karardır (Steyerberg, 2019).

Tümör mikroçevresi açısından, 5.1'de RCB ile sürekli bir ilişki içinde gösterilen TIL düzeyi, öngörü modelinde pCR'ye özgü bir ek katkı sunmaktadır. TIL'in modeldeki katkısı, yalnızca immün aktivasyonun derecesini yansıtmakla kalmayıp aynı zamanda tümör-stroma etkileşiminin kemoterapi yanıtı üzerindeki rolünü de dolaylı olarak temsil etmektedir (Salgado ve ark., 2015; Denkert ve ark., 2018). Biyolojik güçlü bir belirteç olan TIL'in öngörü modeline entegrasyonunun pratik sınırlılığı, merkezler arası değerlendirme değişkenliği ve standart kesim noktasının henüz netleşmemiş olmasıdır (Denkert ve ark., 2018). Bu nedenle çalışmamız, TIL'in öngörü mimarisine dahil edilmesinin yalnızca istatistiksel değil, ölçümsel standardizasyon açısından da ayrıca değerlendirilmesi gerektiğini göstermektedir.

Histolojik yapı, öngörü modeli açısından bağımsız ama sınırlı katkı veren bir eksen olarak öne çıkmaktadır. İnvaziv lobüler karsinom ve mikst alt tiplerin invaziv duktal karsinoma kıyasla daha dirençli bir profil göstermesi, e-kaderin kaybı ve diskoheziv büyüme paterni ile uyumludur; bu özellikler kemoterapötik ajanların tümör dokusu üzerindeki etkinliğini sınırlayabilmektedir (Arpino ve ark., 2004; Cristofanilli ve ark., 2005). Yüksek histolojik grade ve artmış mitotik aktivite ise daha agresif bir biyolojiye işaret etmekle birlikte sitotoksik duyarlılığı artırabilmekte; bu paradoks pCR öngörüsünde grade ve alt tip değişkenlerinin birbirinden bağımsız yorumlanamayacağını, aksine etkileşimli biçimde değerlendirilmesi gerektiğini göstermektedir (Prat ve ark., 2015). Bu nedenle histolojik alt tip ve grade değişkenleri,

öngörü modelinde yalnızca ikili sınıflandırıcılar olarak değil, biyolojik bağlamla birlikte yorumlanabilecek etkileşim terimleri olarak ele alınmalıdır.

Hastalık yaygınlığı ve metastatik yük açısından, lenf nodu tutulumu ve ileri evre hastalığın pCR olasılığını azaltması; klonal heterojenliğin artışı ve sistemik hastalık biyolojisinin karmaşılaşmasının bir yansıması olarak değerlendirilebilir (Yates ve ark., 2017; Greaves & Maley, 2012). Bu ilişkinin öngörü modeline katkısı, evre ve nodal durumun yalnızca hastalık yaygınlığını değil, tümörün evrimsel olgunluğunu ve çoklu direnç mekanizmalarının olgunlaşma derecesini dolaylı biçimde temsil ettiğini düşündürmektedir. Bu açıdan neoadjuvan stratejilerin hasta seçimi ve tedavi yoğunluğu kararlarında biyolojik katmanları da dikkate alması gerekmektedir; öngörü modeli bu kararı destekleyen ama ikame etmeyen bir araç olarak konumlanmalıdır (Collins ve ark., 2015).

Radyolojik değişkenlerin modele anlamlı katkı sunması, çalışmanın özgün bulgularından birini oluşturmaktadır. Kitle konturu, kitle şekli ve kitle dansitesi gibi mamografik ve ultrasonografik özelliklerin pCR ile ilişkili olması, görüntüleme fenotipinin altta yatan biyolojik davranışı kısmen yansıtabildiğini düşündürmektedir. Spiküle konturlu ve düzensiz şekilli lezyonların çoğunlukla fibrotik stromaya ve daha yavaş büyüyen, hormon reseptörü pozitif fenotiplere işaret etmesi; buna karşılık daha belirsiz kontur ve farklı dansite özelliklerinin daha yüksek proliferatif alt tiplerle ilişkilenebilmesi, görüntülemenin biyolojik alt tip için dolaylı ama anlamlı olabileceğini göstermektedir (Mazurowski ve ark., 2014; Sutton ve ark., 2021; Ghezzawi ve ark., 2025). Bu bulgu radyogenomik yaklaşımın temel varsayımıyla uyumludur; ancak söz konusu ilişkinin ileri görüntüleme yöntemleri ve çok merkezli doğrulama ile test edilmemiş olması, klinik uygulanabilirlik açısından önemli bir sınırlılık oluşturmaktadır.

Biyokimyasal değişkenlerin ve komorbiditelerin büyük bölümünün modelde anlamlı bulunmaması, bu belirteçlerin klinik değersizliğinden değil, tek zaman noktasına ait ölçümlerin tedavi sürecindeki dinamik değişimleri yansıtmadaki sınırlılığından kaynaklanıyor olabilir. Benzer biçimde yaş ve komorbidite, kısa dönem tümör yanıtından çok uzun dönem sağkalım üzerinde daha belirgin etkiler gösterebilir (Søgaard ve ark., 2013). Bu nedenle biyokimya ve demografik bloklar modelden

dışlanmak yerine, farklı sonlanım yapılarında test edilmesi gereken aday katmanlar olarak değerlendirilmelidir.

Modelleme stratejisi açısından, parsimoniyöz ve kapsamlı modellerin karşılaştırmalı sınanması metodolojik güç sunan bir yaklaşımdır. Regülerize modelin daha dengeli ve stabil performans göstermesi, korelasyonlu değişkenlerin katsayı küçültme yoluyla yönetilmesinin görece küçük ve homojen kohortlarda aşırı uyumu sınırladığını düşündürmektedir (Hastie ve ark., 2009; Kuhn & Johnson, 2019). L1 regülarizasyonu değişken seçimini otomatikleştirirken model yorumlanabilirliğini güçleştirmekte; L2 ise katsayı kararlılığını artırmakla birlikte tüm değişkenleri modelde tutmaktadır. Bu denge, değişkenlerin yalnızca anlamlılık düzeyine göre değil, model içi katkı ve kalıcılık açısından da değerlendirilmesi gerektiğini ortaya koymaktadır. Çalışmamızın katkısı, regülerize modellerin küçük örneklemli klinik veri setlerinde hem pratik hem de kararlı bir çözüm sunabileceğini göstermesidir; sınırlılığı ise bu modellerin dış doğrulamada aynı dengede performans gösterip göstermeyeceğinin bilinmemesidir.

Modelin en kritik klinik mesajı, yüksek negatif öngörü değerine sahip olmasıdır. Bu özellik, pCR elde etme olasılığı düşük olan hastaların erken dönemde ayırt edilmesini sağlar; böylece tedavi yoğunlaştırma ya da alternatif neoadjuvan stratejilerin düşünülmesine olanak tanır. Buna karşılık görece sınırlı özgüllük, modelin tek başına de-eskalasyon kararları için yeterli olmadığını düşündürmektedir (Vickers & Elkin, 2006). Bu yönüyle model, klinik kararı ikame eden değil destekleyen bir araç olarak konumlandırılmalıdır; karar eğrisi analizi gibi klinik fayda odaklı değerlendirmeler bu modelin gerçek pratikte getirisi için kritik öneme sahiptir (Vickers & Elkin, 2006; Collins ve ark., 2015).

Sonuç olarak bu bölüm, pCR öngörüsünün tek bir biyolojik eksenle sınırlandırılmayacağını; ancak çok değişkenli regülerize modeller aracılığıyla bireysel hasta düzeyinde güvenilir bir öngörü çerçevesi kurulabileceğini göstermektedir. Bulgular, klinik öngörü modellerinin yalnızca istatistiksel doğrulukla değil, biyolojik tutarlılık, model kararlılığı ve klinik karar süreçlerine uygulanabilirlik açısından da değerlendirilmesi gerektiğini ortaya koymaktadır (Steyerberg, 2019; Collins ve ark., 2015). Bu çerçevede öngörü modellerinin gelecekte genomik imzalar, dolaşımdaki tümör DNA'sı ve radyomik özelliklerle zenginleştirilmesi,

bireyselleştirilmiş neoadjuvan kararlar için daha güçlü bir zemin oluşturabilir (Sutton ve ark., 2021; Yau ve ark., 2022).

5.3. Makine Öğrenmesi Kapsamında Modüler ve Kademeli Modelleme Yaklaşımı

Bu bölümde; NAK sonrası RCB kategorilerinin öngörülmesine yönelik geliştirilen modüler ve kademeli makine öğrenmesi yaklaşımının, veri bloklarının katkısının homojen olmadığını ortaya koyduğu görülmektedir. Bulgular, bazı veri kümelerinin modelin ayrıştırıcı omurgasını oluştururken, bazı kümelerin daha çok destekleyici ya da bağlamsal bilgi sunduğunu göstermektedir. Bu durum, model karmaşıklığı ile öngörü performansı arasındaki ilişkinin doğrusal olmadığını; özellikle patolojik ve onkolojik verilerin bir araya geldiğinde sinerjik bir güç oluşturduğunu, buna karşılık komorbidite ve biyokimya gibi doğrudan tümör biyolojisini yansıtmayan blokların modele eklendiğinde sınıflandırma performansını her zaman artırmadığını düşündürmektedir. Bu yaklaşım, heterojen veri entegrasyonunun yalnızca veri hacmi açısından değil, taşıdığı biyolojik anlam açısından da değerlendirilmesi gerektiğini göstermesi bakımından önemlidir (Topol, 2019; Esteva ve ark., 2017). Çok modlu tıbbi yapay zekâ çalışmalarında da klinik anlamı sınırlı özelliklerin modele eklenmesinin performansı otomatik olarak yükseltmediği, aksine gürültü ve aşırı uyum riskini artırabildiği bildirilmiştir (Weng ve ark., 2017; Beam & Kohane, 2018). Bununla birlikte, komorbidite ve laboratuvar verilerinin bazı sonlanımlarda anlamlı katkı sağlayabildiği gösterildiğinden, bu blokların RCB gibi daha çok tümör biyolojisine duyarlı bir sonlanımda sınırlı kalması, klinik değersizlikten çok sonlanımspesifik etki ile ilişkili görünmektedir (Kourou ve ark., 2015).

Çalışmanın en dikkat çekici bulgularından biri, radyolojik veri bloğunun tek başına en yüksek test performansına ulaşmasıdır. Radyolojik değişkenlerin patolojik, onkolojik ve diğer tek bloklu modelleri geride bırakması, biyolojik ve metodolojik açıdan anlamlıdır. Bunun temel nedeni, RCB skorunun patolojik bileşenlerle zaten doğrudan ilişkili bir sonlanım olması ve bazı patolojik değişkenlerin sonuç değişkenine yalnızca dolaylı bilgi taşımasıdır. Buna karşılık radyolojik özellikler, tümörün makroskobik yapısını, morfolojik organizasyonunu, kalsifikasyon paternini, konturunu ve çevre doku ile ilişkisini birlikte yansıtarak neoadjuvan tedavi öncesi tümör biyolojisinin daha bütüncül bir fenotipini sunmaktadır. Bu okuma, görüntüleme fenotipinin

moleküler imzaların güvenilir olabileceğini öne süren radyogenomik literatürle uyumludur. Nitekim MR temelli radyomik yaklaşımların pCR öngörüsünde klinik belirteçlerden daha güçlü ya da en azından tamamlayıcı performans gösterebildiği, son yıllarda yayımlanan sistematik derlemeler ve meta-analizlerde de bildirilmiştir (Mazurowski ve ark., 2014; Bitencourt ve ark., 2021; Guo ve ark., 2022; Zhang ve ark., 2024). Özellikle MR temelli radyomik özelliklerin tedavi yanıtını ve moleküler alt tip ayrımını yansıtabilmesi, radyolojinin yalnızca anatomik değil, biyolojik bilgi taşıyan bir alan olduğunu göstermektedir (Sutton ve ark., 2021; Braman ve ark., 2017). Bununla birlikte literatürde radyomik modellerin çoğu zaman klinik-radyomik birleşik çerçevelerde en iyi sonucu verdiği, tek başına radyolojik değişkenlerin ise dış doğrulamada dalgalanabildiği gösterilmiştir (Zhang ve ark., 2024; Hu ve ark., 2025). Bu açıdan, yalnız radyolojik bloğun yüksek performans üretmesi güçlü bir bulgu olmakla birlikte, tek merkezli yapı ve görece standardize okuma koşulları bu üstünlüğün çok merkezli ortamlarda aynı düzeyde korunup korunmayacağı sorusunu gündemde tutmaktadır. Çalışmamızın özgün katkısı, radyolojik fenotipin bu kohortta beklenenden güçlü bir ayırt edici sinyal taşıdığını göstermesidir; sınırlılığı ise bu üstünlüğün bağımsız kohortlarda henüz doğrulanmamış olmasıdır.

Patolojik ve onkolojik özelliklerin birlikte değerlendirilmesi, model performansında belirgin bir iyileşme sağlamıştır. Salt patolojik değişkenlerin tek başına sınırlı kalmasına karşın, onkolojik değişkenlerle birleştirildiğinde daha güçlü bir ayrıştırma kapasitesi ortaya çıkmıştır. Bu bulgu, neoadjuvan yanıtın yalnızca tümörün hücresel ve morfolojik özellikleriyle değil, aynı zamanda hastalığın klinik yaygınlığı ve tedavi ilişkili bileşenleriyle de şekillendiğini düşündürmektedir. Bu yönüyle sonuçlar, meme kanserinde pCR öngörüsünün yalnızca biyopsi temelli histopatolojik parametrelerle tam olarak açıklanamayacağını, klinik evreleme ve moleküler özelliklerin birlikte ele alınması gerektiğini vurgulayan literatürle uyumludur (Cortazar ve ark., 2014; von Minckwitz ve ark., 2012). Histolojik tip, Ki-67, moleküler alt tip ve tanı evresi gibi değişkenlerin karar mekanizmasına katkı sunması, klinik pratikte multidisipliner değerlendirme mantığının makine öğrenmesi modelleri tarafından da desteklendiğini göstermektedir. Özellikle proliferatif aktivitenin ve biyolojik alt tipin tedavi duyarlılığını yansıtabildiği, birçok çalışmada pCR ile ilişkili bulunmuştur; ancak bu belirteçlerin klinik anlamı çoğu zaman evre ve sistemik hastalık yükü ile birlikte

değerlendirildiğinde daha belirgin hale gelmektedir (Denkert ve ark., 2018; Prat ve ark., 2015). Patolojik değerlendirmelerin statik morfolojik bilgi taşıması, tedavi yanıtının ise dinamik ve çok boyutlu bir süreç olması nedeniyle, tek başına patolojiye dayalı modellerin sınırlı kalması beklenebilir. Buna karşılık Ki-67 ve TIL gibi belirteçlerde gözlemci ve merkezler arası değişkenlik ile standardizasyon eksikliği, bu blokların performansını sınırlayan ek bir unsur olarak değerlendirilmelidir (Sychra, 2021).

Onkolojik veri bloğunun patolojik bloktan daha güçlü performans göstermesi, klinik hastalık yükü ve tedavi ilişkili değişkenlerin rezidüel hastalık davranışını daha iyi yansıttığını düşündürmektedir. Metastaz durumu, hastalık evresi ve tedavi yoğunluğu gibi değişkenlerin modele katkı sunması, tümör biyolojisinin yalnızca primer tümörün histopatolojik özellikleriyle açıklanamayacağını ortaya koymaktadır. Bu yönüyle bulgular, neoadjuvan yanıtın yalnızca başlangıç tümör fenotipine bağlı olmadığını; aynı zamanda sistemik hastalık yayılımı, tedavi baskısı ve tümörün evrimsel dinamikleri ile şekillendiğini vurgulayan literatürle uyumludur (Yates ve ark., 2017; Hu ve ark., 2020). Özellikle metastatik kapasitenin ve hastalık evresinin tedavi yanıtıyla ilişkisi, klonal seçim ve tümör evrimi çerçevesinde açıklanmakta; bu durum, sistemik yükü yüksek olgularda rezidüel hastalık riskinin artmasını biyolojik olarak anlamlı kılmaktadır (Greaves ve Maley, 2012; Yates ve ark., 2017). Bu nedenle onkolojik blok, tek başına yeterli bir belirleyici olmaktan çok, patolojik ve radyolojik verileri tamamlayan sistemik bir katman olarak değerlendirilmelidir.

Demografik değişkenlerin patolojik ve onkolojik verilere eklenmesiyle model performansında kısmi bir artış gözlenmiş olması, yaş ve benzeri faktörlerin tümör biyolojisine doğrudan ait olmamakla birlikte tedavi yanıtını etkileyen sistemik çerçeveye katkıda bulunabildiğini düşündürmektedir. Bununla birlikte bu katkının sınırlı kalması, demografik değişkenlerin bu bağlamda daha çok tamamlayıcı nitelikte olduğunu göstermektedir. Nitekim yaşın meme kanserinde prognozla ilişkili olduğu, ancak bu etkinin menopoz durumu ve diğer klinik özelliklerle birlikte değerlendirilmesi gerektiği bildirilmiştir (Partridge ve ark., 2016). Buna karşılık komorbidite ve biyokimya bloklarının eklenmesiyle performansın gerilemesi, veri entegrasyonunun her zaman doğrusal biçimde fayda üretmediğini açık biçimde ortaya

koymaktadır. Özellikle doğrudan tümör biyolojisine temas etmeyen değişkenlerin yüksek boyutlu veri uzayına eklenmesi, yararlı sinyali seyreletmekte ve gürültüyü artırabilmektedir. Bu durum, makine öğrenmesi literatüründe boyutluluk sorunu ve bilgi yoğunluğu düşük değişkenlerin model performansı üzerindeki olumsuz etkisi ile uyumludur (Guyon & Elisseeff, 2003; Hastie ve ark., 2009; Kuhn & Johnson, 2019). Ayrıca komorbidite yükü ve rutin biyokimyasal parametrelerin, özellikle tek zaman noktasında ölçüldüğünde, tedavi yanıtını öngörmede sınırlı kalabildiği; buna karşılık daha çok toksisite, tedavi toleransı ve uzun dönem sonuçlarla ilişkili olabildiği de bildirilmektedir (Søgaard ve ark., 2013; Liu ve ark., 2025).

Tüm blokların birlikte kullanılmasıyla performansın yeniden yükselmesi, çok modlu veri entegrasyonunun etkileşimsel avantajını göstermektedir. LightGBM'nin tüm değişken bloklarını birlikte değerlendirerek en yüksek performansı üretmesi, farklı veri türleri arasındaki doğrusal olmayan ilişkileri öğrenebilme kapasitesiyle uyumludur. Bu sonuç, çok katmanlı veri yapılarında tek tek bloklardan ziyade bloklar arası etkileşimlerin belirleyici olabileceğini düşündürmektedir. Nitekim çok modlu klinik veri entegrasyonuna dayalı çalışmalar, görüntüleme, klinik ve patolojik verilerin birlikte kullanılmasının tekil veri kaynaklarına kıyasla daha yüksek öngörü gücü sağlayabildiğini; ancak bu kazanımın veri kaynakları arasındaki tamamlayıcılık derecesine bağlı olarak değiştiğini göstermektedir (Acosta ve ark., 2022). Elde edilen sinerji, blokların basit toplamından daha fazlasına işaret etmekte; radyolojik, patolojik ve onkolojik değişkenlerin birlikte ele alındığında rezidüel kanser yükü için daha güçlü bir karar alanı oluşturduğunu göstermektedir. Bununla birlikte, bu tür bir kazanımın eğitim verisine özgü etkileşimleri yansıtmaya olasılığı göz ardı edilmemelidir. Bu nedenle, performanstaki artışın bağımsız kohortlarda da sürüp sürmediğinin gösterilmesi, modelin klinik genellenebilirliği açısından kritik önem taşımaktadır (Lambin ve ark., 2017; Vickers & Elkin, 2006).

Algoritma seçimi açısından bakıldığında, LightGBM'nin final model olarak öne çıkması, yalnızca en yüksek performansı sağlamasıyla değil, veri mimarisi ile öğrenme mimarisi arasındaki uyumla da ilişkilidir. Histogram tabanlı karar bölmeleri ve yaprak bazlı büyüme stratejisi, yüksek boyutlu ve etkileşim içeren tablolarda güçlü sonuçlar üretmektedir. Random Forest ve XGBoost'un belirli bloklarda iyi performans

göstermesi ise algoritma-veri uyumunun blok bazında değişebildiğini göstermektedir. Bu örüntü, klinik makine öğrenmesi çalışmalarında tek bir varsayılan algoritmaya bağlı kalmak yerine, veri yapısına özgü modelleme tercihlerinin yapılması gerektiğini ortaya koymaktadır. Nitekim ağaç tabanlı yöntemlerin performansı, veri yapısının karmaşıklığı, değişkenler arası etkileşim düzeyi ve sinyal-gürültü oranına duyarlı olarak değişmektedir; bu nedenle daha sınırlı ve görece kararlı sinyal taşıyan bloklarda Random Forest'in, doğrusal olmayan ama orta düzey ilişkiler içeren yapılarda XGBoost'un, çok katmanlı ve etkileşim zengin veri kümelerinde ise LightGBM'nin daha avantajlı olabildiği bildirilmektedir (Breiman, 2001; Chen & Guestrin, 2016; Ke ve ark., 2017). Bu bağlamda çalışmamızın güçlü yönü, algoritma seçimini sabit bir teknik tercih olarak değil, veri yapısıyla uyumlu bir modelleme kararı olarak ele almasıdır. Bununla birlikte, farklı algoritmaların blok bazında değişen üstünlüğü, model optimizasyonunun yalnızca performans metriğine göre değil, genellenebilirlik ve yorumlanabilirlik boyutları birlikte dikkate alınarak yapılması gerektiğini de göstermektedir.

Sınıf bazlı performans asimetrisi, çalışmanın en önemli tartışma alanlarından birini oluşturmaktadır. Minimal rezidüel hastalığı temsil eden RCB-1 sınıfının ayırt edilmesindeki güçlük, bir yandan sınıf dengesizliği, diğer yandan ise klinik olarak geçişken bir ara fenotipin varlığı ile açıklanabilir. Nitekim RCB-1, minimum rezidüel hastalığı temsil eder ve daha favorable sonuçlarla ilişkilidir; bu nedenle bu sınıfın tahmin edilmesi çoğu zaman diğer RCB kategorilerine kıyasla daha güç olabilir (Han ve ark., 2023; Symmans ve ark., 2017). Buna karşın RCB-1'in bazı modellerde yüksek doğrulukla sınıflandırılabilmesi, minimal rezidüel hastalığın belirli bir radyolojik fenotip üzerinden ayrıştırılabildiğini düşündürmektedir. Özellikle BI-RADS, meme dansitesi ve lezyon türü gibi değişkenlerin bu sınıf üzerinde belirleyici olması, rezidüel hastalığın yalnızca patolojik değil, aynı zamanda radyolojik bir iz taşıdığını göstermektedir. Bu bulgu, görüntüleme ile saptanabilen minimal rezidüel hastalık imzasının tamamen homojen olmadığını, ancak belirli fenotipik örüntüler üzerinden tanımlanabildiğini düşündürmektedir. Bu açıdan çalışmamızın güçlü yönü, RCB-1'i salt sayısal bir ara sınıf olarak değil, özgül bir görüntüleme karşılığı olabilecek ayrı bir biyolojik alt grup olarak işaret etmesidir. Sınırlılığı ise bu sınıfın görece az sayıda

örnekle temsil edilmesi ve dolayısıyla model kararlılığının dış kohortlarda yeniden sınanma ihtiyacıdır (Lambin ve ark., 2017; Zwanenburg ve ark., 2020).

Buna karşılık RCB-3 sınıfında performansın belirgin biçimde zayıflaması, yaygın rezidüel hastalığın biyolojik olarak daha heterojen ve modelleme açısından daha güç bir kategori olduğunu düşündürmektedir. Bu sınıfın görece düşük temsili, algoritmanın yeterli örüntü öğrenmesini sınırlamış olabilir; ancak mesele yalnızca örneklem büyüklüğü değildir. RCB-3, farklı direnç mekanizmaları, klonal seçim süreçleri ve tedavi baskısına adaptasyon yolları üzerinden gelişebilen, dolayısıyla tek bir fenotip altında toplanması zor bir rezidüel hastalık örüntüsünü temsil etmektedir. Rezidüel hastalığın kendisinin heterojen bir biyolojik varlık olduğu, farklı alt tipler arasında prognostik etkisinin değişebildiği ve RCB'nin özellikle sürekli ölçekte prognostik gücünün alt tipe göre farklılaştığı daha önce gösterilmiştir (Symmans ve ark., 2017; Yau ve ark., 2019; Yau ve ark., 2022). Bu nedenle RCB sınıflarının nominal kategoriler olarak ele alınması, sınıflar arasındaki doğal sıralama bilgisini kısmen kaybettirmektedir. Bu bağlamda ordinal modelleme yaklaşımları, RCB-0'dan RCB-3'e uzanan biyolojik sürekliliği daha iyi temsil edebileceğinden gelecekte daha uygun bir çerçeve sunabilir (Hornung, 2020). Bu açıdan çalışmamızın güçlü yönü, yaygın rezidüel hastalığı yalnızca bir kötü sınıf olarak değil, biyolojik olarak heterojen ve tahmini güç bir sonlanım grubu olarak tartışmaya açmasıdır; sınırlılığı ise RCB-3 örnek sayısının görece az olması nedeniyle model kararlılığının bu alt grupta düşmesidir.

SMOTE'un bazı modellerde sınıf dengesini iyileştirirken yüksek performanslı modellerde dalgalanma yaratması, sentetik örnekleme yöntemlerinin bağlama duyarlı biçimde değerlendirilmesi gerektiğini göstermektedir. Bu sonuç, sınıf dengesizliği veri literatürüyle uyumludur; zira SMOTE'un özellikle yüksek boyutlu ve heterojen biyomedikal veri kümelerinde her zaman performans artışı sağlamadığı, bazı durumlarda sınıflar arası yapay örtüşme yaratarak karar sınırını bulanıklaştırabildiği gösterilmiştir (Batista ve ark., 2004; Haixiang ve ark., 2017; Blagus & Lusa, 2013). Azınlık sınıflarının sentetik olarak artırılması, karar sınırını bazen iyileştirirken bazen de biyolojik gerçekliği tam yansıtmayan yapay bölgeler oluşturabilmektedir; bu durum özellikle kategorik değişkenlerin ve yüksek korelasyonlu prediktörlerin yoğun olduğu tıbbi veri setlerinde daha belirgindir (Fernández ve ark., 2018; Arefeen ve ark., 2024).

Bu nedenle sınıf dengesizliği sorununa yaklařırken tek bir yöntem yerine, veri yapısına göre uyarlanmış ve maliyet duyarlı stratejilerin deęerlendirilmesi daha uygun g r nmektedir.  zellikle azınlık sınıfının yapay olarak  oęaltılması yerine, sınıf aęırlıklandırma, eřik optimizasyonu ve maliyet-duyarlı  ęrenme gibi yaklařımlar daha dengeli sonu lar verebilir; nitekim y ksek boyutlu biyomedikal veri baęlamında SMOTE'un faydasının deęiřken olduęu ve bazı senaryolarda alt  rnekleme ya da hibrit stratejilerin daha iyi performans verdięi bildirilmiřtir (He & Garcia, 2009; Fern ndez et al., 2018; Ganganwar, 2012). Bu a ıdan  alıřmamızın g  l  y n , SMOTE'un evrensel bir   z m olmadıęını ampirik olarak g stermesi; sınırlılıęı ise alternatif dengeleme stratejilerinin sistematik olarak karřılařtırılmamıř olmasıdır.

Doęrulama stratejisinin g c , modelin klinik yorumlanabilirlięini destekleyen bir dięer  nemli unsur olmuřtur. Nested cross-validation, bootstrap ve kalibrasyon analizlerinin birlikte kullanılması, modelin yalnızca bir kez iyi  alıřan bir yapı olmadıęını, daha kararlı ve genellenebilir bir performans sergiledięini g stermektedir. Bu yaklařım, klinik tahmin modellerinin deęerlendirilmesinde i  doęrulama, optimism d zeltmesi ve dıř genellenebilirlik tartıřmasının zorunlu unsurlar haline geldięini vurgulayan g ncel metodoloji literat r yle uyumludur (Collins ve ark., 2024; Riley ve ark., 2024). Bununla birlikte bazı sınıflar i in g ven aralıklarının geniřlięi, nokta tahminlerine ařırı g venilmemesi gerektięini ortaya koymaktadır. Zira bootstrap temelli g ven aralıklarının,  zellikle model optimizasyon yanlılıęı d zeltilmedięinde, ger ek belirsizlięi olduęundan dar g sterebildięi bildirilmiřtir (Noma ve ark., 2021).  zellikle RCB-3 gibi kritik kategorilerde model performansının deęiřken olması, klinik karar s re lerinde destekleyici ama tek bařına belirleyici olmayan bir rol  stlenmesi gerektięini d ř nd rmektedir. Kalibrasyonun iyileřmesi ise modelin yalnızca ayırt edici deęil, olasılık  ıktıları bakımından da daha g venilir hale geldięini g stermektedir. Bu durum, klinik karar destek sistemlerinde yalnızca AUC'nin deęil, kalibrasyon ve karar eęrisi temelli klinik yarar  l  tlerinin de birlikte deęerlendirilmesi gerektięine iřaret etmektedir (Vickers & Elkin, 2006; Collins ve ark., 2024). Bu a ıdan  alıřmamızın g  l  y n , yalnızca ayırıştırma g c n  deęil, kalibrasyon ve genellenebilirlięi de birlikte tartıřmasıdır; sınırlılıęı ise dıř doęrulama yapılmaksızın bu performansın ger ek d nya klinik ortamına tam olarak aktarılıp aktarılamayacaęının hen z g sterilememiř olmasıdır.

Bu bölümün güçlü yönleri arasında, modüler ve kademeli veri entegrasyonu yaklaşımının sistematik biçimde uygulanması, farklı algoritmaların karşılaştırmalı olarak değerlendirilmesi, güçlü iç doğrulama stratejilerinin kullanılması, kalibrasyon ve karar eğrisi analizleri ile modelin klinik kullanılabilirliğinin ayrı bir ekseninde tartışılması ve SHAP analizi ile yorumlanabilirliğin artırılması yer almaktadır. Özellikle çok bloklu veri yapısında yalnızca ayırt edicilik performansının değil, modelin açıklanabilirliğinin ve klinik karar desteğine uygunluğunun da birlikte ele alınmış olması, çalışmanın metodolojik değerini güçlendirmektedir. Buna karşılık çalışmanın bazı sınırlılıkları da bulunmaktadır. Tek merkezli tasarım dış geçerliliği sınırlamakta, sınıf dengesizliği özellikle RCB-1 ve RCB-3 kategorilerinde performansı etkilemekte, ordinal yapının nominal sınıflandırma ile ele alınması sınıflar arasındaki doğal sıralı ilişkiyi zayıflatmakta ve radyolojik verilerin tek merkezli değerlendirilmesi genellenebilirliği sınırlayabilmektedir. Ayrıca uzun dönem sağkalım verilerinin bulunmaması, RCB kategorilerinin bu kohortta prognostik anlamının tam olarak değerlendirilmesini engellemektedir. Bu nedenle çalışma, güçlü bir iç yöntemsel çerçeve sunmakla birlikte, bulguların bağımsız ve çok merkezli kohortlarda doğrulanmasına ihtiyaç olduğunu göstermektedir.

Sonuç olarak bu çalışma, neoadjuvan kemoterapi sonrası rezidüel kanser yükü kategorilerinin öngörülmesinde modüler ve kademeli bir makine öğrenmesi yaklaşımının sistematik olarak uygulanmasının, veri bloklarının eşit değil, biyolojik anlam ve ayırtıcı kapasiteye göre farklı katkılar sunduğunu göstermektedir. Bu bulgu, çok kaynaklı veri entegrasyonunun yalnızca teknik bir birleştirme işlemi olmadığını; aksine, her veri bloğunun taşıdığı biyolojik sinyalin model başarısına farklı düzeylerde yansıdığını ortaya koymasından önemlidir. Radyolojik verilerin güçlü bir omurga oluşturması, patolojik ve onkolojik verilerin sinerjik biçimde birbirini tamamlaması, komorbidite ve biyokimya verilerinin ise daha sınırlı katkı sunması, biyolojik anlamlılık ile istatistiksel fayda arasındaki farkı görünür kılmaktadır. LightGBM'nin yüksek boyutlu veri entegrasyonunda üstün performans göstermesi, veri yapısı ile öğrenme yapısı arasındaki uyumu doğrularken; sınıf bazlı asimetri ve SMOTE'un değişken etkisi, modelleme stratejilerinin bağlama duyarlı biçimde seçilmesi gerektiğini göstermektedir. Bu açıdan çalışmanın özgün değeri, yalnızca en iyi algoritmayı tanımlamakta değil, hangi veri bloğunun hangi klinik ve

biyolojik bilgiyi taşıdığını ve bu bilginin hangi koşullarda anlamlı bir öngörüye dönüştüğünü göstermesinde yatmaktadır.

İleriye dönük olarak, bu modelin çok merkezli dış doğrulama ile test edilmesi, farklı hasta popülasyonlarında genellenebilirliğinin ortaya konulması ve merkezler arası değişkenliğe karşı dayanıklılığının değerlendirilmesi gerekmektedir. Ayrıca ordinal modelleme yaklaşımlarının uygulanması, RCB sınıfları arasındaki doğal sıralı yapının daha doğru temsil edilmesine katkı sağlayabilir. Dinamik görüntüleme verilerinin, tedavi sırasında elde edilen ara dönem radyolojik yanıtların ve uzun dönem sağkalım sonuçlarının modele eklenmesi, hem öngörü gücünü hem de prognostik anlamı güçlendirecektir. Bunun yanında, sınıf dengesizliğine yönelik maliyet duyarlı öğrenme stratejilerinin ve alternatif örnekleme yöntemlerinin karşılaştırmalı olarak değerlendirilmesi, modelin kritik alt sınıflardaki kararlılığını artırabilir. Bu çerçevede çalışma, yalnızca mevcut veri seti için güçlü bir öngörü modeli sunmakla kalmamakta, aynı zamanda daha rafine, daha genellenebilir ve klinik kullanıma daha yakın yeni araştırma sorularına da zemin hazırlamaktadır.

5.4. PET-BT Verilerinin RCB Öngörüsüne Katkısı

Bu bölümde, meme kanseri hastalarında NAK sonrası RCB öngörülmesinde klinik-radyolojik veriler ile ^{18}F -FDG PET/BT görüntülerinden elde edilen metabolik ve radyomik özniteliklerin katkısı kapsamlı bir makine öğrenmesi çerçevesinde değerlendirilmiştir. Elde edilen bulgular, PET-BT türevli metabolik parametrelerin klinik anlam taşıdığını; ancak tek başına ya da mevcut entegre klinik-radyolojik modelin üzerine otomatik üstünlük getirmediğini göstermektedir. Bu sonuç, “daha fazla görüntüleme verisi her zaman daha iyi performans sağlar” varsayımının meme kanseri gibi biyolojik heterojenitesi yüksek tümörlerde doğrusal biçimde işlemediğini düşündürmektedir. Nitekim PET/BT’nin neoadjuvan tedavi yanıtını öngörmedeki katkısı literatürde de çoğunlukla bağlama bağımlı olarak tanımlanmakta; özellikle biyolojik alt tipe, görüntüleme zamanlamasına ve sonlanımın tanımına göre değişkenlik göstermektedir (Memişoğlu & Sarı, 2022). Çalışmanın temel katkısı, PET-BT’nin etkisini yalnızca tek bir performans metriği üzerinden değil; nested cross-validation, bootstrap, kalibrasyon, permütasyon önemliliği ve sınıf bazlı ROC analizleri gibi çok katmanlı değerlendirme stratejileriyle incelemiş olmasıdır. Bu

yaklaşım, yapay zekâ çalışmalarında sık görülen aşırı performans odaklı ve metodolojik olarak dar değerlendirme anlayışının ötesine geçmektedir (Collins ve ark., 2015; Davis ve ark., 2018).

Yalnızca PET-BT değişkenlerine dayanan Model PET'in gerek test setinde gerekse nested çapraz doğrulama analizlerinde sergilediği zayıf performans, tümörün biyolojik davranışının tek bir metabolik kesit üzerinden modellenmesinin sınırlılıklarını göstermektedir. Çapraz doğrulama aşamasında daha iyi görünen AUC'nin bağımsız test setinde belirgin biçimde düşmesi, yüksek boyutlu özellik uzayının nispeten küçük ve dengesiz bir kohortta değerlendirilmesinin varyans şişmesine yol açtığını düşündürmektedir. ¹⁸F-FDG afinitesi tümörün glikolitik aktivitesini yansıtmakla birlikte; RCB gibi primer tümör yatağı, in situ komponent, nodal yük ve anatomik yaygınlık içeren çok boyutlu bir sonlanımı tek başına eksiksiz açıklaması beklenmez (Avanzo ve ark., 2020). Bu biyolojik uyumsuzluk şaşırtıcı değildir; çünkü PET metabolik aktiviteyi, RCB ise histopatolojik ve anatomik yükü ölçer. Bu nedenle, PET'in özellikle yüksek metabolik aktivite gösteren alt gruplarda güçlü sinyal vermesine rağmen, RCB gibi bileşik sonlanımlarda tek başına yeterli olmaması beklenen bir durumdur. Çalışmamızda klinik ve konvansiyonel radyolojik değişkenlerin karar ağacında PET özneliliklerinden daha önde yer alması da, metabolik bilginin mevcut biyolojik omurgayı çoğu durumda ancak sınırlı biçimde genişlettiğini düşündürmektedir (Hatt ve ark., 2017).

Literatürde de PET/BT'nin neoadjuvan yanıt öngörüsündeki performansı çoğunlukla bağlam bağımlı olarak rapor edilmiştir. (Dursun, 2024), FDG-PET/BT'nin özellikle triple-negatif ve HER2-pozitif meme kanserlerinde erken metabolik yanıtı öngörebildiğini göstermiştir. Ancak bu çalışmaların önemli bölümü ikili sonlanımlar üzerinden yürütülmüş; RCB gibi çok sınıflı ve biyolojik olarak daha ince ayrımlı bir sonlanım kullanılmamıştır. Mevcut çalışmada dört sınıflı RCB yapısının modellenmesi, metabolik parametrelerin daha heterojen ve kompleks bir karar uzayında değerlendirilmesine yol açmıştır. Bu nedenle PET-BT'nin sınırlı performansı, bir yandan yöntemsel olarak daha zorlayıcı bir sınıflandırma problemiyle ilişkili olabilirken, diğer yandan baseline PET'in tek zamanlı olması nedeniyle metabolik değişimin dinamik yönünü yakalayamamasından kaynaklanmış olabilir. Interim PET ve delta-radyomik yaklaşımların neoadjuvan tedavi yanıtını daha iyi

öngörebildiğini bildiren çalışmalar, bu yorumu desteklemektedir (Han & Choi, 2020). Baseline veriye dayalı yaklaşımın sınırlılığı, PET'in gerçek potansiyelini olduğundan düşük gösterebilir.

PET-BT parametrelerinin doğası gereği yüksek biyolojik ve teknik değişkenlik taşıması da önemli bir etkidir. SUV temelli ölçümler; görüntüleme zamanı, glukoz düzeyi, cihaz kalibrasyonu, segmentasyon yöntemi ve rekonstrüksiyon algoritmalarından etkilenebilmektedir (Boellaard, 2009). Özellikle PET radyomik özelliklerde merkezler arası standardizasyon eksikliği, genellenebilirliği sınırlandıran temel sorunlardan biridir (Zwanenburg ve ark., 2020). Mevcut çalışmanın tek merkezli yapısı ölçüm standardizasyonu açısından bir avantaj sağlasa da, PET alt örnekleminin küçük olması gerçek ayrıştırıcı kapasitenin ortaya çıkmasını zorlaştırmış olabilir. Ayrıca bu alt örneklemin ana kohorta göre seçilmiş bir hasta grubunu temsil etmesi, örneklem kompozisyonunu etkilemiş ve model davranışını değiştirmiş olabilir. Bu yönüyle çalışmamızın güçlü yanı, PET verisini yüksek kontrol altında ölçülmüş bir çerçevede değerlendirmesi; sınırlılığı ise örneklem büyüklüğünün, özellikle radyomik özelliklerin kararlılığını test etmek için yetersiz kalabilmesidir.

PET eklenmesinin model davranışı üzerindeki etkisi dikkat çekici biçimde paradoksaldır. PET değişkenlerinin Model ALL'e eklenmesi test setinde küçük bir düşüşe, nested cross-validation'da ise küçük bir artışa yol açmıştır. Bu durum, PET-BT'nin sağladığı bilginin tamamen değersiz olmadığını; ancak bu bilginin önemli bir kısmının mevcut klinik-radyolojik model içinde zaten temsil ediliyor olabileceğini düşündürmektedir. Başka bir deyişle PET, yeni bir biyolojik eksen açmaktan çok, mevcut sinyali başka bir biçimde yeniden üretmiş olabilir. Bootstrap güven aralıklarının Model ALL ile Model ALL+PET arasında büyük ölçüde örtüşmesi ve etki büyüklüğünün ihmal edilebilir düzeyde kalması, iki modelin genel performans kapasitesinin birbirine oldukça yakın olduğunu göstermektedir. Bu noktada bilgi örtüşmesi hipotezi önem kazanmaktadır. Klinik değişkenler, radyolojik kitle özellikleri ve patolojik alt yapı birlikte ele alındığında tümör yükü ve agresiflik hakkında zaten güçlü bir çerçeve oluşmaktadır. PET'in sunduğu metabolik aktivite, ancak bu çerçevenin dolduramadığı özgün bir boşluğu kapatıyorsa anlamlı katkı sağlayabilir.

Ki-67 ile FDG tutulumu arasındaki belgelenmiş korelasyon, PET'in sağladığı bilginin bir kısmının modelde zaten vekil değişkenlerle temsil edildiğini düşündürmektedir (Buck ve ark., 2002). Benzer şekilde kitle konturu, kalsifikasyon morfolojisi ve klinik evre gibi değişkenlerin de tümörün metabolik davranışını dolaylı olarak yansıtabildiği düşünülebilir. Bu nedenle multimodal modellemenin her zaman daha iyi performans anlamına gelmediği bir kez daha görülmektedir. Modalite sayısı arttıkça performansın otomatik olarak yükseleceği varsayımı, yalnızca ek modalite gerçekten yeni bilgi üretiyorsa geçerlidir. Aksi halde model karmaşıklığı artar, varyans yükselir ve genellenebilirlik azalır. Nitekim PET değişkenlerinin sayısının artmasına karşın güven aralığının genişlemesi, modele eklenen bazı değişkenlerin yararlı sinyalden çok gürültü taşıyabileceğini düşündürmektedir. Bu durum, yüksek boyutlu ve korelasyonlu veri kümelerinde özellik fazlalığı ve boyutluluk sorunu ile uyumludur (Guyon & Elisseeff, 2003).

Çalışmanın metodolojik açıdan en özgün yönlerinden biri, bağımsız test seti üzerindeki paired bootstrap analizi ile nested çapraz doğrulama sonuçları arasında gözlenen istatistiksel uyumsuzluğun eleştirel biçimde yorumlanmasıdır. Test setinde Model ALL ile Model ALL+PET arasındaki AUC farkının aşırı anlamlı bulunmasına karşın, nested CV düzleminde fold'lar üzerinden yapılan paired testin anlamlı fark göstermemesi, örneklem büyüklüğü ve örnekleme varyasyonunun model doğrulamasındaki kritik rolünü ortaya koymaktadır. Bootstrap analizlerinde küçük test kümelerinde tekrar örnekleme yapılmasının varyansı olduğundan dar gösterebilmesi ve istatistiksel gücü yapay olarak artırabilmesi beklenen bir durumdur. Buna karşılık nested CV daha muhafazakâr bir genelleme tahmini sunmakla birlikte, fold sayısının sınırlı olması nedeniyle daha geniş belirsizlik alanı bırakabilir (Varma & Simon, 2006). Bu nedenle bootstrap ve nested CV sonuçlarının birlikte raporlanmış olması çalışmanın önemli bir metodolojik gücüdür; çünkü performansın yalnızca noktasal değil, belirsizlik ekseninde de değerlendirilmesini sağlamaktadır.

Permütasyon önemliliği ve radyomik özelliklerin davranışı da PET-BT kısmının önemli bir tartışma alanıdır. Yapısal feature importance ile permütasyon önemliliği arasında görülen farklılık, bazı gelişmiş doku analizi parametrelerinin eğitim verisinde yüksek önem taşıırken bağımsız test setinde performans katkı vermeyebileceğini göstermektedir. Bu durum, ağaç tabanlı modellerin eğitim verisindeki kovaryans

yapısını ezberleyebilmesi ve bazı özniteliklerin yalnızca örnekleme özgü korelasyonları yansıtabilmesiyle açıklanabilir (Breiman, 2001; Strobl ve ark., 2007). PET değişken havuzunda SUVmax, TLG, asferisite ve küresellik gibi parametrelerin pozitif katkı göstermesine karşın, bazı yüksek dereceli tekstür özelliklerinin nötr ya da negatif katkı vermesi, PET radyomik alanında standardizasyon ve tekrarlanabilirlik sorunlarının hâlâ önemli olduğunu düşündürmektedir (Traverso ve ark., 2018; Larue ve ark., 2017). Bu nedenle çalışmamızın bir başka katkısı, karmaşık radyomik özniteliklerin her zaman avantaj sağlamadığını, daha yalın ve biyolojik karşılığı daha net değişkenlerin klinik karar desteği için daha işlevsel olabileceğini göstermesidir.

Seçici özellik kullanımı senaryoları bu bağlamda özellikle değerli bir bulgu sunmaktadır. Negatif ve nötr etkili özniteliklerin elendiği agresif yaklaşımda performansın artması ve yalnızca SUVmax, TLG ve MTV gibi geleneksel parametreleri içeren minimal yaklaşımın kapsamlı yapıya benzer sonuçlar vermesi, “kalite > miktar” ilkesini desteklemektedir (Vallières ve ark., 2015). SUVmax, MTV ve TLG gibi ölçümler hekimler tarafından daha kolay yorumlanabilir, biyolojik karşılığı daha nettir ve model kararlarına daha rahat entegre edilir. Buna karşılık bazı tekstür özellikleri, teknik rekonstrüksiyon farklarına ve ROI çizim yöntemlerine yüksek duyarlılık gösterdiğinden faydadan çok gürültü üretebilir. Bu bulgu, PET radyomik literatüründe uzun süredir tartışılan standardizasyon ve yeniden üretilebilirlik sorunu ile uyumludur. Dolayısıyla çalışmamız, maksimum veri entegrasyonu yerine biyolojik olarak optimize edilmiş veri entegrasyonunun daha uygun olabileceğini düşündürmektedir.

Sınıf bazlı performans örüntüleri de PET-BT’nin katkısını anlamada önemlidir. RCB-I sınıfının her iki modelde de en yüksek ayrıştırılabilirliğe sahip olması, minimal rezidüel hastalık fenotipinin metabolik ve morfolojik açıdan daha özgün bir biyolojik profil taşıyabileceğini düşündürmektedir. Symmans ve ark. (2017) de RCB-I grubunun uzun dönem sağkalım açısından pCR’ye yakın ama biyolojik olarak tamamen aynı olmayan bir konumda bulunduğunu göstermiştir. Buna karşılık RCB-0 ve RCB-3 gibi uç sınıflarda kalibrasyon eğrilerinin ideal çizgiden sapması ve ham veride RCB-3 sınıfının performansının zayıf kalması, şiddetli sınıf dengesizliğinin ve klinik sınır belirsizliğinin bir sonucudur. Özellikle ileri rezidüel hastalıkta tümör heterojenliği, tedaviye bağlı klonal adaptasyon ve mikroskobik progresyon örüntüleri daha karmaşık

hale gelmektedir. RCB-3 örneklerinin görece düşük temsili, modelin bu sınıfı yeterince öğrenmesini de sınırlamış olabilir.

SMOTE uygulamasının karmaşık etkisi de bu bölümde dikkat çekicidir. Azınlık sınıflarda sentetik örnekleme yapmanın bazı modellerde F1 skorunu kısmen iyileştirmesine rağmen genel AUC üzerinde dalgalanma yaratması, yapay veri üretiminin her zaman klinik gerçekliği yansıtmadığını göstermektedir (Fernández ve ark., 2018). SMOTE, komşuluk temelli doğrusal interpolasyonla sentetik örnekler oluşturur; ancak meme kanserinde pCR ile parsiyel yanıt arasındaki geçiş bölgeleri keskin geometrik sınırlar yerine örtüşen biyolojik sinyallerle tanımlanır. Bu nedenle sentetik manifold yapıları, eğitim setinde aşırı iyimser bir tablo yaratabilirken test dağılımında aynı dayanıklılığı göstermeyebilir. Literatürde de oversampling yöntemlerinin özellikle karmaşık sınıf yapısına sahip tıbbi veri setlerinde dikkatli uygulanması gerektiği bildirilmektedir (Fernández ve ark., 2018; Elreedy & Atiya, 2019). Bu açıdan çalışmamız, SMOTE'un etkisini olumlu ya da olumsuz diye basitleştirmek yerine, bağlama ve algoritmaya duyarlı bir araç olarak değerlendirmektedir.

Kalibrasyon ve öğrenme eğrisi analizleri ise PET-BT entegrasyonunun model davranışını dramatik biçimde değiştirmedeğini göstermektedir. Her iki modelde de benzer overfitting gap değerlerinin bulunması, PET-BT eklenmesinin öğrenme dinamiğini kökten dönüştürmediğini düşündürmektedir. Buna karşılık bootstrap güven aralığının genişlemesi ve test-CV farkının artması, PET eklenen modelin daha değişken bir performans profiline sahip olduğunu göstermektedir. Bu bulgu klinik açıdan önemlidir; çünkü gerçek yaşam uygulamalarında yalnızca yüksek doğruluk değil, öngörü kararlılığı da kritik öneme sahiptir. Kalibrasyon eğrilerinin ideal çizgiye yakınlığı, özellikle RCB-I ve RCB-0 gibi daha net sınıflarda, modelin olasılık çıktılarının güvenilir olduğunu göstermektedir. Bu durum, klinik karar destek sistemlerinde ayırt edicilik kadar kalibrasyonun da zorunlu olduğunu vurgulayan literatürle uyumludur (Van Calster ve ark., 2019).

Çalışmanın önemli güçlü yönlerinden biri, PET-BT katkısını yalnızca tek bir performans metriği üzerinden değil; nested CV, bootstrap, kalibrasyon, permutation importance ve sınıf bazlı ROC analizleri gibi çok katmanlı değerlendirme stratejileriyle incelemiş olmasıdır. Bu yaklaşım, yapay zekâ çalışmalarında sık görülen

performans odaklı dar değerlendirme anlayışının ötesine geçmektedir. Özellikle senaryo analizleri yoluyla farklı PET entegrasyon stratejilerinin sistematik karşılaştırılması, translasyonel değer açısından anlamlıdır. Bununla birlikte çalışmanın sınırlılıkları da belirgindir. Tek merkezli tasarım ve PET-BT alt örnekleminin küçük büyüklüğü dış geçerliliği sınırlamaktadır. Yalnızca baseline PET verilerinin kullanılması, tedavi sırasındaki metabolik değişimin yakalanmasını engellemiştir. Ayrıca sınıf dengesizliği özellikle RCB-3 kategorisinde performansı etkilemiş, radyomik özelliklerin standardizasyonu konusunda merkezler arası doğrulama yapılamamıştır. Uzun dönem sağkalım verilerinin olmaması da RCB kategorilerinin prognostik anlamını bu kohortta değerlendirmeyi zorlaştırmaktadır.

Sonuç olarak bu çalışma, ^{18}F -FDG PET/BT türevli metabolik ve radyomik özelliklerin RCB öngörüsüne katkısının sistematik biçimde değerlendirilmesini sağlamıştır. Bulgular, PET-BT parametrelerinin klinik anlam taşıdığını; ancak mevcut klinik-radyolojik mimariye otomatik üstünlük getirmediğini göstermektedir. Yalnızca PET verilerine dayanan modelin sınırlı performansı, metabolik görüntülemenin tek başına RCB gibi çok boyutlu patolojik sonlanımları açıklamakta yetersiz kaldığını düşündürmektedir. Klinik-radyolojik modele PET eklenmesinin marjinal ve değişken etkisi, bilgi örtüşmesi ve boyutluluk sorunu ile açıklanabilir. Permütasyon önemliliği analizleri, PET değişkenlerinin heterojen katkı gösterdiğini ve bazı yüksek dereceli radyomik özelliklerin performansı düşürebildiğini ortaya koymuştur. Seçici özellik kullanımı senaryoları, yalnızca SUVmax, TLG ve MTV gibi geleneksel metabolik parametrelerin klinik karar desteği için yeterli olabileceğini göstermektedir. Sınıf bazlı performans asimetrisi, minimal rezidüel hastalığın özgün bir biyolojik imzaya sahip olabileceğini; yaygın rezidüel hastalığın ise daha karmaşık yaklaşımlar gerektirdiğini düşündürmektedir. SMOTE'un paradoksal etkisi, sınıf dengeleme stratejilerinin bağlam-bağımlı değerlendirilmesi gerektiğini göstermektedir. Gelecekte çok merkezli dış doğrulama, delta-radyomik entegrasyonu, derin öğrenme yaklaşımları, genomik veri entegrasyonu ve uzun dönem sağkalım analizleri, PET-BT'nin neoadjuvan tedavi yanıt öngörüsündeki gerçek klinik değerini daha net biçimde ortaya koyacaktır.

5.5. Makine Öğrenmesi Modellerinin Klinik Karar Destek Sistemine Entegrasyonu ve Çevirimsel Tıp Uygulamaları

Makine öğrenmesi ve ileri istatistiksel modelleme yöntemlerinin onkoloji pratiğine entegrasyonu, biyomedikal bilişimde translasyonel bir eksen oluşturmaktadır; ancak bu entegrasyonun klinik faydaya dönüşmesi, yalnızca algoritmik performansla değil, dış doğrulama, kalibrasyon ve gerçek dünya genellenebilirliği ile ölçülmektedir (Van Calster ve ark., 2019; Davis ve ark., 2018;). Neoadjuvan kemoterapi sonrası pCR veya RCB kategorilerini öngören modeller de bu örüntüden bağımsız değildir: yüksek içsel ayırıştırma güce rağmen çoğu çalışmada dış doğrulama eksikliği, prospektif değerlendirme sınırlılığı ve klinik karar akışına entegrasyonun yetersizliği belirgindir (Symmans ve ark., 2007; Topol, 2019; Sendak ve ark., 2020). Bu durum, klinik yapay zekâ literatüründe "AI chasm" olarak tanımlanan, modelin laboratuvar başarısı ile klinik uygulamaya taşınması arasındaki yapısal boşluğu yansıtmaktadır (Van Calster ve ark., 2019; Davis ve ark., 2018; (Madam & Ashok, 2024)). Bu bölümün tasarladığı çok katmanlı dijital ekosistem (pCR Hesaplayıcı, BCRIS Web, BCRIS Masaüstü ve HİP Mobil Uygulaması), söz boşluğu hedef olarak tanımlanan translasyonel eksenin mühendislik karşılığıdır; tek bir platform, tek bir sonlanım ya da tek bir model etrafında kurgulanan klasik karar destek sistemlerinden farklı olarak, pCR için ikili sınıflandırma ve RCB için çok sınıflı öngörü yapabilen bileşenleri aynı hiyerarşik karar yapısı altında birleştirir (Shortliffe & Sepúlveda, 2018; Sittig & Singh, 2010). Bu yönüyle çalışma, yalnızca bir algoritma geliştirme girişimi değil; model geliştirme, kullanıcı deneyimi ve veri toplama süreçlerini birlikte ele alan translasyonel bir tasarım örneğidir. Bununla birlikte, literatürdeki başarılı örneklerin giderek daha fazla prospektif klinik karar destek çerçevelerine, bakım akışına gömülü testlere ve sürekli izleme mekanizmalarına yöneldiği göz önüne alındığında, bu ekosistemin mevcut hali daha çok prototip ve metodolojik doğrulama aşamasında kalmaktadır (Friedman ve ark., 2010; Sendak ve ark., 2020). Dolayısıyla çalışmanın en güçlü yanı, "fikirden ürüne" geçişi teknik olarak başlatması; en belirgin sınırlılığı ise bu geçişin henüz gerçek dünya etkinliği ve klinik fayda kanıtıyla desteklenmemiş olmasıdır.

Bu bölümün ayırt edici gücü, tek bir tahmin aracını değil, bir dijital ekosistemi tasarlamış olmasıdır. pCR hesaplayıcısı, BCRIS web uygulaması (veya BCRIS

masaüstü sürümü) ve HİP mobil uygulaması birbirini tamamlayan bileşenler olarak kurgulanmıştır. Böylece veri toplama, model uygulama, sonuç sunumu ve paylaşım süreçleri tekil bir yazılımın sınırlarını aşarak sistematik bir çerçeveye taşınmıştır. Literatürde klinik karar destek sistemlerinin çoğu, belirli bir bakım noktasında çalışan ve tek bir işlevi yerine getiren araçlar olarak tasarlanırken, burada farklı kullanım senaryolarına uyarlanabilen katmanlı bir mimari geliştirilmiş olması önemli bir farklılık oluşturmaktadır (Kawamoto ve ark., 2005; Shortliffe & Sepúlveda, 2018). Bu yaklaşım, translasyonel tıbbın temel mantığıyla, yani laboratuvarıdan klinik uygulamaya geçişin kesintisiz bir veri ve bilgi akışı gerektirdiği anlayışla uyumludur (Friedman ve ark., 2010). Aynı modelin farklı platformlara uyarlanması, sistemin klinik bağlamdan kopmadan taşınabilir olmasını sağlamış; özellikle masaüstü sürümün çevrimdışı kullanım, web sürümün çok kullanıcıli erişim ve mobil sürümün veri toplama ve koordinasyon işlevleri üzerinden farklı ihtiyaçları karşılaması, tek çözümün tüm klinik senaryolara yeterli olmayacağı gerçeğini görünür kılmıştır (Greenhalgh ve ark., 2017; Rieke ve ark., 2020). Bununla birlikte, çok platformlu mimarilerin literatürde sıklıkla karşılaştığı sürüm yönetimi, entegrasyon ve bakım yükü sorunları bu çalışmada henüz tam olarak çözümlenmemiştir; bu da çalışmayı güçlü bir prototip, fakat henüz tam olgun bir klinik ürün olmayan bir noktada konumlandırmaktadır (Sendak ve ark., 2020).

Web tabanlı BCRIS platformunun en önemli katkılarından biri, standartlaştırılmış veri girişini ve merkezi kullanım mantığını aynı çatı altında birleştirmesidir. Altı tematik sekmeye ayrılmış yapı (Patoloji, Onkoloji, Demografi, Komorbidite, Biyokimya, Radyoloji), farklı uzmanlık alanlarına ait klinik değişkenleri tek bir arayüz içinde düzenleyerek kullanıcıya daha sistematik bir giriş akışı sunmaktadır. Klinik karar destek sistemleri literatürü, veri toplama aşamasında yaşanan tutarsızlığın ve serbest biçimli girişlerin model performansını olduğu kadar uygulanabilirliği de zayıflattığını; bu nedenle yapılandırılmış formlar ve zorunlu alan mantığının veri kalitesini artırmada kritik olduğunu göstermektedir (Sittig ve Singh, 2010; Shortliffe ve Sepúlveda, 2018; Sendak ve ark., 2020). Bu açıdan BCRIS'in sekme temelli mimarisi, yalnızca kullanıcı deneyimini iyileştiren bir tasarım tercihi değil, aynı zamanda değişken uyumsuzluğunu en baştan sınırlamaya yönelik bir veri yönetişimi stratejisi olarak da değerlendirilebilir. Bununla birlikte, 64 değişkenin tematik olarak gruplandırılmış

olmasına rağmen bazı sekmelerde değişken yoğunluğunun yüksek kalması, bilişsel yük açısından sınıra yaklaşan bir yapı oluşturmaktadır; bu durum, form tasarımında katmanlı açılır menüler, koşullu alan gösterimi ya da dinamik genişletme mekanizmalarının ileride daha uygun olabileceğini düşündürmektedir. Böylece platform, literatürde sıkça vurgulanan “iyi model kadar iyi arayüz” gerekliliğini karşılamakla birlikte, daha da rafine edilebilecek bir kullanılabilirlik düzeyi sunmaktadır.

Masaüstü sürümün değeri ise özellikle kurumsal esneklikte ortaya çıkmaktadır. İnternet bağlantısının sınırlı olduğu ortamlarda hasta verisinin dış sunucuya çıkmadan yerel düzeyde işlenebilmesi, hem veri güvenliği hem de operasyonel süreklilik açısından önemli bir üstünlük sağlamaktadır. Klinik yapay zekâ uygulamalarına ilişkin yayınlar, bulut bağımlılığının özellikle ağ altyapısının heterojen olduğu merkezlerde erişim eşitsizliği yaratabildiğini; buna karşılık çevrimdışı ya da yerel çalışan çözümlerin, düşük kaynaklı kurumlarda daha sürdürülebilir olabildiğini göstermektedir (Wang ve ark., 2019; Topol, 2019; Esteva ve ark., 2021). Bu bağlamda taşınabilir .exe mimarisi, yalnızca teknik bir tercih değil, aynı zamanda sağlık bilişimi altyapısı değişken olan ortamlara uyum sağlayan pragmatik bir translasyonel çözümdür. Yine de literatürde başarıyla benimsenmiş masaüstü tabanlı klinik sistemlerin çoğunda kurum içi entegrasyon, güncelleme mekanizmaları ve sürüm kontrolü kritik bileşenler olarak öne çıkmaktadır; dolayısıyla bu mimarinin uzun dönem sürdürülebilirliği, bakım ve güncelleme süreçlerinin ne kadar iyi yönetileceğine bağlıdır.

Mobil HİP uygulaması ise veri toplama ve çok merkezli koordinasyon açısından anlamlıdır; çünkü klinik verinin oluşturulma anı çoğu zaman karar destek modelinden daha kırılgan bir süreçtir. Mobil platformun bu noktada devreye girmesi, verinin baştan standardize edilmesi ve farklı merkezlerden gelen kayıtların ortak bir mantıkta birleştirilmesi için önemli bir translasyonel adımdır. Mobil sağlık uygulamaları üzerine yapılan çalışmalar, verinin kaynağında standardizasyon sağlandığında hem veri bütünlüğünün hem de sonraki modelleme aşamalarının daha güvenilir hale geldiğini; ayrıca saha temelli veri toplama araçlarının merkezler arası koordinasyonu kolaylaştırdığını göstermektedir (Friedman ve ark., 2010; Rieke ve ark., 2020;

Greenhalgh ve ark., 2017). HİP uygulamasının doğrudan tahmin üretmek yerine veri toplama ve koordinasyon platformu olarak konumlandırılması, klinik yapay zekânın sürdürülebilirliği açısından doğru bir tercihtir; çünkü model başarısı çoğu zaman ilk aşamadaki veri üretim kalitesine bağlıdır. Çalışmada geliştirilen 20 karakterli alfanumerik benzersiz kod sistemi, hasta kimliğinden ayrıştırılmış veri paylaşımını mümkün kılarak hem anonimleştirme hem de veri bütünlüğü açısından önemli bir çözüm sunmaktadır. Bu yaklaşım, çok merkezli onkoloji pratiğinde farklı disiplinlerden gelen bilgilerin aynı hasta özelinde güvenli biçimde bütünleştirilmesini sağlayarak multidisipliner bakımın dijital karşılığına yaklaşmaktadır. Ancak bu yapının gerçek klinik yayılımında etkili olabilmesi için token eşleştirme güvenliği, hata toleransı ve olası veri kaybı senaryolarının ayrıca test edilmesi gerekir.

Klinik karar destek sistemlerinin önündeki en büyük engellerden biri, hasta verilerinin güvenliği ve KVKK/GDPR gibi düzenlemelere uyumdur; bu vurgu hem sağlık bilişimi literatüründe hem de son yıllardaki veri koruma tartışmalarında giderek daha merkezi hale gelmiştir (Kaplan, 2020; Sittig & Singh, 2015). Bu bağlamda pCR Klinik Karar Destek Aracı'nın tamamen istemci tabanlı mimariyle tasarlanması, veriyi sunucuya göndermeyen ve yerel depolama kullanmayan yapısıyla, gizliliği sonradan eklenen bir güvenlik katmanı değil, doğrudan tasarım ilkesi olarak ele alması bakımından ayırt edicidir. Buna karşın literatürde bulut tabanlı merkezi sistemlerin de ölçeklenebilirlik ve bakım kolaylığı nedeniyle yaygın kullanıldığı; ancak veri iletimi, yetkisiz erişim ve kurumsal sızıntı riskleri nedeniyle özellikle hassas sağlık verilerinde ek güvenlik ve yönetim katmanlarına ihtiyaç duyduğu belirtilmektedir (Sittig & Singh, 2015; Kaplan, 2020). Bu nedenle çalışmanın temel farkı, teknik performansı artırmak için değil, veri egemenliği ve hukuki risk azaltımı için istemci taraflı mimariyi merkezî bir tasarım tercihi olarak konumlandırmasıdır.

Son yıllarda GDPR ve HIPAA benzeri düzenlemelerle birlikte merkezi veri işleme yerine uç cihazda hesaplama ve edge computing yaklaşımlarına ilginin artması, bu tasarım tercihinin literatürle daha uyumlu hale getirmektedir (Rieke ve ark., 2020). Bu çalışma, JavaScript tabanlı yerel hesaplama motorunun Python modeliyle neredeyse tam uyum göstermesi sayesinde, web tarayıcılarının ileri düzey istatistiksel modelleri güvenilir biçimde çalıştırabildiğini göstermektedir; 0,00002 mutlak hata düzeyi, klinik

kullanım açısından ihmal edilebilir bir sapmaya işaret etmektedir. Bunun güçlü yanı, düşük gecikme ve düşük kaynak tüketimiyle kaynak kısıtlı klinik bilgisayarlarda da çalışabilmesidir; zayıf yanı ise bu performansın farklı donanım, tarayıcı ve işletim sistemlerinde henüz prospektif olarak sınanmamış olmasıdır. Klinik bilişim çalışmalarında zaman baskısı altında çalışan hekimler için gecikmesiz ve kesintisiz yanıt üreten sistemlerin benimsenme olasılığının daha yüksek olduğu bilindiğinden, bu mimari operasyonel kullanım açısından da anlamlı bir avantaj sağlar (Greenes, 2014).

Dosya boyutu karşılaştırması da dağıtım sürtünmesi açısından önemli bir üstünlük sunmaktadır; istemci-tabanlı HTML5 dosyasının 24,2 KB olması, masaüstü sürümün 106,5 MB’lık boyutuna kıyasla güncelleme ve dağıtım süreçlerinde belirgin kolaylık yaratır. Literatürde “deployment friction” olarak tartışılan bu konu, sağlık yazılımlarında yalnızca teknik değil, kurumsal benimseme açısından da belirleyicidir; küçük ve taşınabilir yapılar, özellikle farklı merkezlere hızlı yayılım ve sürüm güncellemesi gerektiren ortamlarda daha avantajlıdır (Gülseçen & Aksaya, 2021). Buna karşın küçük dosya boyutunun tek başına yeterli olmadığı, bakım mekanizmaları, bağımlılık yönetimi ve sürüm doğrulamasının da klinik güvenilirlik için gerekli olduğu unutulmamalıdır. Yani çalışmanın katkısı dağıtım kolaylığıdır; eksik tarafı ise bu kolaylığın uzun dönemli kurumsal entegrasyon ve yaşam döngüsü yönetimiyle henüz tam desteklenmemiş olmasıdır.

Sistemin güvenlik altyapısı ise güçlü ve zayıf yönleri birlikte barındırmaktadır. SSL Labs A notu, TLS 1.3 desteği, AES-256 şifreleme ve Django üzerinden sağlanan CSRF, SQL injection ve XSS korumaları, OWASP Top 10 perspektifinden bakıldığında güçlü bileşenlerdir; Django’nun güvenlik odaklı mimarisi de bu çerçevede avantaj sağlar (Open Web Application Security Project [OWASP], 2021; Django Software Foundation, 2024). Buna karşın HSTS ve Content Security Policy eksikliği, özellikle SSL stripping ve XSS saldırılarına karşı savunma yüzeyini genişletmektedir; bu eksiklik, güvenli görünen bir sistemin pratikte hâlâ kırılgan kalabileceğini gösterir. Daha kritik olan ise KVKK/GDPR aydınlatma metninin eksikliğidir; çünkü teknik güvenlik önlemleri güçlü olsa bile, hukuki şeffaflık ve açık rıza altyapısı tamamlanmadan sistemin Türkiye ve AB’de gerçek klinik kullanıma

açılması mümkün değildir. Çalışmanın en önemli artısı, güvenliği mimari düzeyde ele almasıdır.

Eksikliklerin açık biçimde raporlanması, çalışmanın metodolojik dürüstlüğünü güçlendirmektedir. Özellikle HSTS, CSP ve KVKK/GDPR dokümantasyon eksikliklerinin kritik risk düzeyinde değerlendirilmesi, sistemin klinik kullanıma tam hazır olmadığını göstermektedir. Literatürde de benzer biçimde, yüksek algoritmik performans bildiren birçok sağlık yapay zekâ sistemi; güvenlik, yönetim ve düzenleyici uyum eksikleri nedeniyle gerçek dünyaya geçememektedir (Jiang ve ark., 2017; Sendak ve ark., 2020; Topol, 2019). Bu açıdan çalışmanızın farkı, sistemi olduğundan daha olgun göstermeye çalışmak yerine sınırlılıklarını açıkça ortaya koymasıdır; bu tutum, son yıllarda önerilen trustworthy AI yaklaşımıyla da uyumludur.

Bu durum aslında translasyonel yapay zekâ çalışmalarında sık gözlenen bir sorunu yansıtmaktadır: algoritmik doğruluk ile regülasyon uyumluluğu arasındaki boşluk. Literatür, klinik yapay zekânın başarısının yalnızca AUC, duyarlılık veya özgüllük gibi metriklerle ölçülemeyeceğini; veri yönetimi, siber güvenlik, açıklanabilirlik ve kurum içi iş akışı uyumunun da en az performans kadar belirleyici olduğunu göstermektedir (Jiang ve ark., 2017; Sittig ve Singh, 2015; Rajpurkar ve ark., 2022). Bu nedenle çalışmanızın burada yaptığı en doğru hamle, teknik olarak güçlü görünen bir sistemin hukuki ve operasyonel hazır bulunuşluk açısından eksik kalabileceğini açıkça söylemesidir. Eksik taraf ise bu tartışmanın klinik yaygınlaştırma yol haritası ile daha net bağlanmamasıdır; yani “hazır değil” demek yerine hangi adımların tamamlanması gerektiğini de kısa biçimde belirtmektedir.

HİP mobil uygulamasının güvenlik yaklaşımı daha olgun bir yapı sergilemektedir. AES-256 şifreleme, JWT kimlik doğrulama ve KVKK/GDPR uyumunun belirtilmiş olması, mobil platformun klinik veri üretimi açısından daha ileri düzeyde yapılandırıldığını düşündürmektedir. Bu yönüyle mobil bileşen, web platformundaki eksiklere kıyasla daha kontrollü bir güvenlik tasarımı sunar; ancak literatürde mobil sağlık uygulamalarının da yalnızca şifreleme ile değil, oturum yönetimi, anahtar saklama, cihaz güvenliği ve yaşam döngüsü güncellemeleriyle değerlendirilmesi gerektiği vurgulanmaktadır (Rieke ve ark., 2020; Greenhalgh ve ark., 2017). Bu

nedenle mobil bileşen güçlü görünse de, onun da gerçek saha koşullarında dayanıklılığı ayrıca doğrulanmalıdır.

Bu durum web platformundaki eksiklerle birlikte değerlendirildiğinde, sistemin farklı bileşenlerinin farklı olgunluk seviyelerinde bulunduğunu göstermektedir. Bu heterojen yapı aslında büyük ölçekli dijital sağlık ekosistemlerinin doğal bir özelliğidir; çünkü klinik sistemler çoğu zaman eş zamanlı gelişmekte ve tüm bileşenler aynı teknik olgunluğa aynı anda ulaşamamaktadır. Literatürde de dijital sağlık dönüşümünün çoğu kez modüler ve aşamalı ilerlediği, bu nedenle bileşenler arasında farklı olgunluk seviyelerinin normal kabul edildiği belirtilmektedir (Friedman ve ark., 2010; Sittig ve Singh, 2015). Çalışmanın burada güçlü tarafı, bu heterojenliği bir kusur gibi saklamaması; zayıf tarafı ise bileşenler arası olgunluk farklarının hangi entegrasyon planıyla kapanacağını henüz net sunulmamasıdır.

Klinik karar destek sistemlerinin gerçek hayattaki en büyük sınavı, iş akışı ile ne kadar uyumlu olduklarıdır. Meme kanseri multidisipliner bir yaklaşım gerektirdiğinden, bir hastaya ait klinik, patolojik, biyokimyasal ve radyolojik parametrelerin sayısı oldukça yüksektir. BCRIS web ve masaüstü uygulamalarında 64 değişkenin altı tematik sekme altında mantıksal olarak gruplandırılması, doğrudan bilişsel yük teorisine dayanan bir arayüz stratejisi olarak değerlendirilebilir. Bilişsel yük kuramı, öğrenme sırasında işleyen belleğin sınırlı kapasitesinin dikkatle yönetilmesi gerektiğini vurgular; bu nedenle bilgilerin tematik olarak gruplanması ve görsel arayüzün sade tutulması, kullanıcı üzerindeki konu dışı yükü azaltarak daha etkili bir etkileşim sağlayabilir (Sweller, 1988; Sweller, 2019). Literatür, tek ekranda çok sayıda veri alanı barındıran karmaşık klinik sistemlerin kullanıcıda zihinsel yükü artırdığını, veri girişinde hata oranını yükselttiğini ve uzun vadede sistem terkine yol açabildiğini göstermektedir (Karaağaç, 2019). Bu açıdan BCRIS'in sekme temelli yapısı, yalnızca estetik bir tasarım tercihi değil, kullanıcı dikkatini bölmeden veri akışını yapılandırmayı amaçlayan bilinçli bir kullanım kolaylığı stratejisidir. Bununla birlikte, bazı sekmelerde değişken yoğunluğunun hâlâ yüksek olması, bilişsel yükü tamamen ortadan kaldırmasa da daha yönetilebilir bir düzeye indirdiğini düşündürmektedir.

Pilot kullanılabilirlik testlerinde kullanıcıların büyük bir kısmının ikinci kullanımdan itibaren sistemi rahatlıkla deneyimleyebilmesi, arayüzün taksonomik doğruluğunu ve

klirik iş akışına olan yatkınlığını desteklemektedir. Bu sonuç, literatürde sık vurgulanan “ilk temas bariyeri”nin aşıldığını ve sistemin öğrenilebilirlik düzeyinin kabul edilebilir olduğunu göstermesi bakımından önemlidir. Ancak kullanılabilirliğin yalnızca kısa süreli denemelerle değil, yoğun iş yükü altında uzun dönem kullanımla da test edilmesi gerektiği unutulmamalıdır. Bu nedenle çalışmanın güçlü yanı, arayüzü iş akışına göre düzenlemiş olmasıdır; sınırlılığı ise bu düzenin henüz prospektif ve gerçek dünya kullanım verileriyle tam olarak doğrulanmamış olmasıdır.

Kullanıcı istatistiklerinde öne çıkan en çarpıcı bulgulardan biri, hekimlerin ve sağlık profesyonellerinin yarısından fazlasının (%61,5) manuel veri girişi yerine Excel dosyası yükleme özelliğini tercih etmesidir. Bu tercih, klinik pratikte toplu veri işleme rutinlerinin baskın olduğunu ve tek tek form doldurmanın zaman, dikkat ve iş yükü açısından sürdürülebilir bulunmadığını göstermektedir. Klinik karar destek sistemleri literatürü, veri giriş sürecinin mümkün olduğunca klinik akışa gömülü, kısa ve tekrar edilebilir biçimde tasarlanmadığında benimsenme oranının düştüğünü; özellikle manuel girişin kullanıcı yorgunluğunu ve terk oranını artırabildiğini ortaya koymaktadır. Bu açıdan Excel yükleme seçeneğinin daha çok tercih edilmesi, sistemin kullanıcı davranışıyla kısmen uyumlu olduğunu gösteren önemli bir bulgudur; ancak aynı zamanda, klinik kullanıcıların ayrıntılı arayüz etkileşiminden kaçınma eğilimini de yansıtmaktadır. Dolayısıyla bu sonuç, arayüzün avantajı olduğu kadar, gelecekte veri girişinin daha da otomatikleştirilmesi gerektiğine işaret eden bir geri bildirim olarak da okunmalıdır.

Manuel girişte %42,3, Excel yüklemede ise %19,2 olarak saptanan ilk kullanıcı hata oranları, yüksek boyutlu veri girişine dayalı makine öğrenmesi modellerinin üretim ortamındaki en kırılgan yönünü açık biçimde ortaya koymaktadır. Literatürde “garbage in, garbage out” ilkesi, yalnızca teknik bir uyarı değil, klinik karar desteğinde hasta güvenliği açısından doğrudan bir kalite sorunu olarak ele alınmaktadır (Greenes, 2014; Shortliffe & Sepúlveda, 2018). Bu çerçevede Excel yükleme seçeneğinin hata oranını azaltması, yapılandırılmış toplu veri girişinin manuel işleme göre daha güvenli olabileceğini düşündürmektedir; buna karşın %19,2’lik hata oranı da toplu yüklemenin tek başına yeterli olmadığını, dosya standardizasyonu, alan eşleştirme doğrulaması ve ön-işleme kontrollerinin zorunlu olduğunu göstermektedir. Çalışmanın bu bulguyu

açık biçimde raporlaması metodolojik olarak güçlüdür; çünkü birçok benzer çalışmada kullanıcı hataları ya hiç ölçülmez ya da yalnızca yüzeysel olarak geçilir. Buradaki eksik yön ise, hata tiplerinin ayrıntılandırılmamış olmasıdır; yani hangi alanlarda, hangi veri türlerinde ve hangi kullanıcı profillerinde hatanın yoğunlaştığı daha net ortaya konulursa, arayüz iyileştirmeleri daha hedefli yapılabilir.

Bu bulgu, literatürde elektronik sağlık kayıtlarıyla ilişkili kullanım hatalarının önemli bir kısmının kullanıcı arayüzü ve veri giriş tasarımından kaynaklandığını bildiren çalışmalarla paralellik göstermektedir (Ratwani ve ark., 2018). Bu nedenle, gelecekteki sürümlerde otomatik Hastane Bilgi Yönetim Sistemi (HBYS) entegrasyonlarının ve Doğal Dil İşleme tabanlı epikriz okuma modüllerinin sisteme dahil edilmesi yalnızca bir iyileştirme önerisi değil, klinik uygulanabilirlik açısından yapısal bir gereklilik olarak değerlendirilmelidir. Özellikle çok değişkenli onkolojik değerlendirmelerde veri giriş sürecinin uzaması, sistemin gerçek iş akışına uyumunu zedeleyebilir; web uygulamasında ortalama 8,5 dakika, pCR hesaplayıcısında ise 2,5 dakika süren manuel veri girişi, beş dakikayı aşan giriş sürelerinin sistem terkinde artırabildiğini bildiren literatürle uyumludur (Belyaev, 2018). Buradaki fark, pCR aracının web sürümüne kıyasla daha kısa sürede tamamlanabilmesi olsa da, her iki platformda da manuel girdinin hâlâ insan emeğine fazla bağımlı kalmasıdır. Bu yönüyle çalışma, veri toplamanın otomasyonla desteklenmediği durumlarda karar destek sistemlerinin hız avantajını tam olarak koruyamayacağını göstermektedir.

Öte yandan kullanıcı memnuniyetinin yüksek olmasına rağmen Likert ölçeğinde 4,5–4,6 puanla değerlendirilen sistemlerin ilk kullanımda belirgin teknik destek gerektirmesi (%92,3), klinik yapay zekâ sistemlerinde öğrenilebilirlik probleminin hâlâ sürdüğünü düşündürmektedir. Sağlık profesyonellerinin dijital okuryazarlık düzeylerinin heterojen olması, aynı platformun hekim, teknisyen ve sekreter gibi farklı kullanıcı grupları tarafından kullanılmasını daha zor bir tasarım problemi haline getirmektedir. Literatürde klinik karar destek sistemlerinin çoğu hekim merkezli değerlendirildiği için, veri girişinde aktif rol alan diğer kullanıcı profillerinin deneyimi sıklıkla arka planda kalmaktadır (Shortliffe & Sepúlveda, 2018; Kushniruk ve ark., 2005). Bu açıdan çalışmadaki çoklu kullanıcı profili değerlendirmesi önemli bir güçlü yön oluşturmaktadır; çünkü sistemin yalnızca teknik doğruluğunu değil, farklı

kullanıcılar için öğrenilebilirliğini de görünür kılmaktadır. İkinci kullanım sonrası rahat kullanım oranının web için %76, pCR aracı için %89 olması, sistemin öğrenme eğrisi açısından kabul edilebilir bir düzeye ulaştığını düşündürmektedir. Ancak eksik taraf, bu öğrenme eğrisinin zaman içinde kalıcılığının ve yoğun klinik iş yükü altında sürüp sürmediğinin henüz gösterilmemiş olmasıdır.

Çalışmanın dikkat çekici yönlerinden biri, algoritmik doğruluk kadar açıklanabilirlik ve izlenebilirliğe de önem verilmiş olmasıdır. Özellikle pCR modelinde beta katsayılarının, eşik değerlerinin ve referans kategorilerinin şeffaf biçimde sunulması, “black-box AI” eleştirilerine karşı önemli bir metodolojik avantaj sağlamaktadır. Literatürde klinik yapay zekâ sistemlerinin benimsenmesinin önündeki en büyük engellerden birinin, modelin karar üretme mantığının klinisyen tarafından yeterince anlaşılmaması olduğu vurgulanmaktadır (Rudin, 2019). Bu açıdan mevcut çalışmanın farkı, yalnızca yüksek performans bildiren bir model sunmakla yetinmemesi; modelin nasıl çalıştığını da yeniden üretilebilir ve denetlenebilir biçimde ortaya koymasındır. Özellikle Avrupa Birliği Yapay Zekâ Yasası’nın yüksek riskli sistemlere yönelik şeffaflık, açıklanabilirlik ve insan gözetimi ilkelerini öne çıkarması, bu yaklaşımın yalnızca metodolojik değil, aynı zamanda düzenleyici açıdan da yerinde olduğunu göstermektedir. Bununla birlikte, açıklanabilirlik sunulmuş olsa da, bunun klinisyenler tarafından ne ölçüde gerçekten anlaşıldığı ve karar değişikliğine yol açıp açmadığı henüz prospektif olarak gösterilmemiştir.

Güven meselesi yalnızca siber güvenlikten ibaret değildir. Klinik kullanıcılar bir sistemi benimserken, çıktının nasıl üretildiğine, hangi değişkenlere dayandığına ve hata durumunda ne tür riskler doğurabileceğine de bakarlar. Bu nedenle açıklanabilirlik, klinik karar destek sistemlerinde giderek daha merkezi bir rol kazanmaktadır. Modelin belirli bir riski neden önerdiği kabaca anlaşılabiliriyorsa, sistemin klinik mantıkla uyumu güçlenir ve kullanıcı güveni artar. Özellikle RCB ve pCR gibi çok değişkenli karar problemlerinde, modelin yalnızca bir tahmin üretmesi değil, bu tahmini destekleyen değişken ilişkilerini görünür kılması önemlidir (Ghassemi ve ark., 2019). Bu çalışmada arayüz sadeleştirilmesi, sekme yapısı, doğrulama mekanizmaları, Excel entegrasyonu ve çoklu dil desteği gibi unsurlar yalnızca teknik ayrıntılar değil, klinik kabul edilebilirliği etkileyen yapısal bileşenler

olarak konumlanmıştır. Ancak eksik yön, açıklanabilirliğin kullanıcı davranışı ve karar kalitesi üzerindeki etkisinin ölçülmemiş olmasıdır; yani sistem şeffaf olsa da, bu şeffaflığın klinik yarara dönüşümü henüz kanıtlanmamıştır.

Meme kanseri yönetiminde cerrah, tıbbi onkolog, radyolog ve patolog arasındaki koordinasyon, doğru tedavi stratejisinin belirlenmesi için kritik önemdedir (Symmans ve ark., 2007). HİP (Hekim İletişim Platformu) mobil uygulamasının sunduğu dağıtık veri toplama altyapısı, bu multidisipliner gereksinime doğrudan yanıt veren bir tasarım yaklaşımıdır. Farklı uzmanlık alanlarındaki hekimlerin, hastanın kimlik bilgilerinden arındırılmış 20 karakterli alfanumerik bir benzersiz kod üzerinden yalnızca kendi alanlarına ait verileri girmesi ve bu verilerin sunucu tarafında birleştirilmesi, sağlık bilişiminde veri mahremiyeti ile klinik iş birliğini aynı anda gözetken yenilikçi bir yönetim modeli sunmaktadır. Literatürde çok merkezli ve çok disiplinli onkoloji çalışmalarında en sık karşılaşılan sorunlardan biri, veri standardizasyonunun sağlanamaması ve merkezi veri girişinde oluşan operasyonel tıkanıklıklardır (Shortliffe & Sepúlveda, 2018; Friedman ve ark., 2010). Bu açıdan HİP'in katkısı, veriyi tek merkezde toplamak yerine kaynağında yapılandırıp ortak bir kimlik kodu üzerinden senkronize etmesidir; eksik yönü ise bu yapının tam anlamıyla otomatik entegrasyon yerine hâlâ kısmen manuel doğrulamaya dayanmasıdır.

Bu bulgu aynı zamanda sağlık hizmetlerinin giderek daha dağıtık veri yapıları üzerinden yürütüldüğünü göstermektedir. Geleneksel elektronik kayıt sistemleri çoğunlukla tek merkezli ve statik veri organizasyonuna dayanırken, modern yapay zekâ sistemleri dinamik ve çok kaynaklı veri akışına ihtiyaç duymaktadır. Mevcut çalışmadaki veri birleştirme mimarisi, federated ve collaborative veri toplama yaklaşımlarına kavramsal olarak yakın bir yapı sunmaktadır; ancak tam federated learning altyapısı kurulmadığı için bu benzerlik kavramsal düzeydedir, operasyonel düzeye henüz taşınmamıştır. Yine de veri paylaşımı yerine yapılandırılmış veri senkronizasyonunun tercih edilmesi, gelecekteki dağıtık öğrenme sistemleri için güçlü bir temel oluşturmaktadır. Sistem yöneticisi tarafından gerçekleştirilen 1-3 iş günlük manuel hekim doğrulama süreci ilk bakışta operasyonel bir yavaşlık gibi görünse de, sisteme yalnızca yetkili ve gerçek uzmanların veri girişi yapmasını sağlayarak veri havuzunun klinik güvenilirliğini koruyan bir kalite güvence mekanizması işlevi

görmektedir. HİP uygulamasından dışa aktarılan Excel dosyalarının BCRIS platformları ile %100 uyumlu olması ise, ekosistemin modüler yapısının ve platformlar arası veri akış mimarisinin başarılı biçimde kurgulandığını göstermektedir. Bununla birlikte, bu uyumun farklı merkezler, farklı kullanıcı alışkanlıkları ve farklı veri hacimleri altında ne kadar sürdürülebilir olduğu ilerleyen aşamalarda ayrıca test edilmelidir.

Elde edilen başarılı arayüz ve performans çıktılarına karşın, sistem mimarisi açısından önemli sınırlılıklar bulunmaktadır. Öncelikle, geliştirilen bileşenlerin prototip düzeyinde kalması ve gerçek klinik ortamda prospektif validasyonun henüz yapılmamış olması, bulguların dış geçerliliğini sınırlandırmaktadır. Kullanıcı testlerinin pilot düzeyde gerçekleştirilmiş olması, uzun dönem kullanım davranışları, sistem kararlılığı ve klinik sonuçlara etkiler hakkında henüz yeterli kanıt sunmamaktadır. İkinci olarak, HBYS entegrasyonunun bulunmaması, sistemin rutin klinik iş akışına tam olarak gömülmesini engelleyen temel bir kısıtlılıktır. Üçüncü olarak, web platformunda HSTS, CSP ve KVKK/GDPR dokümantasyonuna ilişkin eksiklikler, teknik olarak güçlü görünen yapının yasal kullanım açısından henüz olgunlaşmadığını göstermektedir. Dördüncü olarak, tek merkezli test ortamı, sistemin farklı kurumsal yapılarda nasıl performans göstereceğine ilişkin genellenabilirliği sınırlamaktadır. Beşinci olarak, manuel veri girişinde %42,3'e ulaşan kullanıcı hata oranı, özellikle yüksek boyutlu klinik veri akışlarında sistem güvenilirliği açısından önemli bir risk oluşturmaktadır.

Gelecek araştırmalarda öncelik verilmesi gereken başlıca alanlar arasında çok merkezli ve prospektif klinik validasyon çalışmalarının yürütülmesi yer almaktadır. Bunun yanında, HBYS ve elektronik sağlık kayıt sistemleriyle HL7 FHIR standardı üzerinden entegrasyonun geliştirilmesi, sistemin klinik iş akışına daha doğal biçimde yerleşmesini sağlayacaktır. Doğal Dil İşleme tabanlı modüllerle epikriz, patoloji ve radyoloji raporlarından otomatik veri çıkarımı yapılması, manuel girişe bağlı hata yükünü azaltabilecek stratejik bir adımdır. Web platformunda HSTS, CSP ve KVKK/GDPR uyumluluğunun tamamlanması, sistemin güvenlik ve regülasyon boyutunu güçlendirecektir. Kullanıcı hata oranlarını azaltmak için akıllı form doğrulama, otomatik tamamlama ve gerçek zamanlı uyarı mekanizmalarının

eklenmesi de önemlidir. Ayrıca federated learning altyapısı ile çok merkezli model güncelleme mekanizmalarının kurulması, veri paylaşımı yerine model paylaşımına dayalı daha sürdürülebilir bir yapı oluşturabilir. Mobil platform için iOS desteğinin eklenmesi ve gerekirse React Native veya Flutter gibi çapraz platform çerçevelerin değerlendirilmesi, erişilebilirliği artırabilir. Açıklanabilir yapay zekâ bileşenlerinin SHAP ve LIME gibi yöntemlerle sisteme entegrasyonu, klinisyen güvenini ve karar şeffaflığını destekleyecektir. Son olarak, klinik etki çalışmaları ile sistemin tedavi kararları, hasta sonuçları ve maliyet-etkinlik üzerindeki etkisinin değerlendirilmesi ile FDA ve CE-IVD gibi düzenleyici onay süreçlerine yönelik dokümantasyonun başlatılması, çalışmanın translasyonel değerini bir üst aşamaya taşıyacaktır.

Sonuç olarak, bu çalışma neoadjuvan kemoterapi sonrası patolojik tam yanıt ve rezidüel kanser yükü öngörü modellerinin klinik karar destek sistemlerine entegrasyonunu çok platformlu bir dijital ekosistem üzerinden gerçekleştiren bütüncül bir mühendislik yaklaşımı sunmaktadır. pCR Hesaplayıcı, BCRIS Web, BCRIS Masaüstü ve HİP Mobil Uygulaması, teorik modeller ile klinik pratik arasındaki translasyonel boşluğu kapatmayı hedefleyen tamamlayıcı bileşenler olarak yapılandırılmıştır. İstemci tabanlı hesaplama mimarisiyle veri mahremiyeti ve güvenlik alanında sağlanan avantajlar, çok platformlu yapının farklı klinik senaryolara uyum kapasitesi ve çok merkezli veri yönetişimi açısından sunduğu esneklik, çalışmanın temel güçlü yönlerini oluşturmaktadır. Kullanıcı testlerinden elde edilen bulgular, sistemin kabul edilebilir bir öğrenme eğrisi sunduğunu ve kullanıcı memnuniyetinin yüksek olduğunu göstermektedir. Bununla birlikte, yüksek kullanıcı hata oranları, kritik güvenlik eksiklikleri, HBYS entegrasyonunun bulunmaması ve prospektif klinik validasyonun yapılmamış olması, sistemin klinik kullanıma tam anlamıyla hazır olmadığını ortaya koymaktadır. Gelecekte çok merkezli validasyon, entegrasyon, otomatik veri çıkarımı, güvenlik uyumu ve federated learning altyapısının geliştirilmesi, bu sistemlerin translasyonel etkisini belirgin biçimde artıracaktır. Bu çalışma, yapay zekâ modellerinin klinik uygulamaya aktarılmasında yalnızca algoritmik performansın değil; kullanıcı deneyimi, veri güvenliği, iş akışı uyumu ve düzenleyici uyumluluğun da eşit derecede belirleyici olduğunu göstermektedir.

5.6. Sağlık Ekonomisi ve Maliyet-Etkinlik Analizi Perspektifi

Bu çalışmada geliştirilen çok değişkenli Model ALL'ın, yalnızca radyolojik verilere dayalı Model R'ye kıyasla daha yüksek duyarlılık göstermesi, multimodal veri entegrasyonunun klinik yanıtı daha iyi temsil edebildiğini düşündürmektedir. Bu fark, özellikle yanlış negatif olguların azaltılması açısından önemlidir; çünkü pCR varlığının gözden kaçırılması, gereksiz tedavi maruziyetine ve buna bağlı toksisite yüküne yol açabilir. Klinik karar destek sistemlerinde duyarlılığın yalnızca istatistiksel bir üstünlük değil, doğrudan tedavi yoğunluğu ve hasta yükü üzerinde belirleyici bir parametre olduğu bu bulgu ile bir kez daha ortaya çıkmaktadır.

Model ALL'ın radyoloji tabanlı modele göre daha fazla gerçek pCR olgusunu doğru tanımlaması, yanlış negatiflerin klinik yükünü azaltma potansiyeli açısından anlamlıdır. Ancak çalışmanın daha dikkat çekici yönü, bu performans artışının yalnızca tanısal doğruluk düzeyinde kalmaması, sağlık ekonomisi açısından da ölçülebilir bir karşılık üretmesidir. Gereksiz adjuvan kemoterapinin azaltılması, toksisiteye bağlı yaşam kalitesi kaybını düşürürken aynı zamanda kaynak kullanımını da optimize etmektedir. Bu durum, meme kanseri bakımında “daha yoğun tedavi” yerine “doğru hastaya doğru tedavi” yaklaşımının giderek merkezileştiğini göstermektedir (Cortazar ve ark., 2014; Spring ve ark., 2020). Dolayısıyla modelin klinik değeri, yalnızca sınıflandırma başarısından değil, yanlış tedavi maruziyetini azaltma kapasitesinden kaynaklanmaktadır.

Hata örüntüsü analizi, çalışmanın klinik güvenlik açısından önemli bir katkısını ortaya koymaktadır. Her iki modelin de yüksek rezidüel hastalık yükünü ifade eden RCB-3 sınıfında görece düşük performans göstermesi, daha önce de belirtildiği üzere; bu grubun biyolojik çeşitliliği ve örneklem içindeki sınırlı temsili ile ilişkili olabilir. Buna karşın yanlış sınıflandırmaların ağırlıklı olarak RCB-2 yönüne kayması, modelin yüksek riskli hastaları pCR kategorisine yanlış atama eğiliminde olmadığını göstermektedir. Bu durum, klinik açıdan daha güvenli bir hata yapısına işaret eder; çünkü pCR lehine yanlış pozitif kararlar, yetersiz tedavi riskini artırırken, mevcut hata örüntüsü daha çok rezidüel hastalık spektrumu içinde kalmaktadır. Yapay zekâ destekli onkolojik kararlarda hata tipinin yönü, toplam hata oranı kadar önemlidir; konservatif hata eğilimleri bazı klinik senaryolarda daha kabul edilebilir olabilir.

Bununla birlikte RCB-3 sınıfı gibi, az temsil edilen sınıflarda model başarımının düşmesi, makine öğrenmesi literatüründe iyi bilinen bir durumdur. RCB-3 grubunun hem sayısal olarak daha az temsil edilmesi hem de biyolojik heterojenliğinin yüksek olması, modelin bu sınıfı ayırt etmesini zorlaştırmış olabilir. Bu nedenle gelecekte daha dengeli veri kümeleri, cost-sensitive learning, focal loss ya da sentetik örnek üretimi gibi yöntemlerle bu grubun temsil gücü artırılmalıdır. Ayrıca moleküler imzalar ve ek biyobelirteçlerin modele dahil edilmesi, RCB grupları arasındaki ayrımı güçlendirebilir (Johnson & Khoshgoftaar, 2019).

Sağlık ekonomisi boyutu, bu çalışmanın literatürdeki benzer modellerden ayrıştığı en güçlü alanlardan biridir. Yapay zekâ çalışmalarının çoğu algoritmik başarıya odaklanırken, bu başarının maliyet-etkinlik karşılığı sıklıkla ihmal edilmektedir. Oysa gerçek klinik uygulamada bir modelin değeri, yalnızca doğruluk metriğiyle değil; kaynak kullanımı, iş gücü yükü, toksisite azalması ve hasta çıktıları üzerindeki etkisiyle birlikte değerlendirilmelidir (Topol, 2019; Drummond ve ark., 2015). Model ALL'in operasyonel maliyet artışına rağmen yanlış negatif sayısını azaltarak net maliyet avantajı üretmesi, bu açıdan önemli bir bulgudur. Özellikle 506.667 TL/QALY düzeyindeki ICER değerinin Türkiye için kabul edilebilir eşiklerin altında kalması, modelin yalnızca klinik değil, ekonomik olarak da uygulanabilir olduğunu düşündürmektedir.

Bununla birlikte maliyet-etkinlik sonuçlarının popülasyon bağımlı olduğu açıkça görülmektedir. PCR prevalansının değiştiği senaryolarda modelin ekonomik performansının da değişmesi, yapay zekâ sistemlerinin tek tip merkezler yerine lokal hasta profillerine göre uyarlanması gerektiğini göstermektedir. Özellikle triple-negatif ve HER2-pozitif alt tiplerde pCR oranlarının daha yüksek, luminal alt tiplerde ise daha düşük olması, modelin farklı merkezlerde farklı ekonomik değer üretebileceğini düşündürmektedir (von Minckwitz ve ark., 2012). Bu nedenle sağlık teknolojisi değerlendirmelerinde yalnızca ortalama performans değil, popülasyon-spesifik sağlamlık da dikkate alınmalıdır.

Hibrit strateji, çalışmanın gerçek dünya uygulanabilirliği açısından dikkat çekici bir orta yol sunmaktadır. Radyoloji tabanlı Model R ile ön tarama yapıp yalnızca belirsiz olgularda Model ALL'a geçilmesi, hem operasyonel yükü azaltmakta hem de maliyet-etkinlik çerçevesini korumaktadır. Bu yaklaşım, klinik triaj mantığıyla uyumlu olduğu

için özellikle kaynak kısıtlı merkezlerde daha uygulanabilir görünmektedir. Ayrıca tüm hastalarda yüksek maliyetli multimodal analiz yerine risk tabanlı seçici kullanım, teknolojinin yaygınlaşmasını kolaylaştırabilir. Bu açıdan hibrit yaklaşım, tam entegre modelin performans avantajı ile daha sade iş akışının pratikliğini bir araya getiren dengeli bir strateji olarak okunmalıdır.

Çalışmanın ulusal bütçe etkisi boyutu da önemlidir. Bir teknolojinin bireysel düzeyde maliyet-etkin olması, sistem düzeyinde sürdürülebilir olduğu anlamına gelmez. Yüksek hacimli meme kanseri popülasyonlarında küçük birim maliyet farkları bile toplam bütçe üzerinde anlamlı etki yaratabilir. Bu nedenle bütçe etkisi analizleri, ICER hesaplarının doğal tamamlayıcısıdır (Neumann ve ark., 2018). Model ALL'ın daha yüksek QALY kazancı sağlamasına karşın daha yüksek başlangıç maliyeti üretmesi, kademeli yaygınlaştırma veya hedeflenmiş kullanım stratejilerinin daha rasyonel olabileceğini düşündürmektedir. Özellikle altyapı ve insan kaynağı farklılıklarının belirgin olduğu sağlık sistemlerinde, teknoloji benimsenmesinin merkez bazlı değil, kapasite bazlı planlanması daha doğru olabilir.

Bununla birlikte çalışmanın bazı sınırlılıkları da vardır. Ekonomik analizlerin gerçek yaşam verileri yerine simülasyon tabanlı yürütülmüş olması, dış geçerliliği sınırlamaktadır. Ayrıca dolaylı maliyetler, üretkenlik kaybı, uzun dönem toksisite ve hasta perspektifli ekonomik çıktılar değerlendirilmemiştir. Modellerin yalnızca statik zaman noktasına dayalı çalışması da önemli bir kısıttır; çünkü tedavi yanıtı dinamik bir süreçtir ve longitudinal veri kullanımı performansı artırabilir. Güncel literatür, zaman-serisi temelli modellerin tedavi yanıt tahmininde daha güçlü sonuçlar verebildiğini göstermektedir (Ataman & Sarıyer, 2022). Bu nedenle gelecekte seri biyobelirteçler, ardışık görüntüleme bulguları ve uzun dönem sağkalım verileri modele dahil edilmelidir.

Sonuç olarak bu bölüm, yapay zekâ tabanlı pCR öngörü modellerinin yalnızca tanısal doğruluk açısından değil, sağlık ekonomisi, toksisite yükü, yaşam kalitesi ve sistem sürdürülebilirliği açısından da değerlendirilmesi gerektiğini göstermektedir. Multimodal veri entegrasyonu, daha yüksek klinik fayda ve daha düşük yanlış negatif oranı sağlamış; buna karşın sınıf dengesizliği, RCB-3 sınıfındaki düşük performans ve tek merkezli veri yapısı önemli sınırlılıklar olarak kalmıştır. Buna rağmen Model ALL'ın maliyet-etkin profili ve hibrit stratejinin operasyonel avantajı, bu tür yapay

zekâ sistemlerinin orta gelirli sađlık sistemlerinde uygulanabilir bir çerçeve sunabileceđini düşündürmektedir. Bu nedenle gelecek çalışmaların, yalnızca algoritmik doğruluđu deđil; merkezler arası genellenebilirlik, uzun dönem klinik sonuçlar ve gerçek dünya bütçe etkisini de içeren daha kapsamlı deđerlendirmelere yönelmesi gerektiđi düşünölmektedir.

Sonuç ve Öneriler

Bu çalışma, meme kanserinde neoadjuvan kemoterapi yanıtını öngörmek için biyoinformatik, istatistiksel analiz ve makine öğrenmesini birleştiren çok katmanlı bir metodolojik çerçeve sunmuştur. 328 hastadan derlenen 78 kategorik değişkenin (14 PET Değişkeni dahil) sistematik analiziyle, RCB skorunun sadece patolojik biyobelirteçlerle değil, demografik, metabolik ve radyolojik parametrelerle de karmaşık bir ilişki ağı içinde olduğu kanıtlanmıştır. Çalışmanın en çarpıcı bulgusu, triple-negatif ve HER2-pozitif alt tiplerin pCR'ye yatkınlığının yanı sıra, beklenmedik şekilde hipertansiyon, diyabet ve tiroid hastalıklarının tedavi yanıtıyla anlamlı ilişkiler göstermesidir—bu durum, kanser tedavisinde sistemik metabolik durumun göz ardı edilemez rolünü vurgulamaktadır.

Özgün önem skrolama sistemi, literatürde standart bir yöntem olarak bulunmayan ancak bu çalışmada 78 değişkenin objektif sıralamasını sağlayan metodolojik bir yeniliktir. İkili lojistik regresyondan elde edilen odds ratio, p-değeri ve güven aralığı genişliği gibi parametrelerin entegrasyonu ile oluşturulan bu sistem, gelecek araştırmalar için tekrarlanabilir bir referans çerçeve sunmaktadır. Çoklu lojistik regresyon modeli, test setinde AUC=0.782 ile klinik olarak kabul edilebilir bir ayırt edicilik göstermiş; ancak asıl atılım, makine öğrenmesi algoritmalarıyla gerçekleşmiştir. LightGBM modeli, SMOTE ile dengelenmiş veri setinde AUC=0.891'e ulaşarak, karmaşık non-lineer ilişkileri yakalama kapasitesini ortaya koymuştur. SHAP değerleri, "kara kutu" algısını kırarak her değişkenin model kararına katkısını şeffaf hale getirmiş ve klinik yorumlanabilirliği güçlendirmiştir.

PET/CT verilerinin entegrasyonu, çalışmanın en yenilikçi boyutlarından birini oluşturmuştur. 198 hastalık alt kohortta, SUVmax, MTV ve TLG gibi metabolik parametrelerin RCB tahminine anlamlı katkı sağladığı gösterilmiştir. Ancak permütasyon önemliliği analizi, bazı tekstür özelliklerinin model performansına zararlı olabileceğini ortaya koymuş ve "daha fazla veri her zaman daha iyi sonuç verir" varsayımını sorgulatmıştır. Özellik seçimi senaryolarıyla optimize edilen Model ALL+PET, yalnızca klinik değişkenler içeren modele kıyasla istatistiksel olarak anlamlı üstünlük göstermiş ve moleküler görüntülemenin prognostik değerini kanıtlamıştır.

Çalışmanın belki de en etkileyici çıktısı, geliştirilen tahmin modellerinin aktif klinik karar destek sistemlerine dönüştürülmesidir. BCRIS web platformu (beris.site), Django framework'u ile inşa edilmiş, çok dilli (Türkçe/İngilizce) arayüzü ve gerçek zamanlı tahmin kapasitesiyle hekimlere hasta başında kullanılabilir bir araç sunmaktadır. Offline çalışabilen BCRIS masaüstü uygulaması, internet bağlantısı olmayan ortamlarda bile RCB ve pCR tahminlerini mümkün kılmaktadır. HİP Android uygulaması ise branş bazlı veri toplama sistemiyle, çok merkezli araştırmaların önündeki en büyük engellerden biri olan veri standardizasyonu sorununa çözüm getirmiştir. Bu üç platform, akademik araştırmanın "çevirsel tıp"a dönüşümünün somut bir örneğidir.

6.1. Klinik Pratiğe Yönelik Öneriler

- NAK öncesi RCB tahmin modellerinin tedavi planlamasında rutin olarak değerlendirilmesi, düşük pCR olasılığı olan hastalarda alternatif tedavi stratejilerinin erken dönemde gözden geçirilmesine olanak sağlayabilmektedir.
- PET/CT'nin yalnızca evreleme amacıyla değil, tedavi yanıtını öngörmek için de sistematik olarak kullanılması, klinik karar süreçlerine önemli katkılar sunabilmektedir.
- Hipertansiyon, diyabet ve tiroid hastalıklarının optimal kontrolünün, kanser tedavisi sürecinde daha fazla önem kazanması ve bu komorbiditelerle tedavi yanıtı arasındaki ilişkilerin daha detaylı araştırılması faydalı olabilmektedir.

6.2. Araştırma ve Geliştirmeye Yönelik Öneriler

- Çok merkezli, prospektif validasyon çalışmalarının başlatılması, geliştirilen modellerin genelleştirilebilirliğini test etmek açısından kritik öneme sahip olabilmektedir.
- Genomik verilerin (gen ekspresyon profilleri, mutasyon panelleri) klinik verilerle entegrasyonu, tedavi yanıtının moleküler imzasını ortaya çıkarmada yeni perspektifler kazandırabilmektedir.
- Yapay zeka modellerinin gerçek zamanlı klinik karar destek sistemlerine entegrasyonunun, randomize kontrollü çalışmalarla test edilmesi, bu teknolojilerin klinik etkinliğini kanıtlamak için gerekli görünmektedir.

- HİP Android uygulamasının ulusal düzeyde bir veri toplama altyapısına dönüştürülmesi ve farklı kurumlardan veri akışının standardize edilmesi, çok merkezli araştırmaların kalitesini artırabilmektedir

6.3. Metodolojik Öneriler

- Özgün önem skorlama sisteminin, diğer kanser türlerinde ve farklı tedavi modalitelerinde test edilerek genelleştirilebilirliğinin değerlendirilmesi, metodolojik katkısını güçlendirebilmektedir.
- SHAP değerlerinin klinik kılavuzlara entegre edilmesi yoluyla model yorumlanabilirliğinin standart hale getirilmesi, yapay zeka tabanlı sistemlerin klinik kabul edilebilirliğini artırabilmektedir.
- Permütasyon önemliliği temelli özellik seçiminin, makine öğrenmesi çalışmalarında rutin bir adım olarak benimsenmesi, model performansını optimize etmede etkili bir yaklaşım olarak değerlendirilebilmektedir.

Son Söz

“Data are profoundly dumb. Data can tell you that the people who took a medicine recovered faster than those who did not take it, but they can't tell you why.”

(Judea Pearl)

Bu çalışma, Pearl'ün uyarısına somut bir örnek teşkil etmektedir: Veri tek başına anlamsız olabilir, ancak doğru sorularla sorgulandığında, istatistiksel yöntemlerle derinleştirildiğinde ve yapay zeka ile yorumlandığında, her bir sayı bir hastanın iyileşme hikâyesine dönüşür. 78 değişken, 5 metodolojik bölüm, 3 aktif platform ve 328 hastanın hikâyesi, "neden" sorusuna yanıt aramanın somut göstergeleridir. Gelecek, verinin anlamsızlıktan çıkıp içgörüye dönüştüğü, yapay zekanın hekimin yerini değil kararlarını güçlendirdiği ve her hastanın kendi tedavi haritasına sahip olduğu bir çağa işaret etmektedir. Bu tez, o çağın mimarlarına bir tuğla sunmaktadır.

Kaynaklar

- Acosta, J. N., Falcone, G. J., Rajpurkar, P., & Topol, E. J. (2022). Multimodal biomedical AI. *Nature Medicine*, 28(9), 1773–1784. <https://doi.org/10.1038/s41591-022-01981-2>
- Akpınar, E. E., Haliloğlu, A. H., Öztürk, E., & Gülhan, M. (2012). False positivity and false negativity on positron emission tomography in a patient with lung cancer. *Türk Toraks Dergisi*, 13(3), 174–177. <https://doi.org/10.5152/ttd.2012.36>
- Al-Hakim, M., Moran, M. S., Abraham, J., Abramson, V., Aft, R., Agnese, D., Allison, K. H., Anderson, B., Burstein, H. J., Chew, H., Dang, C., Elias, A. D., Giordano, S. H., Goetz, M. P., Goldstein, L. J., Hurvitz, S. A., Jankowitz, R. C., Javid, S. H., Krishnamurthy, J.,... Kumar, R. (2021). NCCN Guidelines : Breast Cancer Screening and Diagnosis. *Journal of the National Comprehensive Cancer Network*, 21(1), 1–30. <https://doi.org/10.6004/jnccn.2021.0001>
- Alabdulkareem, H., Pinchinat, T., Khan, S., Landers, A., Christos, P., Simmons, R., & Moo, T.-A. (2018). The impact of molecular subtype on breast cancer recurrence in young women treated with contemporary adjuvant therapy. *The Breast Journal*, 24(2), 148–153. <https://doi.org/10.1111/tbj.12853>
- Almadani, B., Kaiser, H., Thoker, I. R., & Aliyu, F. (2025). A systematic survey of distributed decision support systems in healthcare. *Systems*, 13(3), 157. <https://doi.org/10.3390/systems13030157>
- Altmann, A., Toloşi, L., Sander, O., & Lengauer, T. (2010). Permutation importance: A corrected feature importance measure. *Bioinformatics*, 26(10), 1340–1347. <https://doi.org/10.1093/bioinformatics/btq134>
- American College of Radiology. (2014). ACR BI-RADS® atlas: Breast imaging reporting and data system (5th ed.) (C. J. D'Orsi, E. A. Sickles, E. B. Mendelson, & E. A. Morris, Eds.). American College of Radiology.

Amin, M. B., Edge, S. B., Greene, F. L., Byrd, D. R., Brookland, R. K., Washington, M. K., Gershenwald, J. E., Compton, C. C., Hess, K. R., Sullivan, D. C., Jessup, J. M., Brierley, J. D., Gaspar, L. E., Schilsky, R. L., Balch, C. M., Winchester, D. P., & Asare, E. A. (Eds.). (2017). *AJCC cancer staging manual* (8th ed.). Springer.

Amin, M. B., Greene, F. L., Edge, S. B., Compton, C. C., Gershenwald, J. E., Brookland, R. K., Meyer, L., Gress, D. M., Byrd, D. R., & Winchester, D. P. (2017). The Eighth Edition AJCC cancer staging manual: Continuing to build a bridge from a population-based to a more "personalized" approach to cancer staging. *CA: A Cancer Journal for Clinicians*, 67(2), 93–99. <https://doi.org/10.3322/caac.21388>

An, Y. Y., Kim, S. H., & Kang, B. J. (2017). Residual microcalcifications after neoadjuvant chemotherapy for locally advanced breast cancer: Comparison of the accuracies of mammography and MRI in predicting pathological residual tumor. *World Journal of Surgical Oncology*, 15(1), 198. <https://doi.org/10.1186/s12957-017-1263-8>

Antoniou, A., Pharoah, P. D. P., Narod, S., Risch, H. A., Eyfjord, J. E., Hopper, J. L., Loman, N., Olsson, H., Johannsson, O., Borg, A., Pasini, B., Radice, P., Manoukian, S., Eccles, D. M., Tang, N., Olah, E., Anton-Culver, H., Warner, E., Lubinski, J., Gronwald, J., Gorski, B., Tulinius, T., Thorlacius, S., Eerola, H., Nevanlinna, H., Syrjäkoski, K., Kallioniemi, O.-P., Thompson, D., Evans, C., Peto, J., Lalloo, F., Evans, D. G., & Easton, D. F. (2003). Average risks of breast and ovarian cancer associated with BRCA1 or BRCA2 mutations detected in case series unselected for family history: A combined analysis of 22 studies. *American Journal of Human Genetics*, 72(5), 1117–1130. <https://doi.org/10.1086/375033>

Araz, M., Soydal, Ç., Gündüz, P., Kırmızı, A., Bakırarar, B., Dizbay Sak, S., & Özkan, E. (2022). Can radiomics analyses in 18F-FDG PET/CT images of primary breast carcinoma predict hormone receptor status? *Molecular Imaging and Radionuclide Therapy*, 31(1), 49–56. <https://doi.org/10.4274/mirt.galenos.2022.59140>

Armitage, J. O., Gascoyne, R. D., Lunning, M. A., & Cavalli, F. (2017). Non-Hodgkin lymphoma. *The Lancet*, 390(10091), 298–310.)32407-2.
[https://doi.org/10.1016/s0140-6736\(16\)32407-2](https://doi.org/10.1016/s0140-6736(16)32407-2)

Arpino, G., Bardou, V. J., Clark, G. M., & Elledge, R. M. (2004). Infiltrating lobular carcinoma of the breast: Tumor characteristics and clinical outcome. *Breast Cancer Research*, 6(3), R149–R156. <https://doi.org/10.1186/bcr767>

Artzy-Randrup, Y., Epstein, T., Brown, J. S., Costa, R. L. B., Czerniecki, B. J., & Gatenby, R. A. (2021). Novel evolutionary dynamics of small populations in breast cancer adjuvant and neoadjuvant therapy. *npj Breast Cancer*, 7, 26.
<https://doi.org/10.1038/s41523-021-00230-y>

Ataman, M. G., & Sariyer, G. (2022). Mode of arrival aware models for forecasting flow of patient and length of stay in emergency departments. *Eurasian Journal of Emergency Medicine*, 21(1), 34–44.
<https://doi.org/10.4274/eajem.galenos.2021.27676>

Avanzo, M., Wei, L., Stancanella, J., Vallières, M., Rao, A., Morin, O., Mattonen, S. A., & El Naqa, I. (2020). Machine and deep learning methods for radiomics. *Medical Physics*, 47(5), e185–e202. <https://doi.org/10.1002/mp.13678>

Bates, D. W., Saria, S., Ohno-Machado, L., Shah, A., & Escobar, G. (2021). Reporting and implementing interventions involving machine learning and artificial intelligence. *Annals of Internal Medicine*, 174(2), 195–201.
<https://doi.org/10.7326/m19-0872>

Batista, G. E. A. P. A., Prati, R. C., & Monard, M. C. (2004). A study of the behavior of several methods for balancing machine learning training data. *ACM SIGKDD Explorations Newsletter*, 6(1), 20–29. <https://doi.org/10.1145/1007730.1007735>

Baumann, L. A., Baker, J., & Elshaug, A. G. (2018). The impact of electronic health record systems on clinical documentation times: A systematic review. *Health Policy*, 122(8), 827–836. <https://doi.org/10.1016/j.healthpol.2018.05.014>

Beadle, B. M., Woodward, W. A., & Buchholz, T. A. (2011). The impact of age on outcome in early-stage breast cancer. *Seminars in Radiation Oncology*, 21(1), 26–34. <https://doi.org/10.1016/j.semradonc.2010.09.001>

Beam, A. L., & Kohane, I. S. (2018). Big data and machine learning in health care. *JAMA*, 319(13), 1317–1318. <https://doi.org/10.1001/jama.2017.18391>

Belyaev K., Sun W., Ray I. and Ray I. (2018) On the Design and Analysis of Protocols for Personal Health Record Storage on Personal Data Server Devices. *Future Generation Computer Systems* 80: 467-482. <https://doi.org/10.1016/j.future.2016.05.027>

Ben Rabah, C., Sattar, A., Ibrahim, A., & Serag, A. (2025). A multimodal deep learning model for the classification of breast cancer subtypes. *Diagnostics*, 15(8), 995. <https://doi.org/10.3390/diagnostics15080995>

Benjamini, Y., & Hochberg, Y. (1995). Controlling the false discovery rate: A practical and powerful approach to multiple testing. *Journal of the Royal Statistical Society: Series B (Methodological)*, 57(1), 289–300. <https://doi.org/10.1111/j.2517-6161.1995.tb02031.x>

Bishop, C. M. (2006). *Pattern recognition and machine learning*. Springer.

Bitencourt, A. G. V., Gibbs, P., Rossi Saccarelli, C., Daimiel, I., Lo Gullo, R., Fox, M. J.,... & Pinker, K. (2021). MRI-based machine learning radiomics can predict HER2 expression level and pathologic response after neoadjuvant therapy in HER2-positive breast cancer. *European Radiology*, 31(10), 7660–7670. <https://doi.org/10.1007/s00330-021-07749-1>

Blagus, R., & Lusa, L. (2013). SMOTE for high-dimensional class-imbalanced data. *BMC Bioinformatics*, 14, 106. <https://doi.org/10.1186/1471-2105-14-106>

Boellaard, R. (2009). Standards for PET image acquisition and quantitative data analysis. *Journal of Nuclear Medicine*, 50(Suppl 1), 11S–20S. <https://doi.org/10.2967/jnumed.108.057182>

Boice, J. D., Jr., Preston, D. L., Mattsson, A., Holmberg, E., Shore, R., Hildreth, N. G., & Mattsson, A. (2002). Radiation effects on breast cancer risk: A pooled analysis of eight cohorts. *Radiation Research*, 158(2), 220–235. [https://doi.org/10.1667/0033-7587\(2002\)158\[0220:reobcr\]2.0.co;2](https://doi.org/10.1667/0033-7587(2002)158[0220:reobcr]2.0.co;2)

Boxwala, A. A., Dierks, M., Keenan, M., Jackson, S., Hanscom, R., Bates, D. W., & Sato, L. (2004). Organization and representation of patient safety data: Current status and issues around generalizability and scalability. *Journal of the American Medical Informatics Association*, 11(6), 468–478. <https://doi.org/10.1197/jamia.M1317>

Bradshaw, T. J., Huemann, Z., Hu, J., & Rahmim, A. (2023). A guide to cross-validation for artificial intelligence in medical imaging. *Radiology: Artificial Intelligence*, 5(4), e220232. <https://doi.org/10.1148/ryai.220232>

Braman, N. M., Etesami, M., Prasanna, P., Dubchuk, C., Gilmore, H., Tiwari, P., Plecha, D., & Madabhushi, A. (2017). Intratumoral and peritumoral radiomics for the pretreatment prediction of pathological complete response to neoadjuvant chemotherapy based on breast DCE-MRI. *Breast Cancer Research*, 19(1), 57. <https://doi.org/10.1186/s13058-017-0846-1>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Buck, A., Schirrmeister, H., Kühn, T., Shen, C., Kalker, T., Kotzerke, J., Dankerl, A., Glatting, G., Reske, S., & Mattfeldt, T. (2002). FDG uptake in breast cancer: Correlation with biological and clinical prognostic parameters. *European Journal of Nuclear Medicine and Molecular Imaging*, 29(10), 1317–1323. <https://doi.org/10.1007/s00259-002-0880-8>

Bufi, E., Belli, P., Di Matteo, M., Terribile, D., Franceschini, G., Nardone, L., Petrone, G., & Bonomo, L. (2014). Effect of breast cancer phenotype on diagnostic performance of MRI in the prediction to response to neoadjuvant treatment. *European Radiology*, 24(9), 1631–1638. <https://doi.org/10.1016/j.ejrad.2014.05.002>

Burstein, H. J., Curigliano, G., Loibl, S., Dubsy, P., Gnant, M., Poortmans, P., Colleoni, M., Denkert, C., Piccart-Gebhart, M., Regan, M., Senn, H.-J., Winer, E. P., Thürlimann, B., & Members of the St. Gallen International Consensus Panel on the Primary Therapy of Early Breast Cancer 2019. (2019). Estimating the benefits of therapy for early-stage breast cancer: The St. Gallen International Consensus Guidelines for the primary therapy of early breast cancer 2019. *Annals of Oncology*, 30(10), 1541–1557. <https://doi.org/10.1093/annonc/mdz235>

Burstein, H. J., Curigliano, G., Thürlimann, B., Weber, W. P., Poortmans, P., Regan, M. M., Senn, H. J., Winer, E. P., Gnant, M., & Panelists of the St Gallen Consensus Conference. (2021). Customizing local and systemic therapies for women with early breast cancer: The St. Gallen International Consensus Guidelines for treatment of early breast cancer 2021. *Annals of Oncology*, 32(10), 1216–1235. <https://doi.org/10.1016/j.annonc.2021.06.023>

Cabitza, F., Rasoini, R., & Gensini, G. F. (2017). Unintended consequences of machine learning in medicine. *JAMA*, 318(6), 517–518. <https://doi.org/10.1001/jama.2017.7797>

Carey, L. A., Dees, E. C., Sawyer, L., Gatti, L., Moore, D. T., Collichio, F., Ollila, D. W., Sartor, C. I., Graham, M. L., & Perou, C. M. (2007). The triple negative paradox: Primary tumor chemosensitivity of breast cancer subtypes. *Clinical Cancer Research*, 13(8), 2329–2334. <https://doi.org/10.1158/1078-0432.CCR-06-1109>

Castaneda, C. A., Flores, R., Rojas, K., Flores, C., Castillo, M., & Milla, E. (2014). Association between mammographic features and response to neoadjuvant

chemotherapy in locally advanced breast carcinoma. *Hematology/Oncology and Stem Cell Therapy*, 7(4), 149–156. <https://doi.org/10.1016/j.hemonc.2014.09.001>

Cattell, R. (2011). Scalable SQL and NoSQL data stores. *ACM SIGMOD Record*, 39(4), 12–27. <https://doi.org/10.1145/1978915.1978919>

Char, D. S., Shah, N. H., & Magnus, D. (2018). Implementing machine learning in health care — addressing ethical challenges. *New England Journal of Medicine*, 378(11), 981–983. <https://doi.org/10.1056/NEJMp1714229>

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>

Chen, M., Mao, S., & Liu, Y. (2014). Big data: A survey. *Mobile Networks and Applications*, 19(2), 171–209.

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. <https://doi.org/10.1145/2939672.2939785>

Christodoulou, E., Ma, J., Collins, G. S., Steyerberg, E. W., Verbakel, J. Y., & Van Calster, B. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110, 12–22. <https://doi.org/10.1016/j.jclinepi.2019.02.004>

Colditz, G. A., & Bohlke, K. (2014). Priorities for the primary prevention of breast cancer. *CA: A Cancer Journal for Clinicians*, 64(3), 186–194. <https://doi.org/10.3322/caac.21225>

Colleoni, M., Bagnardi, V., Rotmensz, N., Dellapasqua, S., Viale, G., Pruneri, G.,... & Goldhirsch, A. (2008). Increasing steroid hormone receptors expression defines breast cancer subtypes with different prognosis and chemotherapy response. *Breast Cancer Research and Treatment*, 124(3), 793–802. <https://doi.org/10.1007/s10549-008-0223-y>

Colleoni, M., Viale, G., Goldhirsch, A., Pruner, G., Veronesi, P., Torrisi, R., Cardillo, A., Montagna, E., Luini, A., Intra, M., Galimberti, V., Bottiglieri, L., Mastropasqua, M. G., Rocca, A., Ghisini, R., Curigliano, G., Bagnardi, V., & Gianni, L. (2010). Chemotherapy is more effective in patients with breast cancer not expressing steroid hormone receptors: A study of preoperative treatment. *Clinical Cancer Research*, 16(4), 1234–1241. <https://doi.org/10.1158/1078-0432.CCR-04-0380>

Collins, G. S., Moons, K. G. M., Dhiman, P., Riley, R. D., Beam, A. L., Van Calster, B., Ghassemi, M., Liu, X., Reitsma, J. B., van Smeden, M., Boulesteix, A.-L., Camaradou, J. C., Celi, L. A., Denaxas, S., Denniston, A. K., Glocker, B., Golub, R. M., Harvey, H., Heinze, G.,... Logullo, P. (2024). TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, 385, e078378. <https://doi.org/10.1136/bmj-2023-078378>

Collins, G. S., Reitsma, J. B., Altman, D. G., & Moons, K. G. M. (2015). Transparent reporting of a multivariable prediction model for individual prognosis or diagnosis (TRIPOD): The TRIPOD statement. *Annals of Internal Medicine*, 162(1), 55–63. <https://doi.org/10.7326/M14-0697>

Coombes, R. C., Page, K., Salari, R., Hastings, R. K., Armstrong, A., Ahmed, S., Ali, S., Cleator, S., Kenny, L., Stebbing, J., Rutherford, M., Sethi, H., Boydell, A., Swenerton, R., Fernandez-Garcia, D., Gleason, K. L. T., Goddard, K., Guttery, D. S., Assaf, Z. J.,... & Shaw, J. A. (2019). Personalized detection of circulating tumor DNA antedates breast cancer metastatic recurrence. *Clinical Cancer Research*, 25(14), 4255–4263. <https://doi.org/10.1158/1078-0432.CCR-18-3663>

Cortazar, P., Zhang, L., Untch, M., Mehta, K., Costantino, J. P., Wolmark, N., Bonnefoi, H., Cameron, D., Gianni, L., Valagussa, P., Swain, S. M., Prowell, T., Loibl, S., Wickerham, D. L., Bogaerts, J., Baselga, J., Perou, C., Blumenthal, G., Blohmer, J., Mamounas, E. P., Bergh, J., Semiglazov, V., Justice, R., Eidtmann, H., Paik, S., Piccart, M., Sridhara, R., Fasching, P. A., Slaets, L., Tang, S., Gerber, B.,

Geyer, C. E., Jr., Pazdur, R., Ditsch, N., Rastogi, P., Eiermann, W., & von Minckwitz, G. (2014). Pathological complete response and long-term clinical benefit in breast cancer: The CTNeoBC pooled analysis. *The Lancet*, 384(9938), 164–172. [https://doi.org/10.1016/S0140-6736\(13\)62422-8](https://doi.org/10.1016/S0140-6736(13)62422-8)

Cristofanilli, M., Gonzalez-Angulo, A., Sneige, N., Kau, S.-W., Broglio, K., Theriault, R. L., Valero, V., Buzdar, A. U., Kuerer, H., Buchholz, T. A., & Hortobagyi, G. N. (2005). Invasive lobular carcinoma classic type: Response to primary chemotherapy and survival outcomes. *Journal of Clinical Oncology*, 23(1), 41–48. <https://doi.org/10.1200/JCO.2005.03.111>

Curigliano, G., Burstein, H. J., Gnant, M., Loibl, S., Cameron, D., Regan, M. M., Denkert, C., Poortmans, P., Weber, W. P., Thürlimann, B., & St Gallen Consensus Conference Panelists 2023. (2023). Understanding breast cancer complexity to improve patient outcomes: The St Gallen International Consensus Conference for the Primary Therapy of Individuals with Early Breast Cancer 2023. *Annals of Oncology*, 34(11), 970–986. <https://doi.org/10.1016/j.annonc.2022.11.001>

Davis, S. E., Lasko, T. A., Chen, G., & Matheny, M. E. (2018). Calibration drift among regression and machine learning models for hospital mortality. *AMIA Annual Symposium Proceedings*, 2017, 625–634.

de Azambuja, E., Cardoso, F., de Castro, G., Jr., Colozza, M., Mano, M. S., Durbecq, V., Sotiriou, C., Larsimont, D., Piccart-Gebhart, M., & Paesmans, M. (2007). Ki-67 as prognostic marker in early breast cancer: A meta-analysis of published studies involving 12 155 patients. *British Journal of Cancer*, 96(10), 1504–1513. <https://doi.org/10.1038/sj.bjc.6603756>

de Groot, S., Janssen, L. G. M., Charehbili, A., Dijkgraaf, E. M., Smit, V. T. H. B. M., Kessels, L. W., van Bochove, A., van Laarhoven, H. W. M., Meershoek-Klein Kranenbarg, E., van Leeuwen-Stok, A. E., van de Velde, C. J. H., Putter, H., Nortier, J. W. R., van der Hoeven, J. J. M., Pijl, H., & Kroep, J. R. (2015). Thyroid function alters during neoadjuvant chemotherapy in breast cancer patients: Results from the

NEOZOTAC trial (BOOG 2010-01). *Breast Cancer Research and Treatment*, 149(2), 461–466. <https://doi.org/10.1007/s10549-014-3256-4>

Denduluri, N., Somerfield, M. R., Chavez-MacGregor, M., Comander, A. H., Dayao, Z., Eisen, A., Freedman, R. A., Giordano, S. H., Harbeck, N., Hobday, T. J., Hsu, G., Kravitz, S. N., Mittendorf, M. E., Morales, L., Morrison, W. H., Peugnikoff, K. A., Rhee, S. M., Schettin, P. J., Seidner, A., & Liu, S. (2021). Selection of Optimal Adjuvant Chemotherapy and Targeted Therapy for Early Breast Cancer: ASCO Guideline Update. *Journal of Clinical Oncology*, 39(6), 685–693. <https://doi.org/10.1200/JCO.20.02510>

Denkert, C., von Minckwitz, G., Darb-Esfahani, S., Lederer, B., Heppner, B. I., Weber, K. E., Budczies, J., Huober, J., Klauschen, F., Furlanetto, J., Schmitt, W. D., Blohmer, J.-U., Karn, T., Pfitzner, B. M., Kümmel, S., Engels, K., Schneeweiss, A., Hartmann, A., Noske, A., Fasching, P. A., Jackisch, C., van Mackelenbergh, M., Sinn, P., Schem, C., Hanusch, C., Untch, M., & Loibl, S. (2018). Tumour-infiltrating lymphocytes and prognosis in different subtypes of breast cancer: A pooled analysis of 3771 patients treated with neoadjuvant therapy. *The Lancet Oncology*, 19(1), 40–50. [https://doi.org/10.1016/S1470-2045\(17\)30904-X](https://doi.org/10.1016/S1470-2045(17)30904-X)

Dent, R., Trudeau, M., Pritchard, K. I., Hunt, T. M., Hanna, W., Levine, M. N., Chow-Bian, C., & Rawlinson, E. (2007). Triple-negative breast cancer: Clinical features and patterns of recurrence. *Clinical Cancer Research*, 13(15), 4429–4434. <https://doi.org/10.1158/1078-0432.ccr-06-3045>

DeVita, V. T., Jr., Lawrence, T. S., & Rosenberg, S. A. (Eds.). (2022). *DeVita, Hellman, and Rosenberg's cancer: Principles & practice of oncology* (12th ed.). Wolters Kluwer.

DeVita, V. T., Lawrence, T. S., & Rosenberg, S. A. (Eds.). (2019). *DeVita, Hellman, and Rosenberg's cancer: Principles & practice of oncology* (11th ed.). Wolters Kluwer.

Dieci, M. V., Orvieto, E., Dominici, M., Conte, P., & Guarneri, V. (2014). Rare breast cancer subtypes: Histological, molecular, and clinical peculiarities. *The Oncologist*, 19(8), 805–813. <https://doi.org/10.1634/theoncologist.2014-0108>

Django Software Foundation. (2024). Django documentation. Retrieved from <https://www.djangoproject.com/>

Django Software Foundation. (2025). Django security documentation. <https://docs.djangoproject.com/en/stable/topics/security/>

Doshi-Velez, F., & Kim, B. (2017). Towards a rigorous science of interpretable machine learning. arXiv preprint. <https://doi.org/10.48550/arXiv.1702.08608>

Drummond, M. F., Sculpher, M. J., Claxton, K., Stoddart, G. L., & Torrance, G. W. (2015). *Methods for the economic evaluation of health care programmes* (4th ed.). Oxford University Press.

Duffy, M. J., Evoy, D., & McDermott, E. W. (2010). CA 15-3: Uses and limitation as a biomarker for breast cancer. *Clinical Biochemistry*, 43(15), 1417–1423. <https://doi.org/10.1016/j.cca.2010.08.039>

Dursun, B., Yaşar, H. A., Soydal, Ç., & Demirkazık, A. (2024). Lokal ileri meme kanserinde neoadjuvan tedavi sonrası metabolik yanıt ile patolojik tam yanıt ilişkisi [S-098 sunum özeti]. *Türk Tıbbi Onkoloji Kongresi (TTOD 2024)*. Türk Tıbbi Onkoloji Derneği.

Early Breast Cancer Trialists' Collaborative Group. (2005). Effects of chemotherapy and hormonal therapy for early breast cancer on recurrence and 15-year survival: An overview of the randomised trials. *The Lancet*, 365(9472), 1687–1717. [https://doi.org/10.1016/S0140-6736\(05\)66544-0](https://doi.org/10.1016/S0140-6736(05)66544-0)

Ecem Memiřođlu, & Ramazan Sarı. (2022). Meme kanserinde neoadjuvan kemoterapi yanıtını deđerlendirmede PET'nin etkinliđi ve patolojik yanıtı etkileyen faktörler. *Southern Clinics of Istanbul Eurasia*, 33(2), 162–167.

Elkan, C. (2001). The foundations of cost-sensitive learning. In *Proceedings of the Seventeenth International Joint Conference on Artificial Intelligence* (pp. 973–978). <https://doi.org/10.5555/1642194.1642224>

Elreedy, D., & Atiya, A. F. (2019). A comprehensive analysis of Synthetic Minority Oversampling Technique (SMOTE) for handling class imbalance. *Information Sciences*, 505, 32–64. <https://doi.org/10.1016/j.ins.2019.07.070>

Elston, C. W., & Ellis, I. O. (1991). Pathological prognostic factors in breast cancer. I. The value of histological grade in breast cancer: Experience from a large study with long-term follow-up. *Histopathology*, 19(5), 403–410. <https://doi.org/10.1111/j.1365-2559.1991.tb00229.x>

Epizitone, A., Moyane, S. P., & Agbehadji, I. E. (2023). A systematic literature review of health information systems for healthcare. *Healthcare*, 11(7), 959. <https://doi.org/10.3390/healthcare11070959>

Eskiler, G. G., Deveci Özkan, A., Bilir, C., & Kaleli, S. (2019). Zoledronik asidin meme kanseri alt tiplerinde terapötik etkisinin deđerlendirilmesi. *Sakarya Medical Journal*, 9(1), 1–11. <https://doi.org/10.31832/smj.511954>

Esteva, A., Chou, K., Yeung, S., Naik, N. V., Madani, A., Mottaghi, A., Liu, Y., Topol, E. J., Dean, J., & Socher, R. (2021). Deep learning-enabled medical computer vision. *NPJ Digital Medicine*, 4, Article 5. <https://doi.org/10.1038/s41746-020-00325-9>

Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. *Nature*, 542(7639), 115–118. <https://doi.org/10.1038/nature21056>

Estourgie, S. H., Nieweg, O. E., Olmos, R. A. V., Rutgers, E. J. T., & Kroon, B. B. R. (2004). Lymphatic drainage patterns from the breast. *Annals of Surgery*, 239(2), 232–237. <https://doi.org/10.1097/01.sla.0000109156.26378.90>

Evcimik, T. (2008). Meme kanserinde prognostik faktörlerin sağkalıma etkisi [Uzmanlık tezi, İstanbul Göztepe Eğitim ve Araştırma Hastanesi, 3. Genel Cerrahi Kliniği]. İstanbul, Türkiye.

Fasching, P. A., Heusinger, K., Haeberle, L., Niklos, M., Hein, A., Bayer, C. M., Rauh, C., Schulz-Wendtland, R., Bani, M. R., Schrauder, M., Kahmann, L., Lux, M. P., Strehl, J. D., Hartmann, A., Dimmler, A., Beckmann, M. W., & Wachter, D. L. (2011). Ki67, chemotherapy response, and prognosis in breast cancer patients receiving neoadjuvant treatment. *BMC Cancer*, 11, 486. <https://doi.org/10.1186/1471-2407-11-486>

Fernández, A., Garcia, S., Herrera, F., & Chawla, N. V. (2018). SMOTE for learning from imbalanced data: Progress and challenges, marking the 15-year anniversary. *Journal of Artificial Intelligence Research*, 61, 863–905. <https://doi.org/10.1613/jair.1.11192>

Fontanella, C., Lederer, B., Gade, S., Vanoppen, M., Blohmer, J. U., Costa, S. D., Denkert, C., Eidtmann, H., Gerber, B., Hanusch, C., Hilfrich, J., Huober, J., Schneeweiss, A., Paepke, S., Jackisch, C., Mehta, K., Nekljudova, V., Untch, M., Neven, P., von Minckwitz, G., & Loibl, S. (2015). Impact of body mass index on neoadjuvant treatment outcome: A pooled analysis of eight prospective neoadjuvant breast cancer trials. *Breast Cancer Research and Treatment*, 150(1), 127–139. <https://doi.org/10.1007/s10549-015-3287-5>

Ford, D., Easton, D. F., Stratton, M., Narod, S., Goldgar, D., Devilee, P., Bishop, D. T., Weber, B., Lenoir, G., Chang-Claude, J., Sobol, H., Teare, M. D., Struwing, J., Arason, A., Scherneck, S., Peto, J., Rebbeck, T. R., Tonin, P., Neuhausen, S., Barkardottir, R., Eyfjord, J., Lynch, H., Ponder, B. A., Gayther, S. A., Zelada-Hedman, M., & The Breast Cancer Linkage Consortium. (1998). Genetic heterogeneity and penetrance analysis of the BRCA1 and BRCA2 genes in breast

cancer families. The Breast Cancer Linkage Consortium. *American Journal of Human Genetics*, 62(3), 676–689. <https://doi.org/10.1086/301749>

Friedman, C. P., Wong, A. K., & Blumenthal, D. (2010). Achieving a nationwide learning health system. *Science Translational Medicine*, 2(57), 57cm29. <https://doi.org/10.1126/scitranslmed.3001456>

Gambhir, S. S. (2002). Molecular imaging of cancer with positron emission tomography. *Nature Reviews Cancer*, 2(9), 683–693. <https://doi.org/10.1038/nrc882>

Ganganwar, V. (2012). An overview of classification algorithms for imbalanced datasets. *International Journal of Emerging Technology and Advanced Engineering*, 2(4), 42–47.

Gennari, A., André, F., Barrios, C. H., Cortés, J., de Azambuja, E., DeMichele, A., Dent, R., Fenlon, D., Gligorov, J., Hurvitz, S. A., Im, S. A., Krug, D., Kunz, W. G., Merlin, J. L., Nader-Marta, G., Namer, M., O'Regan, R., Loi, S.,... & Curigliano, G. (2021). ESMO Clinical Practice Guideline for the diagnosis, staging and treatment of patients with metastatic breast cancer. *Annals of Oncology*, 32(12), 1475–1495. <https://doi.org/10.1016/j.annonc.2021.09.019>

Ghassemi, M., Naumann, T., Schulam, P., Beam, A. L., Chen, I. Y., & Ranganath, R. (2019). Practical guidance on artificial intelligence for health-care data. *The Lancet Digital Health*, 1(4), e157–e159.

Ghezzawi, M., El Charif, M. H., Lteif, L., Panossian, V., Haddad, A., Sarkis, S., Zebian, Y., Kheil, M., & Sbaity, E. (2025). Patterns of response of breast cancer after neoadjuvant chemotherapy according to molecular subtype. *Frontiers in Oncology*, 15, 1670594. <https://doi.org/10.3389/fonc.2025.1670594>

Gholampour, S. (2024). Impact of nature of medical data on machine and deep learning for minority class classification. *Machine Learning and Knowledge Extraction*, 6(2), 658–682. <https://doi.org/10.3390/make6020039>

Gianni, L., Eiermann, W., Semiglazov, V., Manikhas, A., Lluch, A., Tjulandin, S., Zambetti, M., Vazquez, F., Byakhov, M., Lichinitser, M., Climent, M. A., Ciruelos, E., Ojeda, B., Mansutti, M., Bozhok, A., Baronio, R., Feyereislova, A., Barton, C., Valagussa, P., & Baselga, J. (2010). Neoadjuvant chemotherapy with trastuzumab followed by adjuvant trastuzumab versus neoadjuvant chemotherapy alone, in patients with HER2-positive locally advanced breast cancer (the NOAH trial): A randomised controlled superiority trial with a parallel HER2-negative cohort. *The Lancet*, 375(9712), 377–384. [https://doi.org/10.1016/S0140-6736\(09\)61964-4](https://doi.org/10.1016/S0140-6736(09)61964-4)

Gianni, L., Pienkowski, T., Im, Y.-H., Roman, L., Tseng, L.-M., Liu, M.-C., Lluch, A., Staroslawska, E., de la Haba-Rodríguez, J., Im, S.-A., Pedrini, J. L., Poirier, B., Morandi, P., Semiglazov, V., Srimuninnimit, V., Bianchi, G. V., Szado, T., Ratnayake, J., Ross, G., Valagussa, P., & Baselga, J. (2012). Efficacy and safety of neoadjuvant pertuzumab and trastuzumab in women with locally advanced, inflammatory, or early HER2-positive breast cancer (NeoSphere): A randomised multicentre, open-label, phase 2 trial. *The Lancet Oncology*, 13(1), 25–32. [https://doi.org/10.1016/S1470-2045\(11\)70336-9](https://doi.org/10.1016/S1470-2045(11)70336-9)

Gillies, R. J., Kinahan, P. E., & Hricak, H. (2016). Radiomics: Images are more than pictures, they are data. *Radiology*, 278(2), 563–577. <https://doi.org/10.1148/radiol.2015151169>

Gold, M. R., Siegel, J. E., Russell, L. B., & Weinstein, M. C. (Eds.). (1996). *Cost-effectiveness in health and medicine*. Oxford University Press.

Gradishar, W. J., Moran, M. S., Abraham, J., Abramson, V., Aft, R., Agnese, D., Allison, K. H., Anderson, B., Burstein, H. J., Chew, H., Dang, C., Elias, A. D., Giordano, S. H., Goetz, M. P., Goldstein, L. J., Hurvitz, S. A., Jankowitz, R. C., Javid, S. H., Krishnamurthy, J., Leitch, A. M., Lyons, J., Mortimer, J., Patel, S. A., Pierce, L. J., Rosenberger, L. H., Rugo, H. S., Schneider, B., Smith, M. L., Soliman, H., Stringer-Reasor, E. M., Telli, M. L., Wei, M., Wisinski, K. B., Young, J. S., Yeung, K., Dwyer, M. A., & Kumar, R. (2023). NCCN Guidelines® Insights: Breast Cancer, Version 4.2023. *Journal of the National Comprehensive Cancer Network*, 21(6), 594–608. <https://doi.org/10.6004/jnccn.2023.0031>

Greaves, M., & Maley, C. C. (2012). Clonal evolution in cancer. *Nature*, 481(7381), 306–313. <https://doi.org/10.1038/nature10762>

Greenes, R. A. (2014). *Clinical decision support: The road to widespread adoption*. Academic Press. <https://doi.org/10.1016/C2012-0-02563-0>

Greenhalgh, T., Wherton, J., Papoutsis, C., Lynch, J., Hughes, G., A'Court, C., Hinder, S., Fahy, N., Procter, R., & Shaw, S. (2017). Beyond adoption: A new framework for theorizing and evaluating nonadoption, abandonment, and challenges to the scale-up, spread, and sustainability of health and care technologies. *Journal of Medical Internet Research*, 19(11), e367. <https://doi.org/10.2196/jmir.8775>

Groheux, D., Hindie, E., Giacchetti, S., Delord, M., Hamy, A.-S., de Roquancourt, A., Vercellino, L., Berenger, N., Marty, M., & Espié, M. (2012). Triple-negative breast cancer: Early assessment with ¹⁸F-FDG PET/CT during neoadjuvant chemotherapy identifies patients who are unlikely to achieve a pathologic complete response and are at a high risk of early relapse. *Journal of Nuclear Medicine*, 53(2), 249–254. <https://doi.org/10.2967/jnumed.111.094045>

Guo, H., Li, Y., Shang, J., Gu, M., Huang, Y., & Gong, B. (2017). Learning from class-imbalanced data: Review of methods and applications. *Expert Systems with Applications*, 73, 220–239. <https://doi.org/10.1016/j.eswa.2016.12.035>

Guo, Y., Gong, X., Zhu, T., Peng, X., Xing, D., & Zhang, M. (2022). Diagnostic performance of radiomics in predicting axillary lymph node metastasis in breast cancer: A systematic review and meta-analysis. *Frontiers in Oncology*, 12, 1046005. <https://doi.org/10.3389/fonc.2022.1046005>

Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3, 1157–1182.

Gülseçen, S., & Aksaya, H. (2021). Klinik karar destek sistemleri. In N. Buzbaba & S. Gülseçen (Eds.), *Tıp bilişimi* (pp. xx–xx). İstanbul University Press.
<https://doi.org/10.26650/B/ET07.2021.003.15>

Hamadi, R., Alameddine, Z., Karam, I., Salib, C., Gill, S., Wu, Y., Salama, J., & Brown, J. (2026). Impact of diabetes and glycemic control on pathologic complete response after neoadjuvant chemotherapy in breast cancer in an Afro-Caribbean population: A retrospective cohort study. *Journal of Clinical Oncology*, 44(16_suppl), e12625. https://doi.org/10.1200/JCO.2026.44.16_suppl.e12625

Hammond, M. E., Hayes, D. F., Dowsett, M., Allred, D. C., Hagerty, K. L., Badve, S., Fitzgibbons, P. L., Francis, G., Goldstein, N. S., Hayes, M., Hicks, D. G., Lester, S., Love, R., Mangu, P. B., McShane, L., Miller, K., Osborne, C. K., Paik, S., Perlmutter, J.,... & Wolff, A. C. (2010). American Society of Clinical Oncology/College of American Pathologists guideline recommendations for immunohistochemical testing of estrogen and progesterone receptors in breast cancer. *Journal of Clinical Oncology*, 28(16), 2784–2795.
<https://doi.org/10.1200/JCO.2009.25.6529>

Hamy, A.-S., Grandal, B., Jochum, F., Dumas, É., Sella, N., Kassara, A., Barraud, S., Dubois, T., Ballesta, A., Everhard, S., Lemonnier, J., Sauzey, M., Bertaut, A., Blay, J.-Y., Cottu, P., Tredan, O., Joly, F., Gougis, P., Asselain, B., Latouche, A., Vaz Luis, I., Andre, F., & Reyat, F. (2025). Causal analyses of the impact of comorbid conditions and concomitant medications on response to neoadjuvant chemotherapy in breast cancer: Analysis of a multicenter prospective cohort study (CANTO). *ESMO Open*, 10(5), 104507. <https://doi.org/10.1016/j.esmoop.2025.104507>

Han, H. S., Vikas, P., Costa, R. L. B., Jahan, N., Taye, A., & Stringer-Reasor, E. M. (2023). Early-stage triple-negative breast cancer journey: Beginning, end, and everything in between. *ASCO Educational Book*, 43, e390464.
https://doi.org/10.1200/EDBK_390464

Han, S., & Choi, J. Y. (2020). Prognostic value of 18F-FDG PET and PET/CT for assessment of treatment response to neoadjuvant chemotherapy in breast cancer: A systematic review and meta-analysis. *Breast Cancer Research*, 22(1), 119. <https://doi.org/10.1186/s13058-020-01350-2>

Hanahan, D. (2022). Hallmarks of cancer: New dimensions. *Cancer Discovery*, 12(1), 31–46. <https://doi.org/10.1158/2159-8290.CD-21-1059>

Hanahan, D., & Weinberg, R. A. (2011). Hallmarks of cancer: The next generation. *Cell*, 144(5), 646–674. <https://doi.org/10.1016/j.cell.2011.02.013>

Harrell, F. E. (2015). *Regression modeling strategies: With applications to linear models, logistic and ordinal regression, and survival analysis* (2nd ed.). Springer.

Harris, L., Fritsche, H., Mennel, R., Norton, L., Ravdin, P., Taube, S., Somerfield, M. R., Hayes, D. F., Bast, R. C., Jr., & American Society of Clinical Oncology. (2007). American Society of Clinical Oncology 2007 update of recommendations for the use of tumor markers in breast cancer. *Journal of Clinical Oncology*, 25(33), 5287–5312. <https://doi.org/10.1200/JCO.2007.14.2364>

Hashmi, A. A., Bukhari, U., Najam, J., Dowlah, T., Ali, A. H., Diwan, M. A., Anjali, F., Sham, S., Zia, S., & Irfan, M. (2023). Luminal B, Human Epidermal Growth Factor Receptor 2 (HER2/neu), and Triple-Negative Breast Cancers Associated With a Better Chemotherapy Response Than Luminal A Breast Cancers in Postneoadjuvant Settings. *Cureus*, 15(6), e40066. <https://doi.org/10.7759/cureus.40066>

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>

- Hatt, M., Tixier, F., Visvikis, D., & Cheze Le Rest, C. (2017). Radiomics in PET/CT: More than meets the eye? *Journal of Nuclear Medicine*, 58(3), 365–366. <https://doi.org/10.2967/jnumed.116.184655>
- He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>
- Hornung, R. (2020). Ordinal forests. *Journal of Classification*, 37(1), 4–17. <https://doi.org/10.1007/s00357-018-9302-x>
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3rd ed.). John Wiley & Sons.
- Hu, Y., Chen, L., Wang, J., Zhang, H., Liu, J., & Sun, L. (2025). Predicting breast cancer response to neoadjuvant therapy by integrating traditional radiomics and 3D deep learning features from DCE-MRI. *BMC Cancer*, 25(1), 1747. <https://doi.org/10.1186/s12885-025-15095-8>
- Hu, Z., Li, Z., Ma, Z., & Curtis, C. (2020). Multi-cancer analysis of clonality and the timing of systemic spread in paired primary tumors and metastases. *Nature Genetics*, 52(7), 701–708. <https://doi.org/10.1038/s41588-020-0628-z>
- Huang, S., Yang, J., Fong, S., & Zhao, Q. (2020). Artificial intelligence in cancer diagnosis and prognosis: Opportunities and challenges. *Cancer Letters*, 471, 61–71. <https://doi.org/10.1016/j.canlet.2019.12.007>
- Husereau, D., Drummond, M., Augustovski, F., de Bekker-Grob, E. W., Briggs, A. H., Carswell, C., Caulley, L., Chaiyakunapruk, N., Greenberg, D., Loder, E., Mauskopf, J., Mullins, C. D., Petrou, S., Pwu, R.-F., & Staniszewska, S. (2022). Consolidated Health Economic Evaluation Reporting Standards (CHEERS) 2022 explanation and elaboration: A report of the ISPOR CHEERS II Good Practices Task Force. *Value in Health*, 25(1), 10–31. <https://doi.org/10.1016/j.jval.2021.10.008>

Husereau, D., Drummond, M., Petrou, S., Carswell, C., Moher, D., Greenberg, D., Augustovski, F., Briggs, A. H., Mauskopf, J., Loder, E., & CHEERS Task Force. (2013). Consolidated Health Economic Evaluation Reporting Standards (CHEERS) statement. *BMJ*, 346, f1049. <https://doi.org/10.1136/bmj.f1049>

Hylton, N. M., Blume, J. D., Bernreuter, W. K., Pisano, E. D., Rosen, M. A., Morris, E. A., Weatherall, P. T., Lehman, C. D., Newstead, G. M., Polin, S., Marques, H. S., Esserman, L. J., & Schnall, M. D. (2012). Locally advanced breast cancer: MR imaging for prediction of response to neoadjuvant chemotherapy—results from ACRIN 6657/I-SPY TRIAL. *Radiology*, 263(3), 663–672. <https://doi.org/10.1148/radiol.12110748>

Ibrahim, J. G., Chu, H., & Chen, M.-H. (2012). Missing data in clinical studies: Issues and methods. *Journal of Clinical Oncology*, 30(26), 3297–3303. <https://doi.org/10.1200/JCO.2011.38.7589>

International Agency for Research on Cancer. (2022). World cancer report 2022. <https://publications.iarc.fr/619>

International Immuno-Oncology Biomarker Working Group. (2021). The tale of TILs in breast cancer: A report from The International Immuno-Oncology Biomarker Working Group. *npj Breast Cancer*, 7(1), 150. <https://doi.org/10.1038/s41523-021-00346-1>

Jain, A. K. (2010). Data clustering: 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651–666. <https://doi.org/10.1016/j.patrec.2009.09.011>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). An introduction to statistical learning: With applications in R. Springer.

Janssen, L. M., den Dekker, B. M., Gilhuijs, K. G. A., van Diest, P. J., van der Wall, E., & Elias, S. G. (2022). MRI to assess response after neoadjuvant chemotherapy in breast cancer subtypes: A systematic review and meta-analysis. *NPJ Breast Cancer*, 8(1), 107. <https://doi.org/10.1038/s41523-022-00475-1>

Jha, A. K., Mithun, S., Sherkhane, U. B., Dwivedi, P., Puts, S., Osong, B., Traverso, A., Purandare, N., Wee, L., Rangarajan, V., & Dekker, A. (2023). Emerging role of quantitative imaging (radiomics) and artificial intelligence in precision oncology. *Exploration of Targeted Antitumor Therapy*, 4(4), 569–582.
<https://doi.org/10.37349/etat.2023.00153>

Jiang, F., Jiang, Y., Zhi, H., Dong, Y., Li, H., Ma, S., Wang, Y., Dong, Q., Shen, H., & Wang, Y. (2017). Artificial intelligence in healthcare: Past, present and future. *Stroke and Vascular Neurology*, 2(4), 230–243. <https://doi.org/10.1136/svn-2017-000101>

Johnson, J. M., & Khoshgoftaar, T. M. (2019). Survey on deep learning with class imbalance. *Journal of Big Data*, 6, 27. <https://doi.org/10.1186/s40537-019-0192-5>

Jyothi, P. N., Lakshmi, D. R., & Rao, K. V. S. N. R. (2020). A supervised approach for detection of outliers in healthcare claims data. *Journal of Engineering Science and Technology Review*, 13(3), 204–213.

Kannampallil, T. G., Abraham, J., & Patel, V. L. (2016). Methodological framework for evaluating clinical processes: A cognitive informatics perspective. *Journal of Biomedical Informatics*, 64, 342–351. <https://doi.org/10.1016/j.jbi.2016.11.002>

Kantarjian, H., & Short, N. J. (2023). Using immunotherapy and novel trial designs to optimise front-line therapy in adult acute lymphoblastic leukaemia: Breaking with the traditions of the past. *The Lancet Haematology*, 10(5), e382–e388.
[https://doi.org/10.1016/S2352-3026\(23\)00064-9](https://doi.org/10.1016/S2352-3026(23)00064-9)

Kaplan, B. (2020). Seeing through health information technology: The need for transparency in software, algorithms, data privacy, and regulation. *Journal of Law and the Biosciences*, 7(1), lsaa062. <https://doi.org/10.1093/jlb/lsaa062>

Karaağaç, M. (2019). Dijital hastane sistemlerinin hemşirelerin zihinsel iş yükü ve tıbbi hataya eğilimlerine etkisi [Yüksek lisans tezi, Gaziantep Üniversitesi, Sağlık Bilimleri Enstitüsü]. Gaziantep Üniversitesi.

Kawamoto, K., Houlihan, C. A., Balas, E. A., & Lobach, D. F., "Improving clinical practice using clinical decision support systems: A systematic review of trials to identify features critical to success",. *British Medical Journal*, 330, 765-772 (2005).

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
<https://dl.acm.org/doi/10.5555/3294996.3295074>

Kim, E. Y., Lee, K. H., Yun, J.-S., Park, Y. L., Park, C. H., Jang, S. Y., Ryu, J. M., Lee, S. K., Chae, B.-J., Lee, J. E., Kim, S. W., Nam, S. J., & Yu, J. H. (2024). Impact of residual microcalcifications on prognosis after neoadjuvant chemotherapy in breast cancer patients. *BMC Women's Health*, 24(1), 187.
<https://doi.org/10.1186/s12905-024-02973-9>

Kim, H. S., Yoo, T. K., Park, W. C., & Chae, B. J. (2019). Potential benefits of neoadjuvant chemotherapy in clinically node-positive luminal subtype breast cancer. *Journal of Breast Cancer*, 22(3), 412–424. <https://doi.org/10.4048/jbc.2019.22.e35>

Knight, J. A., Lesosky, M., Barnett, H., Raboud, J. M., & Vieth, R. (2007). Vitamin D and reduced risk of breast cancer: A population-based case-control study. *Cancer Epidemiology, Biomarkers & Prevention*, 16(3), 422–429.
<https://doi.org/10.1158/1055-9965.EPI-06-0865>

Kourou, K., Exarchos, T. P., Exarchos, K. P., Karamouzis, M. V., & Fotiadis, D. I. (2015). Machine learning applications in cancer prognosis and prediction. *Computational and Structural Biotechnology Journal*, 13, 8–17.
<https://doi.org/10.1016/j.csbj.2014.11.005>

Kris, M. G., Gaspar, L. E., Chaft, J. E., Kennedy, E. B., Azzoli, C. G., Ellis, P. M., Lin, S. H., Pass, H. I., Seth, R., Shepherd, F. A., Spigel, D. R., Strawn, J. R., Ung, Y. C., & Weyant, M. (2017). Adjuvant systemic therapy and adjuvant radiation therapy for stage I to IIIA completely resected non-small-cell lung cancers: American Society of Clinical Oncology/Cancer Care Ontario clinical practice guideline update. *Journal of Clinical Oncology*, 35(25), 2960–2974.
<https://doi.org/10.1200/JCO.2017.72.4401>

Krittanawong, C., Zhang, H., Wang, Z., Aydar, M., & Kitai, T. (2020). Artificial intelligence in precision cardiovascular medicine. *Journal of the American College of Cardiology*, 75(21), 2657–2664. <https://doi.org/10.1016/j.jacc.2020.03.517>

Kuhn, M., & Johnson, K. (2019). Feature engineering and selection: A practical approach for predictive models. CRC Press.

Lambin, P., Leijenaar, R. T. H., Deist, T. M., Peerlings, J., de Jong, E. E. C., van Timmeren, J.,... & Walsh, S. (2017). Radiomics: The bridge between medical imaging and personalized medicine. *Nature Reviews Clinical Oncology*, 14(12), 749–762. <https://doi.org/10.1038/nrclinonc.2017.141>

Langin, C. (2019). Introduction to data mining. *Scalable Computing: Practice and Experience*. https://doi.org/10.1007/978-1-4302-0248-6_11

Larson, S. M., Erdi, Y., Akhurst, T., Mazumdar, M., Macapinlac, H. A., Finn, R. D., Yeung, H. W. D., & Humm, J. L. (1999). Tumor treatment response based on visual and quantitative changes in global tumor glycolysis using PET-FDG imaging: The visual response score and the change in total lesion glycolysis. *Clinical Positron Imaging*, 2(3), 159–171. [https://doi.org/10.1016/S1095-0397\(99\)00016-3](https://doi.org/10.1016/S1095-0397(99)00016-3)

Larue, R. T. H., Defraene, G., De Ruysscher, D., Lambin, P., & van Baardwijk, A. (2017). Quantitative radiomics studies for tissue characterization: A review of technology and methodological procedures. *British Journal of Radiology*, 90(1062), 20160665. <https://doi.org/10.1259/bjr.20160665>

Launay-Vacher, V., Oudard, S., Janus, N., Gligorov, J., Pourrat, X., Rixe, O., Morere, J.-F., Beuzeboc, P., & Deray, G.; Renal Insufficiency and Cancer Medications (IRMA) Study Group. (2007). Prevalence of renal insufficiency in cancer patients and implications for anticancer drug management: The renal insufficiency and anticancer medications (IRMA) study. *Cancer*, 110(6), 1376–1384. <https://doi.org/10.1002/cncr.22904>

Lee, J. H., Kim, E. K., Kim, S. J., Park, B. W., Lee, H. J., Kim, Y. J., Kim, J. H., Kim, S. W., & Ryu, H.-S. (2020). Imaging and clinicopathologic features associated with pathologic complete response in patients with HER2-positive breast cancer receiving neoadjuvant chemotherapy and dual blockade. *Clinical Breast Cancer*, 20(1), 25–32. <https://doi.org/10.1016/j.clbc.2019.06.015>

Li, S., Li, Z., Li, S., Jiang, P., Han, H., Zhang, Y., & Lu, Y. (2025). Development and Cross-Institutional Validation of a Comprehensive Machine Learning Model Predicting Response to Neoadjuvant Therapy for Rectal Cancer. *Cancer Management and Research*, 17, 1563–1575. <https://doi.org/10.2147/CMAR.S517949>

Liedtke, C., Mazouni, C., Hess, K. R., André, F., Tordai, A., Mejia, J. A., Symmans, W. F., Gonzalez-Angulo, A. M., Hennessy, B., Green, M. C., Brown, P., & Gianni, L. (2008). Response to neoadjuvant therapy and long-term survival in patients with triple-negative breast cancer. *Journal of Clinical Oncology*, 26(8), 1275–1281. <https://doi.org/10.1200/JCO.2007.14.4147>

Lips, E. H., Mulder, L., de Ronde, J. J., Mandjes, I. A., Koolen, B. B., Wessels, L. F., Rodenhuis, S., & Wesseling, J. (2013). Neoadjuvant chemotherapy in ER+ HER2-breast cancer: Response prediction based on immunohistochemical and molecular characteristics. *Breast Cancer Research and Treatment*, 141(3), 359–368. <https://doi.org/10.1007/s10549-011-1488-0>

- Litjens, G., Kooi, T., Babenko, B., Karssemeijer, N., Hendriks, C. L., & van der Laak, J. A. (2017). A survey on deep learning in medical image analysis. *Medical Image Analysis*, 42, 60–88. <https://doi.org/10.1016/j.media.2017.07.005>
- Liu, H., Ibrahim, E. I. K., Centanni, M., Sarr, C., Venkatakrishnan, K., & Friberg, L. E. (2025). Integrated modeling of biomarkers, survival and safety in clinical oncology drug development. *Advanced Drug Delivery Reviews*, 216, 115476. <https://doi.org/10.1016/j.addr.2024.115476>
- Liu, T., Lin, J., Zhang, J., Lou, J., Zou, Q., Wang, C., ... & Jiang, Y. (2025). The clinical value of radiomics models based on multi-parameter MRI features in evaluating the different expression status of HER2 in breast cancer. *Acta Radiologica*, 66(3), 289–298. <https://doi.org/10.1177/02841851251319110>
- Liu, X., Chen, L., Wang, S., Zhang, Y., Huang, Y., Liu, S., ... & Xu, H. (2019). Radiomics of multiparametric MRI for pretreatment prediction of pathologic complete response to neoadjuvant chemotherapy in breast cancer: A multicenter study. *Clinical Cancer Research*, 25(12), 3538–3547. <https://doi.org/10.1158/1078-0432.CCR-18-3190>
- Loibl, S., Volz, C., Mau, C., Blohmer, J.-U., Costa, S. D., Eidtmann, H., Fasching, P. A., Gerber, B., Hanusch, C., Jackisch, C., Kümmel, S., Huober, J., Denkert, C., Hilfrich, J., Konecny, G. E., Fett, W., Stickeler, E., Harbeck, N., Mehta, K. M., Nekljudova, V., von Minckwitz, G., & Untch, M. (2014). Response and prognosis after neoadjuvant chemotherapy in 1,051 patients with infiltrating lobular breast carcinoma. *Breast Cancer Research and Treatment*, 144(1), 153–162. <https://doi.org/10.1007/s10549-014-2861-6>
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774. <https://doi.org/10.48550/arXiv.1705.07874>

Madam, R., & Ashok, M. (2024). AI operationalisation chasm: Evidence from Canadian public administration [Conference paper]. ECIS 2024 Proceedings.

Manyika, J., Chui, M., Brown, B., Bughin, J., Dobbs, R., Roxburgh, C., & Byers, A. H. (2011). Big data: The next frontier for innovation, competition, and productivity. McKinsey Global Institute.

Marinovich, M. L., Sardanelli, F., Ciatto, S., Mamounas, E., Brennan, M., Macaskill, P., Irwig, L., von Minckwitz, G., & Houssami, N. (2012). Early prediction of pathologic response to neoadjuvant therapy in breast cancer: Systematic review of the accuracy of MRI. *Breast*, 21(5), 669–677.
<https://doi.org/10.1016/j.breast.2012.07.006>

Marseille, E., Larson, B., Kazi, D. S., Kahn, J. G., & Rosen, S. (2015). Thresholds for the cost-effectiveness of interventions: Alternative approaches and the need for context-specific values. *The American Journal of Tropical Medicine and Hygiene*, 93(4), 846–850. <https://doi.org/10.2471/BLT.14.138206>

Masuda, N., Lee, S. J., Ohtani, S., Im, Y. H., Lee, E. S., Yokota, I., Kuroi, K., Im, S. A., Park, B. W., Kim, S. B., Yanagita, Y., Ohno, S., Takao, S., Aogi, K., Iwata, H., Jeong, J., Kim, A., Park, K. H., Sasano, H.,... Toi, M. (2017). Adjuvant capecitabine for breast cancer after preoperative chemotherapy. *The New England Journal of Medicine*, 376(22), 2147–2159. <https://doi.org/10.1056/NEJMoa1612645>

Mateo, J., Lord, C. J., Serra, V., Tutt, A., Balmaña, J., Castroviejo-Bermejo, M.,... & Kaufman, B. (2021). A decade of clinical development of PARP inhibitors in perspective. *Annals of Oncology*, 32(9), 1097–1108.
<https://doi.org/10.1016/j.annonc.2021.05.019>

Mathur, V., Purkayastha, S., & Gichoya, J. W. (2020). Artificial intelligence for global health: Learning from a decade of digital transformation in health care. ICLR 2020 Workshop on Practical ML for Developing Countries.
<https://doi.org/10.48550/arXiv.2005.12378>

Mazurowski, M. A. (2015). Radiogenomics: What it is and why it is important. *Journal of the American College of Radiology*, 12(8), 862–866.
<https://doi.org/10.1016/j.jacr.2015.04.019>

Micha, J. P., Rettenmaier, M. A., Bohart, R. D., & Goldstein, B. H. (2022). Hormone therapy and risk of breast cancer: Where are we now? *Journal of Menopausal Medicine*, 28(2), 47–51. <https://doi.org/10.6118/jmm.21035>

Mikkelsen, M. K., Lindblom, N. A. F., Dyhl-Polk, A., Juhl, C. B., Johansen, J. S., & Nielsen, D. (2022). Systematic review and meta-analysis of C-reactive protein as a biomarker in breast cancer. *Critical Reviews in Clinical Laboratory Sciences*, 59(7), 480–500. <https://doi.org/10.1080/10408363.2022.2050886>

Miras, I., Gil, A., Benavent, M., Castilla, M. A., Vieites, B., Dominguez-Cejudo, M. A., Molina-Pinelo, S., Alfaro, L., Frutos, J., Ruiz-Borrego, M., Falcón, A., Cejuela, M., & Salvador-Bofill, J. (2024). Predictive factors for complete pathologic response in luminal breast cancer: Impact of Ki67 and HER2 low expression. *Therapeutic Advances in Medical Oncology*, 16, 17588359241309169.
<https://doi.org/10.1177/17588359241309169>

Maryoosh, A. A., & Hussein, E. M. (2022). A review: Data mining techniques and its applications. *International Journal of Computer Science and Mobile Applications*, 10(3), 1–14. <https://doi.org/10.47760/ijcsma.2022.v10i03.001>

Modi, S., Jacot, W., Yamashita, T., Sohn, J., Vidal, M., Tokunaga, E., Tsurutani, J., Ueno, N. T., Prat, A., Chae, Y. S., Lee, K. S., Niikura, N., Park, Y. H., Xu, B., Tamura, K., André, F., Iwata, H., Ito, Y., Jerusalem, G.,... Krop, I. (2022). Trastuzumab deruxtecan in previously treated HER2-low advanced breast cancer. *The New England Journal of Medicine*, 387(1), 9–20.
<https://doi.org/10.1056/NEJMoa2203690>

Molinaro, A. M., Simon, R., & Pfeiffer, R. M. (2005). Prediction error estimation: A comparison of resampling methods. *Bioinformatics*, 21(15), 3301–3307.
<https://doi.org/10.1093/bioinformatics/bti499>

Moons, K. G. M., Damen, J. A. A., Kaul, T., Hooft, L., Andaur Navarro, C. L., Dhiman, P., Beam, A. L., Van Calster, B., Celi, L. A., Denaxas, S., Denniston, A. K., Ghassemi, M., Heinze, G., Kengne, A. P., Maier-Hein, L., Liu, X., Logullo, P., McCradden, M. D., Liu, N., Oakden-Rayner, L., Singh, K., Ting, D. S., Wynants, L., Yang, B., Reitsma, J. B., Riley, R. D., Collins, G. S., & van Smeden, M. (2025). PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. *BMJ*, 388, e082505. <https://doi.org/10.1136/bmj-2024-082505>

Moscoso, A., Ruibal, Á., Domínguez-Prado, I., Fernández-Ferreiro, A., Herranz, M., Albaina, L., Argibay, S., Silva-Rodríguez, J., Pardo-Montero, J., & Aguiar, P. (2018). Texture analysis of high-resolution dedicated breast 18F-FDG PET images correlates with immunohistochemical factors and subtype of breast cancer. *European Journal of Nuclear Medicine and Molecular Imaging*, 45(2), 196–206.
<https://doi.org/10.1007/s00259-017-3830-1>

National Cancer Institute. (2024). What is cancer? National Institutes of Health. Retrieved from <https://www.cancer.gov/about-cancer/understanding/what-is-cancer>

National Comprehensive Cancer Network. (2024). Breast cancer, Version 3.2024, NCCN Clinical Practice Guidelines in Oncology. *Journal of the National Comprehensive Cancer Network*, 22(5), 331–357.
<https://doi.org/10.6004/jnccn.2024.0035>

Negreanu, R. A., Verga, N., & Găinariu, E. (2026). Taxane-induced peripheral neuropathy–driven treatment modification and pathologic complete response after neoadjuvant TCHP in HER2-positive breast cancer: A retrospective cohort study. *Clinical Breast Cancer*, 26(6), 44–51. <https://doi.org/10.1016/j.clbc.2026.04.006>

Neumann, P. J., Sanders, G. D., Russell, L. B., Siegel, J. E., & Ganiats, T. G. (Eds.). (2018). *Cost-effectiveness in health and medicine* (2nd ed.). Oxford University Press.

Nioche, C., Orlhac, F., Boughdad, S., Reuzé, S., Goya-Outi, J., Robert, C., Pellot-Barakat, C., Soussan, M., Frouin, F., & Buvat, I. (2018). LIFEx: A freeware for radiomic feature calculation in multimodality imaging to accelerate advances in the characterization of tumor heterogeneity. *Cancer Research*, 78(16), 4786–4789. <https://doi.org/10.1158/0008-5472.can-18-0125>

Noma, H., Shinozaki, T., Iba, K., Teramukai, S., & Furukawa, T. A. (2021). Confidence intervals of prediction accuracy measures for multivariable prediction models based on the bootstrap-based optimism correction methods. *Statistics in Medicine*, 40(26), 5691–5701. <https://doi.org/10.1002/sim.9148>

Obermeyer, Z., & Emanuel, E. J. (2016). Predicting the future—big data, machine learning, and clinical medicine. *New England Journal of Medicine*, 375(13), 1216–1219. <https://doi.org/10.1056/nejmp1606181>

Ohno, S., Chow, L. W. C., Sato, N., Masuda, N., Yamauchi, H., Itoh, K., Yamashita, T., Hasegawa, Y., Hato, M., Shimomura, A., Saji, S., Iwata, H., Kuroi, K., Toi, M., & trial collaborators. (2013). Randomized trial of preoperative docetaxel with or without capecitabine after 4 cycles of 5-fluorouracil–epirubicin–cyclophosphamide (FEC) in early-stage breast cancer: Exploratory analyses identify Ki67 as a predictive biomarker for response to neoadjuvant chemotherapy. *Breast Cancer Research and Treatment*, 142(1), 69–80. <https://doi.org/10.1007/s10549-013-2691-y>

Open Web Application Security Project (OWASP). (2021). OWASP Top 10 - 2021: The ten most critical web application security risks. Retrieved from <https://owasp.org/www-project-top-ten/>

Osheroff, J. A., Teich, J. M., Levick, D., Saldana, L., Velasco, F. T., Sittig, D. F., Rogers, K. M., & Jenders, R. A. (2021). *Improving outcomes with clinical decision support: An implementer's guide* (3rd ed.). Healthcare Information and Management Systems Society.

OWASP Foundation. (2021). OWASP Top 10: 2021 web application security risks. <https://owasp.org/Top10/>

Partridge, A. H., Hughes, M. E., Warner, E. T., Ottesen, R. A., Wong, Y. N., Edge, S. B.,... & Winer, E. P. (2016). Subtype-dependent relationship between young age at diagnosis and breast cancer survival. *Journal of Clinical Oncology*, 34(27), 3308–3314. <https://doi.org/10.1200/JCO.2015.65.8013>

Peintinger, F., Sinn, B., Hatzis, C., Albarracin, C., Downs-Kelly, E., Morkowski, J., Gould, R., & Symmans, W. F. (2015). Reproducibility of residual cancer burden for prognostic assessment of breast cancer after neoadjuvant chemotherapy. *Modern Pathology*, 28(7), 913–920. <https://doi.org/10.1038/modpathol.2015.53>

Pektaş, F. (2016). Mamografide tek projeksiyonda görülen fokal asimetrik opasitelerin meme MRG ile değerlendirilmesi [Doktora tezi, Uludağ Üniversitesi].

Peng, J., Hong, Y., Chen, Q., Xu, F., Zhang, D., Yao, J., Zou, Q., Yuan, L., Li, L., Long, Q., Liao, L., Liu, M., Liu, X., Wang, S., & Yi, W. (2024). Comparison of neoadjuvant chemotherapy response and prognosis between HR-low/HER2-negative BC and TNBC: An exploratory real-world multicentre cohort study. *Frontiers in Endocrinology*, 15, Article 1347762. <https://doi.org/10.3389/fendo.2024.1347762>

Piato, J. R. M., Andrade, R. D. J., Chala, L. F., de Barros, N., Mano, M. S., Melitto, A. S., Goncalves, R., Soares Junior, J. M., Baracat, E. C., & Filassi, J. R. (2016). MRI to predict nipple involvement in breast cancer patients. *American Journal of Roentgenology*, 206(5). <https://doi.org/10.2214/AJR.15.15187>

Prat, A., Cheang, M. C. U., Martin, M., Parker, J. S., Carrasco, E., Caballero, R., Tyldesley, S., Gelmon, K., Bernard, P. S., Nielsen, T. O., & Perou, C. M. (2013). Prognostic significance of progesterone receptor–positive tumor cells within immunohistochemically defined luminal A breast cancer. *Journal of Clinical Oncology*, 31(2), 203–209. <https://doi.org/10.1200/JCO.2012.43.4134>

Prat, A., Fan, C., Fernández, A., Hoadley, K. A., Martinello, R., Vidal, M.,... & Perou, C. M. (2015). Response and survival of breast cancer intrinsic subtypes following multi-agent neoadjuvant chemotherapy. *BMC Medicine*, 13, 303. <https://doi.org/10.1186/s12916-015-0540-z>

Prat, A., Pineda, E., Adamo, B., Galván, P., Fernández, A., Gaba, L., Díez, M., Viladot, M., Arance, A., & Muñoz, M. (2015). Clinical implications of the intrinsic molecular subtypes of breast cancer. *The Breast*, 24(Suppl 2), S26–S35. <https://doi.org/10.1016/j.breast.2015.07.008>

Raghupathi, W., & Raghupathi, V. (2014). Big data analytics in healthcare: Promise and potential. *Health Information Science and Systems*, 2(1), 3.

Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine learning in medicine. *New England Journal of Medicine*, 380(14), 1347–1358. <https://doi.org/10.1056/nejmra1814259>

Rajpurkar, P., Chen, E., Banerjee, O., & Topol, E. J. (2022). AI in health and medicine. *Nature Medicine*, 28(1), 31–38. <https://doi.org/10.1038/s41591-021-01614-0>

Ratwani, R. M., Savage, E., Will, A., Arnold, R., Khairat, S., Miller, K., Fairbanks, R. J., Hodgkins, M., & Hettinger, A. Z. (2018). A usability and safety analysis of electronic health records: A multi-center study. *Journal of the American Medical Informatics Association*, 25(9), 1197–1201. <https://doi.org/10.1093/jamia/ocy088>

Reig, B., Lewin, A. A., Du, L., Heacock, L., Toth, H. K., Heller, S. L., Gao, Y., & Moy, L. (2021). Breast MRI for evaluation of response to neoadjuvant therapy. *RadioGraphics*, 41(3). <https://doi.org/10.1148/rg.2021200134>

Rieke, N., Hancox, J., Li, W., Milletari, F., Roth, H. R., Albarqouni, S., Bakas, S., Galtier, M. N., Landman, B. A., Maier-Hein, K., & Navab, N. (2020). The future of digital health with federated learning. *NPJ Digital Medicine*, 3, 119.

<https://doi.org/10.1038/s41746-020-00323-1>

Riley, R. D., Ensor, J., Snell, K. I. E., Harrell, F. E., Jr., Martin, G. P., Reitsma, J. B.,... & Collins, G. S. (2024). Clinical prediction models: A practical approach to development, validation, and updating (2nd ed.). *BMJ*, 385, e078377.

<https://doi.org/10.1136/bmj-2023-078377>

Rouzier, R., Mathieu, M. C., Sideris, L., Yousti, D., Rajan, R., Garbay, J. R., Spielmann, M., & Pusztai, L. (2005). Breast-conserving surgery after neoadjuvant anthracycline-based chemotherapy for large breast tumors. *Cancer*, 104(4), 688–693.

<https://doi.org/10.1002/cncr.20491>

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215. <https://doi.org/10.1038/s42256-019-0048-x>

Saha, G. B. (2010). *Fundamentals of nuclear pharmacy* (6th ed.). Springer.

Saleh, K., Carton, M., Dieras, V. C., Heudel, P.-E., Brain, E., Firmin, N., Mailliez, A., Patsouris, A., Mouret Reynier, M. A., Gonçalves, A., Ferrero, J.-M., Petit, T., Levy, C., Uwer, L., Cottu, P. H., Veron, L., Deluche, E., Savignoni, A., Robain, M., & Delaloge, S. (2019). 367P – Prognostic impact of body mass index (BMI) on overall survival in patients with metastatic breast cancer. *Annals of Oncology*, 30(Suppl 5), v134. <https://doi.org/10.1093/annonc/mdz242.062>

Salgado, R., Denkert, C., Campbell, C., Aftimos, P., Savaş, A., Lindley, J., Piccart, M., & Loi, S. (2015). Tumor-infiltrating lymphocytes and associations with pathological complete response and event-free survival in HER2-positive early-stage breast cancer treated with lapatinib and trastuzumab: A secondary analysis of the NeoALTTO trial. *JAMA Oncology*, 1(4), 448–454.

<https://doi.org/10.1001/jamaoncol.2015.0830>

Salgado, R., Denkert, C., Demaria, S., Sirtaine, N., Klauschen, F., Pruner, G., Wienert, S., Van den Eynden, G., Baehner, F. L., Penault-Llorca, F., Perez, E. A., Thompson, E. A., Symmans, W. F., Richardson, A. L., Brock, J., Criscitiello, C., Bailey, H., Ignatiadis, M., Floris, G.,... Loi, S. (2015). The evaluation of tumor-infiltrating lymphocytes (TILs) in breast cancer: Recommendations by an International TILs Working Group 2014. *Annals of Oncology*, 26(2), 259–271. <https://doi.org/10.1093/annonc/mdu450>

Schmid, P., Cortes, J., Pusztai, L., McArthur, H., Kümmel, S., Bergh, J., Denkert, C., Park, Y. H., Hui, R., Harbeck, N., Takahashi, M., Untch, M., Fasching, P. A., Cardoso, F., Gelber, R. D., Piccart, M., & Loi, S. (2020). Pembrolizumab for early triple-negative breast cancer. *The New England Journal of Medicine*, 382(9), 810–821. <https://doi.org/10.1056/NEJMoa1910549>

Seabold, S., & Perktold, J. (2010). Statsmodels: Econometric and modeling with Python. In *Proceedings of the 9th Python in Science Conference* (pp. 57–61). <https://doi.org/10.25080/Majora-92bf1922-011>

Sendak, M. P., D'Arcy, J., Kashyap, S., Gao, M., Nichols, M., Corey, K., Ratliff, W., & Balu, S. (2020). A path for translation of machine learning products into healthcare delivery. *NEJM Catalyst Innovations in Care Delivery*, 1(6). <https://doi.org/10.33590/emjinnov/19-00172>

Shalev-Shwartz, S., & Ben-David, S. (2014). *Understanding machine learning: From theory to algorithms*. Cambridge University Press. <https://doi.org/10.1017/CBO9781107298019>

Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining. *Journal of Data Warehousing*, 5(4), 13–22.

Shortliffe, E. H., & Sepúlveda, M. J. (2018). Clinical decision support in the era of artificial intelligence. *JAMA*, 320(21), 2199–2200.

<https://doi.org/10.1001/jama.2018.17163>

Siegel, R. L., Giaquinto, A. N., & Jemal, A. (2024). Cancer statistics, 2024. *CA: A Cancer Journal for Clinicians*, 74(1), 12–49. <https://doi.org/10.3322/caac.21820>

Sittig, D. F., & Singh, H. (2010). A new sociotechnical model for studying health information technology in complex adaptive healthcare systems. *Quality & Safety in Health Care*, 19(Suppl 3), i68–i74. <https://doi.org/10.1136/qshc.2010.042085>

Slamon, D. J., Eiermann, W., Robert, N., Pienkowski, T., Martin, M., Press, M., Mackey, J., Glaspy, J., Chan, A., Pawlicki, M., Pinter, T., Valero, V., Liu, M. C., Sauter, G., von Minckwitz, G., Visco, F., Bee, V., Buyse, M., Bendahmane, B.,... & Crown, J. (2011). Adjuvant trastuzumab in HER2-positive breast cancer. *New England Journal of Medicine*, 365(14), 1273–1283.

<https://doi.org/10.1056/nejmoa0910383>

Sollini, M., Cozzi, L., Ninatti, G., Antunovic, L., Cavinato, L., Chiti, A., & Kirienko, M. (2021). PET/CT radiomics in breast cancer: Mind the step. *Methods*, 188, 122–132. <https://doi.org/10.1016/j.ymeth.2020.01.007>

Spring, L. M., Fell, G., Arfe, A., Sharma, C., Greenup, R., Reynolds, K. L., Smith, B. L., Alexander, B., Moy, B., Isakoff, S. J., Parmigiani, G., & Bardia, A. (2020). Pathologic complete response after neoadjuvant chemotherapy and impact on breast cancer recurrence and survival: A comprehensive meta-analysis. *Clinical Cancer Research*, 26(12), 2838–2848. <https://doi.org/10.1158/1078-0432.CCR-19-3492>

Spring, L. M., Tolaney, S. M., Fell, G., Bossuyt, V., Abelman, R. O., Wu, B., Maheswaran, S., Trippa, L., Comander, A., Mulvey, T., McLaughlin, S., Ryan, P., Ryan, L., Abraham, E., Rosenstock, A., Garrido-Castro, A. C., Lynce, F., Moy, B., Isakoff, S. J.,... Bardia, A. (2024). Response-guided neoadjuvant sacituzumab govitecan for localized triple-negative breast cancer: Results from the NeoSTAR

trial. *Annals of Oncology*, 35(3), 293–301.
<https://doi.org/10.1016/j.annonc.2023.11.018>

Sterne, J. A. C., White, I. R., Carlin, J. B., Spratt, M., Royston, P., Kenward, M. G., Wood, A. M., & Carpenter, J. R. (2009). Multiple imputation for missing data in epidemiological and clinical research: Potential and pitfalls. *BMJ*, 338, b2393.
<https://doi.org/10.1136/bmj.b2393>

Steyerberg, E. W. (2019). *Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating* (2nd ed.). Springer International Publishing.
<https://doi.org/10.1007/978-3-030-16399-0>

Stratton, I. M., Adler, A. I., Neil, H. A. W., Matthews, D. R., Manley, S. E., Cull, C. A., Hadden, D., Turner, R. C., & Holman, R. R. (2000). Association of glycaemia with macrovascular and microvascular complications of type 2 diabetes (UKPDS 35): prospective observational study. *BMJ*, 321(7258), 405–412.
<https://doi.org/10.1136/bmj.321.7258.405>

Strobl, C., Boulesteix, A.-L., Zeileis, A., & Hothorn, T. (2007). Bias in random forest variable importance measures: Illustrations, sources and a solution. *BMC Bioinformatics*, 8, 25. <https://doi.org/10.1186/1471-2105-8-25>

Sun, W., Wu, Y., Ma, F., Fan, J., & Qiao, Y. (2023). Efficacy of PARP inhibitor, platinum, and immunotherapy in BRCA-mutated HER2-negative breast cancer patients: A systematic review and network meta-analysis. *Journal of Clinical Medicine*, 12(4), 1588. <https://doi.org/10.3390/jcm12041588>

Sutton, E. J., Oh, J. H., Dashevsky, B. Z., Veeraraghavan, H., Apte, A. P., Thakur, S. B., Morris, E. A., & Deasy, J. O. (2021). Breast cancer molecular subtype classifier that incorporates MRI features. *Journal of Magnetic Resonance Imaging*, 53(4), 1224–1233. <https://doi.org/10.1002/jmri.25119>

Sutton, R. T., Pincock, D., Baumgart, D. C., Sadowski, D. C., Fedorak, R. N., & Kroeker, K. I. (2020). An overview of clinical decision support systems: benefits, risks, and strategies for success. *NPJ Digital Medicine*, 3, Article 17. <https://doi.org/10.1038/s41746-020-0221-y>

Sweller, J. (1988). Cognitive load during problem solving: Effects on learning. *Cognitive Science*, 12(2), 257–285.

Sweller, J., van Merriënboer, J. J. G., & Paas, F. (2019). Cognitive architecture and instructional design: 20 years later. *Educational Psychology Review*, 31(2), 261–292.

Sychra, K. (2021). Neoadjuvante Chemotherapie beim Mammakarzinom – Bestimmung von Ki-67 und tumorinfiltrierenden Lymphozyten in intermediären Biopsien [Doctoral dissertation, Freie Universität Berlin]. Refubium – Freie Universität Berlin Repository. <https://refubium.fu-berlin.de/handle/fub188/29982>

Symmans, W. F., Peintinger, F., Hatzis, C., Rajan, R., Kuerer, H., Valero, V., Assad, L., Poniecka, A., Hennessy, B., Green, M., Buzdar, A. U., Singletary, S. E., Hortobagyi, G. N., & Pusztai, L. (2007). Measurement of residual breast cancer burden to predict survival after neoadjuvant chemotherapy. *Journal of Clinical Oncology*, 25(28), 4414–4422. <https://doi.org/10.1200/JCO.2007.10.6823>

Symmans, W. F., Wei, C., Gould, R., Yu, X., Zhang, Y., Liu, M.,... & Hatzis, C. (2017). Long-term prognostic risk after neoadjuvant chemotherapy associated with residual cancer burden and breast cancer subtype. *Journal of Clinical Oncology*, 35(10), 1049–1060. <https://doi.org/10.1200/JCO.2015.63.1010>

Søgaard, M., Thomsen, R. W., Bossen, K. S., Sørensen, H. T., & Nørgaard, M. (2013). The impact of comorbidity on cancer survival: A review. *Clinical Epidemiology*, 5(Suppl 1), 3–29. <https://doi.org/10.2147/CLEP.S47150>

- Takefuji, Y. (2025). Limitations of logistic regression in analyzing complex ambulatory blood pressure data: A call for non-parametric approaches. *European Heart Journal*, 46(38), 3790–3791. <https://doi.org/10.1093/eurheartj/ehaf541>
- Tang, L., Huang, Z., Mei, H., & Hu, Y. (2023). Immunotherapy in hematologic malignancies: achievements, challenges and future prospects. *Signal Transduction and Targeted Therapy*, 8, 306. <https://doi.org/10.1038/s41392-023-01521-5>
- Tarantino, P., Hamilton, E., Tolaney, S. M., Cortes, J., Morganti, S., Ferraro, E., Marra, A., Viale, G., & Curigliano, G. (2020). HER2-low breast cancer: Pathological and clinical landscape. *Journal of Clinical Oncology*, 38(17), 1951–1962. <https://doi.org/10.1200/jco.19.02488>
- Tenenbaum, J. D., Sansone, S. A., & Haendel, M. (2014). A sea of standards for omics data: Sink or swim? *Journal of the American Medical Informatics Association*, 21(2), 200–203. <https://doi.org/10.1136/amiajnl-2013-002066>
- Teng, H., Ma, Y., & Teng, D. (2020). Algorithm and simulation of association rules of drug relationship based on network model. *Journal of Healthcare Engineering*, 2020, 8839563. <https://doi.org/10.1155/2020/8839563>
- Thompson, B. M., Chala, L. F., Shimizu, C., Mano, M. S., Filassi, J. R., Geyer, F. C., Torres, U. S., de Mello, G. G. N., & da Costa Leite, C. (2022). Pre-treatment MRI tumor features and post-treatment mammographic findings: May they contribute to refining the prediction of pathologic complete response in post-neoadjuvant breast cancer patients with radiologic complete response on MRI? *European Radiology*, 32(3), 1663–1675. <https://doi.org/10.1007/s00330-021-08290-1>
- Tian, F., Shen, G., Deng, Y., Diao, W., & Jia, Z. (2017). The accuracy of ¹⁸F-FDG PET/CT in predicting the pathological response to neoadjuvant chemotherapy in patients with breast cancer: A meta-analysis and systematic review. *European Radiology*, 27(11), 4786–4796. <https://doi.org/10.1007/s00330-017-4831-y>

Topol, E. J. (2019). High-performance medicine: The convergence of human and artificial intelligence. *Nature Medicine*, 25(1), 44–56.
<https://doi.org/10.1038/s41591-018-0300-7>

Traverso, A., Wee, L., Dekker, A., & Gillies, R. (2018). Repeatability and reproducibility of radiomic features: A systematic review. *International Journal of Radiation OncologyBiologyPhysics*, 102(4), 1143–1158.
<https://doi.org/10.1016/j.ijrobp.2018.05.053>

Tutt, A., Robson, M., Garber, J. E., Domchek, S. M., Audeh, M. W., Weitzel, J. N., Friedlander, M., Arun, B., Loman, N., Schmutzler, R. K., Wardley, A., Mitchell, G., Earl, H., Wickens, M., & Carmichael, J. (2010). Oral poly(ADP-ribose) polymerase inhibitor olaparib in patients with BRCA1 or BRCA2 mutations and advanced breast cancer: A proof-of-concept trial. *The Lancet*, 376(9737), 235–244.
[https://doi.org/10.1016/S0140-6736\(10\)60892-6](https://doi.org/10.1016/S0140-6736(10)60892-6)

Türkiye Endokrinoloji ve Metabolizma Derneği. (2023). Tiroid hastalıkları tanı ve tedavi kılavuzu. <https://temd.org.tr>

Türkoğlu, S. A., Poyrazlı, F., Babacan, D., & Köçkar, F. (2021). Hipoksi ve kanser. *Journal of Advanced Research in Natural and Applied Sciences*, 7(3), 450–463.
<https://doi.org/10.28979/jarnas.930938>

Ugurlu, M. U., Bugdayci, O., Akmercan, A., Kaya, H., Akin Telli, T., Akoglu, H., & Gulluoglu, B. M. (2023). Prediction of nipple involvement in breast cancer after neoadjuvant chemotherapy: Should we rely on breast MRI to preserve the nipple? *Breast Cancer Research and Treatment*, 201(3), 417–424.
<https://doi.org/10.1007/s10549-023-07041-8>

Vallières, M., Kay-Rivest, E., Perrin, L. J., Liem, X., Furstoss, C., Aerts, H. J. W. L., Kahn Jr., W., & Zygmanski, P. (2015). A radiomics model from joint FDG-PET and MRI texture features for the prediction of lung metastases in soft-tissue sarcomas. *European Radiology*, 25(10), 2991–3000. <https://doi.org/10.1088/0031-9155/60/14/5471>

Van Calster, B., McLernon, D. J., van Smeden, M., Wynants, L., & Steyerberg, E. W. (2019). Calibration: The Achilles heel of predictive analytics. *BMC Medicine*, 17(1), 230. <https://doi.org/10.1186/s12916-019-1466-7>

Varma, S., & Simon, R. (2006). Bias in error estimation when using cross-validation for model selection. *BMC Bioinformatics*, 7, 91. <https://doi.org/10.1186/1471-2105-7-91>

Vickers, A. J., & Elkin, E. B. (2006). Decision curve analysis: A novel method for evaluating prediction models. *Medical Decision Making*, 26(6), 565–574. <https://doi.org/10.1177/0272989X06295361>

Villegas, S. L., Nekljudova, V., Pfarr, N., Engel, J., Untch, M., Schrodi, S., Schneeweiss, A., Denkert, C., & Loibl, S. (2021). Therapy response and prognosis of patients with early breast cancer with low positivity for hormone receptors—An analysis of 2,765 patients from neoadjuvant clinical trials. *European Journal of Cancer*, 148, 159–170. <https://doi.org/10.1016/j.ejca.2021.02.020>

von Minckwitz, G., Huang, C. S., Mano, M. S., Loibl, S., Mamounas, E. P., Untch, M., Wolmark, N., Rastogi, P., Schneeweiss, A., Redondo, A., Fischer, H. H., Jacot, W., Conlin, A., Arce-Salinas, C., Wapnir, I. L., Jackisch, C., DiGiovanna, M. P., Fasching, P. A., Crown, J. P.,... KATHERINE Investigators. (2019). Trastuzumab emtansine for residual invasive HER2-positive breast cancer. *The New England Journal of Medicine*, 380(7), 617–628. <https://doi.org/10.1056/NEJMoa1814017>

von Minckwitz, G., Untch, M., Blohmer, J. U., Costa, S. D., Eidtmann, H., Fasching, P. A., Gerber, B., Eiermann, W., Hilfrich, J., Huober, J., Jackisch, C., Kühn, T., Nekljudova, V., Loibl, S., & Baselga, J. (2012). Definition and impact of pathologic complete response on prognosis after neoadjuvant chemotherapy in various intrinsic breast cancer subtypes. *Journal of Clinical Oncology*, 30(15), 1796–1804. <https://doi.org/10.1200/JCO.2011.38.8595>

von Waldenfels, G., Loibl, S., Furlanetto, J., Machleidt, A., Lederer, B., Denkert, C., Hanusch, C., Kümmel, S., von Minckwitz, G., Schneeweiss, A., Untch, M., Rhiem, K., Fasching, P. A., & Blohmer, J.-U. (2018). Outcome after neoadjuvant chemotherapy in elderly breast cancer patients: A pooled analysis of individual patient data from eight prospectively randomized controlled trials. *Oncotarget*, 9(20), 15168–15179. <https://doi.org/10.18632/oncotarget.24586>

Wang, F., Casalino, L. P., & Khullar, D. (2019). Deep learning in medicine—promise, progress, and challenges. *JAMA Internal Medicine*, 179(3), 293–294. <https://doi.org/10.1001/jamainternmed.2018.7117>

Weinstein, M. C., & Stason, W. B. (1977). Foundations of cost-effectiveness analysis for health and medical practices. *The New England Journal of Medicine*, 296(13), 716–721. <https://doi.org/10.1056/nejm197703312961304>

Weng, S. F., Reys, J., Kai, J., Garibaldi, J. M., & Qureshi, N. (2017). Can machine-learning improve cardiovascular risk prediction using routine clinical data? *PLOS ONE*, 12(4), e0174944. <https://doi.org/10.1371/journal.pone.0174944>

White, T. (2012). *Hadoop: The definitive guide* (3rd ed.). O'Reilly Media.

Witten, I. H., Frank, E., & Hall, M. A. (2011). *Data mining: Practical machine learning tools and techniques* (3rd ed.). Morgan Kaufmann.

Wolff, A. C., Hammond, M. E. H., Allison, K. H., Harvey, B. E., Mangu, P. B., Bartlett, J. M. S., Bilous, M., Ellis, I. O., Fitzgibbons, P., Hanna, W., Jenkins, R. B., Press, M. F., Spears, P. A., Vance, G. H., Viale, G., McShane, L. M., & Dowsett, M. (2018). Human epidermal growth factor receptor 2 testing in breast cancer: American Society of Clinical Oncology/College of American Pathologists clinical practice guideline focused update. *Journal of Clinical Oncology*, 36(20), 2105–2122. <https://doi.org/10.1200/jco.2018.77.8738>

World Health Organization. (2024). Cancer prevention.

<https://www.who.int/news/item/03-02-2026-four-in-ten-cancer-cases-could-be-prevented-globally>

Xie, F., Yuan, H., Ning, Y., Ong, M. E. H., Feng, M., Hsu, W., Chakraborty, B., & Liu, N. (2022). Deep learning for temporal data representation in electronic health records: A systematic review of challenges and methodologies. *Journal of Biomedical Informatics*, 126, Article 103980.

<https://doi.org/10.1016/j.jbi.2021.103980>

Yates, L. R., Knappskog, S., Wedge, D., Farmery, J. H. R., Gonzalez, S., Bergh, J.,... & Campbell, P. J. (2017). Genomic evolution of breast cancer metastasis and relapse. *Cancer Cell*, 32(2), 169–184. <https://doi.org/10.1016/j.ccell.2017.07.005>

Yau, C., Osdoit, M., van der Noordaa, M., Shad, S., Wei, J., de Croze, D., Hamy, A. S., Laé, M., Reyat, F., Sonke, G. S., Steenbruggen, T. G., van Seijen, M., Wesseling, J., Martín, M., Del Monte-Millán, M., López-Tarruella, S., Boughey, J. C., Goetz, M. P., Hoskin, T., ... Symmans, W. F. (2022). Residual cancer burden after neoadjuvant chemotherapy and long-term survival outcomes in breast cancer: A multicentre pooled analysis of 5161 patients. *The Lancet Oncology*, 23(1), 149–160.

[https://doi.org/10.1016/S1470-2045\(21\)00589-1](https://doi.org/10.1016/S1470-2045(21)00589-1)

Yee, D., DeMichele, A. M., Yau, C., Isaacs, C., Symmans, W. F., Albain, K. S., Chen, Y. C., Kulkarni, S., Godellas, C. V., Boughey, J. C., Hoskin, T. L., Han, H. S., Langevin, A. M., Lang, J. E., Elias, A. D., Rui, H., Stoler, A. J., Cobleigh, M. A., Jaskowiak, N. T.,... Esserman, L. J. (2020). Association of event-free and overall survival with residual cancer burden after neoadjuvant breast cancer therapy: An I-SPY2 meta-analysis. *JAMA Oncology*, 6(9), 1355–1362.

<https://doi.org/10.1001/jamaoncol.2020.2535>

Yeh, E., Slanetz, P., Kopans, D. B., Rafferty, E., Georgian-Smith, D., Moy, L., Halpern, E., Moore, R., Kuter, I., & Taghian, A. (2005). Prospective comparison of mammography, sonography, and MRI in patients undergoing neoadjuvant

chemotherapy for palpable breast cancer. *AJR. American Journal of Roentgenology*, 184(3), 868–877. <https://doi.org/10.2214/AJR.184.3.01840868>

Yerushalmi, R., Woods, R., Ravdin, P. M., Hayes, M. M., & Gelmon, K. A. (2010). Ki67 in breast cancer: Prognostic and predictive potential. *The Lancet Oncology*, 11(2), 174–183. [https://doi.org/10.1016/S1470-2045\(09\)70262-1](https://doi.org/10.1016/S1470-2045(09)70262-1)

Yetişir, A. E., & Paydaş, S. (2021). Clinicopathological factors determining the pathological response to neoadjuvant therapy in HER2 positive breast cancer. *Namık Kemal Tıp Dergisi*, 9(2), 179–183. <https://doi.org/10.4274/nkmj.galenos.2021.32932>

Yoshioka, T., Hosoda, M., Yamamoto, M., Taguchi, K., Hatanaka, K. C., Takakuwa, E., Hatanaka, Y., Matsuno, Y., & Yamashita, H. (2015). Prognostic significance of pathologic complete response and Ki67 expression after neoadjuvant chemotherapy in breast cancer. *Breast Cancer*, 22(2), 185–191. <https://doi.org/10.1007/s12282-013-0474-2>

Yu, Y., Wang, Z., Wang, Q., Su, X., Li, Z., Wang, R., Guo, T., Gao, W., Wang, H., & Zhang, B. (2023). Radiomic model based on magnetic resonance imaging for predicting pathological complete response after neoadjuvant chemotherapy in breast cancer patients. *Frontiers in Oncology*, 13, 1249339. <https://doi.org/10.3389/fonc.2023.1249339>

Zapata, B. C., Fernández-Alemán, J. L., Idri, A., & Toval, A. (2015). Empirical studies on usability of mHealth apps: A systematic literature review. *Journal of Medical Systems*, 39(2), 1–19.

Zhang, J., Yao, Y.-H., Li, B.-G., Yang, Q., Zhang, P.-Y., & Wang, H.-T. (2015). Prognostic value of pretreatment serum lactate dehydrogenase level in patients with solid tumors: A systematic review and meta-analysis. *Scientific Reports*, 5, 9800. <https://doi.org/10.1038/srep09800>

Zhang, Y., Li, X., Wang, Z., Duan, T., Zhang, C., & Zhao, T. (2024). Deep learning radiomics based on two-dimensional ultrasound for predicting pathological complete response to neoadjuvant chemotherapy in breast cancer. *Journal of Medical Ultrasonics*, 51, 215–225. <https://doi.org/10.1177/01617346241276168>

Zhou, Z., Zhang, Y., Li, Y., Jiang, C., Wu, Y., Shang, L., Huang, Y., & Cheng, S. (2023). Metabolic syndrome is a risk factor for breast cancer patients receiving neoadjuvant chemotherapy: A case-control study. *Frontiers in Oncology*, 12, 1080054. <https://doi.org/10.3389/fonc.2022.1080054>

Zhu, C., Chen, M., Liu, Y., Li, P., Ye, W., Ye, H., Ye, Y., Liu, Z., Liang, C., & Liu, C. (2023). Value of mammographic microcalcifications and MRI-enhanced lesions in the evaluation of residual disease after neoadjuvant therapy for breast cancer. *Quantitative Imaging in Medicine and Surgery*, 13(9), 5593–5604. <https://doi.org/10.21037/qims-22-1170>

Zwanenburg, A., Vallières, M., Abdalah, M. A., Aerts, H. J., Andrearczyk, V., Apte, A., Ashrafinia, S., Bakas, S., Beukinga, R. J., Boellaard, R., Bogowicz, M., Botticella, L., Brancato, V., Bronstein, L., Buades-Rubio, M.,... & Löck, S. (2020). The image biomarker standardization initiative: Standardized quantitative radiomics for high-throughput image-based phenotyping. *Radiology*, 295(2), 328–338. <https://doi.org/10.1148/radiol.2020191145>

Teşekkür

Sürecin en başından beri gerek konu seçimimde gerekse çalışma düzenimde, özgür irademe ve seçimlerime hep saygı duyan, her olumsuzluğa rağmen beni desteklemekten asla vazgeçmeyen ve bana inanan sevgili danışman hocam Prof. Dr. **Petek Ballar KIRMIZIBAYRAK**'a,

Ailemin bir üyesi gibi gördüğüm, çalışmamın neredeyse her adımını birlikte attığımız, sevgili abim, sırdaşım, hocam **Prof. Dr. Recep BEKİŞ**'e

Etik ilkelerini her daim takip etmeye çalıştığım, benden bir türlü kurtulamayan, benim ise kendisinden kurtulmaya niyetimin olmadığı canım hocam **Prof. Dr. Yasemin BAŞBINAR**'a, Binlerce mamografi dosyasını tarayarak en büyük katkıyı veren, sevgili kuzenim **Dr.Erdinç Hakan İNAN** ve sevgili arkadaşı **Dr.Heves Yaren KARAKAŞ**'a,

Yüzlerce PET verisi ile cebelleşen, yardımını esirgemeyen **Uzm. Dr. Şeref KARABULUT**'a, Onkoloji hastalarımı daha iyi standartize etmemi sağlayarak beni RCB standartlarına yönlendiren, sevgili arkadaşım **Doç. Dr. Hüseyin Salih SEMİZ**'e,

Bir ağacın dallarının ne demek olduğunu bana ilk öğreten, beni matematiksel düşünceye sevkeden, sevgili hocam **Prof. Dr. Burak ORDİN**'e,

Python ile tanışmamı sağlayarak beni neler yapabileceğim konusunda heyecanlandıran, hocam **Doç.Dr.Özgür GÜMÜŞ**'e,

Kodlamalarım konusunda beni en doğru şekilde yönlendiren, hocam **Dr. Öğr. Üyesi Alper KÖSE**'ye,

Süreç boyunca beni çok sık görme fırsatı yakalayamayan ama yine de yan odadan desteğini hiç bırakmayan eşim **Ayça DAĞDEVİREN**'e,

Doğduğum günden beri yanımdan hiç ayrılmayan ve her konuda olduğu gibi bunda da desteğini hiç esirgemeyen sevgili ablam **Handan DAĞDEVİREN**'e ve Uzakta olsa bile teğini hep dile getiren sevgili meslektaşım ve ağabeyim **Hakan DAĞDEVİREN**'e,

Ve tabiki en önemlisi, günde onlarca kez “*Bitti mi Kağancım?*” sorusunu soran, benimle geçireceği oyun zamanlarından feragat etmeyi göze alan, benimle heyecanlanan, benimle gülen, koca yürekli küçük adama, oğlum **ATLAS ÇAĞAN**'a

Ne kadar da teşekkür etsem azdır.

İzmir, 25.06.2026

Yusuf Kağan DAĞDEVİREN

Özgeçmiş

YUSUF KAĞAN DAĞDEVİREN

e-mail: dagdeviren.kagan@gmail.com

Eğitim Bilgileri:

Yüksek Lisans:

2013-Dokuz Eylül Üniversitesi Sağlık Bilimleri Enstitüsü **Temel Onkoloji** Yüksek Lisans

2005-Dokuz Eylül Üniversitesi Sağlık Bilimleri Enstitüsü **Nükleer Tıp** Yüksek Lisans

Lisans:

2025- Anadolu Üniversitesi **Sağlık Yönetimi** Lisans Programı (DE)

2015- Anadolu Üniversitesi İşletme Fakültesi **İşletme** Lisans Programı

2001- Ege Üniversitesi **Eczacılık** Fakültesi

Önlisans:

2022- Atatürk Üniversitesi **Bilgisayar Programcılığı** Önlisans Programı

2025- Ankara Üniversitesi **Bilgi Yönetimi** Bölümü Önlisans Programı (DE)

2020- Atatürk Üniversitesi Açıköğretim Fakültesi **Adalet** Bölümü

2011-Eskişehir Anadolu Üniversitesi Açıköğretim Fakültesi **Sağlık Kurumları İşletmeciliği**

İdari Görevleri:

- Dokuz Eylül Üniversitesi Hastane Eczanesi İlaç Planlama ve Depo Sorumlu Eczacı (2016-2019)

- Dokuz Eylül Üniversitesi Hastanesi Akıllı İlaç Sistemleri Koordinatörü (2013-2015)

- Dokuz Eylül Üniversitesi Hastanesi Başeczacı (2012-2013)

- Dokuz Eylül Üniversitesi Hastanesi Başeczacı Yrd. (2007-2012)

Görev Aldığı Komiteler

- Dokuz Eylül Üniversitesi Enfeksiyon Hastalıkları Komitesi
- Dokuz Eylül Üniversitesi Enfeksiyonların Önlenmesi Komitesi
- Dokuz Eylül Üniversitesi Akılcı İlaç Kullanımı ve Yönetimi Komitesi (AİKY)

Biten Lisans Üstü Tez Çalışmaları:

- **Radyoaktif İşaretli Manyetik Partiküllerin Manyetik Alan İle Yönlendirilmesi**

(Dokuz Eylül Üniversitesi Rektörlüğü Bilimsel Araştırmalar Proje Desteği)

- **Ege Bölgesi Rektosigmoid Kansерlerinde Dominant Kras Mutasyon Tipinin Belirlenmesi, İlgili Mutasyonların Protein Foksiyonu ve Yanıtlarına Etkisi?**

(Dokuz Eylül Üniversitesi Rektörlüğü Bilimsel Araştırmalar Proje Desteği)

Patentler:

1. İlaç Taşıyıcısı Olarak I-131 İşaretli Manyetik Nanoparçacıklar

Patent Yılı : 2007

Patent Tipi: İncelemeli Patent

Patenti Alınan Buluşun Sahibi/Sahipleri: P. Ünak, R. Bekiş, **K. Dağdeviren**

Basvuru No 2007-G-185024

Patent Tescil no *TR 2007 06417 B*

Aldığı Ödüller:

1. *VI.Dokuz Eylül Üniversitesi Özel çalışma Modülü Sempozyumu Poster Birincilik Ödülü:*

Farkında mısınız? Kansер geliyorum der: Deri kanseri

(VI.Dokuz Eylül Üniversitesi Özel çalışma Modülü Sempozyumu – İzmir 2012)

2. Prof.Dr. Suphi Altunkal Nükleer Tıp Bilim Ödülü:

Sentinel Lenf Düğümü Çalışmasında Yeni Bir Yöntem

(8th International Nuclear Oncology Congress – İstanbul 2008)

Teşekkür Belgeleri:

1. Kemoterapi Kursu, İzmir, İzmir İl Sağlık Müdürlüğü SBÜ İzmir Dr.Behçet Uz Çocuk Hastalıkları ve Cerrahisi Eğitim ve Araştırma Hastanesi, 16-19 Aralık 2024 (Eğitim Koordinatörü - Eğitimci).
2. Komoterapi İlaç Hazırlama ve Uygulamalarında Güvenli Yaklaşımlar Eğitimi, İzmir Suat Seren Eğitim ve Araştırma Hastanesi, 28 Kasım 2018 (Eğitimci Olarak)
3. Hastane Eczacılığı İzmir Sempozyumu, Katip Çelebi Üniversitesi, İzmir, 24-25 Eylül 2018 (Konuşmacı Olarak)
4. Eczacılıkta Gelecek Yönelimleri ve Kariyer Sempozyumu “Geleceğini Seç 3” – İzmir Eczacı Odası, 2 Nisan 2016 “Üniversite Hastaneleri” (Davetli Konuşmacı Olarak)
5. Onkoloji Eczacılığı Eğitimi Sağlık Bakanlığı-TÜKED Eğitim Programı, Ankara, 20 Aralık 2014. (Eğitimci olarak)
6. BIMEC 2014, Azerbaycan, Mayıs 2014. (Türkiye’den Davetli Konuşmacı olarak)
7. Birinci Basamak Hekimlere Yönelik Kansere Yaklaşımları, Dokuz Eylül Üniversitesi, İzmir, 2012. (Sempozyum Görevlisi olarak)
8. 1.Ulusal Kamu Eczacıları Kongresi – Antalya ,2012 (Oturma Başkanlığı)

Yayınları:

1. Vildan Avkan Oguz, Caglar Irmak, **Kagan Dagdeviren**, Oya Eren Kutsoylu, Arzu Nazli, Muammer Çelik, Serdar Bayrak "*The Effect of the Pandemic on Antifungal Use, What Has Changed? The Effect of the Pandemic on Antifungal Use*" , IDCM Journal, 2022, 3, 156-162.
2. Gizem Çalıbaşı, Tıp Fakültesi 2013-2014 Yılı Dönem 2 Öçm Öğrencileri, Arsalan Amirfallah, **Kağan Dağdeviren**, Mahdi Akbarpour, Tuğba Uysal, Ece Çakıroğlu, Yasemin Baskın, Hülya Ellidokuz "*İnciraltı Yerleşkesinde Biyoistatistik ve Biyoinformatik Program Kullanım Sıklığı ve Farkındalığı*" DEÜ Tıp Fakültesi, Dergisi. Cilt 28, Sayı 2, (Ağustos) 2014, 45–50
3. Yasemin Baskın, Gizem Çalıbaşı, Arsalan Amirfallah, **Yusuf Kağan Dağdeviren**, Aras Emre Canda, Sülen Sarioğlu, Özgül Sağol, Hülya Ellidokuz, İlhan Öztop, Uğur Yılmaz. "*KRAS and BRAF Mutation Frequencies in a Series of Turkish Colorectal Cancer Patients*", Transl Cancer Res 2014;3(2):160-166.
4. Yasemin Baskın, **Yusuf Kagan Dagdeviren**, Gizem Calibasi, Aras Emre Canda, Sulen Sarioglu, Hulya Ellidokuz, Ilhan Oztop "*KRAS mutation profile differences between rectosigmoid localized adenocarcinomas and colon adenocarcinomas*" J. Gastrointest Oncol. 2014; 5(4): 265-269.
5. Recep Bekiş, İlker Medine, **Kağan Dağdeviren**, Türkan Ertay, Perihan Unak "*Sentinel Lenf Düğümü Saptanmasında Yeni Bir Yöntem*" Turkish Journal of Nuclear Medicine, 17, 1, 49, No:22, 2008
6. **K.Dağdeviren** , P.Ünak, R.Bekiş "*Radioiodinated Magnetic Targeted Carriers (¹³¹I-MTC)*" Journal of Radioanalytical and Nuclear Chemistry Vol. 273 number 3 /sep 2007; p:635-639)
7. P.Kara, **K.Dağdeviren**, M.Özsöz "*An Electrochemical DNA Biosensor for the Detection of DNA Damage Caused by Radioactive Iodine and Technetium*" Turkish Journal of Chemistry Volume 31, Issue 3 (2007) p:243-249
8. **K. Dagdeviren**, P. Unak, R. Bekis, F. Z. Biber, O. Ulker, T. Ertay, H. Durak "*Radioiodinated Magnetic Targeted Carriers (I-131-MTC)*" European Journal

of Nuclear Medicine and Molecular Imaging, - Abstracts Annual Congress of the EANM İstanbul, 314, Volume 32, Supplement 1, September, Turkey, 2005

9. **Kağan Dağdeviren**, Perihan Unak, Recep Bekis, F. Zümrüt Biber, Turkan Ertay, Özden Ulker, Hatice Durak “*Radioiodinated Magnetic Targeted Carriers*” 1st-INCC, 1st International Nuclear Chemistry Congress, Abstract Book p. 373, 22-29 May 2005

Uluslararası Bildiriler:

1. FDA Onaylı Monoklonal Antikorların Karşılaştırılması (**Y.Kağan Dağdeviren**, Recep Bekiş, Ayça Dağdeviren) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
2. Epigenetik, Kansere İlişkisi ve Tedavi Yaklaşımı (**Y.Kağan Dağdeviren**, Recep Bekiş, Hatice Küçükçukurt) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
3. Plasebo nedir? Ne değildir? Etik midir? (**Y.Kağan Dağdeviren**) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
4. İlaç Sektöründe Çok Uluslu Yatırımcılar ve Türkiye (**Y.Kağan Dağdeviren**, Hatice Küçükçukurt) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
5. Sahte/Taklit İlaç Kavramı ve Cezai Yaptırımlar (Hatice Küçükçukurt, **Y.Kağan Dağdeviren**) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
6. Türkiye’de Sağlık Hukuku Programlarına Genel Bir Bakış (Hatice Küçükçukurt, **Y.Kağan Dağdeviren**) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015

7. Radyofarmasötiklerde Kalite Kontrol (**Y. Kağan Dağdeviren**, Recep Bekiş, Berna Polack) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
8. Radyofarmasötiklerde Advers Etki Gözlenir mi? (**Y. Kağan Dağdeviren**, Recep Bekiş, Berna Polack) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
9. Radyofarmasötiklerde Lokalizasyon Mekanizmaları (**Y. Kağan Dağdeviren**, Recep Bekiş, Berna Polack) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
10. Radyofarmasötiklerde Atık Yönetimi (**Y. Kağan Dağdeviren**, Recep Bekiş, Berna Polack) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
11. Tedarik Zincirinin Parçası Olan Eczacılıkta Etik Yaklaşım (**Y.Kağan Dağdeviren**, Ayça Dağdeviren) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
12. Kemoterapi İlacı Hazırlık ve Uygulama Hatalarının Önleminde Hemşire ve Eczacının Ortak Sorumluluğu (Hatice Küçükkurt, **Y.Kağan Dağdeviren**) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
13. Global Farmakovijilans İzleme Sistemi (UPPSALA Monitoring Centre) (**Y.Kağan Dağdeviren**, Recep Bekiş, Ayça Dağdeviren) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
14. Advers İlaç Reaksiyonları ve TÜFAM'a Ortak Olabilmek (**Y.Kağan Dağdeviren**, Ayça Dağdeviren, Recep Bekiş) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
15. Farmakoepidemiolojik Çalışmalar ve Farmakovijilans İlişkisi (**Y.Kağan Dağdeviren**, Ayça Dağdeviren, Recep Bekiş) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015

16. İlaç Endüstrisinde Atık Yönetimi (**Y.Kağan Dağdeviren**) 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015
17. Follistatin and EGF are Associated with Cell Proliferation in Colorectal Cancers
(Y. Baskin, G. Calibasi, M. Akbarpour, **K. Dagdeviren**, T. Yigitbasi, H. Ellidokuz)
EUROMEDLAB PARIS Paris, Fransa, 21-25 Haziran2015, Poster Bildiri
18. Pharmacogenomics and Pharmacoeconomics (Yasemin Baskın, **Kağan Dağdeviren**, Gizem Çalıbaşı, Arsalan Amirfallah, Hülya Ellidokuz)
Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
19. Nükleer tıp ve Radyofarmasi (**Kağan Dağdeviren**, Recep Bekiş, Berna Pollack) Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
20. Radyonüklid Tedavi ve Onkoloji (**Kağan Dağdeviren**, Recep Bekiş, Berna Pollack) Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
21. Gelişmekte Olan Hastane Eczacılığının Diğer Ülkelerdeki Örneklerle Karşılaştırılması ve Geleceği (Ayça Dağdeviren, Sultan Bağrıaçık Özçelik, **Kağan Dağdeviren**) Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
22. Gıda takviyelerinde Doğru Kullanım (**Kağan Dağdeviren**, Ayça Dağdeviren) Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
23. İlaç Araştırmalarında Gözlemsel Çalışmalar (**Kağan Dağdeviren**, Ayça Dağdeviren) Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
24. Hastane Enfeksiyon komitesi ve Eczacının rolü (**Kağan Dağdeviren**) Uluslararası İlaç ve Eczacılık Kongresi (İVEK), İstanbul, 28-30 Kasım 2014
25. In-Silico Protein Modelling and Predictability of KRAS Mutation on Behavior of Rectosigmoid Cancers (Baskın Y, Çalıbaşı G, **Dağdeviren YK**, Akyuruk H,

Çavaş L, Canda AE, Sarioğlu S, Ellidokuz H, Öztıp İ) 1st International Medical Congress for Student and Young Doctors (BIMEC) 2014, Azerbeycan, Mayıs 2014, Sözlü Sunum

26. Radioiodinated Magnetic Targeted Carriers (I-131-MTC)

EANM'05 Annual congress of the European Association of Nuclear Medicine, İstanbul, Ekim 2005, Sözlü Sunum

27. Radioiodinated Magneted Targeted Carriers. 1st International Nuclear Chemistry Congress, Kuşadası, Mayıs 2005, Sözlü Sunum

28. Electrochemical Biosensor For The Detection Of Dna Damage By Radioactive Iodine And Technetium. XVIII th International Symposium on Bioelectrochemistry and bioenergetics 3rd spring meeting. Coumbra Portugal, June 2005.

29. A New Agent for Sentinel Lymph Node Detection. EANM'08 Annual congress of the European Association of Nuclear Medicine , Berlin Germany, October 2005.

30. DMSA stabilitesinin Zamana Bağlı Değişimi. I.Uluslararası Radyofarmasi Kongresi, İstanbul, Ekim 2004.

Ulusal Bildiriler:

1. *Çocuk Hastanesinde Bir Antibiyotiğin 2016 Yılında Kutu Yerine Doz Olarak Sunulması Durumundaki Maliyet Değişim Analizi* (Meltem Aytekin, Ayça Dağdeviren, **Kağan Dağdeviren**, Hurşit Apa) 5. Ulusal Hastane ve Kurum Eczacıları Kongresi, Antalya, 07-11 Mart 2018, Poster Bildiri
2. *Hekimlerin Biyoinformatik ve Tıbbi Bilişim Alanındaki Farkındalıkları* (Tıp Fak. Dönem 2 ÖÇM Öğrencileri, **Kağan Dağdeviren**, Mahdi Akbarpour, Ece Çakıroğlu, Yasemin Baskın, Hülya Ellidokuz) IX. ÖÇM Sempozyumu, İzmir, 30 Eylül 2015.
3. *Kolon Kanserlerinde Proliferasyon Süreci KRAS ve BRAF Geni Mutasyon Durumuna Bağlı Olarak Farklı Yolaklarla İlişkilidir*

(Yasemin Baskın, Mahdi Akbarpour, Gizem Çalıbaşı, **Yusuf Kağan Dağdeviren**, Hülya Ellidokuz)

21.Ulusal Kanser Kongresi, Antalya, 22-26 Nisan 2015, Poster Bildiri

4. *C-Kit Protoonkogeni Ekzon 11 DELW557-K558 Delesyonları Gastrointestinal Stromal Tümörlerde Metastatik ve Malign Davranış ile İlişkilidir* (Yasemin Baskın, Gizem Çalıbaşı, İlhan Öztop, **Kağan Dağdeviren**, Mahdi Akbarpour, Tuğba Uysal, Özgül Sağol, Hülya Ellidokuz) Nadir Tümörler Sempozyumu, İzmir, 28 Şubat-2 Mart 2014.
5. *C-Kit Protoonkogeni Ekzon 11 ve 13 Mutasyonları Gastrointestinal Stromal Tümörlerde Proliferatif Karakter ile İlişkilidir* (Yasemin Baskın, Gizem Çalıbaşı, İlhan Öztop, **Kağan Dağdeviren**, Tuğba Uysal, Mahdi Akbarpour, Özgül Sağol, Hülya Ellidokuz) Nadir Tümörler Sempozyumu, İzmir, 28 Şubat-2 Mart 2014.
6. *KRAS Geni G13D Mutasyonu Kolorektal Kanserlerde Yavaş Seyirli Kanser Davranışının Göstergesidir* (Yasemin Baskın, **Yusuf Kağan Dağdeviren**, Gizem Çalıbaşı, Utku Oflazoğlu, Mahdi Akbarpour, Sülen Sarıoğlu, Hülya Ellidokuz, İlhan Öztop) 10. Onkolojik Araştırmalar Çalıştay1, 6-9 Kasım 2014, Antalya.
7. *İnciraltı Kampüsü'nde Çalışan Hekimlerde Bilgisayar ve İstatistik Programı Kullanım Sıklığı* (Çalıbaşı G, Aytay AB, Otlı B, Çınar NB, Altay ÖC, Amirfallah A, **Dağdeviren YK**, Açıkgöz A, Aktaş S, Baskın Y, Ellidokuz H) VI. Özel Çalışma Modülü (ÖÇM) Sempozyumu, DEÜ Tıp Fakültesi – İzmir, 2012
8. *Farkında mısınız? Kanser geliyorum der: Deri kanseri* (Çalıbaşı G, Şahin AS, Acar İ, Takmet M, Salim O, Türk S, Amirfallah A, **Dağdeviren YK**, Açıkgöz A, Aktaş S, Baskın Y, Ellidokuz H) VI. Özel Çalışma Modülü (ÖÇM) Sempozyumu, DEÜ Tıp Fakültesi – İzmir, 2012.
9. *Tıp ve Biyoinformatik* (Çalıbaşı G, Ulgen A, Yazkan A, Sever D, Erkol EE, Derin E, Boyer E, Amirfallah A, **Dağdeviren YK**, Ellidokuz H, Baskın Y) VI. Özel Çalışma Modülü (ÖÇM) Sempozyumu, DEÜ Tıp Fakültesi – İzmir, 2012.

10. *Elektromanyetik Alanlar ve Kanser* (Amirfallah A, Selçuk B, Daşdemir G, Yıldız MN, Duman M, Kantarcı S, Çalıbaşı G, **Dağdeviren YK**, Baskın Y, Ellidokuz H) VI. Özel Çalışma Modülü (ÖÇM) Sempozyumu, DEÜ Tıp Fakültesi – İzmir, 2012.
11. *Kanser Tedavisinde Çoklu İlaç Direnci* (Amirfallah A, Çalıbaşı G, **Dağdeviren YK**, Baskın Y) 1.Ulusal Kamu Eczacıları Kongresi – Antalya ,2012.
12. *Araştırma Makalesi Nasıl Yazılır?* (Baskın Y, Çalıbaşı G, Amirfallah A, **Dağdeviren YK**) 1.Ulusal Kamu Eczacıları Kongresi – Antalya ,2012.
13. *The Dose-dependent Variable Effects of Carvacrol on the Cell Proliferation* (Türkan Yiğitbaşı, Baskın Y, Çalıbaşı G, Arsalan Amirfallah, **Dağdeviren YK**, Gazi Yiğitbaşı) IV. Multidisipliner Kanser Araştırma Sempozyumu – Bursa, 2012.
14. *İyot İşaretili Manyetik Partikül Elde Edilmesi* Nükleer Tıp Sempozyumu, Ankara, Mayıs 2005.
15. *Teknesyum İle Oluşturulan DNA Hasarının DNA Biyosensör Yöntemle Tespiti.* (**Kağan Dağdeviren**, Pınar Kara, Şengün Özsöz) Nükleer Tıp Sempozyumu, Ankara, Mayıs 2005.

Görev Aldığı Klinik Faz Çalışmaları:

1. Standart Tedavi Sonrası Nüks Eden veya Standart Tedaviye Cevap Vermeyen Gönüllülerde lokal İleri veya Metastatik Üretelyal Hücre Karsinomunun Tedavisinde B-701 artı Dosetaksel ile Plasebo artı Dosetaksel'in Karşılaştırıldığı Faz 2, Randomize, Çift Kör, Plasebo Kontrollü, Çok Merkezli, Paralel Gruplu Bir Çalışma.
(2018, DEÜ, İç Hastalıkları AD., Tıbbi Onkoloji Bilim Dalı, Sorumlu Araştırmacı: Prof.Dr. Aziz Karaoğlu)
2. A Double-Blind, Randomized, Two Arm Phase 2 study of Nivolumab in Combination with Ipilimumab Placebo in Recurrent or Metastatic Squamous Cell Carcinoma of Head and Neck (SCCHN).

(2017, DEÜ, İç Hastalıkları AD., Tıbbi Onkoloji Bilim Dalı, Sorumlu Araştırmacı: Uzm.Dr. Elif Abağ)

3. Standart Tedavilere Refrakter Metastatik Gastrik Kanser Hastalarında Plasebo Artı En İyi Destekleyici Bakıma (EİDB)'ye Karşı TAS-102 Artı EİDB'yi Değerlendiren Randomize, Çift Kör, Faz 3 Çalışma.

(2017, DEÜ, İç Hastalıkları AD., Sorumlu Araştırmacı: Prof.Dr. Işıl Somalı)

4. 6 İla 18 Yaşındaki (18 Yaşından Küçük) Hipertansiyonlu Çocuklarda AR 14 (Azilsartan Medoksomil) İle tedavi ve İlaç Kesiminin Randomize, Çift Kör, Etkililik Ve Güvenlilik Çalışması ve Ardından Açık Etiketli Uzatma Çalışması.

(2016, Hacettepe Üniversitesi Tıp Fakültesi Çocuk Sağlığı ve Hastalıkları AD., Sorumlu araştırmacı: Prof.Dr. Salih Kavukçu)

5. Kronik Böbrek Yetmezliği Öncesi Hastalarda Anemi tedavisinde Epoetin Alfa (Eprex)'e Karşı Subkutan Eporon İmmünojenitesinin Güvenliğini ve Etkinliğini Değerlendiren Randomize, Aktif Karşılaştırma-Kontrollü, Paralel Grup, Tek Kör, Çok Merkezli, Faz 3 Çalışması.

(2015, DEÜ, Dahiliye AD., Standart DAPS Uygulaması)

6. Yaşa Bağlı Makula Dejenerasyonuna Sekonder Coğrafik Atrofi Olan Hastalara İntravitreal Uygulanan Lampalizumab Etkililik ve Güvenliğini Değerlendirmek Üzere Bir Faz III, Çok merkezli Randomize, Çift Maskeli, Sham kontrollü Çalışma.

(2015, DEÜ, Göz Hastalıkları AD., Sorumlu araştırmacı: Prof.Dr. Ali Osman Saatçi)

7. Nöromyelitis Optika ve Nöromyelitis Optika Spektrum bozukluğu Olan Yetişkinlerde MEDI-551'in Etkinliği ve Güvenliğini değerlendiren, Açık Etiketli Periyoda Sahip Çift Maskeli, Plasebo kontrollü Çalışma.

(2015, DEÜ, Nöroloji AD., Standart DAPS Uygulaması)

8. Nüks Eden Multiple Skleroz Formları Olan Pediyatrik Hastalarda Oral Olarak Günde Bir Kez Uygulanan Teriflunomid'in Etkinlik, Güvenlilik, Tolerabilite

ve Farmakokinetiğini Değerlendirmek İçin iki yıllık, Çok Merkezli, Randomize, Çift Kör, Plasebo-kontrollü, paralel Gruplu Araştırma.

(2014, DEÜ, Nöroloji A.D., Sorumlu Araştırmacı: Prof.Dr. Egemen İdiman)

9. Spinal Anesteziye İntratekal Morfinin Perfüzyon İndeksi Üzerine Etkisi

(2014, DEÜ, Anestezi ve Reanimasyon A.D. Sorumlu Araştırmacı: Uzm.Dr. Nilay Boztaş)

10. Bir Asetilkolinesteraz İnhibitörü ile Tedavi Edilen Hafif-Orta Derecede Alzheimer Hastalarında LuAE58054'ün Değerlendirildiği Randomize, Çift-kör, Paralel Grup, Placebo Kontrollü Çalışma

(2014, DEÜ, Nöroloji A.D., Sorumlu Araştırmacı Prof.Dr. Görsev Yener)

11. Multipl Myeloma Tanısı Yeni Konmuş hastalarda Kemik Hastalığının Tedavisinde Denosumab ile Zoledronik Asidin (Zometa) Karşılaştırıldığı Randomize, Çift Kör, Çok Merkezli bir çalışma

(2014, DEÜ, Hematoloji B.D., Sorumlu Araştırmacı: Prof.Dr. Fatih Demirkan)

12. Ameliyat Geçiren Pediyatrik Hastalarda Operasyon Sonrası Kusma ve Bulantıyı Önlemek İçin Aprepitantin Farmakokinetik/Farmakodinamik, Güvenlilik ve Tolerabilitesinin Değerlendirilmesine Yönelik Çok Merkezli, Aktif Karşılaştırma Kontrollü, Randomize, Kısmi Kör FazII Bir Çalışma.

(2014, DEÜ, Çocuk Cerrahi A.D., Sorumlu Araştırmacı: Prof.Dr. Mustafa Olguner)

13. Rezeke Edilemeyen Plevral ve Peritoneal Malign Mezotelyomalı Gönüllülerin İkinci ve Üçüncü Basamak Tedavisinde Placebo ile Tremelimumabı Karşılaştıran Faz 2b, Randomize, Çift Kör Bir Araştırma.

(2014, DEÜ, Göğüs Hastalıkları A.D., Sorumlu Araştırmacı: Prof.Dr. Atilla Akkoçlu)

14. DeksaMetazon Kullanılan Hastalarda Sugammadex Etkinliğinin Değerlendirilmesi

(2014, DEÜ, Anesteziyoloji ve Reanimasyon A.D., Sorumlu Araştırmacı: Uzm.Dr. Şule Özbilgin)

15. Kronik Böbrek Yetmezliği Öncesi Hastalarda Anemi tedavisinde Epoetin Alfa (Eprex)'e Karşı Subkutan Eporon İmmunojenesitesinin Güvenliğini ve Etkinliğini Değerlendiren Randomize, Aktif Karşılaştırma-Kontrollü, Paralel Grup, Tek Kör, Çok Merkezli, Faz 3 Çalışma.

(2014, DEÜ, Dahiliye A.D.)

16. Diyalize Girmeyen Kronik Böbrek Hastalarında Anemi Tedavisi İçin FG-4592'nin Etkinlik ve Güvenliğinin Araştırıldığı Faz 3, Çift Kör, Plasebo Kontrollü bir Çalışma

(2013,DEÜ, İç Hastalıkları A.D., Sorumlu Araştırmacı: Prof.Dr.Taner Çamsarı)

17. Obez Çocuklarda Metformin Tedavisinin Soluble Leptin Reseptörü ve Leptin Düzeyine Etkisi: Randomize Kontrollü bir çalışma.

(2013,DEÜ, Çocuk Sağlığı ve Hast. A.D., Sorumlu Araştırmacı: Doç.Dr. Ayhan Abacı)

18. Primer jeneralize Tonik-Klonik Nöbetleri Olan Pediyatrik ve Erişkin Gönüllülerde Pregabalin'in ek Tedavi Olarak Kullanıldığı Randomize, Çift-Kör, Plasebo-kontrollü, Paralel Gruplu, Çok Merkezli Çalışması

(2013, DEÜ, Nöroloji AD, Sorumlu Araştırmacı: Prof.Dr. Barış Baklan)

19. İleri Evre veya Metastatik Skuamöz Küçük Hücreli Dışı Akciğer Kanseri Hastalarda İkinci Basamak Tedavi Olarak Buparlisib İle Birlikte yada Tek Başına Dosetaksel ile İlgili Faz Ib/II Çalışma.

(2013, DEÜ, Tıbbi Onkoloji BD, Sorumlu Araştırmacı: Prof.Dr. İlhan Öztop)

20. Daha önce metastatik hastalık için tedavi almamış HER2 pozitif metastatik gastrik ya da gastroözofageal bileşke adenokarsinomu olan hastalarda birinci basamak tedavi olarak, her ikisi de sisplatin / kapesitabin kemoterapisiyle kombine olarak iki trastuzumab doz rejiminin karşılaştırıldığı randomize, açık etiketli, çok merkezli Faz IIIb çalışma

21. Serebral Palsi Nedeniyle Dinamik Ekinus Ayak Deformitesi Olan Çocuklarda Alt Uzun Spastisitesinin Tedavisi için Kullanılan Dysport'un Etkinliğini ve Güvenliliğini Değerlendiren Faz III, Çok Merkezli, Çift Kör, Prospektif, Randomize, Plasebo Kontrollü Çalışma

(2012, DEU, Fizik Tedavi AD, Sorumlu Araştırmacı: Prof.Dr. Özlen Peker)

22. Serebral Palsi Nedeniyle Dinamik Ekinus Ayak Deformitesi Olan Çocuklarda Alt Uzun Spastisitesinin Tedavisi için Kullanılan Tekrar Edilen Dysport Tedavisinin Uzun Vadeli Etkinliğini ve Güvenliliğini Değerlendiren Faz III, Prospektif, Çok Merkezli, Açık Etiketli Uzatma Çalışması

(2012, DEU, Fizik Tedavi AD, Sorumlu Araştırmacı: Prof.Dr. Özlen Peker)

23. Periferik Nöropatik Ağrısı Olan Hastalarda Qutenza™ ve Pregabalin'in Karşılaştırıldığı; Açık Etiketli, Randomize , Çok Merkezli, Non-İnferiyote Etkililik ve Tolerabilite Çalışması

(2012, DEU, Nöroloji AD, Sorumlu Araştırmacı: Doç.Dr.İhsan Şükrü Şengün)

24. Bilateral Diz Protezi Sırasında Propofol Sedasyonu Uygulanan Geriatrik Hastaların Derlenmesinde İntratekal Morfin Uygulamasının Etkisi

(2012, DEU, Anesteziyoloji ve Reanimasyon AD, Sorumlu Araştırmacı: Doç.Dr. Sevdâ Özkardeşler)

25. Rezekte Edilemeyen veya Metastatik Hepatosellüler Karsinomlu Yetişkin Hastalarda MEDI-573 ve Sorafenib Kombinasyonunu tek başına Sorafenib Tedavisiyle Karşılaştırılan Bir Faz 1b/2, açık etiketli, randomize çalışma.

(2012, DEU, Tıbbi Onkoloji AD, Sorumlu Araştırmacı: Prof. Dr. Uğur Yılmaz)

Verdiği Seminer ve Eğitimler:

1. Kemoterapi Kursu, İzmir, İl Sağlık Müdürlüğü SBÜ İzmir Dr.Behçet Uz Çocuk Hastalıkları ve Cerrahisi Eğitim ve Araştırma Hastanesi, 16-19 Aralık 2024.
2. Kemoterapötiklerin Etki Mekanizması ve Malignitelerde Tedavi Rejimleri, Kemoterapi İlaç Hazırlama ve Uygulamalarında Güvenli Yaklaşımlar Eğitimi, İzmir Suat Seren Eğitim ve Araştırma Hastanesi, 28 Kasım 2018

3. Hastanelerde Enfeksiyon Komiteleri ve Eczacının Rolü, Hastane Eczacılığı Sempozyumu, Katip Çelebi Üniversitesi, İzmir, 25 Eylül 2018
4. Nükleer Tıp Uygulamaları ve Radyonüklid Tedavide Eczacının Rolü, Hastane Eczacılığı Sempozyumu, Katip Çelebi Üniversitesi, İzmir, 24 Eylül 2018
5. Üniversite Hastanesi Eczaneleri, İzmir Eczacı Odası – Eczacılıkta Gelecek Yönelimleri ve Kariyer Sempozyumu, İzmir, 2 Nisan 2016.
6. Kemoterapötiklerde Advers Etkiler, Sağlık Bakanlığı-TÜKED Onkoloji Eczacılığı Eğitimi, Ankara, 20 Aralık 2014.
7. Enfeksiyon Komitesinde Eczacının Rolü, 2014, 2.Kamu Eczacıları Kongresi, Kıbrıs
8. Karsinogenesis, 2012, Dokuz Eylül Üniversitesi Onkoloji Enstitüsü
9. Nükleer Tıp ve Tedavide Nükleer Onkoloji, 2012, Dokuz Eylül Üniversitesi Onkoloji Enstitüsü
10. Nükleer Tıp ve PET Uygulamaları, 2011, Dokuz Eylül Üniversitesi Onkoloji Enstitüsü
11. Serbest Oksijen Radikalleri ve Kansere İlişkisi, 2011, Dokuz Eylül Üniversitesi Onkoloji Enstitüsü
12. Tek Gen Hastalıkları: Osteogenesis Imperfecta, 2010, Dokuz Eylül Üniversitesi Tıbbi Biyoloji ve Genetik A.D.
13. Hastane Eczacılığı Uygulamaları, 2009, 2010, Dokuz Eylül Üniversitesi Tıp Fakültesi Asistan Eğitimi Seminerleri
14. Nükleer Tıp Radyofarmasi Uygulamaları, 2004, Ege Üniversitesi Nükleer Bilimler Enstitüsü
15. Gama Kameralar ve Çalışma Prensipleri, 2004, Ege Üniversitesi Nükleer Bilimler Enstitüsü
16. Radyofarmasötiklerin Tutulum Mekanizmaları, 2004, Dokuz Eylül Üniversitesi Nükleer Tıp A.D.

17. Tedavi Amaçlı kullanılan Radyofarmasötiklerin Etki Mekanizmaları, 2004, Dokuz Eylül Üniversitesi Nükleer Tıp A.D.
18. Farmakolojik Stres Ajanları, 2005, Dokuz Eylül Üniversitesi Nükleer Tıp A.D.
19. Personal Dozimetri, 2005, Dokuz Eylül Üniversitesi Nükleer Tıp A.D.

Medikal Eğitimi Sertifikaları

1. **Temel Yaşam Desteği ve Otomatik Eksternal Defibrilatör**, 2024, Dokuz Eylül Üniversitesi Hastanesi, Üniversite Onaylı Katılım Belgesi
2. **Children and Clinical Research Certificate**, 2021, Global Health Training Centre (e-learning Course)
3. **Ethics and best practices in sharing individual-level research data Certificate**, 2021, Global Health Training Centre (e-learning Course)
4. **Introduction to Good Clinical Laboratory Practice Certificate**, 2021, Global Health Training Centre (e-learning Course)
5. **ICH Good Clinical Practice E6 (R2) Certificate**, 2021, Global Health Training Centre (e-learning Course)
6. **Introduction to Collecting and Reporting Adverse Events in Clinical Research Certificate**, 2021, Global Health Training Centre (e-learning Course)
7. **Introduction To Clinical Research Certificate**, 2021, Global Health Training Centre (e-learning Course)
8. **Antineoplastik İlaç Hazırlama teknikleri ve Güvenli Oda Yönetimi Eğitim seminerleri Katılım Sertifikası**, 2016, ESOP onaylı
9. **Araştırma Teknikleri Sertifikası**, 2015, Universal Certificate onaylı
10. **GLP İyi Laboratuvar Uygulamaları Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)

11. **GHP İyi Hijyen Uygulamaları Eğitimi Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
12. **Hijyen ve Sanitasyon Eğitimi Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
13. **Sağlık Kuruluşlarında Hijyen Eğitimi Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
14. **Biyomedikal Kalibrasyon Eğitimi Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
15. **GMP İyi Üretim Uygulamaları Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
16. **Temel İyi Klinik Uygulamalar (İKU) Kursu Başarı Belgesi**, Klinik Araştırmalar Derneği, 31 Mayıs 2015 (T.C. Sağlık Bakanlığı onaylı)
17. **İleri İyi Klinik Uygulamalar (İİKU) Kursu Başarı Belgesi**, , Klinik Araştırmalar Derneği, 31 Mayıs 2015 (T.C. Sağlık Bakanlığı onaylı)
18. **İlk Yardım Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
19. **Hasta Kayıt/Kabul Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
20. **Onkoloji Alanında Uygulamalı İstatistik Çözümleme Kursu**, Dokuz Eylül Üniversitesi Sürekli Eğitim Merkezi (DESEM), 2014
21. **Onkolojide Nano Tıp Uygulamaları Kursu**, 2013, 18.Ege Onkoloji Günleri, Ege Üniversitesi
22. **Enteral-Parantral Nutrisyon ve Eczacının Rolü Meslek İçi Eğitim Programı**, İzmir, 15 Haziran 2013 (KEPAN Onaylı)
23. **İyi Klinik Uygulamalar (İKU) Sertifikası**, Roche - Investigator Module of the Roche Good Clinical Practice course , 28th May 2012
24. **Birinci Basamak Hekimlere Yönelik Kanser Yaklaşımları**, Dokuz Eylül Üniversitesi, İzmir, 2012.

25. **Kanser Biyolojisinde Güncel Konular**, Ege Üniversitesi, 2011.
26. **Preteomik: Temel Bilgiler ve Uygulama Örnekleri Katılım Sertifikası**, İzmir, 4 Mayıs 2011
27. **Deney Hayvanları Kullanımı Sertifikası**, İzmir, 30 Mart 2011, Dokuz Eylül Üniversitesi
28. **Akım Sitometri Kursu**, Çeşme, 10 Şubat 2011
29. **Teknologlar İçin PET Kursu**, Ankara, Mayıs 2005
30. **DEXA uygulamaları ve Osteoporoz Kursu**, Samsun, 13 Mayıs 2003

Bilişim Eğitimi Sertifikaları

1. **CSS (Cascading Style Sheets) Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
2. **Google Drive ile Bulut Teknolojisine Giriş Eğitim Sertifikası**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
3. **Herkes için Yapay Zeka II Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
4. **Sosyal Medya Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
5. **GPower Programı ile Sağlık Bilimlerinde Güç Analizi (Tıp-Eczacılık-Hemşirelik) Eğitimi Katılım Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
6. **iThenticate (İntihal Belirleme Yazılımı) Eğitimi Katılım Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
7. **İleri Biyoistatistiksel Yöntemler- SPSS Uygulamaları- (Tıp, Eczacılık vb Sağlık Alanları için) Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
8. **İleri Düzey Meta Analizi ve CMA Yazılımı Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

9. **İleri Nvivo Kullanımı ve Nitel Veri Analizi Eğitimi Katılımcı Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
10. **İleri SPSS ile Veri Analizi Eğitimi Katılımcı Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
11. **Lisrel Kullanımı Eğitimi (Yapısal Eşitlik Modellemesi ve Doğrulayıcı Faktör Analizleri)**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
12. **Mentimeter İle Etkileşimli Sunum Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
13. **Meta-Analiz ve CMA Kullanımı Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
14. **Sosyal Ağ Analizi ve Ucinet Kullanımı Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
15. **Temel Jamovi Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
16. **Temel Nvivo Kullanımı Eğitimi Katılımcı Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
17. **Veri Analizinde Karar Verme Süreçleri Eğitimi Katılımcı Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
18. **Veri Bilimine Giriş Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
19. **Temel Düzey R Uygulamaları Eğitimi (Tüm Bilim dalları İçin)**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
20. **Teknoloji ile Öğretim (e-Teach) Eğitim Sertifikası**, 2021, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
21. **EndNote Web Kullanımı ve Kaynakça Yönetimi Eğitimi Katılım Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

22. **Herkes İçin Yapay Zeka I Eğitim Sertifikası**, 2021, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
23. **Introduction to data management Certificate**, 2021, Global Health Training Centre (e-learning Course)
24. **Sosyal Medya Çevrimiçi Eğitim Sertifikası**, 2019, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (e-learning)
25. **SWOT Analizi Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
26. **Sistem Yönetimi Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
27. **Ağ (Network) Yönetimi Eğitim Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
28. **Veritabanı (Database) Yönetimi Eğitim Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
29. **InForm (v4.6) for Unblinded Pharmacist/Designee**, MERCK Online Education Certificate, 1/8/2014
30. **Re-Evaluation Date (RED) Extension Labelling, and Use of Batch Record (BR)** Rev 1.00, MERCK Online Education Certificate, 1/8/2014
31. **IVRS Overview for Sites**, MERCK Online Education Certificate, 1/8/2014

Veri Analizi Eğitimi Sertifikaları

1. **YapayZeka Eğitici Eğitimi**, 2022, Fatih Sultan Mehmet Vakıf Üniversitesi Onaylı
2. **Ar-Ge ve İnovasyon Odaklı Projelerde Değerlendirme, Etki Analizi ve Proje Yazımı Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

3. **Araştırma Etiği Eğitimi Katılımcı Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
4. **Atlas.ti Kullanımı ve Nitel Veri Analizi Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
5. **Açımlayıcı ve Doğrulayıcı Faktör Analizi Uygulamaları (Kuramdan Uygulamaya Örneklerle) Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
6. **Başarı Testleri için Test ve Madde Analizi Programı (TAP) Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
7. **Bilimsel Araştırma ve Bilim Etiği Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
8. **Eylem Araştırması (Kuramdan Uygulamaya- Makale-tez yazımı ile) Eğitimi Katılım Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
9. **Her Yönü İle Tez ve Tez Yazımı (Uygulamalı) Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
10. **Hiyerarşik Lineer Modelleme (HLM) Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
11. **Lisansüstü Eğitimde Araştırma Üretkenliği ve Tavsiyeler Eğitimi Katılım Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
12. **Literatür Tarama ve Kaynaklara Ulaşma Stratejileri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
13. **Makalenizin İçeriğine Uygun SSCI/SCI/AHCI İndexte Dergi Bulma Yöntemleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
14. **Nitel Araştırma Yöntemleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

- 15. Nitel Araştırma Raporunun Yazımı Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 16. Roc ve Yaşam Analizi Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 17. SPSS ile Lojistik Regresyon ve Üst Düzey Analizler Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 18. SSCI/SCI/AHCI ve ESCI İndexlerdeki Dergilere Yayın Gönderme Süreçleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 19. Survey Monkey Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 20. Tek Denekli Araştırma Yöntemleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 21. Temel ve Klinik Biyoistatistik-1 (Tıp ve Diş Hekimliği, Eczacılık ve Sağlık Bilimleri İçin SPSS Uygulamalı) Eğitimi Katılım Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 22. Tüm Yönleriyle İntihal Eğitimi ve İntihalden Uzak Durma, Atıf Yapmanın İlkeler Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 23. Tıbbi Araştırma Yöntemleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 24. Tıp Alanında SSCI-SCI İndexte Taranan Dergilere Makale Yazma Stratejileri ve Akademik Yazma Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 25. Yağmacı, Sahte, Şaibeli (Predatory) Dergiler, Yayıncılar ve Konferanslar Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 26. Yeni Başlayanlar İçin Makale Yazımı ve Akademik Yazma Eğitimi 1 Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

- 27. Yeni Başlayanlar İçin Makale Yazımı ve Akademik Yazma Eğitimi 2 Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 28. Yöneylem Araştırmaları Eğitimi Katılımcı Sertifikası**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 29. Ölçek Geliştirme ve Uyarlama Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
- 30. Örnek ve Uygulamalarla Meta-Tematik Analiz Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

Yöneticilik Eğitimi Sertifikaları

- 1. Mobbing Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 2. İnovasyon Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 3. Google Slaytlar ile Etkili Sunum Hazırlama Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 4. Çatışma Yönetimi Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 5. Kriz Yönetimi Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 6. Şikayet Yönetimi Eğitimi**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 7. Stresi Yönetmede Yöneticilerin Rolü ve Durumsal Liderlik**, 2023, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
- 8. Uygulamalı Çok Kriterli Karar Verme Yöntemleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)

9. **Ofiste Sağlıklı Yaşam Eğitimi**, 2019, Bilgeiş (Orta Doğu Teknik Üniversitesi Onaylı)
10. **Satın Alma ve Dış Kaynak Kullanımı Yönetimi**, 2016, Akademas (Akademi Bilgi Uluslararası Onaylı)
11. **İnsan Kaynakları Yönetimi (Personel Güçlendirme)**, 2016, Akademas (Akademi Bilgi Uluslararası Onaylı)
12. **İnsan Kaynakları Yönetimi (Performans Değerlendirme)**, 2016, Akademas (Akademi Bilgi Uluslararası Onaylı)
13. **Tedarik Zinciri Yönetimi (Tedarikçi Seçimi)**, 2016, Akademas (Akademi Bilgi Uluslararası Onaylı)
14. **Türkiye’de Sosyal Güvenlik**, 2016, Akademas (Akademi Bilgi Uluslararası Onaylı)
15. **Entegre Yönetim Sistemi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
16. **Stratejik Yönetim Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
17. **Sağlık Psikolojisi Eğitim Sertifikası**, 2015, Universal Certificate onaylı.
18. **Sağlık Hizmetleri Yönetimi Sertifikası** 2015, Universal Certificate onaylı
19. **Hasta ve Çalışan Güvenliği Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
20. **Etkili Sunum Teknikleri Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
21. **Sağlık Kurumlarında İletişim Eğitimi Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
22. **Dökümantasyon Eğitimi Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)

23. **Meslek Etiği Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
24. **İşletme Yönetimi – Micro MBA Sertifikası**, 2015, İstanbul İşletme Enstitüsü
25. **İş Hayatında Yazışma Teknikleri Sertifikası**, 2015, İstanbul İşletme Enstitüsü
26. **Büro Yönetimi ve Yönetici Asistanlığı Eğitim Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
27. **İnsan Kaynakları Yönetimi Eğitim Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
28. **Kalite Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
29. **İş, Ticaret ve Borçlar Hukuku Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
30. **İş Güvenliği ve İşçi Sağlığı Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
31. **Stok ve Depo Yönetimi Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
32. **Proje Yönetimi Eğitimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)
33. **Protokol Eğitimi Yönetimi Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)

34. **Hızlı Okuma Eğitim Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)

35. **Diksiyon ve Etkili konuşma Eğitim Sertifikası**, Kurumsal Kampüs, 2015 (EETAC – (European Education and Training Accreditation Center) onaylı)

ISO Eğitimi Sertifikaları

1. **ISO 17025 Laboratuvar Akreditasyonu Sertifikası**, 2015, Rodos Grup (TÜRKAK (Türk Akreditasyon Kurumu) Onaylı)
2. **ISO 9001:2008 Temel Kalite Eğitimi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
3. **ISO 14001 Çevre Yönetim Sistemi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
4. **ISO 18001 OHSAS İş Güvenliği ve İş Sağlığı Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
5. **ISO 9001:2008 İç Tetkikçi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
6. **ISO 9001:2015 Revizyon Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
7. **ISO 22000 Gıda Güvenliği Yönetim Sistemi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneği Onaylı)
8. **Resmi Yetkilendirme Belgesi Eğitimi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu) tarafından, 2015

PDR Eğitimi Sertifikaları

1. **Etkili Sunumun Psikolojik Temelleri (THEE)**, 2023, Bilgeiř (Orta Doęu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
2. **Kişisel Stres Yönetimi**, 2023, Bilgeiř (Orta Doęu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
3. **Zor İnsanlarla Baş Etme Eğitimi**, 2023, Bilgeiř (Orta Doęu Teknik Üniversitesi Onaylı) (Çevrimiçi Eğitim)
4. **Psikoloji,Davranış Bilimleri ve PDR'de Araştırma Yöntemleri Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
5. **Psikolojik Test-Ölçek Geliştirme ve Uyarlama Süreci Eğitimi**, 2021, AYEUM (Araştırma Yöntemleri Eğitim ve Uygulama Merkezi)
6. **NLP Eğitim Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneęi Onaylı)
7. **Liderlik Eğitimi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneęi Onaylı)
8. **Bireysel Koçluk Eğitimi Sertifikası**, PRD Akademi (Uluslararası Eğitim ve Belgelendirme Kurumu), 2015 (Psikologlar ve Refleksologlar Derneęi Onaylı)

Katıldığı Sempozyum ve Seminerler

1. HIMSS Eurasia “Saęlık Biliřimi ve Teknolojileri Konferans ve Fuarı, Digital, 11-13 Kasım 2020
2. 6. Ulusal Hastane ve Kurum Eczacıları Kongresi, Antalya, 27 Şubat-3 Mart 2019
3. 5. Ulusal Hastane ve Kurum Eczacıları Kongresi, Antalya, 07-11 Mart 2018
4. 3. Ulusal Hastane ve Kurum Eczacıları Kongresi, Dalaman, 23-27 Kasım 2015
5. 2nd IVEK International Convention of Pharmaceuticals and Pharmacies, İstanbul, 27-29 Kasım 2015

6. II. Nadir Tümörler Sempozyumu, İzmir, 27 Şubat – 1 Mart 2015.
7. İzmir Onkoloji Grubu “Nadir Tümörler Sempozyumu” İzmir, 28 Şubat-2 Mart 2014.
8. Kamu Eczacıları Kongresi, Kıbrıs, 2014
9. 3. Ulusal Hücresel Tedavi ve Rejeneratif Tıp kongresi, Denizli, 2012
10. 6th Orpheus Organization For PhD Education In Biomedicine And Health Sciences, İzmir, 27-30 Nisan 2011
11. 2. Ulusal Hücresel Tedavi ve Rejeneratif Tıp kongresi, Çeşme, 11-13 Şubat 2011
12. II. Uluslararası Moleküler Tanı ve Uygulamaları Sempozyumu, Ege Üniversitesi Eczacılık Fakültesi, 10-14 Mayıs 2004
13. İnsan Genom Projesi Sempozyumu, Dokuz Eylül Üniversitesi Sağlık Bilimleri Enstitüsü
14. Ulusal Toksikoloji ve Klinik Toksikoloji Sempozyumu Dokuz Eylül Üniversitesi Sağlık Bilimleri Enstitüsü, 8-9 Mayıs 2003
15. XVI. Ulusal Nükleer Tıp Kongresi, Samsun, 10-14 Mayıs 2003
16. XVII. Ulusal Nükleer Tıp Kongresi, Çeşme, Mayıs 2004
17. HPLC ve Diğer Separasyon Teknikleri Ulusal Sempozyumu, GATA Ankara , 25-27 Mayıs 2003
18. Nükleer Tıp Sempozyumu, Ankara, 30Nisan-3 Mayıs 2005
19. Uluslararası Avrupa Nükleer Tıp kongresi, İstanbul, Ekim 2005

Bağlı Olduğu Dernekler:

- İzmir Eczacı Odası
- Türkiye Nükleer Tıp Derneği
- Türkiye Kamu Eczacıları Derneği (TUKED)
- Klinik Enteral Parantral Nutrisyon Derneği (KEPAN)
- Dokuz Eylül Bilim Merkezi Derneği (DEBİM)